

SKALA

데이터분석 및 MLOps

데이터분석 Mini Project

2026.09

전임교수 : Byung-sun, Park

parkbs@sk.com

본 문서는 SK(주)C&C의 컨텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

SK 주식회사 C&C

데이터분석 Mini Project

머신러닝 기반 신약 후보물질 독성 예측

Toxicity Prediction of Drug Candidates

본 문서는 SK㈜C&C의 컨텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

SK 주식회사 C&C

프로젝트 주제

사업 현장의 실제 프로젝트의 일부를 과제화

주제 : 신약 후보물질 독성 예측

- 분야 : 제약, 바이오, 화학

- SKxxxx, 중추신경계 신약 개발
- xx병원, 대사성 질환 특화 물질 개발
- xx병원, Dr. Answer 병명진단
- xx의료원, Data Model Based 신약개발
- SKxxxxx, 기능성 화장,식,의약품 원료개발



SKALA

프로젝트 배경

신약개발 프로세스



- 질병의 원인이나 기전을 이해하기 위한 연구가 이루어지며, 이를 통해 치료의 가능성이 있는 분자들이 식별됨

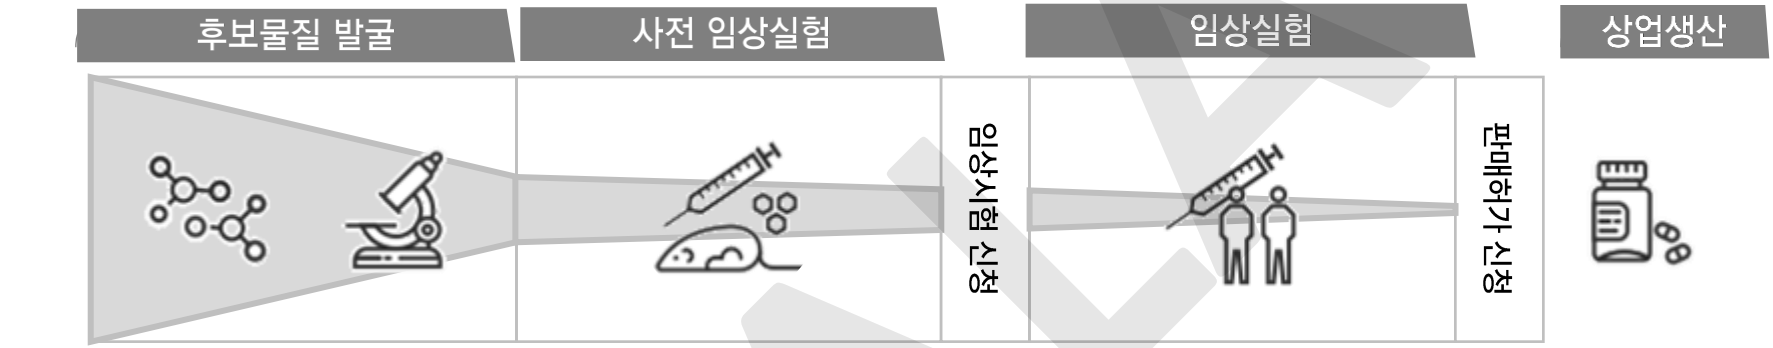
- 기초 연구를 토대로 치료효과가 기대되는 화합물을 찾아내는 단계
- 찾아진 화합물들은 계속해서 최적화되어야 하는데, 이 단계에서는 화합물의 생물학적 이용성, 안정성, 부작용 등을 고려하여 최적의 화합물을 찾는 작업이 이루어짐

- 최적의 화합물이 선정되면 임상시험 단계로 넘어가는데 이 단계에서는 화합물의 안전성과 효과를 환자 대상으로 확인함
- 임상시험을 성공적으로 통과하면 식품의약품 안전처(FDA) 등 국제 기관의 승인을 받게 됨

- 승인을 받은 신약은 대량으로 생산되어 시장에 출시

프로젝트 배경

전체 비용의 37.9%가 후보물질 발굴 단계에서 소요



✓ 탐색 기간 및 비용 과다

✓ 사전 임상시험의 시행 착오 발생을 초래

SKALA

프로젝트 배경

후보 물질 발굴 프로세스



- 질병분석
- 타겟선정
- 검증(유효물질)

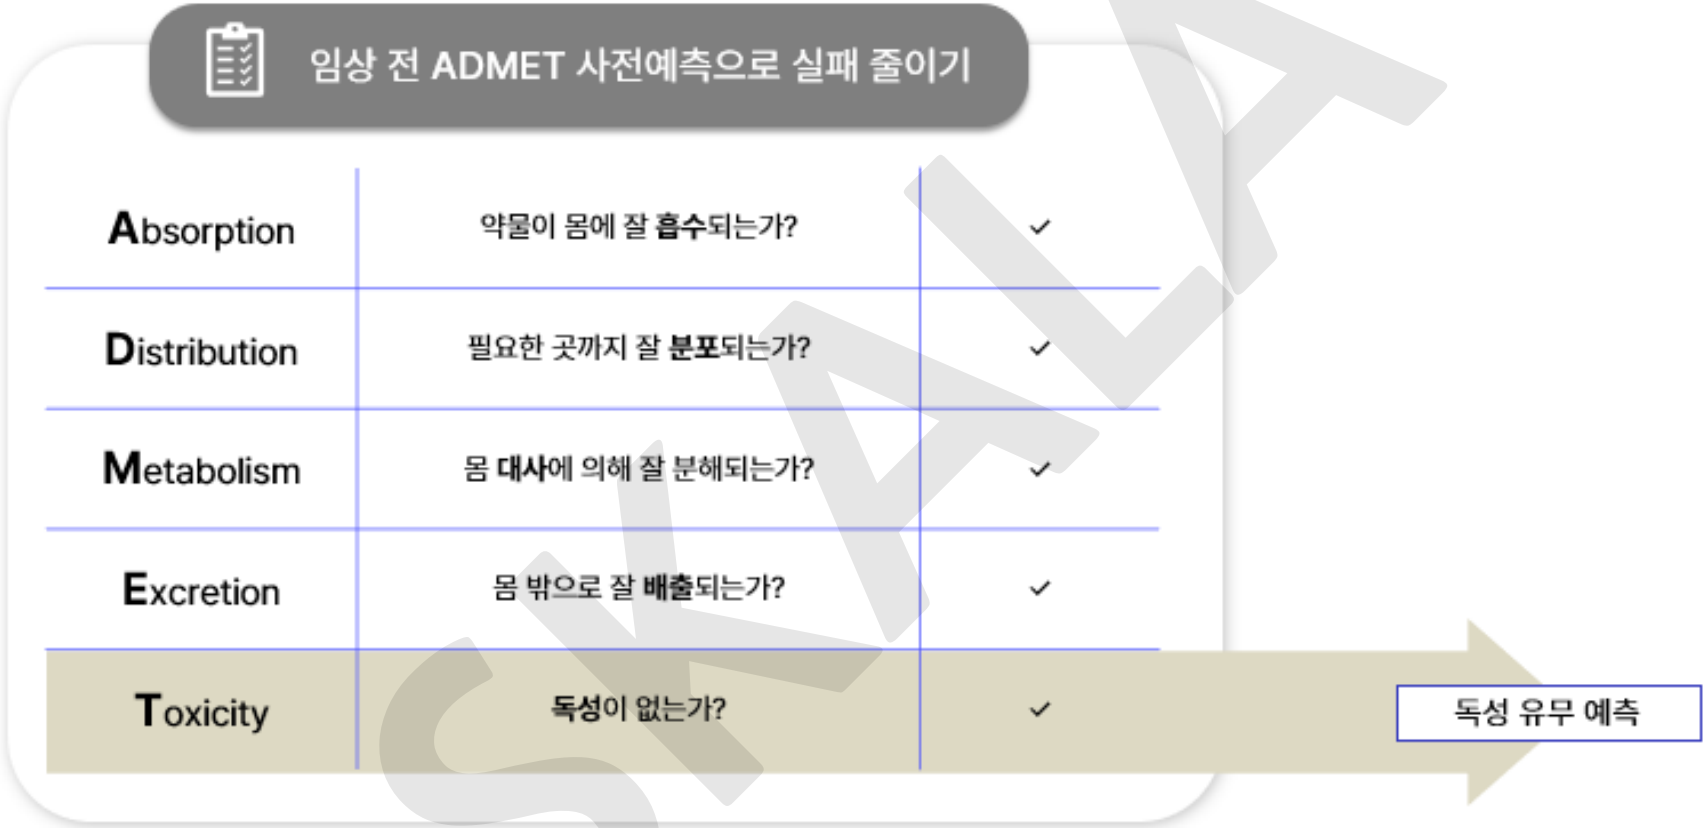
- 선도물질(lead) 탐색 및 스크리닝
- 선도물질 발굴(design)

- 선도물질의 ADMET 프로파일 규명
- 최적 후보물질 선정

SKALA

프로젝트 배경

ADMET: 신약개발의 체크 리스트



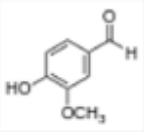
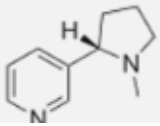
SKALA

[참고] Smiles code, 스마일 표기법

Simplified Molecular Input Line Entry System, 화합물을 글자로 표현한 고유 이름표

- 분자 구조를 string 형태로 표현하여 NLP에 활용된 다양한 머신러닝 / 딥러닝 알고리즘들을 분자 구조에도 적용할 수 있게 해주는 표기법
- 1980년대 후반에 뉴 멕시코에서 개발하여 현재까지 활용
- 분자 구조의 5개 요소인 원자(atom), 결합(bond), 고리(ring), 방향족(aromaticity), 가지(branch) 를 Line String으로 표현



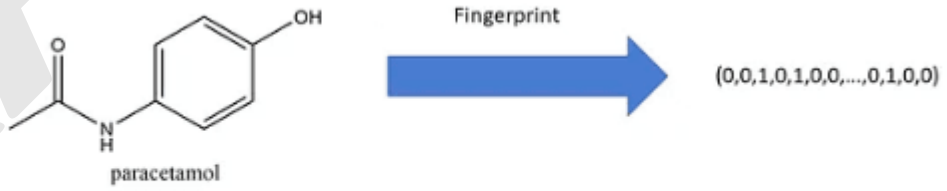
Molecule	Structure	SMILES
Dinitrogen	N≡N	N#N
Vanillin		O=Cc1ccc(O)c(OC)c1COc1cc(C=O)ccc1O
Nicotine ($C_{10}H_{14}N_2$)		CN1CCC[C@H]1c2cccnc2

SKALA

[참고] Fingerprint

화합물의 개인정보, Fingerprint

- 화합물 간의 유사성을 평가하는데 널리 사용
- 고차원 벡터이며(Default 1024), 그 요소는 화학 설명자 값
- 0과 1의 이진(Binary) 형태로 이루어진 경우가 많은데, 각각의 비트는 화합물 내 특정 화학 하위 구조 또는 분자 특성의 유무를 암호화
- 유사성 검색 및 클러스터링부터 선도물질 발굴 및 탐색에 이르기까지 다양한 응용 분야에서 광범위하게 사용
- 독성 예측, 물성 예측 및 화합물 분류를 포함한 다양한 예측 모델링 작업에서 기계 학습 모델의 특성으로 사용될 수 있음



Fingerprint

SKALA

[참고] Fingerprint

화합물의 개인정보, Fingerprint

ECFP

Extended-Connectivity Fingerprints

- 각 원소를 기준으로 거리에 따라 어떤 구조인지 어떤 원소와 결합되어 있는지에 따라 각 값들이 계산이 되며, 이 각 값들을 이용해서 binary 값으로 표현
- 핵심 정보는 원소, 결합 등 원자 자체의 구조정보
- 화학구조의 유사성 판단 등 주로 구조적 유사성 분석을 위해 사용

FCFP

Functional-Class Fingerprints

- 핵심 정보는 원자의 기능적 역할
- 생물학적 활성 유사도 분석 등 주로 기능적 유사성 분석에 활용
- positive ionizable group(양 이온화 가능), hydrogen bond donor(수소결합)..

PTFP

Pattern Fingerprints

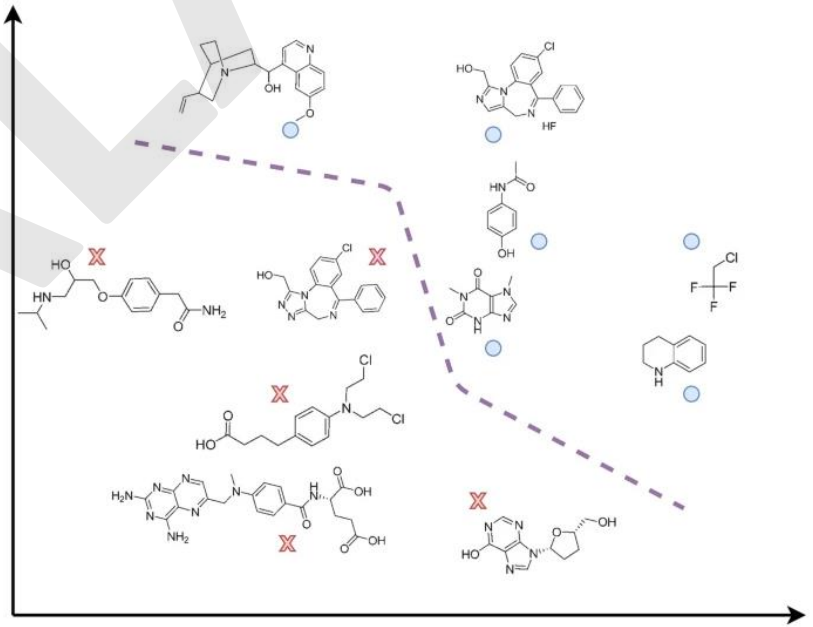
- 기존의 Fingerprint가 원자 혹은 기능 중심의 탐색인 반면, PatternFP는 화학자들이 자주 사용하는 서브구조 패턴들의 존재 여부를 1/0으로 나타냄
- 좀 더 도메인 지식이 반영된 서브구조 기반 fingerprint
- 특히 특정 signature sub-structure가 있다면 PatternFP가 민감하게 반응할 수 있음

SKALA

What Are We Predicting?

사업 현장의 실제 프로젝트의 일부를 과제화

- 화합물 독성 여부 예측
- Target (Y): Toxicity
  - Y = 1 : 독성 없음
  - Y = 0 : 독성 있음
- Task: Binary Classification



- Issue Found : Before modeling, always verify what the target label actually means.

SKALA

Data

프로젝트에서 실제 사용된 데이터세트를 과제에 활용

제공되는 Data



- **train.csv** (약 51.2MB)

  모델 개발을 위한 8,349건의 학습 및 테스트용 데이터세트



- **predict_input.csv** (약 5.7MB)

  개발된 모델을 이용하여 독성 여부를 예측하기 위한 927건의 문제용 데이터세트

제출하는 Data



- **predict_output_작성자.csv**

  예측한 결과를 제출하기 위한 답안용 데이터세트

SKALA

Data

Train 데이터 속성

컬럼 순서	컬럼명	설명	Sample
1	SMILES	• SMILES Code – SMILES 표기법으로 화합물의 구조를 문자열로 표기	
2 ~ 1025	ecfp_0 ~ ecfp_1023	• Molecular Fingerprint Data – 화합물 구조(SMILES Code)를 이진수로 벡터화한 Data로 Fingerprint 종류별 1,024개 컬럼으로 구성 – Fingerprint 3종 : ECFP[1], FCFP[2], PTFP[3]	
1026 ~ 2049	fcfp_0 ~ fcfp_1023		
2050 ~ 3073	ptfp_0 ~ ptfp_1023		
3074	MolWt	• 화합물의 분자 질량 (Molecular Weight, 분자량) – 탄소를 기준으로 한 상대적인 원자 질량의 합	
3075	clogp	• 분배계수 (Partition-coefficient) – Calculated logP : 분배계수 중 이온화되지 않은 농도비율	
3076	sa_score	• 합성 가능성 (Synthetic Accessibility Score) – 합성의 용이성 : 1=쉬움 ~ 10=어려움	
3077	qed	• 약물 유사성 (Drug-Likeness) – 특정 효과가 있는 약물군과의 정량적 유사도	
3078	label	• 독성 여부 1= 독성 無. 0=독성 有	

1) Extended-Connectivity Fingerprints 2) Functional-Class Fingerprints 3) Pattern Fingerprints

SKALA

Data

프로젝트에서 실제 사용된 데이터세트를 과제에 활용

▪ predict_input.csv의 데이터 구조

- train.csv와 동일한 구조이나 '독성 여부(label)'만 없음

컬럼 순서	컬럼명
1	SMILES
2 ~ 1025	ecfp_0 ~ ecfp_1023
1026 ~ 2049	fcfp_0 ~ fcfp_1023
2050 ~ 3073	ptfp_0 ~ ptfp_1023
3074	MolWt
3075	clogp
3076	sa_score
3077	qed

▪ predict_output.csv의 데이터 구조(제출)

- 'SMILES Code' 와 '독성 여부(label)'만 존재

컬럼 순서	컬럼명
1	SMILES
2	label

SKALA

평가지표

과제의 목표를 고려하여 평가지표 선정

화합물 독성 예측

Binary Classifications

1 = 독성 無 (Positive)

VS.

0 = 독성 有 (Negative)

【 분류 예측모델 평가 지표 】

- **Accuracy**
  전체(Positive & Negative) 데이터 중 모델이 맞게 예측한 비율
- **Precision**
  모델이 Positive로 예측한 데이터 중 실제 Positive 인 비율
- **Recall (or Sensitivity)**
  실제 Positive인 데이터 중 모델이 Positive로 예측한 비율
- **F1 Score**
  Trade-off 관계에 있는 Precision과 Recall을 통합적으로 고려한 비율
- **Specificity**
  모델이 Negative로 예측한 데이터 중 실제 Negative 인 비율
- **ROC (Receiver Operating Characteristics)**
- **Precision Recall Plot**
- ⋮

1) 보조 지표 : 주 지표 측정값이 동일한 경우에 사용하는 지표

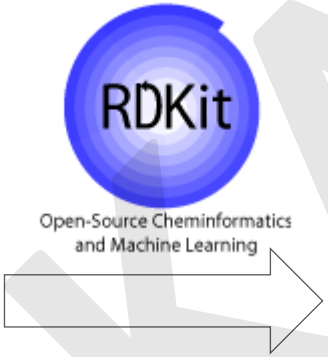
SKALA

[참고] Descriptor

Rdkit, Mordred 를 활용한 물리 화학적 특성 추출

RDKit은 화학 정보학(cheminformatics) 및 분자 모델링을 위한 오픈 소스 Python 라이브러리. 화합물의 처리, 분석, 시각화, 그리고 화학적 속성의 계산을 지원

SMILES
Nc1ccncc1
Cc1cc(n[nH]1)C(=O)O
NCCCS(=O)(=O)O
OC(=O)c1cc2occc2[nH]1
CN1CCC[C@H]1c2cccnc2
CN1CCCC1c2cccnc2
Cc1cc(OC[C@@H]2CCN2)on1
Oc1noc2cc(Cl)ccc12
Cc1ccc(cc1)C23CNCC2C3
[NH3+][C@H]1[C@H](CCC1=C(F)F)
CC(C)(O)C(Cl)(Cl)Cl
CC(N)COc1c(C)cccc1C
COC(=O)C1=CC[C@@H]2CC[C@H]1N2C
Nc1ccc(cc1N)c2ccsc2



분자량	지용성	합성 난이도	...	약물 유사도
94.117	0.6638	1.95106		0.512651
126.115	0.41632	2.373113		0.572518
139.176	-0.777	2.336083		0.502646
151.121	1.4591	2.624244		0.647854
162.236	1.8483	2.499926		0.626152
162.236	1.8483	2.499926		0.626152
168.196	0.72372	3.669144		0.722157
169.567	2.1868	2.564558		0.657699
173.259	1.85592	3.21636		0.683176
177.15	-1.0926	5.470477		0.552459
177.458	2.1275	2.912469		0.562181
179.263	2.02944	2.409173		0.770174
181.235	0.9523	4.217041		0.564045
190.271	2.5795	2.214493		0.67893

SKALA



수고하셨습니다.

본 문서는 SK㈜C&C의 컨텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

SK 주식회사 C&C