SK 주식회사 AX

SKALA

# 머신러닝 기반 신약 후보물질 독성 예측


판교 9반 5조

전경호 - P303
김민정 - P282
이지은 - P299
정원준 - P307

SKALA

# 목차

1. 데이터 소개
2. 데이터 확인
3. 데이터 품질 점검
4. 분석 방향 수립
5. Finger Print
6. 데이터 이해
7. EDA

# 데이터 소개

train.csv 화합물 8349건 x 3078컬럼

**행** 화합물 **8,349**건

**컬럼** **3,078**개 (SMILES 1 + 지문 3,072 + 서술자 4 + label 1)

**타깃** **이진 분류** (1 = 독성 없음 / 0 = 독성 있음)

| 구분 | 컬럼 순서 | 컬럼명 | 설명 |
|---|---|---|---|
| **SMILES**<br>구조 문자열 | 1 | **SMILES** | 화합물의 원자와 결합 관계를 문자열로 표현 |
| **Fingerprint**<br>3 × 1,024비트 | 2–1025 | **ecfp_0 – ecfp_1023** | 원자 주변의 연결 구조를 표현한 분자 지문 (1,024비트) |
| | 1026–2049 | **fcfp_0 – fcfp_1023** | 원자의 화학적 기능을 기준으로 만든 분자 지문 (1,024비트) |
| | 2050–3073 | **ptfp_0 – ptfp_1023** | 특정 부분구조의 존재 여부를 나타낸 분자 지문 (1,024비트) |
| **Descriptor**<br>수치 특성 4개 | 3074 | **MolWt** | 분자량 (Molecular Weight) |
| | 3075 | **clogp** | 계산된 logP · 지용성 관련 지표 |
| | 3076 | **sa_score** | 합성 용이성 점수 · 1(쉬움) ~ 10(어려움) |
| | 3077 | **qed** | 약물 유사성(Drug-Likeness) 점수 |
| **Target**<br>정답 레이블 | 3078 | **label** | 독성 여부 · 1 = 독성 없음 / 0 = 독성 있음 |

# 데이터 확인

## 1. 데이터 타입 확인

| # | Column | Non-Null Count | Dtype |
|---|---|---|---|
| 0 | SMILES | 8349 non-null | object |
| 1 | ecfp_0 | 8349 non-null | int64 |
| 2 | fcfp_0 | 8349 non-null | int64 |
| 3 | ptfp_0 | 8349 non-null | int64 |

| # | Column | Non-Null Count | Dtype |
|---|---|---|---|
| 0 | MolWt | 8349 non-null | float64 |
| 1 | clogp | 8349 non-null | float64 |
| 2 | sa_score | 8349 non-null | float64 |
| 3 | qed | 8349 non-null | float64 |
| 4 | label | 8349 non-null | int64 |

## 2. 실수형 데이터 분포 확인

| | ecfp_0 | fcfp_0 | ptfp_0 | MolWt | clogp | sa_score | qed | label |
|---|---|---|---|---|---|---|---|---|
| count | 8349.000000 | 8349.000000 | 8349.000000 | 8349.000000 | 8349.000000 | 8349.000000 | 8349.000000 | 8349.000000 |
| mean | 0.014253 | 0.998443 | 0.030662 | 443.248753 | 3.794829 | 3.187613 | 0.559151 | 0.544017 |
| std | 0.118540 | 0.039431 | 0.172412 | 88.876374 | 1.379045 | 0.727768 | 0.185664 | 0.498089 |
| min | 0.000000 | 0.000000 | 0.000000 | 94.117000 | -4.048930 | 1.282432 | 0.024365 | 0.000000 |
| 25% | 0.000000 | 1.000000 | 0.000000 | 383.879000 | 2.874500 | 2.663425 | 0.425440 | 0.000000 |
| 50% | 0.000000 | 1.000000 | 0.000000 | 441.522000 | 3.735100 | 3.093155 | 0.556410 | 1.000000 |
| 75% | 0.000000 | 1.000000 | 0.000000 | 495.639000 | 4.652500 | 3.593547 | 0.700506 | 1.000000 |
| max | 1.000000 | 1.000000 | 1.000000 | 1242.488000 | 9.429480 | 7.309297 | 0.947494 | 1.000000 |

## 3. 목표변수 분포 확인



# 데이터 품질 점검

## 1. 결측치, 중복 및 데이터 확인

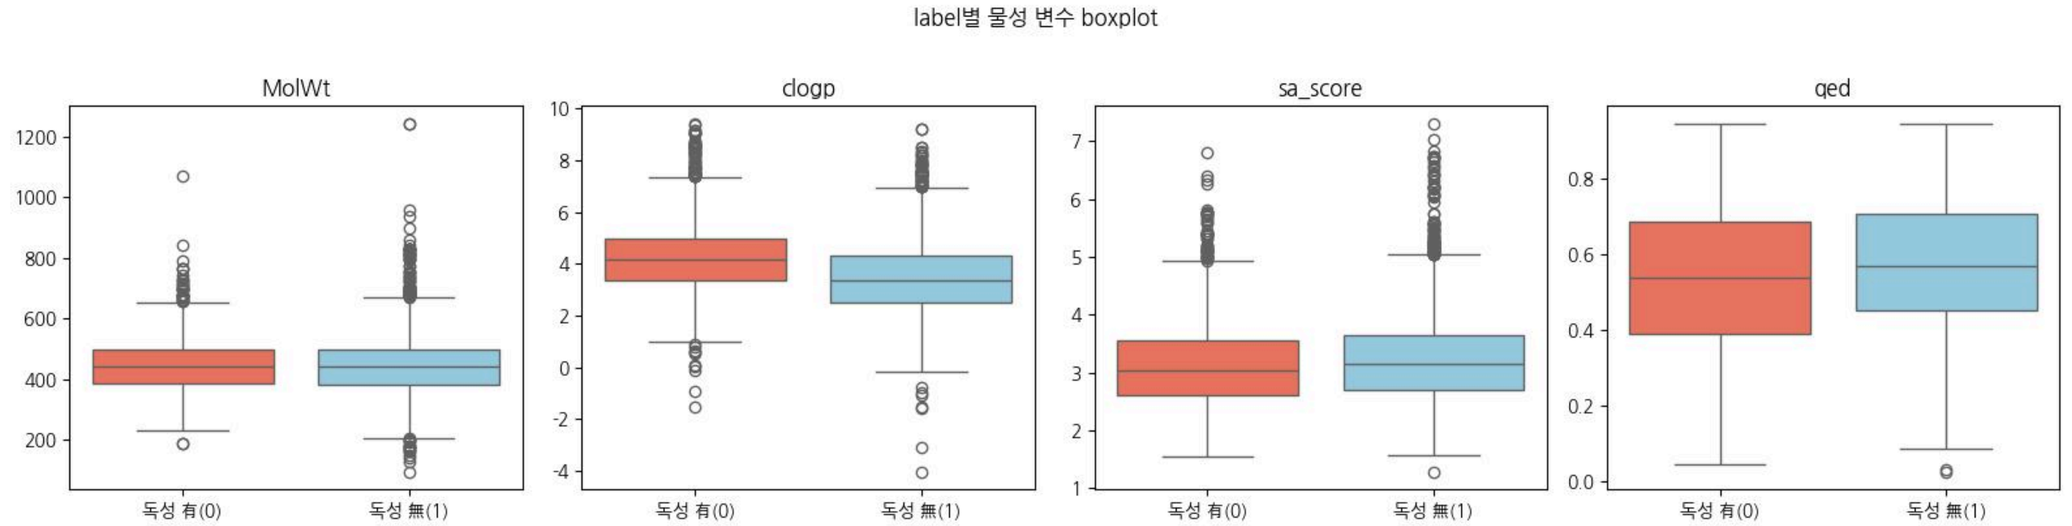
```
print('결측치 합계:', df.isnull().sum().sum())
print('중복 행:', df.duplicated().sum())
print('중복 SMILES:', df['SMILES'].duplicated().sum())
```

```
결측치 합계: 0
중복 행: 0
중복 SMILES: 0
```

**왜 결측이 없는가?**

모든 수치 컬럼이 실험 측정값이 아니라 SMILES로부터 계산한 값이고,
SMILES 8,349개가
100% 파싱됩니다.

## 2. 이상치 확인



# Finger Print

SKALA

**세 FP의 공통점: 분자 안에서 작은 조각을 찾아, 1,024개의 칸에 기록합니다.**

칸 하나가 조각 하나를 맡고, 그 조각이 분자에 있으면 1, 없으면 0입니다. 같은 조각이 여러 번 있어도 1로 같습니다.

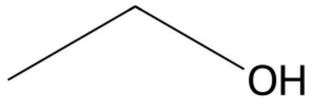
| 구분 | ECFP | FCFP | PTFP |
|---|---|---|---|
| **무엇을 보는가** | 각 원자와, 그 원자에서<br>2칸 안에 있는 주변 원자들의 모양 | ECFP와 같음<br>(각 원자와 2칸 안의 주변 원자) | 한 원자에서 결합을 따라<br>최대 7칸까지 이어지는 길 |
| **원자를 구분하는 기준** | 원소 이름 (C, N, O 등) | 원자가 하는 역할<br>(수소를 주는 원자, 받는 원자, 고리 원자 등)<br>→ O와 N도 역할이 같으면 같은 원자로 봄 | 원소 이름 (C, N, O 등) |
| **에탄올(C-C-O)에서 찾는 조각** | C 하나 / C에 C가 붙은 모양 /<br>O에 C, 그 C에 다시 C가 붙은 모양 | 위와 같은 모양을<br>원소 대신 역할로 표시 | C-C / C-O / C-C-O |
| **구분하지 못하는 것** | 같은 조각이 몇 개인지<br>2칸보다 먼 원자 사이의 관계<br>입체 방향 (3차원 배치) | ECFP가 못 하는 것 전부<br>+ 원소는 달라도 역할이 같은 원자 | 같은 길이 몇 개인지<br>7칸보다 긴 길<br>입체 방향 (3차원 배치) |

# Finger Print

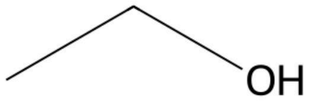
## Smile은 다른데 FP는 같은 케이스

**① 표기만 다름**

같은 분자 (에탄올)




CCO



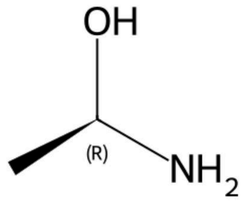

OCC

글자 순서만 다르고 그래프는 동일
FP는 그래프를 보므로 3종 모두 같음
→ 실제 중복 데이터

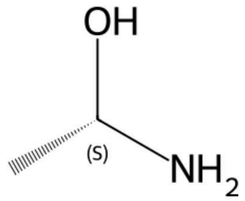
---

**② 입체이성질체**

다른 분자 (거울상)




C[C@H](N)O



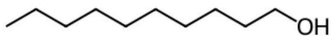

C[C@@H](N)O

연결 구조는 같고 3차원 방향만 다름
3종 모두 입체 정보를 기록하지 않음
→ 독성은 다를 수 있음

---

**③ 반복 구조 길이 차이**

다른 분자 (탄소 10개 vs 11개)




CCCCCCCCCCO

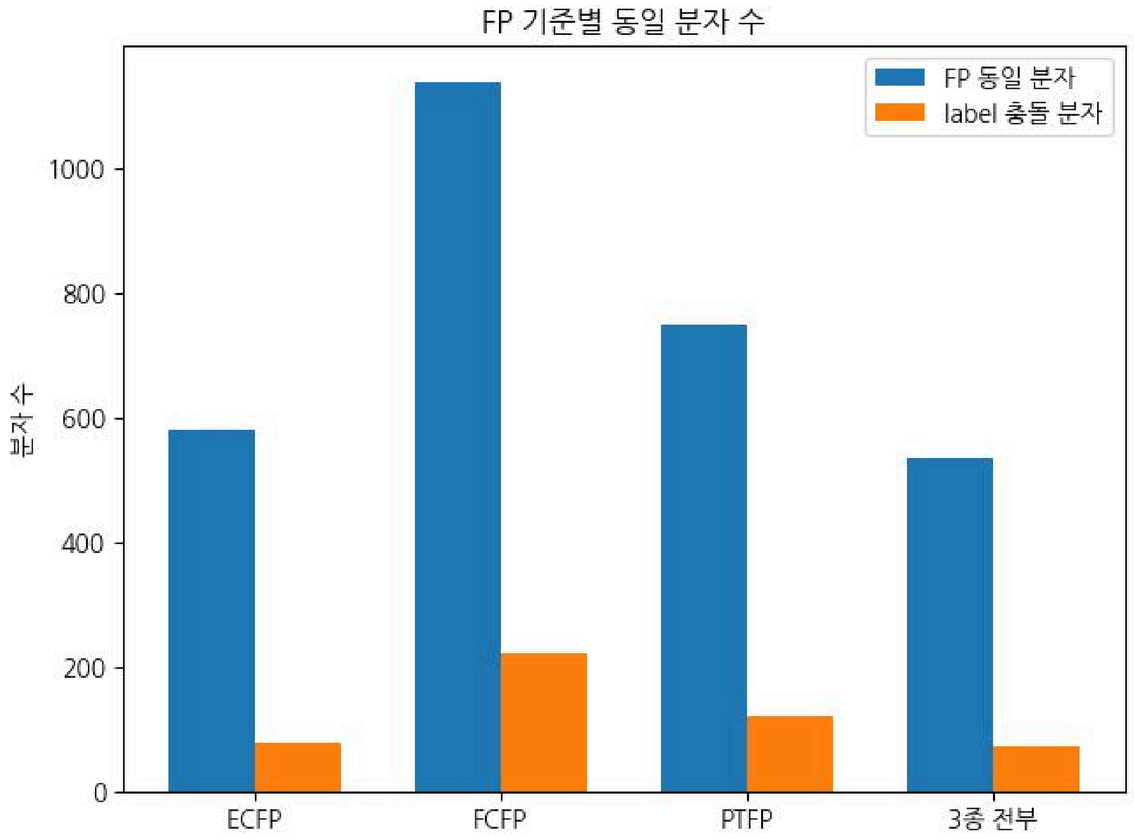


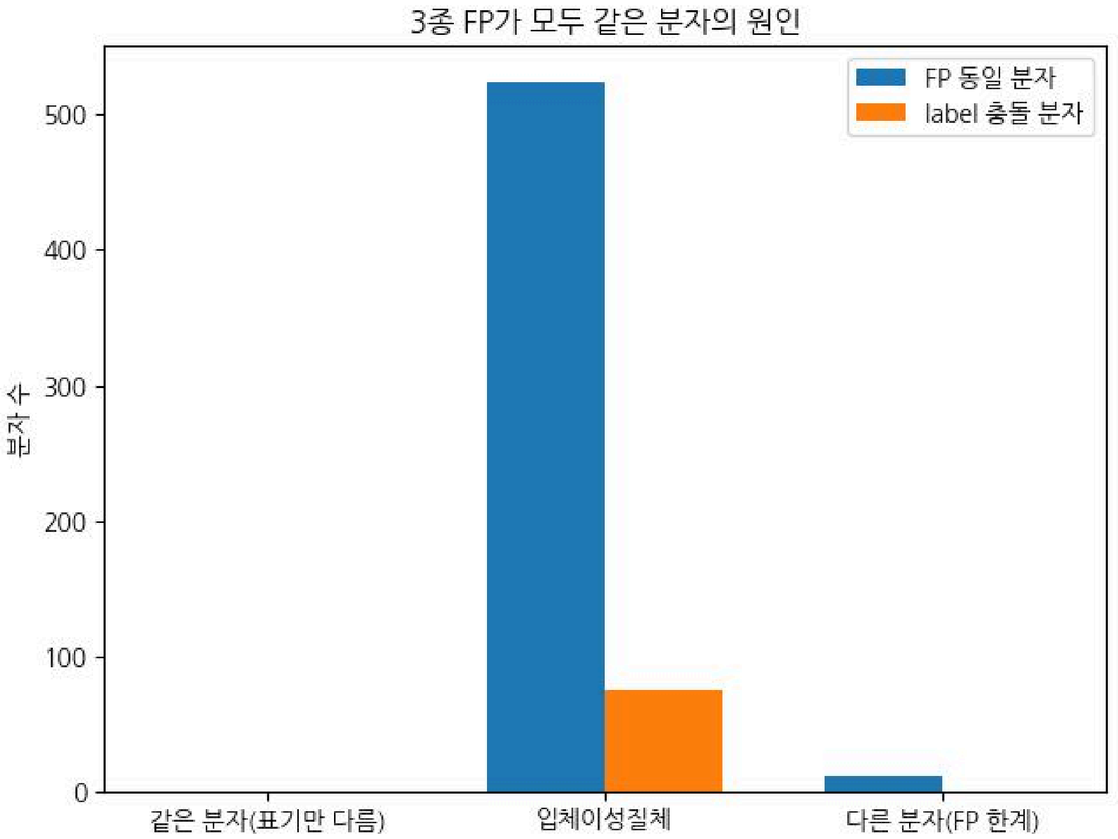

CCCCCCCCCCCO

ECFP·FCFP: 가운데 탄소 주변 모양이 같아
새 조각이 생기지 않음
PTFP: 길이 차이는 7칸 넘는 경로에서만 나타남

# Finger Print

Smile은 다른데 FP는 같은 케이스



# 분석 방향

SKALA

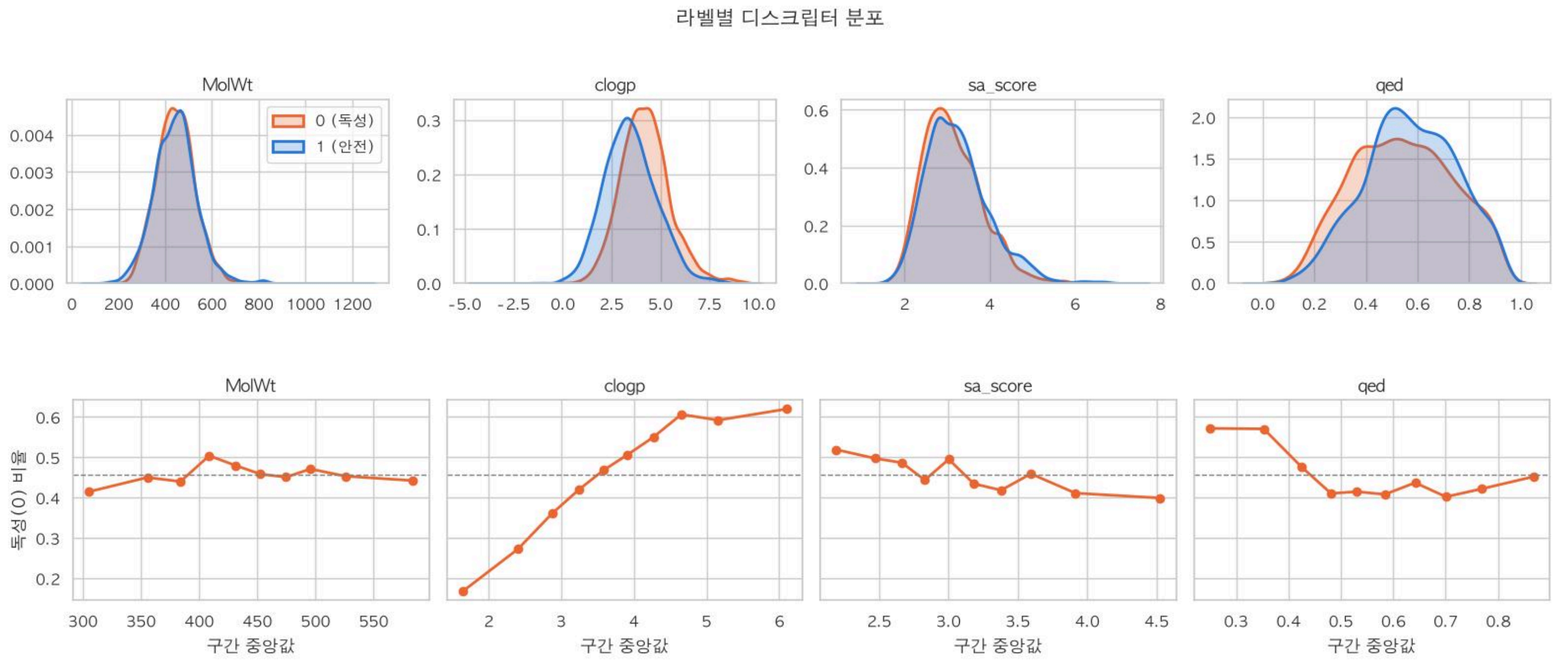
Part A: Descriptor 4개( MolWt, clogp, sa_score, qed )와 label의 관계

Part B: SMILES 문자열에서 뽑은 구조 피처와 label·디스크립터의 관계

Part C: Fingerprint(ECFP/FCFP/PTFP)와 타 변수들관의 관계

Part D: SMILES를 분자 구조로 해석해 추출한 결합·분지·입체 특징과 독성의 연관성 검증

# Part A: 디스크립터 4개( MolWt, clogp, sa_score, qed )와 label의 관계




## 왜 clogP만 차이가 날까?

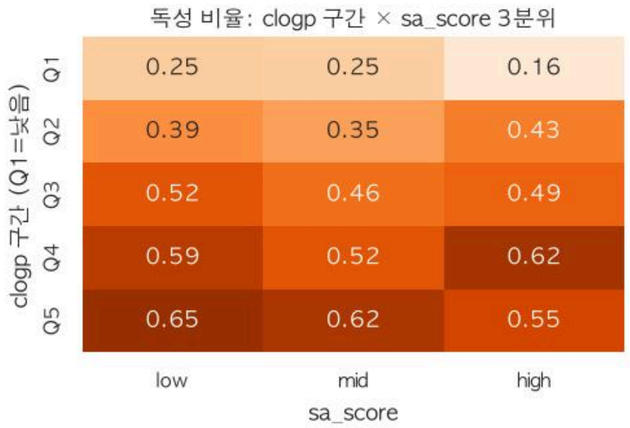
hERG 칼륨 채널 안쪽은 소수성 아미노산(Tyr652, Phe656)으로 둘러싸여 있습니다. 그래서 **지용성이 높고 염기성 질소**를 가진 분자가 잘 들어가 채널을 막습니다.

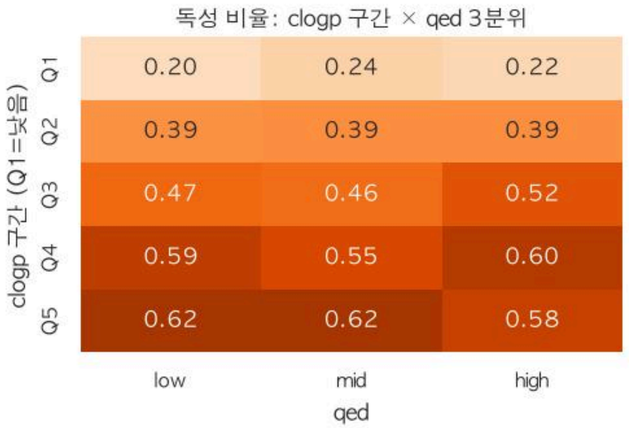
반대로 음전하를 띠는 **카복실산**은 이 결합을 방해합니다. Terfenadine에 -COOH가 붙은 Fexofenadine에 독성이 없는 것도 같은 이유입니다.

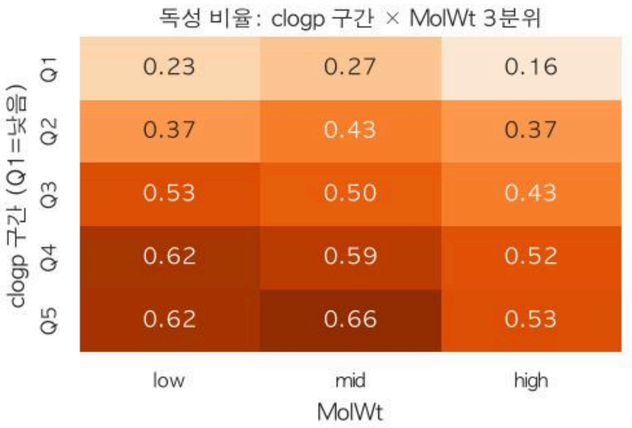
데이터에서 본 clogP 경향이 알려진 약리 메커니즘과 맞기 때문에, 우연한 상관이 아니라 **실제 원인이 있는 신호**로 판단했습니다.

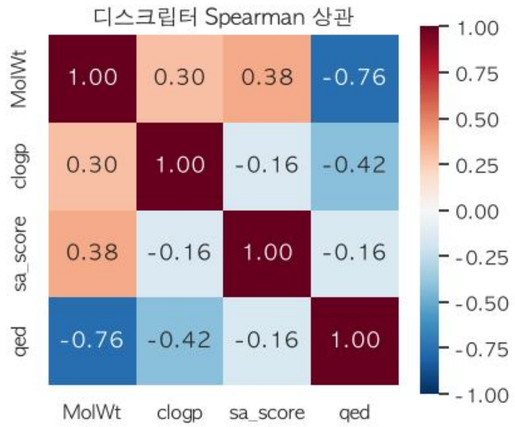
참고: Mitcheson et al., PNAS 2000 / Redfern et al., Cardiovasc Res 2003

# Part A: 디스크립터 4개( MolWt, clogp, sa_score, qed )와 label의 관계



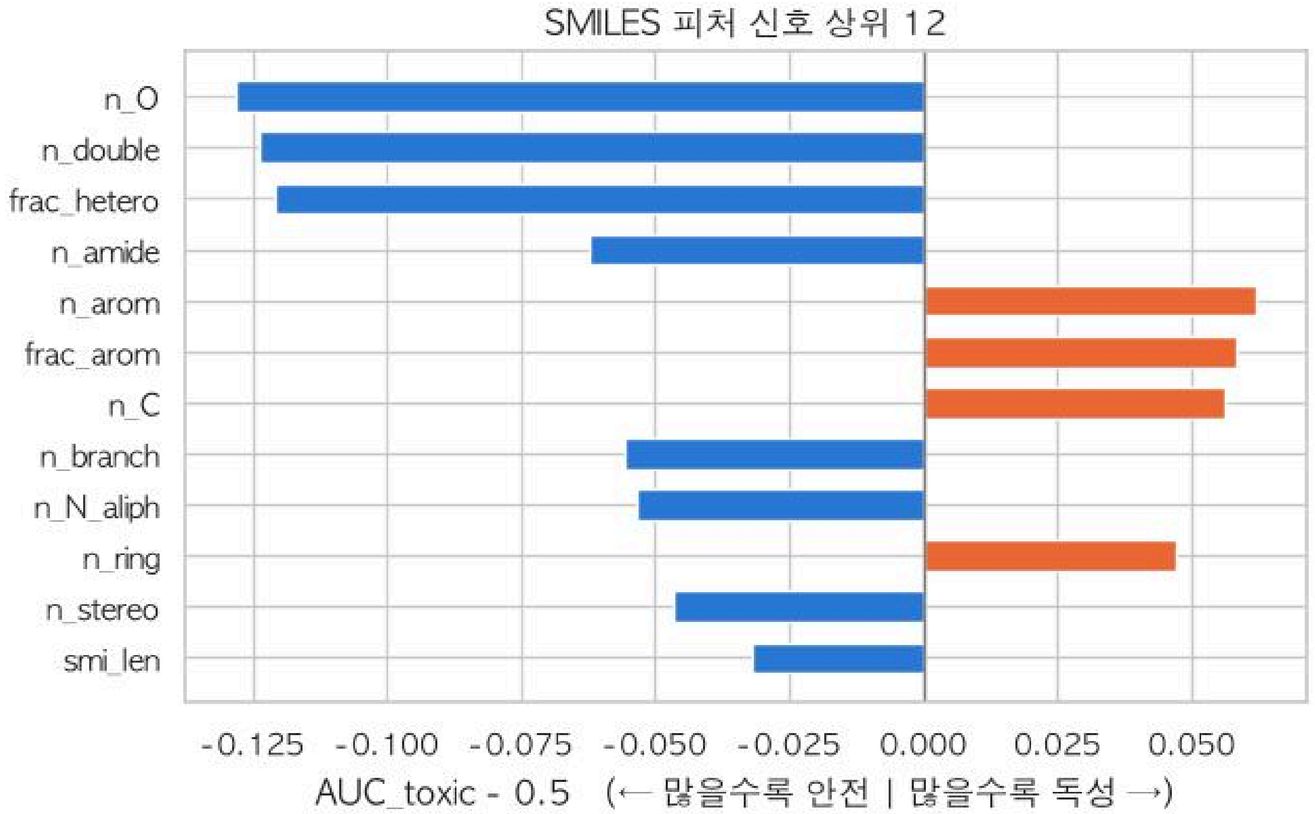

## clogp가 인과성이 있을까?

clogp 가 단순히 상관관계 아니라 인과관계 라는것을 확인하기 위해
sa_score, QED, MolWt를 각각 3분위로 나눠 고정한 상태에서 clogP 5분위별 독성 비율을 비교.
모든 층에서 clogP가 올라갈수록 독성 비율이 단조 증가했고 $p < 10^{-36}$ 임을 확인 했습니다.

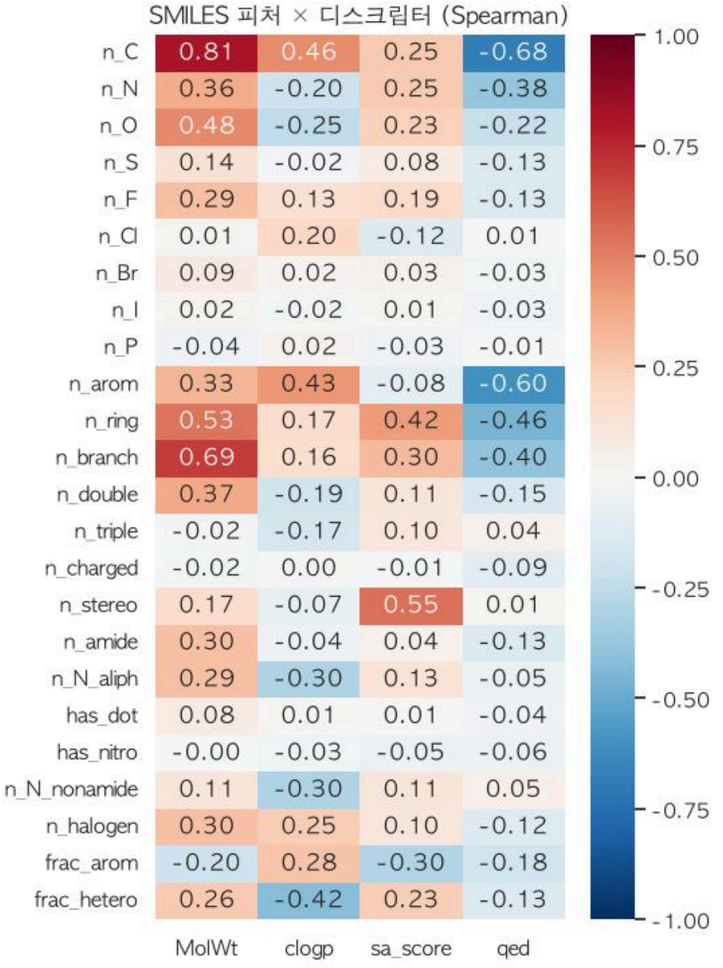
clogP의 효과는 다른 디스크립터가 만들어낸 겉보기 상관이 아니라, 통제 후에도 그대로 남는 독립적인 신호로 확인하였습니다.

https://www.sigmaaldrich.com/KR/ko/tech-docs/paper/294302

# Part B: SMILES 문자열에서 뽑은 구조 피처와 label·디스크립터의 관계

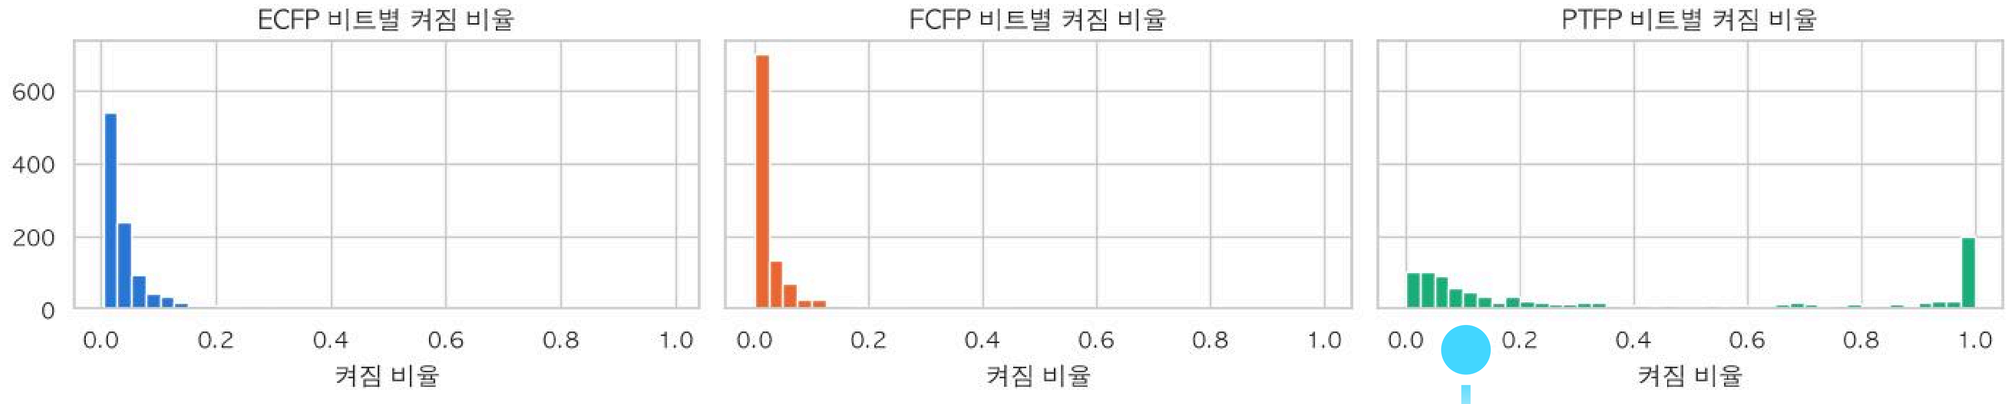


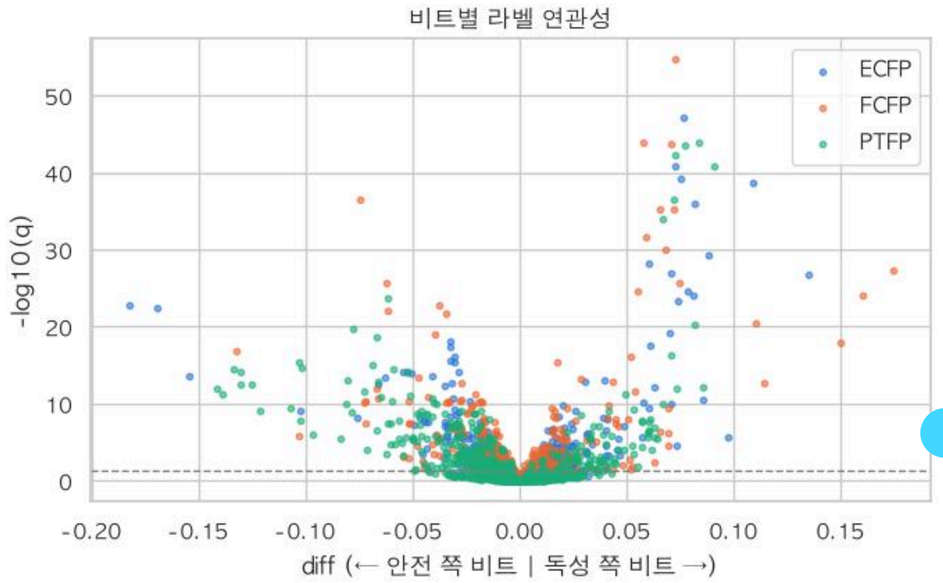

- 방향족·탄소·고리가 많을수록 독성
- 산소·헤테로원자·아마이드가 많을수록 독성 아님




SMILES 피처 × 디스크립터 상관

# Part C: Fingerprint(ECFP/FCFP/PTFP)와 타 변수들관의 관계




- x축: 비트 하나를 골라서 → 8,349개 분자 중 그 비트가 1인 분자의 비율
- y축: 그 비율값을 가진 비트가 몇 개인지

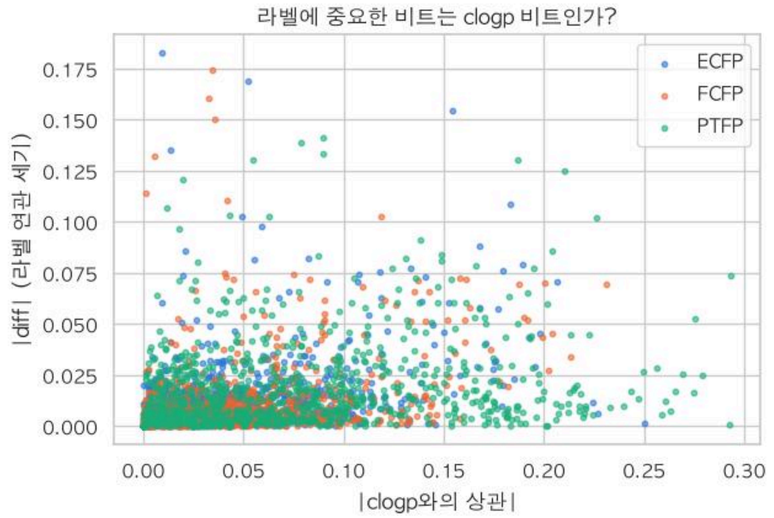
비트가 항상 0이거나, 항상 1인 경우
정보량을 포함하지 않는다고 해석 가능

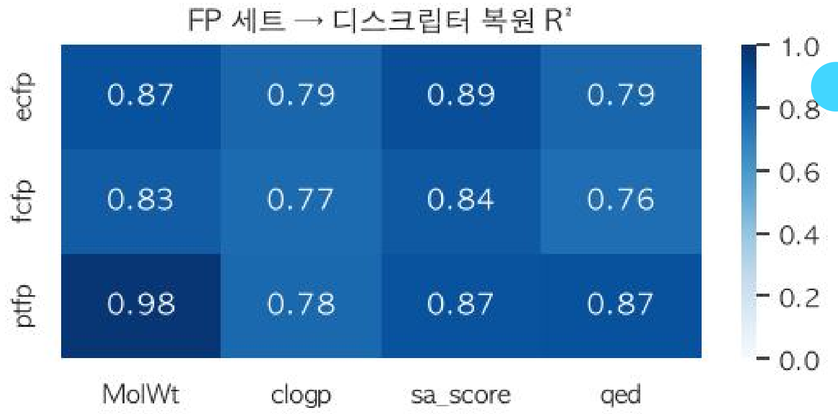
**점 1개 = 비트 1개**

x축 : 독성 – 안전 그룹 비트 비율 차이 (오른쪽일수록 독성 쪽)
y축 : 보정된 유의성 (위일수록 유의, 점선 = 유의 기준)

**독성 쪽(오른쪽)이 에 유의성도 높아 "있으면 위험한 구조" 뚜렷 함**

# Part C: Fingerprint(ECFP/FCFP/PTFP)와 타 변수들관의 관계

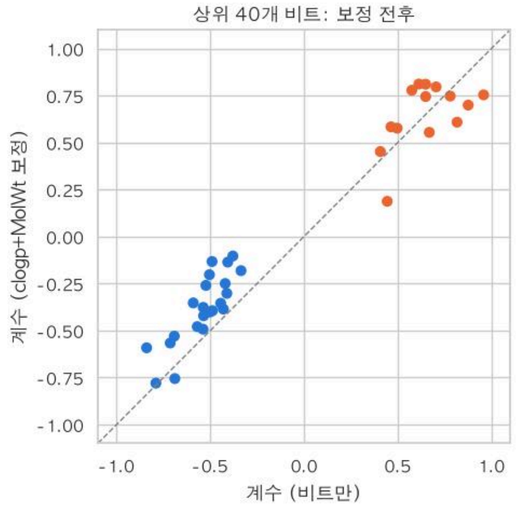



각 fingerprint만으로 디스크립터 4개를 회귀 예측했을 때의 $R^2$ 값

0.76~0.98로 모두 높아 fingerprint가 Descriptor 정보를 사실상 포함하고 있으며, 특히 PTFP는 MolWt를 0.98로 거의 완전히 복원

반면 clogP는 0.77~0.79로 가장 덜 복원됨



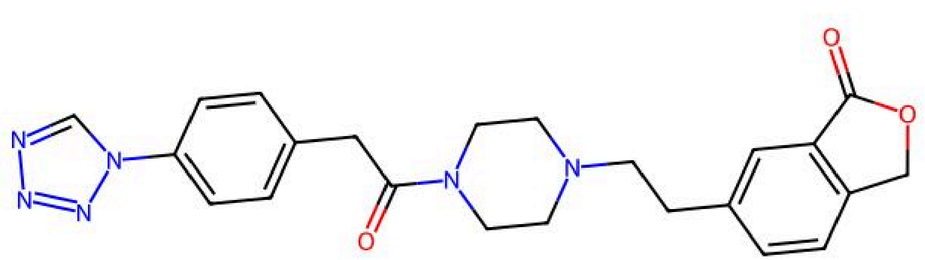

x축: FingerPrint만 넣었을 때의 회귀계수 (라벨 연관이 큰 비트 40개)
y축: clogP·MolWt를 함께 넣어 보정한 계수

점들이 대각선 근처에 몰려 있어 보정 후에도 계수의 부호와 크기가 거의 유지되며, 이 비트들의 효과는 clogP·MolWt로 설명되지 않는 독립적인 구조 정보임을 의미

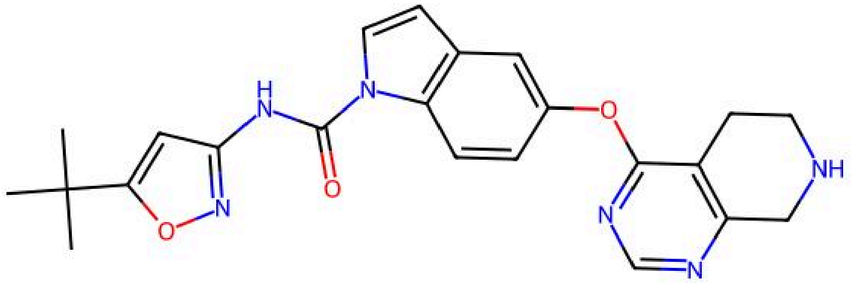
# Part D: SMILES를 분자 구조로 해석해 추출한 결합·분지·입체 특징과 독성의 연관성 검증

가설 : 같은 분자식이라도 연결 구조에 따라 특성이 다를 수 있다.

04 C23H24N6O3 | Different connectivity / different labels



row 3444 | label=1 | MolWt=432.484
clogp=1.262 | SA=2.528 | QED=0.542

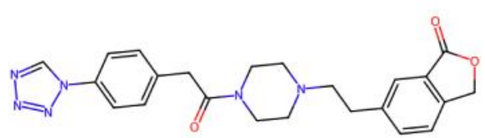


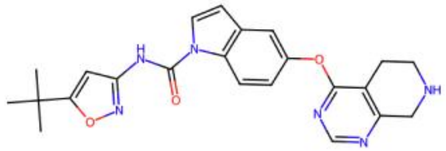
row 3447 | label=0 | MolWt=432.484
clogp=4.235 | SA=3.090 | QED=0.499

ECFP differing bits: 94/1024 | labels are observations, not causal evidence

SKALA

# Part D: SMILES를 분자 구조로 해석해 추출한 결합·분지·입체 특징과 독성의 연관성 검증





| 비교 항목 | 분자 A | 분자 B |
|---|---|---|
| 데이터 인덱스 | 3444 | 3447 |
| 분자식 | $C_{23}H_{24}N_6O_3$ | $C_{23}H_{24}N_6O_3$ |
| 분자량 (MolWt) | 432.484 | 432.484 |
| 지용성 지표 (clogp) | 1.262 | 4.235 |
| 합성 난이도 (sa_score) | 2.528 | 3.090 |
| 약물 유사성 (qed) | 0.542 | 0.499 |
| 독성 라벨 | 1 — 무독성 | 0 — 독성 |
| ECFP 비교 | 두 분자 간 1,024개 중 94개 비트가 다름 | — |

SKALA

# Part D: SMILES를 분자 구조로 해석해 추출한 결합·분지·입체 특징과 독성의 연관성 검증

RDKit 구조 분석을 통해 SMILES의 =, #, @, ( ) 등의 기호를 실제 분자 구조의 특징으로 변환하고, 독성과 통계적으로 유의한 관계가 있는지 확인

| 구조 특징 | 포함 개수 | 포함 독성률 | 미포함 독성률 | 차이 | BH q값 |
|---|---|---|---|---|---|
| **이중결합 (=)** | **5,304** | **41.01%** | **63.30%** | **-22.29%p** | **1.88e-48** |
| **카보닐기 (C=O)** | **4,255** | **39.58%** | **56.16%** | **-16.59%p** | **2.35e-38** |
| **아마이드기** | **3,843** | **39.84%** | **53.40%** | **-13.56%p** | **1.53e-27** |
| 입체중심 지정 (@) | 2,965 | 40.64% | 49.56% | -8.92%p | 1.06e-12 |
| 니트릴기 (C≡N) | 639 | 38.34% | 46.37% | -8.03%p | 2.03e-04 |
| 삼중결합 (#) | 751 | 41.01% | 46.18% | -5.17%p | 0.0140 |

차이 = 구조 포함 그룹 독성 비율 – 구조 미포함 그룹 독성 비율

q값은 12개 구조 특징에 대한 Fisher 검정 결과를 BH 방식으로 보정한 값

SKALA

# Part D: SMILES를 분자 구조로 해석해 추출한 결합·분지·입체 특징과 독성의 연관성 검증

분자량과 지용성(clogp)의 영향을 고려한 후에도 특정 분자 구조와 독성 사이의 관계가 유지되는가?를 확인

| 구조 특징 | 보정 전 차이 | 보정 후 OR | 95% 신뢰구간 | BH q값 | 판정 |
|---|---|---|---|---|---|
| **이중결합 (=)** | **-22.29%p** | **0.475** | **0.416 – 0.544** | **4.00e-27** | **유의** |
| **카보닐기 (C=O)** | **-16.59%p** | **0.519** | **0.465 – 0.580** | **4.03e-30** | **유의** |
| **아마이드기** | **-13.56%p** | **0.606** | **0.545 – 0.674** | **8.38e-20** | **유의** |
| 입체중심 지정 (@) | -8.92%p | 0.766 | 0.692 – 0.848 | 7.84e-07 | 유의 |
| 니트릴기 (C≡N) | -8.03%p | 1.019 | 0.852 – 1.219 | 0.8392 | 비유의 |
| 삼중결합 (#) | -5.17%p | 1.073 | 0.910 – 1.266 | 0.4764 | 비유의 |

OR < 1: 해당 구조를 가진 그룹에서 독성 오즈가 낮은 방향 (인과관계 의미 아님)
보정 전 차이는 %p, 보정 후 OR은 오즈비로 서로 다른 단위

SKALA

# Part D: SMILES를 분자 구조로 해석해 추출한 결합·분지·입체 특징과 독성의 연관성 검증

| 확인한 것 | 아직 확인하지 않은 것 |
| --- | --- |
| 일부 구조 특징과 독성 라벨의 연관성 | 독성 차이의 원인 |
| 일부 관계의 내부 검증 재현 | 외부 데이터에서의 재현성 |
| 구조 기반 파생변수 후보 | 모델의 예측 성능 개선 여부 |

구조 특징을 파생 변수 후보로 도출했으며, 이후 ECFP 등에 추가했을 때 예측 성능이 개선되는지 비교할 예정이다.

SKALA

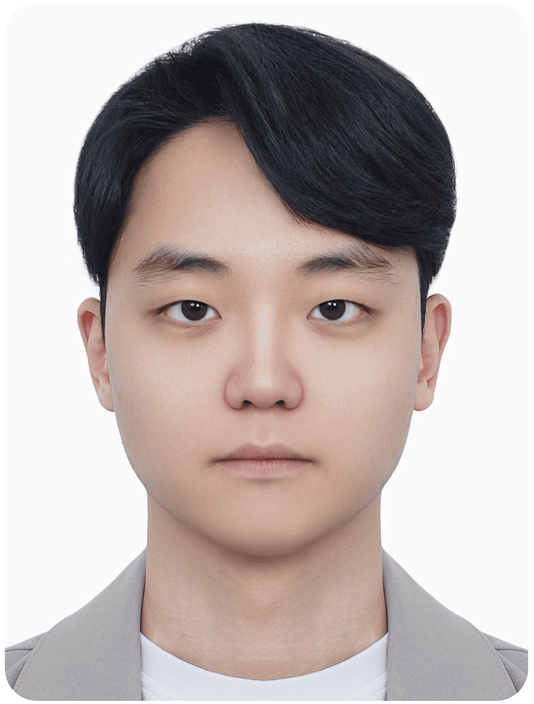
# 팀원 소개

판교 9반 5조



**정원준**

P307



**전경호**

P303



**이지은**

P299



**김민정**

P282