SKALA

데이터 분석 및 AIOps

# 데이터 분석 개요 및 기초통계

## Day1. 기초통계

2026.07

전임교수 : Byung-sun, Park

Ver.4

본 문서는 SK(주)AX의 컨텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

SK Inc. AX



1. Intro
2. 데이터와 변수 이해
3. 기술 통계
4. 추론 통계
5. 가설 검정

데이터 분석 개요 및 기초통계

# Intro

- 왜 통계를 배워야 할까?
- 잘못된 통계의 예
- 통계학이란?

본 문서는 SK㈜AX의 컨텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

SKALA

# 왜 통계를 배워야 할까?

"우리말을 안 익히면 살 수 없을 것.. 영어를 안배우면? 불편할 것..

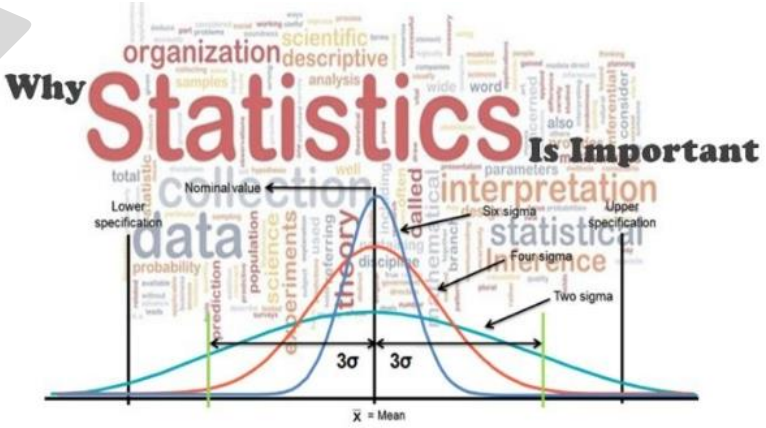
통계학은 하나의 언어.. Communication의 수단..

수많은 분야에서 쓰이는 언어.. 경제, 경영, 사회과학, 인문과학, 법학, 의학, 공학..

주변의 신문, 방송, 광고, 스포츠 등 어디서나 접할 수 있는 언어..

우리는 통계 속에 묻혀 산다고 해도 과언이 아님

통계를 잘 모르면 때로는 괴롭고, 때로는 속고 살기 십상일수도.."




SKALA

# 잘못된 통계의 예

"딸만 셋 나았으니 이제는 아들 낳을 차례다"

"주사위를 던져서 6이 나온다면 다음에는 6이 나오지 않을 것이다"

"과거의 데이터를 보면, 주식시장이 올라간 이후에는 반드시 하락해야 한다."

SKALA

# 잘못된 통계의 예

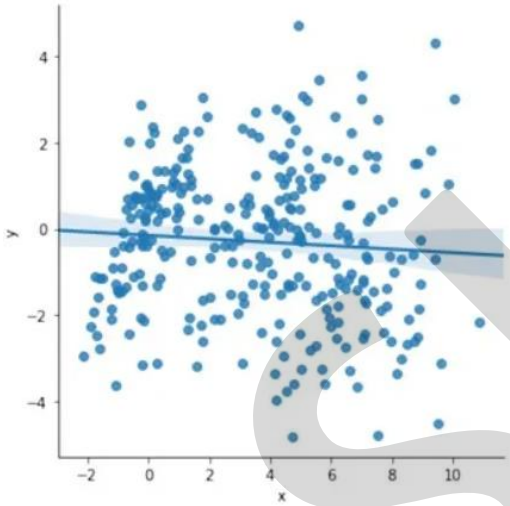
"다양한 자산군에 투자하여 특정 자산군의 영향을 최소화하는 분산투자 원칙을 지키며 투자한 결과,
1개월만에 500%가 넘는 높은 수익률을 기록했습니다"

SKALA

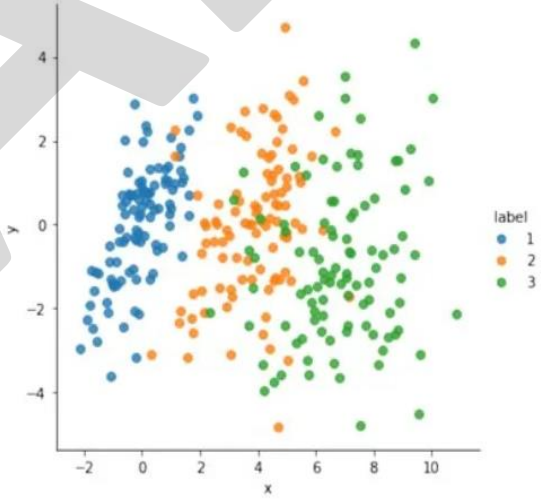
# 잘못된 통계의 예

"수능 성적과 입학 후 학점 간의 상관 관계는 낮습니다. 따라서 수능 성적은 입학 후의 성취를 예측하는데 별로 도움이 되지 못합니다"

<수능성적(x)과 학점(y)>




<학과별 수능성적(x)과 학점(y)>




SKALA

# 잘못된 통계의 예

**아동학대, 친부모‘80%’ 계부모 ‘10%미만’** from 조선일보

- 보건복지부가전국17개시,도 아동학대 예방센터와 신고전화 ‘1391’을 통해 접수한 아동학대 사례는 모두 4,111건이며, 이중2,478건이 실제 아동학대
- 복지부에 신고된 학대 사례들도 사망 등 극한 상황으로 가는 특수한 경우가 아니라, 자기 집에서 친부모에게 거의 매일 학대를 당한 사례가 주종을 이뤘다. 가해자의80%는 친부모이며, 계부모와 양부모는 각각10% 미만이었다.

SKALA

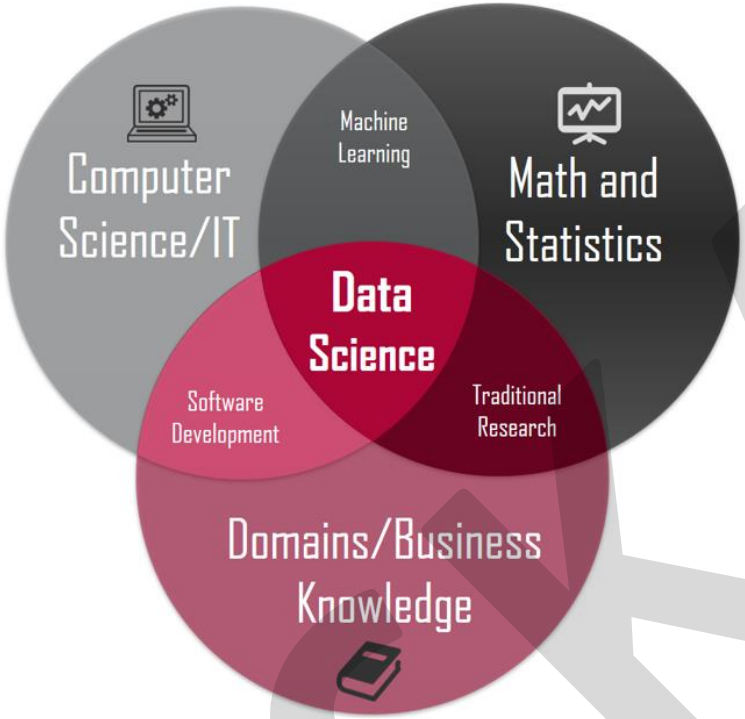
# 잘못된 통계의 예

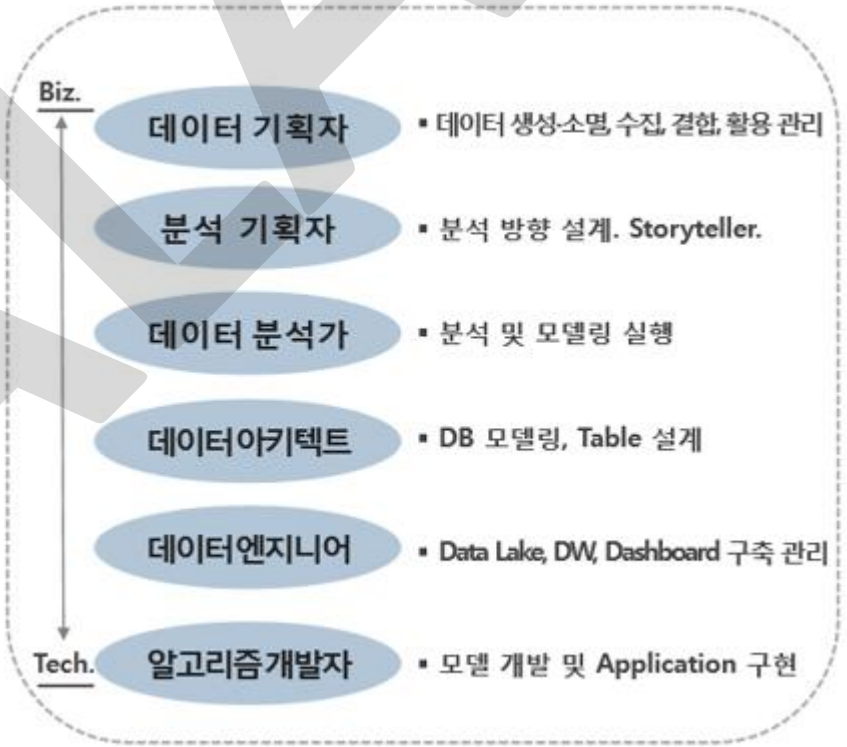
'속도의 유혹', "곧은 길서 사고 더 많아요" from 중앙일보

- 곧게 뻗은 직선도로에서 속도의 유혹을 이기지 못하는 바람에 발생하는 교통사고가 전체 교통사고 10건 중 9건 이나 된다고 합니다. 건설 교통부와 경찰청이 지난해 발생한 교통사고 21만4,000여 건을 분석한 결과입니다.
- 쭉 뻗은 직선도로에 올라서면 가슴이 뻥 뚫리는 듯한 느낌을 받으신 적이 있을겁니다. 차도 별로 많지 않다면 자연스레 액셀러레이터를 밟는 발에 힘이 들어가게 됩니다. 악마의 유혹. 사고의 위험성이 순간적으로 높아지는 순간입니다

SKALA

# 나의 skill set은? 어디에 속할 것인가?




SKALA

# 통계학이란?

"통계학은 불확실성을 다루는 학문..
확실한 결과를 얻을 수 없는 많은 현실의 경우에서,
통계학은 그 불확실성을 수학적, 확률적 방법으로 모델링하고 추론하는 방법론을 제공함.
통계학을 통해 우리는 불확실한 데이터를 바탕으로 합리적이고 신뢰할 수 있는 결정을 내릴 수 있게 됨."

"자료로 가득 차 있는 세상에서
통계학은 자료를 정리하고 분석하여 유용한 정보를 얻기 위한 언어이자 도구"

어떤 신약이 효과가 있는지 알아보기 위해 실험을 진행하지만,
실험에 포함된 표본은 전체 인구의 일부에 불과하기 때문에 불확실성이 존재합니다.
통계학은 이러한 불확실성을 수학적으로 모델링하고, 불확실성의 범위를 추정할 수 있는 방법을 제공합니다.

SKALA

데이터 분석 개요 및 기초통계

# 데이터와 변수 이해

- 척도에 의한 분류
- 형태에 의한 분류
- 기능에 의한 분류

본 문서는 SK㈜AX의 컨텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

SKALA

SK Inc. AX

# 왜 변수를 먼저 이해해야 할까?

좋은 통계 분석은 데이터를 이해하는 것에서 시작

평균을 계산해도 의미가 있는 것은?

- 성별의 평균을 계산할 수 있을까? → 평균에 의미가 없음, 성별이 1.6이라는 것은 무엇을 의미하나?
- 고객등급(A, B, C)의 평균은 의미가 있을까? → 기술적으로 계산할 수 있지만, A와B의 차이와 B와C의 차이는 동일한가?
- 매출액은 평균과 표준편차를 계산할 수 있을까? → ok

✓ 데이터의 특성에 따라 사용할 수 있는 분석 방법이 달라짐

✓ 데이터의 종류를 이해해야 적절한 통계 기법을 선택할 수 있음

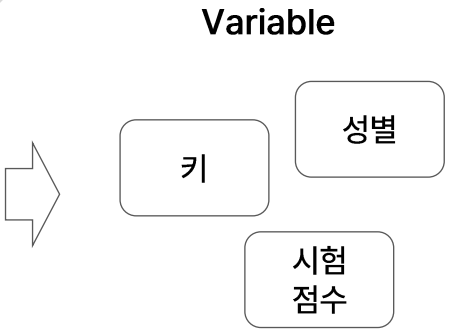
SKALA

# 변수(Variable)란?

**Concept**

- 관측 대상의 특성을 숫자나 값으로 표현한 것
- 관찰 대상(개체)에 따라 서로 다른 값을 가질 수 있는 속성 또는 특성

| 학생 | 키 | 성별 | 시험점수 |
|---|---|---|---|
| A | 170 | 남 | 85 |
| B | 165 | 여 | 92 |
| C | 180 | 남 | 77 |




SKALA

# 변수는 어떻게 구분할까?

변수의 척도(Scale of Measurement)는 변수의 값을 어떻게 표현하고 비교할 수 있는지를 나타내는 기준

## 【 범주형:Categorical 】

### 명목척도(Nominal)

- 대상을 구분하거나 분류하기 위한 척도
- 순서가 없다 / 크기를 비교할 수 없다 / 평균을 계산해도 의미가 없다. / 수치 간의 양적인 의미가 없다
- Ex) 성별, 혈액형, 지역
- 빈도, 최빈값

### 서열척도(Ordinal)

- 순서는 있지만, 각 값 사이의 간격은 일정하지 않은 척도
- 크고 작음을 비교할 수 있다 / 순위를 알 수 있다 / 평균은 일반적으로 해석하지 않는다
- Ex) 고객등급(A/B/C), 서비스만족도(1~5점)
- 중앙값, 순위비교..

## 【 연속형:Continuous 】

### 구간척도(Interval)

- 값 사이의 간격은 동일 & 절대적인 0이 존재하지 않는 척도
- 차이(간격)를 비교할 수 있다 / 평균과 표준편차를 계산할 수 있다 / 비율(두 배, 절반)의 의미는 없다
- Ex) 섭씨온도(°C), IQ
- 평균, 분산, 회귀분석..

### 비율척도(Ratio)

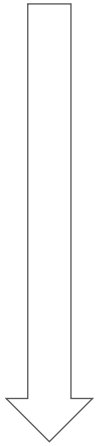
- 절대적인 0을 가지며, 모든 산술 연산이 가능한 척도
- 순서가 있다 / 간격이 동일하다 / 절대적인 0이 존재한다 / 비율 비교가 가능하다
- Ex) 매출액, 키, 나이
- 평균, 분산, 회귀분석, 비율비교..

SKALA

# 변수는 어떻게 구분할까?

변수의 척도(Scale of Measurement)는 변수의 값을 어떻게 표현하고 비교할 수 있는지를 나타내는 기준

| 척도 | 구분 | 순서 | 간격 | 절대적 0 |
|---|---|---|---|---|
| 명목 | O | X | X | X |
| 서열 | O | O | X | X |
| 구간 | O | O | O | X |
| 비율 | O | O | O | O |

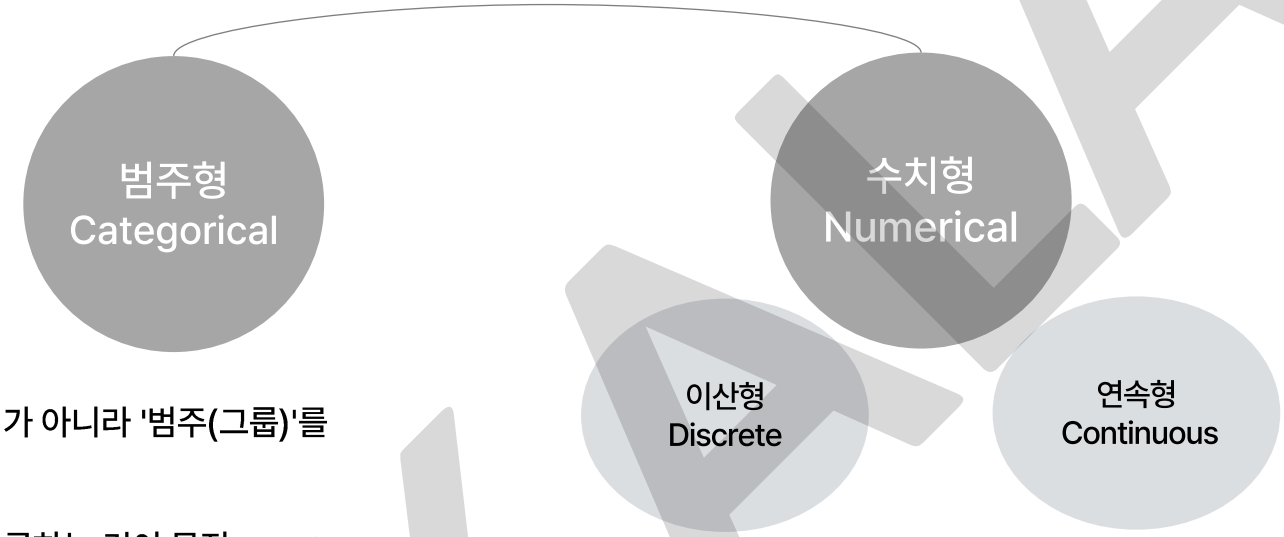


- 척도가 하나씩 올라갈수록 정보량 증가
- 명목척도는 구분만 가능
- 서열척도는 구분 + 순서를 알 수 있음
- 구간척도는 구분 + 순서 + 간격을 비교할 수 있음
- 비율척도는 여기에 절대적인 0까지 있어 비율 비교(두 배, 절반)도 가능

SKALA

# 변수는 어떻게 구분할까?

데이터의 형태(Data Type)에 따른 분류 : 실무에서 자주 사용하는 변수 분류




- 값이 숫자의 크기가 아니라 '범주(그룹)'를 나타내는 변수
- 같은 그룹끼리 분류하는 것이 목적
- Ex) 성별, 혈액형, 등번호

- 셀 수 있는(Count) 값으로 이루어진 변수
- 개수를 세는 데이터
- 정수값을 가진다 / 소수점 값은 일반적으로 존재하지 않는다
- Ex) 판매건수, 불량개수, 자녀수

- 측정(Measure)하여 얻는 값으로 연속적인 값을 가질 수 있는 변수
- 소수점 값을 가질 수 있다 / 두 값 사이에 무수히 많은 값이 존재할 수 있다
- Ex) 키, 시간, 거리, 매출액

SKALA

# 변수는 어떻게 구분할까?

데이터 분석에서 어떤 기능을 하는가? 에 따른 분류

## 종속변수 (Dependent Variable, Target, Y변수)

- 독립변수의 영향을 받는 결과 변수
- Ex) 시험점수, 매출액, 제품 불량률

## 독립변수 (Independent Variable, Input, X변수)

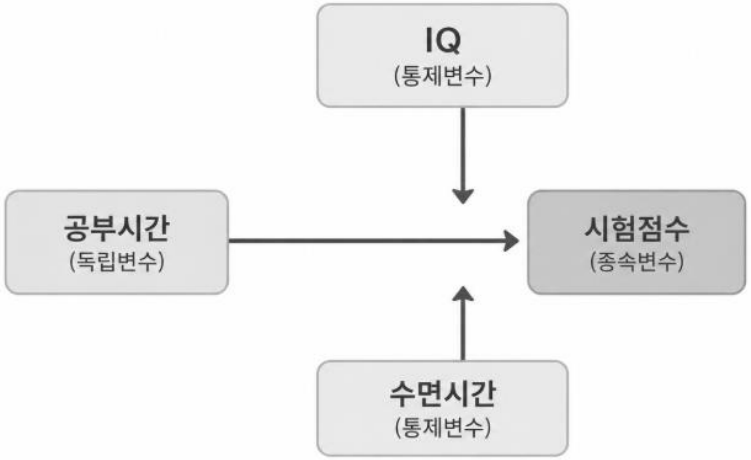
- 결과에 영향을 주는 원인(설명) 변수
- Ex) 공부시간, 광고비, 생산온도

## 통제변수 (Control Variable)

- 결과에 영향을 줄 수 있지만,연구에서는 일정하게 유지하거나 함께 고려하는 변수
- 종속변수에 미치는 영향을 정확하게 파악하기 위해 통제되는 변수
- Ex) IQ, 수면시간, 사교육 여부

**통제변수 Why use?**

- 학생A : 하루 6시간 공부 → 95점
- 학생B : 하루 2시간 공부 → 95점
- 공부시간은 시험점수에 효과가 없는가?
- 학생A가 잠을 거의 못 잤을수도.. 학생B가 IQ가 높거나 사교육을 했을수도..
- 공정한 비교를 위해 다른 영향을 주는 변수들을 함께 고려하는 것이 필요




SKALA

# 변수는 어떻게 구분할까?

서로 다른 분류 기준(관점)에 따른 변수 분류

- 광고가 매출에 미치는 영향을 분석

| 변수 | 척도 | 데이터 타입 | 역할 |
|---|---|---|---|
| 광고비 | 비율척도 | 수치형 | 독립변수 |
| 매출액 | 비율척도 | 수치형 | 종속변수 |
| 지역 | 명목척도 | 범주형 | 통제변수 |
| 매장 규모 | 비율척도 | 수치형 | 통제변수 |

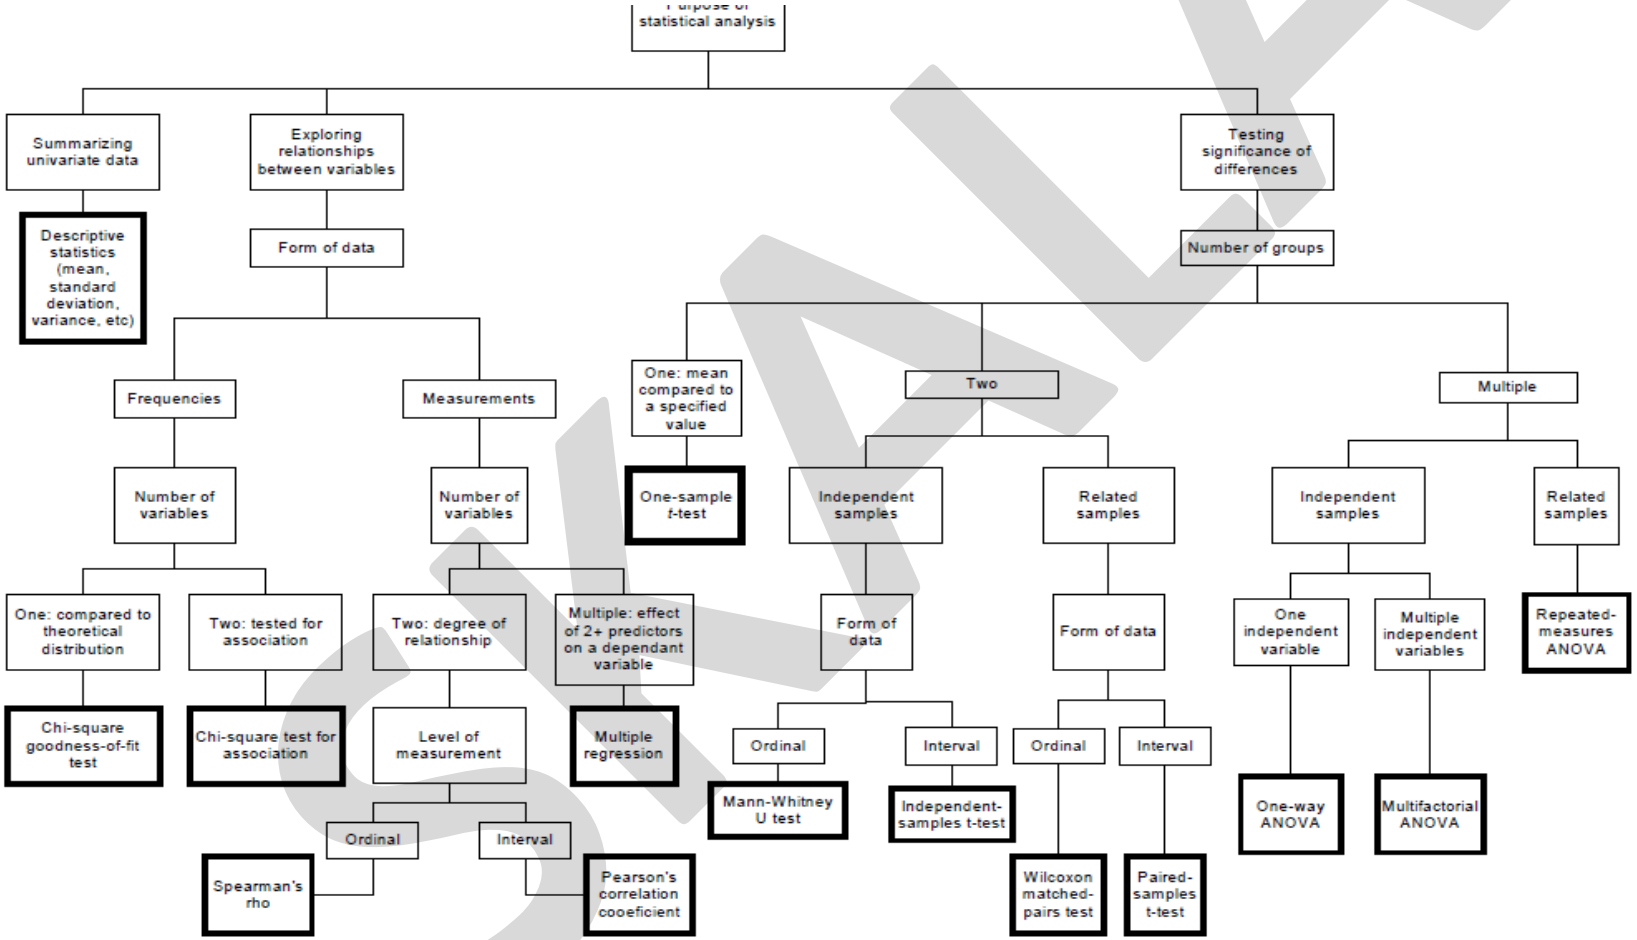
- ✓ 같은 변수도 세 가지 기준으로 동시에 설명할 수 있음 → 변수를 서로 다른 관점에서 이해하기 위한 것
- ✓ 어떤 수준으로 측정,비교 할 수 있는가? → 어떤 통계 분석이 가능할까?
- ✓ 데이터가 어떤 형태인가? → 데이터를 어떻게 처리할 것인가?
- ✓ 분석에서 어떤 역할을 하는가? → 무엇을 예측하거나 설명할 것인가?

SKALA

# 데이터 유형에 따른 통계 기법 선택

어떤 통계 기법을 사용할까?

✓ 데이터 유형에 따라 통계 기법이 달라진다



# 데이터 유형에 따른 통계 기법 선택

어떤 통계 기법을 사용할까?

데이터를 이해하면 통계 기법이 보인다

- 성별에 따라 급여가 다른가? → 범주형 vs 연속형 → t-test
- 광고비가 증가하면 매출도 증가하는가? → 연속형 vs 연속형 → 상관분석, 회귀분석
- 혈액형과 질병은 관련이 있는가? → 범주형 vs 범주형 → 카이제곱 검정

✓ 통계는 데이터의 특성에 맞는 분석 방법을 선택하는 과정

SKALA

데이터 분석 개요 및 기초통계

# 기술 통계

- 중심화
- 퍼짐
- 분포 형태

본 문서는 SK㈜AX의 컨텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

SKALA

SK Inc. AX

# 기술 통계학이란?

기술 통계학, Descriptive Statistics

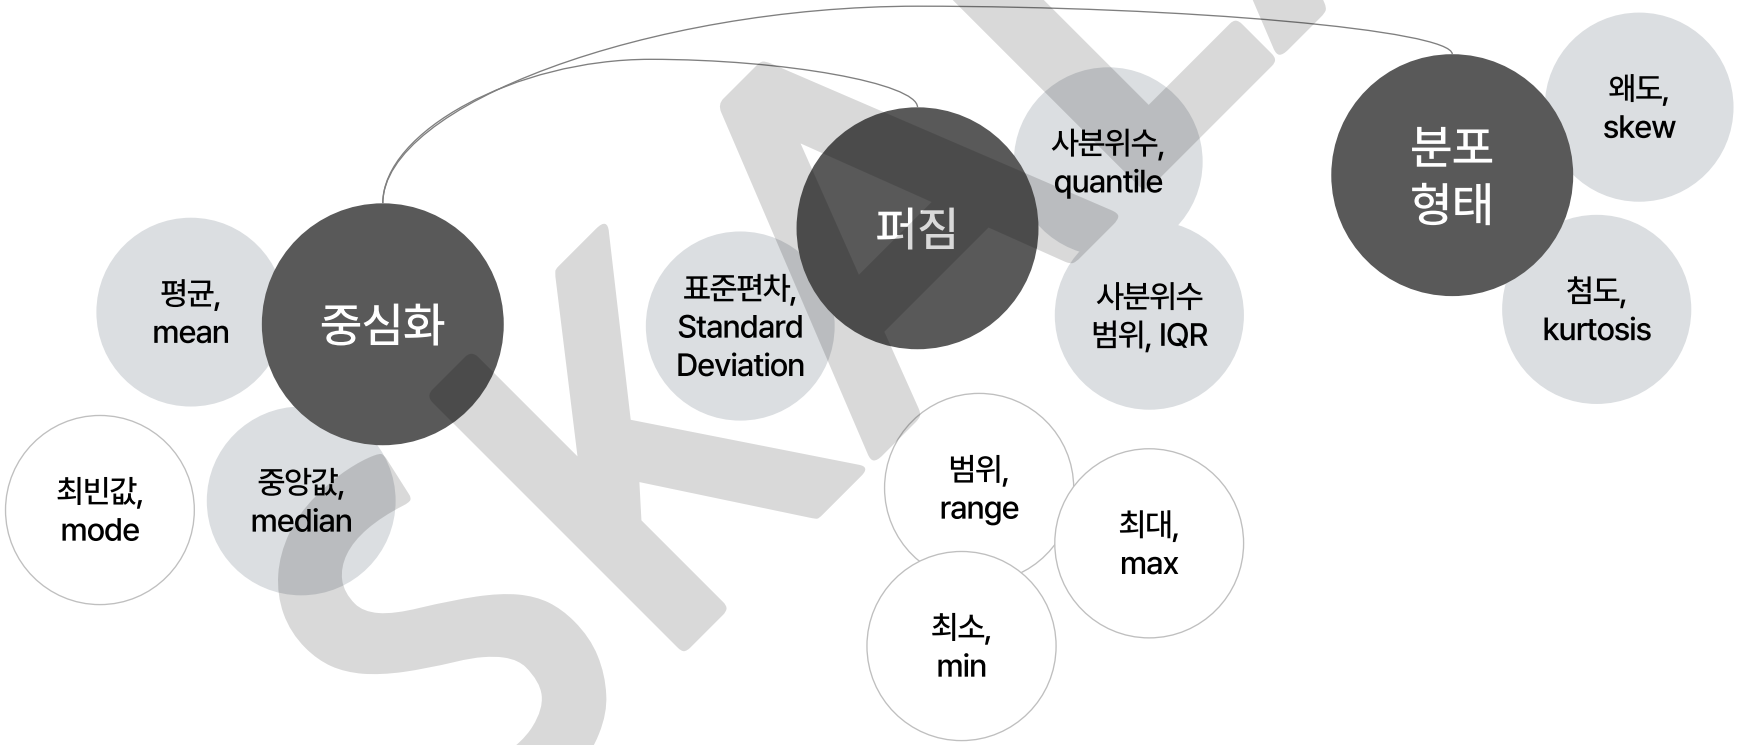
**Concept**

- 수집된 자료들이 가지고 있는 정보를 손쉽게 파악할 수 있도록 표현하는 방법에 대해 다루는 학문분야
- 주어진 데이터 집합을 요약하고 정리하는데 초점을 맞춤
- 중심 경향과 분포 등을 계산하여 데이터 요약(평균,중앙값..), 분포나 관계를 시각화(히스토그램, 박스플랏), 기술 통계량..

SKALA

# Descriptive Statistics

- 기술 통계량은 데이터의 특성을 요약하여 이해하는 가장 기본적인 분석 방법
- 데이터의 중심 위치(중심화), 흩어진 정도(산포:Dispersion), 분포의 형태를 살펴봄으로써 데이터의 전반적인 특성을 빠르게 파악할 수 있음




SKALA

# 중심화(Central Tendency)

데이터의 대표값을 나타내는 통계량

- 중심화는 데이터를 대표하는 하나의 값을 통해 데이터의 중심 위치를 요약하는 통계량

| 통계량 | 의미 | 특징 | When to Use |
|---|---|---|---|
| **평균(Mean)** | 모든 값을 더해 개수로 나눈 값 | 가장 많이 사용되지만 이상치에 민감 | 데이터가 정규분포에 가깝고 이상치가 적은 경우 |
| **중앙값(Median)** | 데이터를 크기순으로 정렬했을 때 가운데 값 | 이상치의 영향을 거의 받지 않음 | 소득, 집값처럼 극단값이 존재하는 경우 |
| **최빈값(Mode)** | 가장 많이 나타나는 값 | 범주형 데이터에서도 활용 가능 | 제품 종류, 선호도 등 범주형 데이터 분석 |

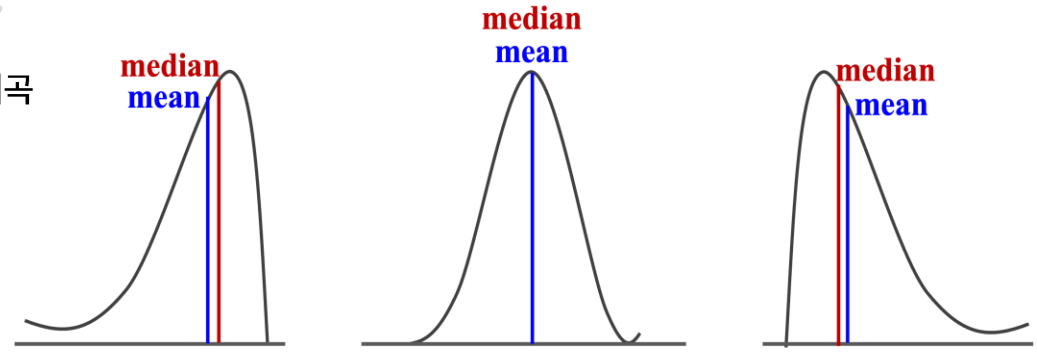
SKALA

# 중심화(Central Tendency)

데이터의 대표값을 나타내는 통계량

| | x = {10, 12, 13, 15, 16} | x = {10, 12, 13, 15, 100} |
|---|---|---|
| **평균 (mean)** | $mean(x) = \frac{(10+12+13+15+16)}{5}$ <br> $= \frac{66}{5} = 13.2$ | $mean(x) = \frac{(10+12+13+15+100)}{5}$ <br> $= \frac{150}{5} = 30$ |
| **중앙값 (median)** | 5개 중 middle, 3 번째 값 <br> $median(x) = 13$ | 5개 중 middle, 3 번째 값 <br> $median(x) = 13$ |

- ✓ 이상치 하나만으로 평균은 크게 변하지만 중앙값은 거의 변하지 않음
- ✓ 평균만 보고 데이터를 판단하면 오류가 발생할 수 있음
- ✓ 이상치가 존재하는 경우에는 중앙값을 함께 확인하여 대표값의 왜곡 여부를 검토하는 것이 중요




SKALA

# 중심화(Central Tendency)

중심화 – mean vs median

## 연령대별 순자산 분포

| 구분 | 순자산 평균 | 중앙값 |
|---|---|---|
| 29세 이하 | 1억 386만원 | 5,090만원 |
| 30-39세 | 2억 5,402만원 | 1억 5,950만원 |
| 40-49세 | 4억 5,064만원 | 2억 9,032만원 |
| 50-59세 | 5억 1,131만원 | 3억 454만원 |
| 60세 이상 | 5억 1,922만원 | 2억 5,200만원 |

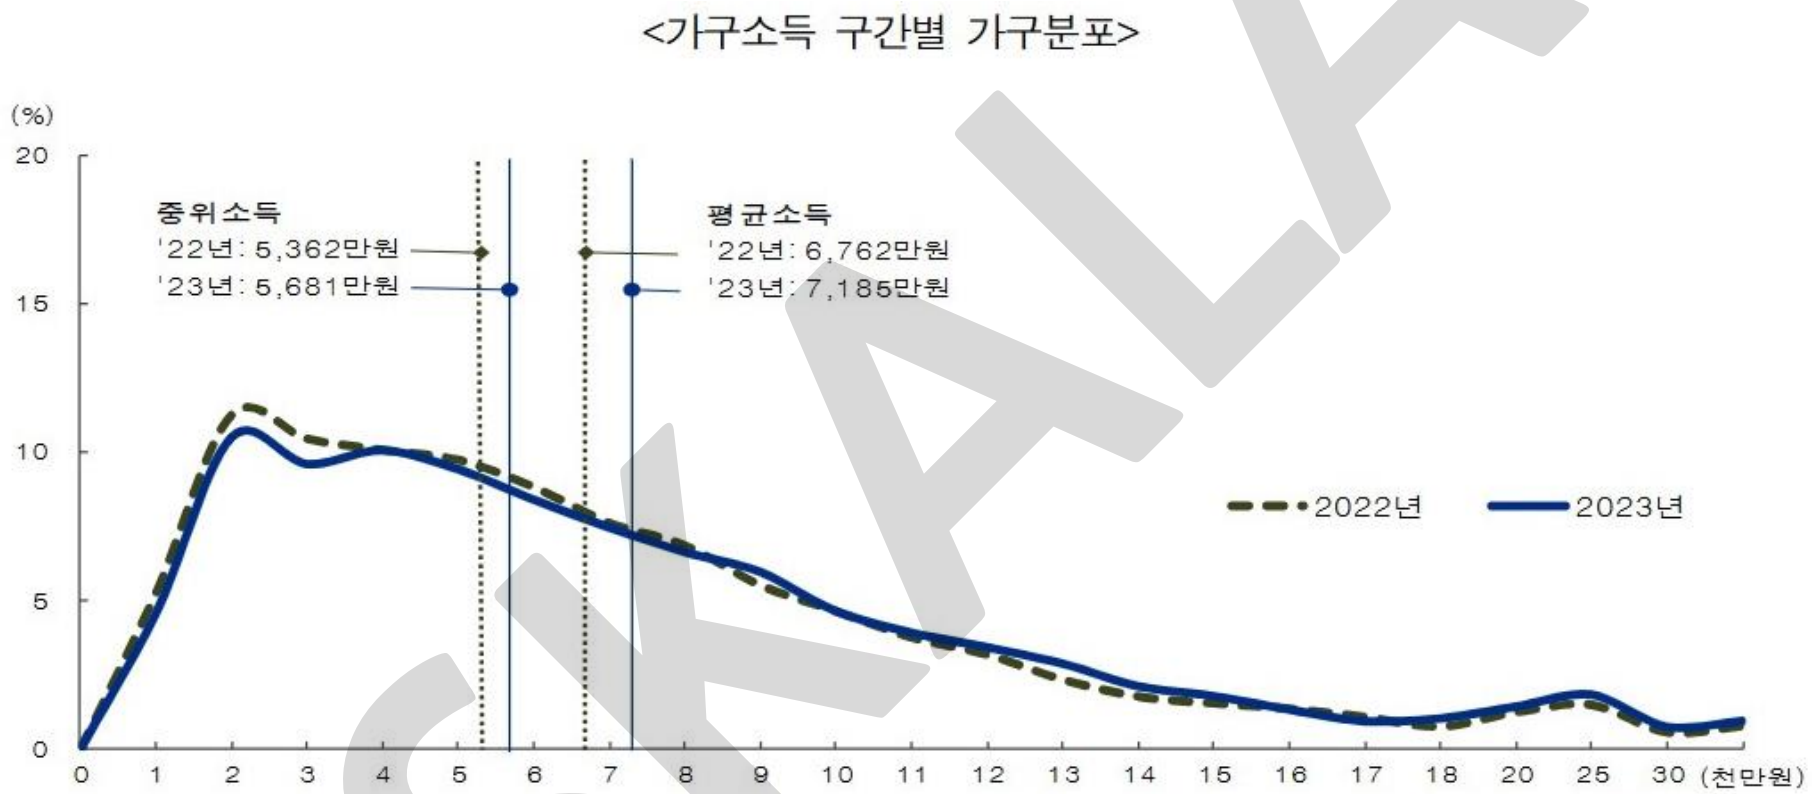
<'통계청 24년 가계금융 복지조사>

- SNS에는 10억부자들이 넘쳐나지만..
- 현실적인 순자산 수준은 어떻게 바라봐야 할까?

SKALA

# 중심화(Central Tendency)

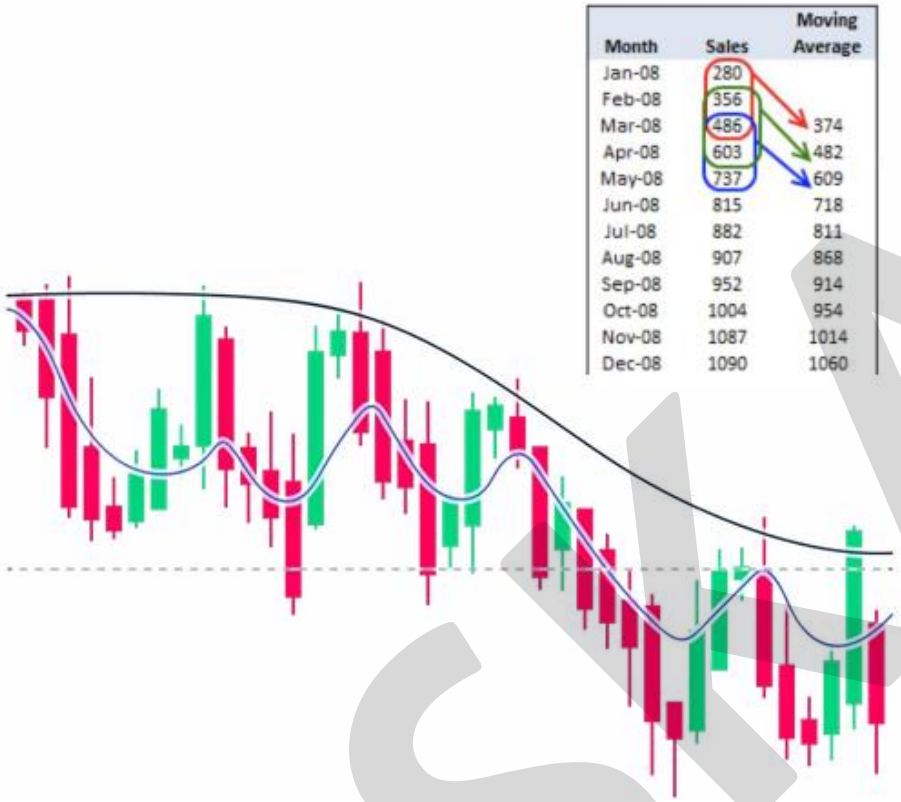
중심화 – mean vs median




SKALA

# 중심화(Central Tendency)

시계열 데이터에서의 중심값은?



| Month | Sales | Moving Average |
|---|---|---|
| Jan-08 | 280 | |
| Feb-08 | 356 | |
| Mar-08 | 486 | 374 |
| Apr-08 | 603 | 482 |
| May-08 | 737 | 609 |
| Jun-08 | 815 | 718 |
| Jul-08 | 882 | 811 |
| Aug-08 | 907 | 868 |
| Sep-08 | 952 | 914 |
| Oct-08 | 1004 | 954 |
| Nov-08 | 1087 | 1014 |
| Dec-08 | 1090 | 1060 |

### 장점

- 변동성 완화 : 데이터의 급격한 변동을 부드럽게 만들어 줌
- 추세파악에 유리 : 상승/하락 흐름을 시각적으로 쉽게 인지 가능
- 계산이 간단하고 직관적

### 활용 시 주의사항

- 지연(Lag) 발생: 실제 변화보다 늦게 반응함
- 이상치에 민감할 수 있음 (특히 단기 평균일수록 영향 큼)
- 적절한 윈도우 크기 선택이 중요 : 너무 크면 흐름이 무뎌 지고, 너무 작으면 잡음이 반영됨

SKALA

# 퍼짐(Dispersion)

산포, 데이터가 얼마나 흩어져 있는지를 나타내는 통계량

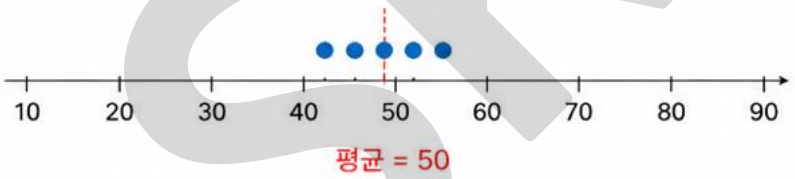
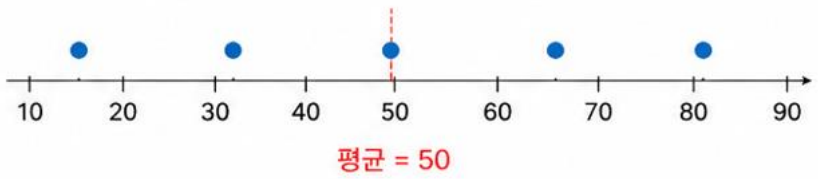
- 데이터가 중심값을 기준으로 얼마나 넓게 퍼져 있는지를 나타내는 통계량
- 평균이 같더라도 산포가 다르면 데이터의 특성과 변동성은 크게 달라질 수 있음

| 통계량 | 의미 | 특징 | When to Use |
|---|---|---|---|
| 분산 (Variance) | 평균으로부터 떨어진 정도의 제곱 평균 | 데이터의 변동성을 수치화 | 통계 분석 및 머신러닝 알고리즘에서 선호 |
| 표준편차 (Standard Deviation) | 분산의 제곱근 | 가장 널리 사용하는 산포 지표 | 데이터의 변동성의 표준적인 비교 |
| 범위 (Range) | 최댓값 – 최솟값 | 계산이 간단하지만 이상치에 민감 | 전체 데이터의 폭을 빠르게 확인할 때 |
| 사분위수 범위 (IQR) | Q3 – Q1 | 이상치의 영향을 적게 받음 | 이상치가 포함된 데이터를 분석할 때 |

SKALA

# 퍼짐(Dispersion)

산포, 평균은 같아도 데이터의 퍼짐 정도는 크게 다를 수 있다

| 데이터 | A = {48, 49, 50, 51, 52} | B = {20, 35, 50, 65, 80} |
|---|---|---|
| 평균 (Mean) | $\bar{x}_A = \frac{48+49+50+51+52}{5} = \frac{250}{5} = 50$ | $\bar{x}_B = \frac{20+35+50+65+80}{5} = \frac{250}{5} = 50$ |
| 표준편차 (Standard Deviation) | ① 각 값의 편차 $(x_i - \bar{x})$<br>48 49 50 51 52<br>-2 -1 0 1 2<br>② 편차 제곱 $(x_i - \bar{x})^2$<br>4 1 0 1 4<br>③ 분산<br>$s_A^2 = \frac{4+1+0+1+4}{5} = \frac{10}{5} = 2$<br>④ 표준편차<br>$s_A = \sqrt{2} \approx 1.41$ | ① 각 값의 편차 $(x_i - \bar{x})$<br>20 35 50 65 80<br>-30 -15 0 15 30<br>② 편차 제곱 $(x_i - \bar{x})^2$<br>900 225 0 225 900<br>③ 분산<br>$s_B^2 = \frac{900+225+0+225+900}{5} = \frac{2250}{5} = 450$<br>④ 표준편차<br>$s_B = \sqrt{450} \approx 21.21$ |
| 산포도 (Dot Plot) | A: 산포가 작음 (데이터가 평균 주변에 밀집)<br>  <br> | B: 산포가 큼 (데이터가 넓게 퍼져 있음)<br>  <br> |

- ✓ 평균만으로는 데이터의 특성을 충분히 설명할 수 없음
- ✓ 산포를 함께 확인해야 데이터의 변동성과 안정성을 올바르게 이해할 수 있음

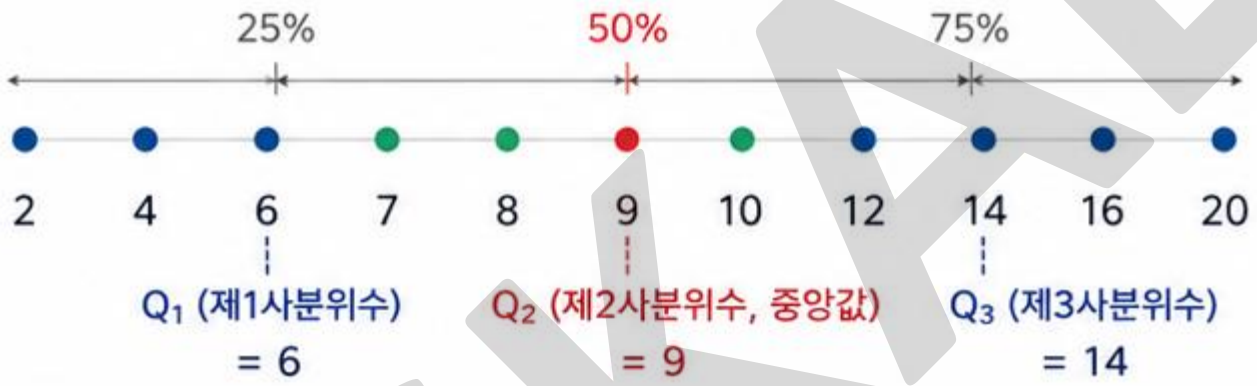
SKALA

# 퍼짐(Dispersion)

사분위수(Quartile)와 사분위수범위(IQR)

## 사분위수(Quartile)

- 데이터를 4등분하여 위치와 퍼짐을 함께 보는 지표
- 데이터를 크기순으로 정렬한 뒤 25%, 50%, 75% 지점의 값을 의미




- Q1( 제1사분위수) : 하위 25% 지점의 값
- Q3(제2사분위수) : 중앙값, 50% 지점의 값
- Q3(제3사분위수) : 하위 75% 지점의 값

### 사분위수(Quartile) 산출

- n이 홀수일 때는 중앙값을 제외하고 각각의 절반에서 사분위수 계산
- n이 짝수일 때는 중앙값이 가운데 두 값의 평균이 되며, Q1과 Q3도 각각 하위 절반과 상위 절반의 중앙값으로 계산

SKALA

# 퍼짐(Dispersion)

사분위수(Quartile)와 사분위수범위(IQR)

## 사분위수 범위(IQR)

- IQR은 Q3에서 Q1을 뺀 값으로, 데이터의 중앙 50%가 얼마나 퍼져 있는지를 나타냄
- IQR = Q3 - Q1




### When to Use

- 이상치(극단값)가 있는 데이터의 산포를 요약할 때
- 평균과 표준편차만으로 데이터 특성이 잘 설명되지 않을 때
- 박스플롯으로 데이터 분포를 시각화할 때 (탐색적 데이터 분석)

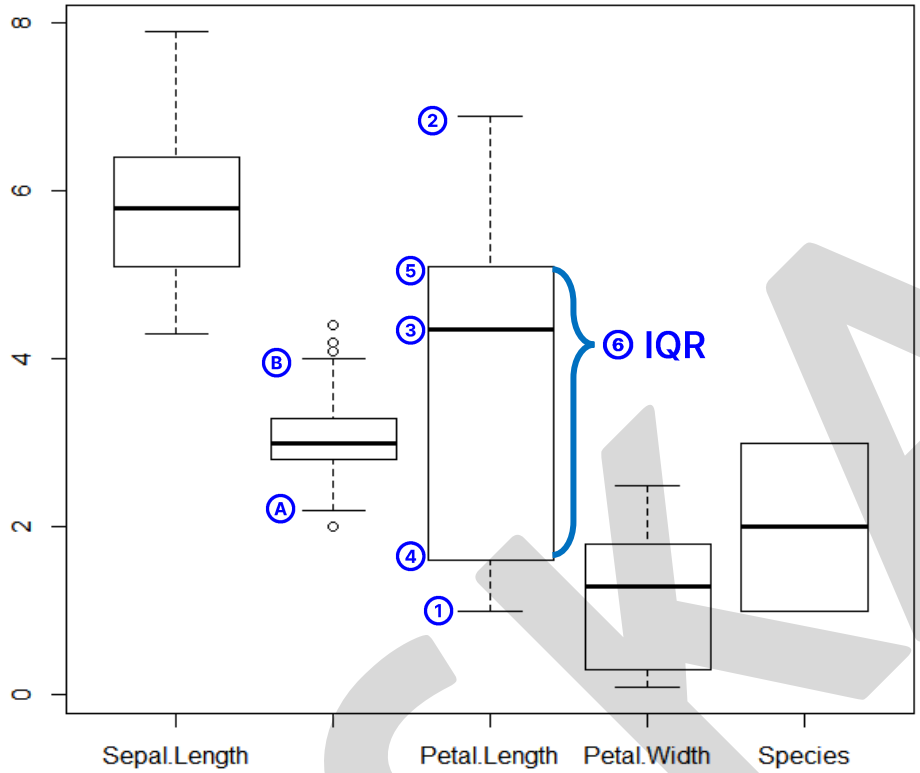
### Interpretation

- IQR이 클수록 중앙 50% 데이터의 퍼짐이 큼 → 변동성 큼
- IQR이 작을수록 중앙 50% 데이터가 촘촘하게 모여 있음 → 변동성 작음
- IQR은 이상치에 상대적으로 덜 민감한 강건한(Robust) 산포 지표

SKALA

# 퍼짐(Dispersion)

사분위수범위(IQR)




[legend]

① min (0%)

② max (100%)

③ median (50%)

④ 1st Quarter (25%)

⑤ 3rd Quarter (75%)

⑥ IQR. Inter-Quantile Range = 3rd Qu. – 1st Qu.

Ⓐ Lower whisker = 1Q – 1.5*IQR , min값이 더 크다면 대체

Ⓑ Upper whisker = 3Q + 1.5*IQR , max값이 더 작다면 대체

* whisker 안으로 min/max값이 들어오면 min/max값으로 대체

SKALA

# 퍼짐(Dispersion)

상대적인  퍼짐의 측정

**평균이 다를때 퍼짐(변동성)은 어떻게 비교할 것인가?**

$$CV = \frac{\sigma}{\mu} \times 100\%$$

- 표준편차를 통해 살펴보면 B공정의 퍼짐이 더 커 보임 → 더 불안정
- 하지만 평균이 다르다면?

| 공정 | 평균 | 표준편차 |
|---|---|---|
| A | 10 | 2 |
| B | 100 | 5 |

SKALA

# 퍼짐(Dispersion)

상대적인 퍼짐의 측정

## 변이계수(Coefficient of Variation, CV)

- 변이계수는 평균이 다른 데이터의 퍼짐(변동성)을 공정하게 비교하는 지표
- 평균이 다른 집단 데이터를 비교시 평균 대비 얼마나 퍼져있는지를 비교해야 함

$$CV = \frac{\sigma}{\mu} \times 100\%$$

| 공정 | 평균 | 표준편차 | 변이계수 |
|---|---|---|---|
| A | 10 | 2 | 20% |
| B | 100 | 5 | 5% |

## Interpretation

- CV가 작다 → 데이터가 비교적 일정
- CV가 크다 → 데이터의 퍼짐(변동성)이 큼
- 평균이 0에 가까우면 활용이 적절치 않음 ( 평균1, 표준편차 10 → 변이게수 1000%, 평균값에 지나치게 민감)
- 평균이 음수인 데이터에는 일반적으로 사용하지 않음 (계산불가)

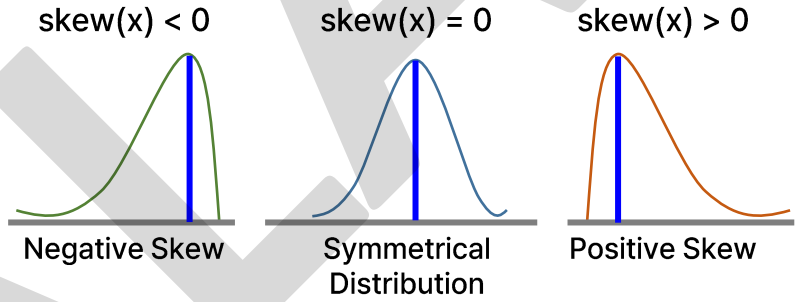
SKALA

# 분포형태(Distribution Shape)

왜도(skewness), 어느 방향으로 치우쳐 있는가?

## Concept

- 왜도는 데이터 분포의 비대칭 정도를 나타내는 통계량
- 왜도가 0에 가까울수록 좌우가 대칭인 분포를 의미
- 정규분포의 왜도는 0 (좌우대치)




## When to Use

- 데이터가 정규분포를 따르는지 확인할 때
- 평균과 중앙값의 차이를 해석할 때
- 모델 입력 데이터의 특성을 분석할 때

## Interpretation

- 왜도 = 0 → 대칭적인 분포
- 왜도 > 0 → 큰 값(이상치)이 오른쪽에 존재
- 왜도 < 0 → 작은 값이 왼쪽에 치우쳐 있음

SKALA

# 분포형태(Distribution Shape)

첨도(kurtosis), 평균 주변에 얼마나 집중되어 있는가?

## Concept

- 첨도는 분포의 뾰족함과 꼬리의 두꺼운 정도를 나타내는 통계량
- 꼬리(Tail)의 두꺼움을 설명하는 지표로도 활용

## When to Use

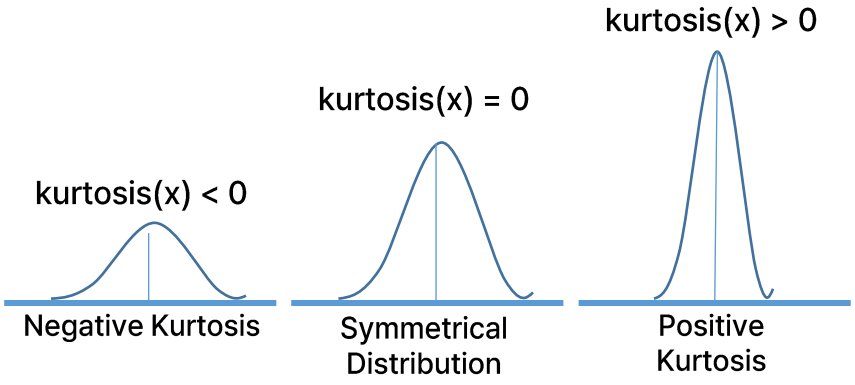
- 이상치 발생 가능성을 확인할 때
- 데이터의 안정성을 비교할 때
- 금융, 품질관리 등 데이터 분석에서 분포 특성을 파악할 때

## Interpretation

- 첨도가 높다 → 이상치 발생 가능성이 높음
- 첨도가 낮다 → 데이터가 비교적 고르게 분포
- 첨도는 분포의 꼬리 특성을 함께 고려해야 함 → 첨도는 "가운데가 뾰족한 정도"만 보는 지표가 아니라, "꼬리가 두꺼운 정도"까지 함께 보는 지표

## Note

- 정규분포의 첨도는 원래 수식상 3
- Kurtosis = $E[(X-\mu)^4] / \sigma^4$
- 초과첨도(Excess Kurtosis)는 비교의 편이를 위해 정규분포 기준값 3을 빼서 만든 값




SKALA

데이터 분석 개요 및 기초통계

# 추론 통계

- 모집단 vs 표본
- 표본 선정
- 정규분포
- 중심극한 정리

본 문서는 SK㈜AX의 컨텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

SK Inc. AX

# 추론 통계학이란?

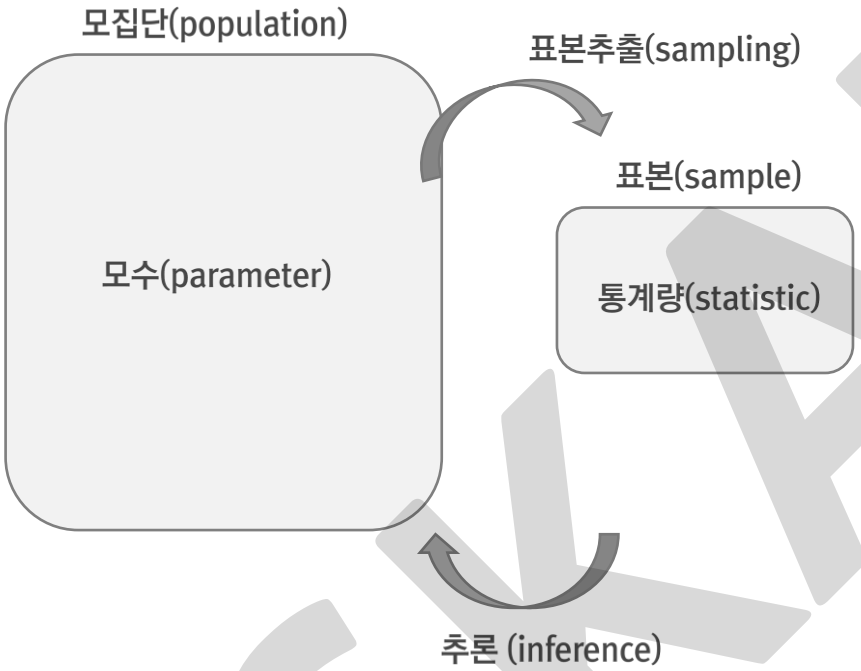
추론 통계학, Inferential Statistics

**Concept**

- 수집된 자료들을 바탕으로 알아내고자 했던 모집단에 대한 추정, 예측, 가설검정 등 결론을 도출하는 방법을 다루는 학문분야
- 수집된 자료를 통하여 원래 알아보고자 했던 문제에 대한 결론을 도출
- 통계학의 대부분의 내용들이 여기에 해당..

SKALA

# 모집단 vs 표본




- 모집단(population) : 확률변수X가 취할 수 있는 모든 값 혹은 대상으로 삼는 대상의 특성전체
- 모수(parameter) : 관심의 대상이 대는 특성

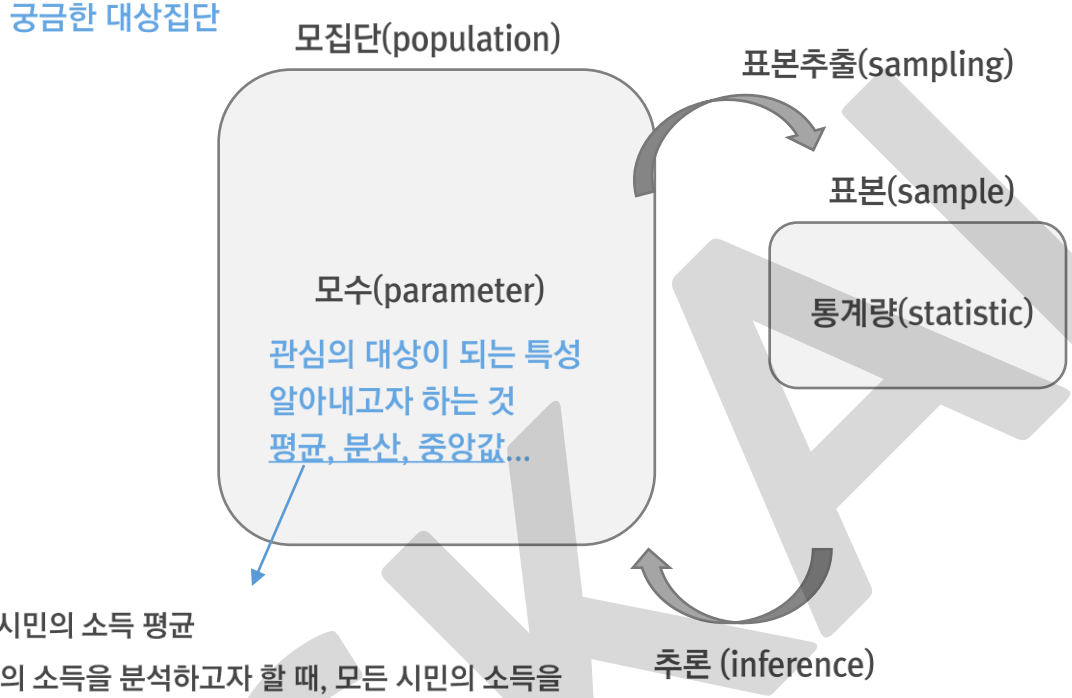
- 표본(sample) : 모집단의 부분 집합
- 통계량(statistics) : 표본을 대표하는 값

- 추론(inference) : 표본 데이터를 바탕으로 모집단에 대한 특성을 추정하는 과정

SKALA

# 모집단 vs 표본

물리적, 시간적, 경제적 제약으로 일부만을 조사하여 이로부터 전체의 특성에 대해 추론




- 왜 일부의 자료만을 분석할까? 전체에 대한 자료가 없기 때문
- 물리적,경제적 또는 시간적 제약으로 일일히 전체를 조사하지 못함

모집단을 다 조사하기 어려우니 일부를 조사
뽑힌 일부가 표본

표본을 통해 계산한 수치 (표본을 대표하는 값)
추정에 사용되면 '추정 통계량'
검정에 쓰이면 '검정 통계량'

- Ex) 서울 시민의 소득 평균
- 서울 시민의 소득을 분석하고자 할 때, 모든 시민의 소득을 수집/정리하는 것 만이 서울 시민의 소득 특성을 파악하는 것이 아님
- 서울 시민의 소득 평균을 추론하고, 흩어진 정도를 분산을 통해 파악하는 방향이 합리적이고 효과적

- 표본을 통해 계산한 통계량은 표본에 따라 달라짐, 실제 모집단의 참값과 차이가 있을 것
- 표본의 크기가 클수록 계산된 통계량은 모수에 근접할 것

SKALA

# 자료(Data)의 수집

통계학은 자료를 분석하는 학문

## Motivation

- 통계학은 표본의 자료를 수집, 정리, 요약하고 나아가 요약된 자료를 바탕으로 그 자료의 모태가 되는 모집단에 대해 짐작, 추론해보는 작업
- 분석 대상과 동떨어진 자료를 분석한다면, 통계학은 잘 위장된 거짓말이 될 수도 있음
- 어떤 자료가 제대로 된 자료인가? 어떤 점을 유의해서 살펴봐야 하는가?

## 실험 vs 관측, 자료를 얻는 2가지 방법

- 실험(Experiment) – 주로 자연과학,의학 분야로 연구자가 실험대상을 통제하기 용이
    - Ex) 신약의 효과를 시험, 새로운 교육 방법의 효과를 측정
- 관측(Observation) – 주로 인문,사회과학 분야로 많은 경우 실험이 불가능해 연구자는 관측을 통해 자료를 확보해야 함, 관측대상을 통제하기 어려움
    - Ex) 소득 수준과 소비패턴에 대한 연구, 도시화 수준과 범죄율의 영향 분석

SKALA

# 자료(Data)의 수집

통계학은 자료를 분석하는 학문

## 자료의 종류

### 횡단면 자료
Cross-sectional data

- 한 시점에서 여러 개체를 관측한 자료
- 한 시점에 대한 정보를 제공하며, 여러 개체를 비교하는데 활용
- Ex) 2024년 1월에 조사된 각 나라의 GDP
- Ex) 특정 시점의 회사별 연봉

### 시계열 자료
Time-series data

- 한 개체를 여러 시점에 걸쳐 관측한 자료
- 시간의 흐름에 따라 수집된 자료로써, 변화패턴을 추적하거나 예측할 때 활용
- Ex) 24.1.1~24.12.31의 일별 기온변화
- Ex) 주식시장의 일별 주가

### 패널 자료
panel data

- 횡단면과 시계열의 특성을 결합하여 여러 개체를 여러 시점에 걸쳐 관측한 자료
- 개체간 차이와 시간적 변화를 동시에 분석
- Ex) A학교 학생들의 학년별 성적 내역
- Ex) 최근 10개년 각 나라의 경제 지표

SKALA

# 표본 선정

표본 선정은 연구 결과의 정확성, 신뢰성, 일반화 가능성에 직접적인 영향을 주는 과정

## 대표성, Representativeness

- 표본은 모집단을 대표할 수 있어야 함. 모집단과 표본이 다르면, 표본을 통해 얻은 결론이 모집단에 그대로 적용되지 않을 수 있음.
- 표본의 구성이 모집단과 비슷해야만 일반화 가능한 결과를 도출할 수 있음

SKALA

# 표본 선정

표본 선정은 연구 결과의 정확성, 신뢰성, 일반화 가능성에 직접적인 영향을 주는 과정

Case Study

- 1936년 미국 대통령 선거, Franklin D. Roosevelt(민주당) vs Alf Landon(공화당)
- 다이제스트 사는 당시 가장 큰 여론조사 기관이었고, 다이제스트사의 루즈벨트 득표율 예측은 43%, 경쟁사였던 갤럽의 예측은 56%
- 결과는 갤럽의 일방적 승리, 심지어 다이제스트사의 예측값에 대한 예측을 44%로 함

어떤 연유일까?

[다이제스트사의 실수]

- 다이제스트 사는 우편 조사 방식으로 여론 조사를 실시함
- 그들은 대규모 전화번호부, 자동차 등록부에서 주로 표본을 추출
- 그러나 이 표본은 특정 계층(부유하고 교육받은 사람들)만을 반영하였기 때문에, 대중의 전반적인 의견을 정확하게 반영하지 않음
- 여론 조사 역사에서 가장 유명한 실수 중 하나

SKALA

# 표본 선정

표본 선정은 연구 결과의 정확성, 신뢰성, 일반화 가능성에 직접적인 영향을 주는 과정

## 편향, Bias

- 표본 선정 과정에서 편향이 발생하지 않도록 주의해야 함.
- 특정 집단이 과도하게 포함되거나, 특정 특성이 과소 대표될 경우 결과가 왜곡될 수 있음

- 선택 편향(Selection Bias): 표본을 선정하는 과정에서 특정 집단이 과대 대표되거나 과소 대표되는 경우.
- 응답 편향(Response Bias): 설문조사나 실험에서 응답자의 성향이나 선택에 의해 결과가 왜곡되는 경우.

**Case Study**

지난 20년 동안의 특정 섹터에서의 주식 성과를 연구하는 상황

→ 20년 전으로 돌아가서 기업들을 선정 해야함

→ 살아있는 기업은 죽은 기업을 대표하지 못한다, 생존 편향(Survivorship bias)

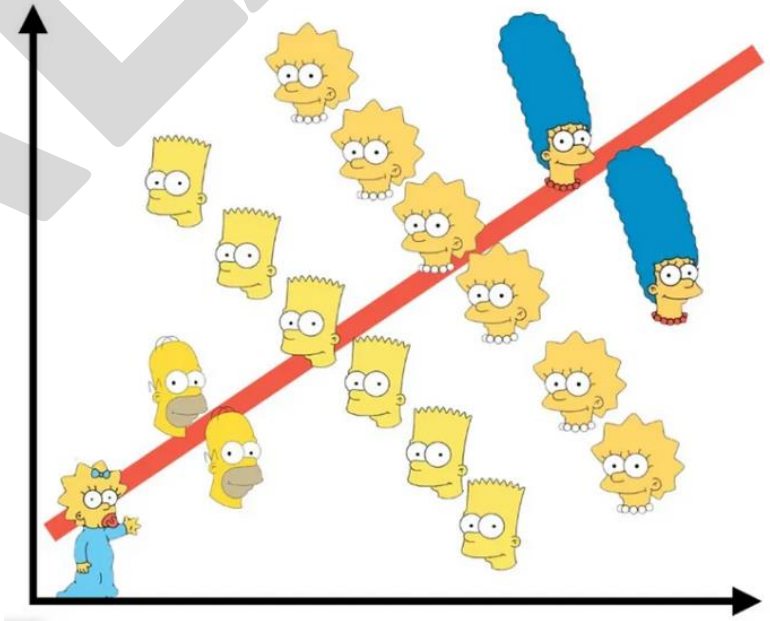
SKALA

# 표본 선정

표본 선정은 연구 결과의 정확성, 신뢰성, 일반화 가능성에 직접적인 영향을 주는 과정

## Simpson's paradox (심슨의 역설)

- 여러 그룹의 자료를 합했을 때의 결과와 각 그룹을 구분했을 때의 결과가 다른 때를 의미
- 부분을 단순히 합친 것 뿐인데 그 결과가 각 부분을 비교했을 때의 결과와 달라지는 것은 일방적인 상식으로 이해가 되지 않으므로 '역설' 이라 불림
- 표본 선정 과정 뿐 아니라 변수간 관계 분석 등에서도 유의해야할 개념

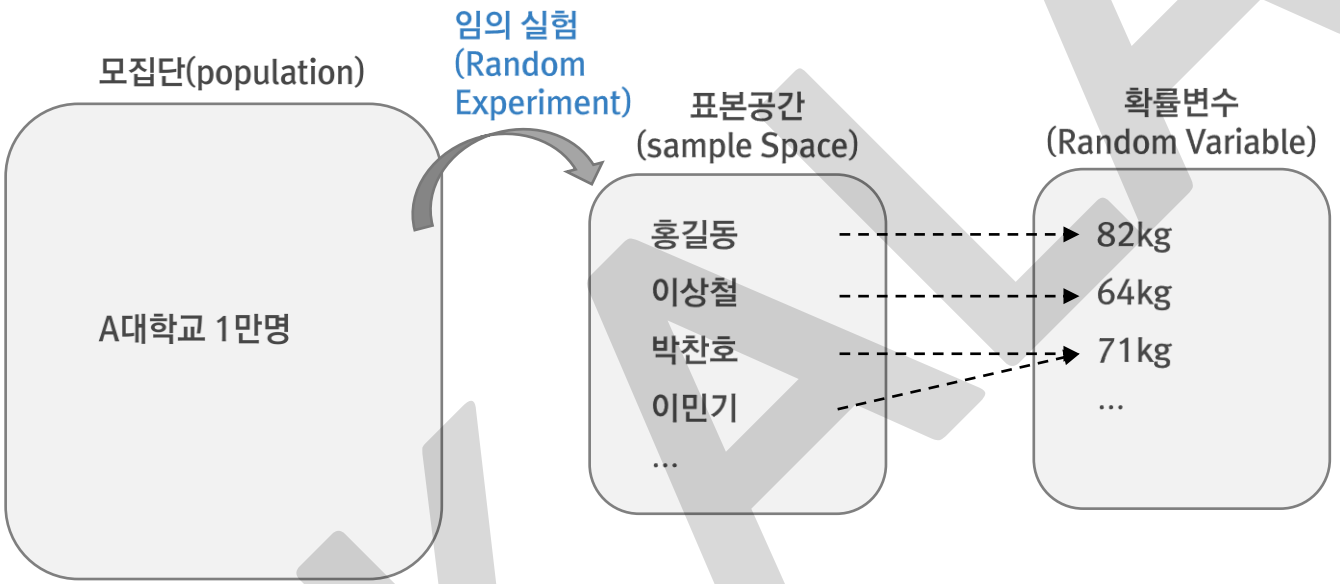


SKALA

# 확률변수(Random Variable)

사전적 분포(Distribution)하에, 사후적으로 데이터를 집어넣으면 Distribution상에서 하나의 숫자로 확정이 되는 값

A대학교의 학생들 몸무게는 어떤 특성을 가지는가?




각 학생의 측정된 몸무게는 다르게 나타날 것 → 확률 변수

확률변수는 어떤 실험이나 사건에서 나올 수 있는, 즉 임의(무작위)로 결정되는 결과를 수치로 나타내는 변수

또 특별히 특정 범위에 모여 있다고 추론해 볼 수 있을 것 → **분포**를 가지고 있음

SKALA

# 확률변수(Random Variable)

사전적 분포(Distribution)하에, 사후적으로 데이터를 집어넣으면 Distribution상에서 하나의 숫자로 확정이 되는 값

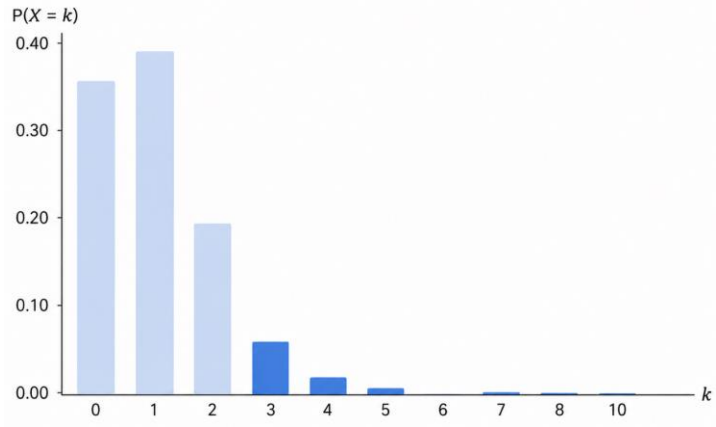
**왜 필요할까?**

**Case**

불량률이 10%인 공정에서 임의로 10개의 제품을 뽑아 검사할 때, 이 가운데 불량품이 3개 이상일 확률은 얼마인가?

→ 모든 경우의 수를 따져서 확률을 구하는 것이 쉽지 않음

- 표본 공간에서 어떤 사건의 확률을 구하는 것이 매우 복잡하거나 어려울 때가 있음
- 이때 표본공간에서 사건을 실제값으로 사상시키고, 사건의 확률을 실제값 위에서 정의된 분포함수를 통해서 구할 수 있음
- 확률변수는 현실 문제에 확률론을 적용하여 불확실성을 수치로 모델링 할 수 있게 함

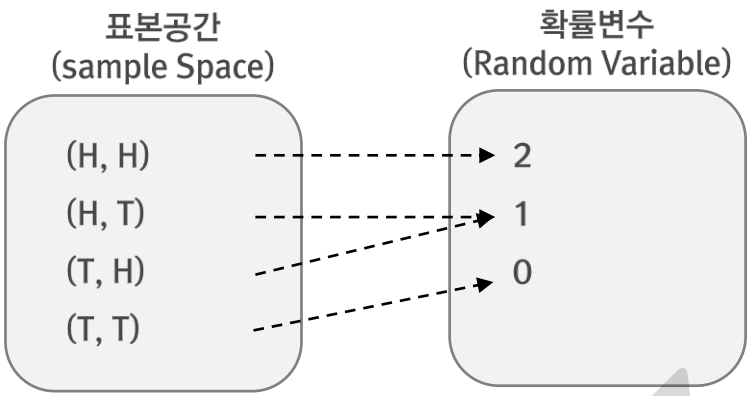



SKALA

# 이산형 확률변수와 PMF

셀 수 있는(Countable) 값에 대한 확률 함수

동전을 2번 던졌을때, 앞면이 나오는 횟수 = X




| x | 0 | 1 | 2 |
|---|---|---|---|
| f(x)=P[X=x] | 1/4 | 1/2 | 1/4 |

- 표본공간에서 정의된 실수함수, 즉 앞면의 개수 X를 확률변수라 할 수 있음
- 확률변수는 흔히 대문자로 나타내며, 확률변수가 취하는 값들은 소문자로 나타냄
- f(x)는 확률변수 X의 확률을 나타내는 함수
- 우리는 X의 값에 대한 확률을 나타내는 f(x)에 관심이 많음

**이산형(Discrete) 확률변수**

- 확률변수X가 취할 수 있는 값들이 유한개 이거나 셀 수 있는 경우
- 자연수 1,2,3.. 과 대응관계를 부여할 수 있는 것

**확률질량함수(PMF: Probability Mass Function)**

- 이산확률변수 X가 x의 값을 취할 확률을 나타내는 함수 (분포함수)
- Ex) 동전 던지기, 주사위 던지기
- f(x)=P[X=x]

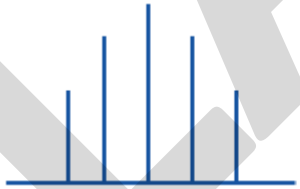
SKALA

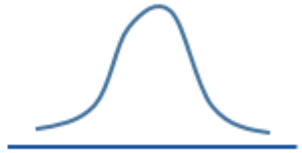
# 연속형 변수에서의 확률은?

연속형 변수에서 확률을 구하기 위한 아이디어, 확률밀도

## 연속형(Continuous) 확률변수

- 확률변수X가 취할 수 있는 값들이 무한개인 경우
- 값이 연속적인 구간(실수 범위)에서 나올 수 있는 확률변수
- Ex) 사람의 키, 온도..

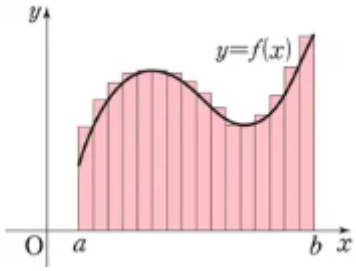




## 확률밀도함수(PDF: Probability Density Function)

- 특정 값 하나가 나올 확률은 0 → 확률을 어떻게 구할까?
- 구간 단위로 확률을 계산한다면?
- 연속값들은 확률을 질량으로 나누는 개념

$$P(a \leq X \leq b) = \int_a^b f(x)\,dx$$




SKALA

# 데이터 분포 요약, 히스토그램

히스토그램을 그리기 위해 필요한 도수 분포표

## 도수 분포표(Frequency table)

- 자료의 분포를 몇 개의 구간으로 나누고, 나누어진 각 구간에 속하는 자료가 몇 개인지 정리한 표
- 구간을 나누면 개별적인 데이터를 보는 것보다 데이터의 전체적인 분포(모양)를 요약해서 볼 수 있기 때문

<대학교 남학생의 신장 데이터, 단위:cm>

| | | | | | | | | | | |
|---|---|---|---|---|---|---|---|---|---|---|
| 170 | 178 | 171 | 168 | 173 | 178 | 171 | 174 | 170 | 170 | 175 |
| 170 | 169 | 166 | 162 | 170 | 171 | 175 | 175 | 171 | 171 | 170 |
| 172 | 179 | 164 | 170 | 181 | 178 | 180 | 177 | 166 | 169 | 168 |
| 165 | 163 | 175 | 166 | 178 | 165 | 168 | 167 | 177 | 168 | 177 |
| 174 | 174 | 176 | 179 | 169 | 173 | 167 | 170 | 173 | 170 | 162 |

## Workflow

(1) 자료의 개수 산출 → 55개

(2) 최대/최소값 산출 → 162~180

(3) 몇 개 구간으로 나눌지 결정 → 5개

(4) 계급구간의 폭 산출 → (180-162)/5 = 3.6 (반올림하여 4)

(5) 각 계급구간의 경계값 산출

(6) 구간별 자료의 개수(도수)를 기입

<대학교 남학생의 도수분포표>

| 계급구간(cm) | 도수 |
|---|---|
| 161.5 이상 165.5 미만 | 6 |
| 165.5 이상 169.5 미만 | 12 |
| 169.5 이상 173.5 미만 | 18 |
| 173.5 이상 177.5 미만 | 11 |
| 177.5 이상 181.5 미만 | 8 |
| 합계 | 55 |

- 구간수가 5개여서 쉽게 데이터 분포를 파악할 수 있지만, 구간수가 10개, 20개..라면?

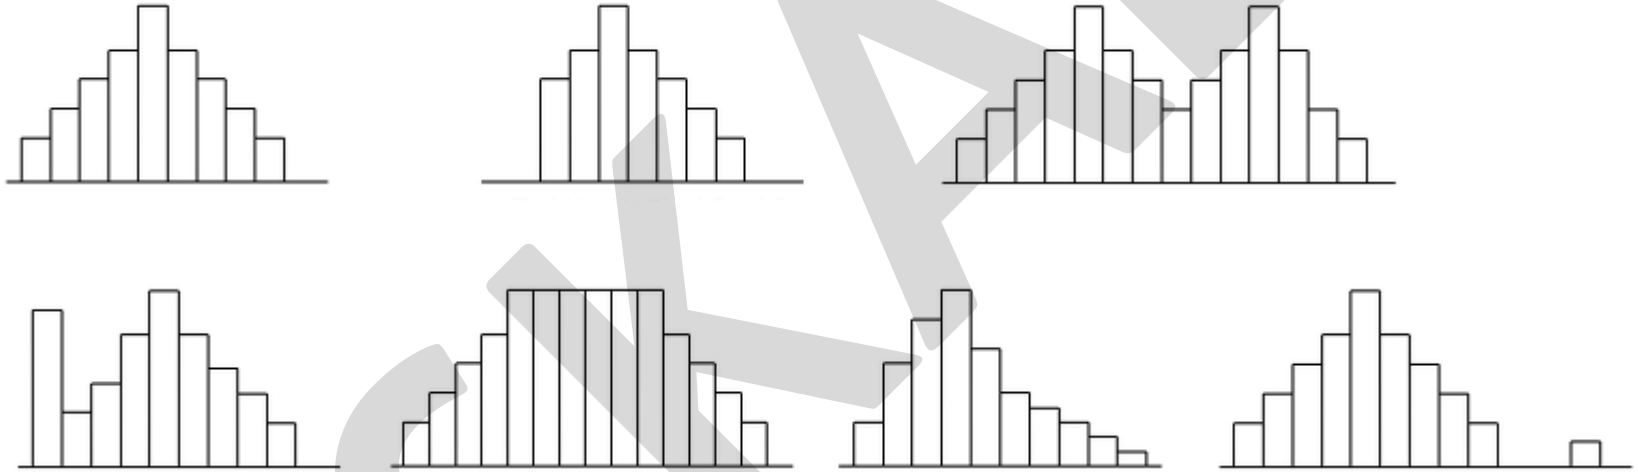
SKALA

# 데이터 분포 요약, 히스토그램

히스토그램을 그리기 위해 필요한 도수 분포표

## 히스토그램(Histogram)

- 도수 분포표를 시각적으로 표현한 막대 그래프
- 데이터가 어떤 범위에 집중되어 있는지, 어떤 구간에 값들이 분포하는지를 쉽게 파악할 수 있음
- X축은 데이터 값이나 구간, Y축은 빈도(해당 구간에 포함된 데이터의 개수)나 비율로 나타낼 수 있음



SKALA

# 정규분포, Normal Distribution

이상적인 히스토그램, 하나의 수학적 모형, 개념상 모집단의 분포

## Definition

- 통계학에서 가장 널리 쓰이는 확률분포 중 하나로 데이터가 평균을 중심으로 좌우 대칭으로 분포하는 확률분포
- 가우시안 분포(Gaussian distribution)라고도 함

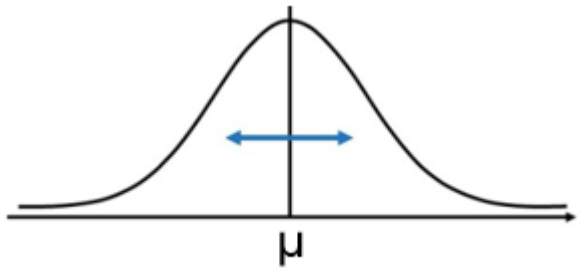
$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

- μ: 모집단의 평균
- σ: 모집단의 표준편차
- $\sigma^2$ : 분산, 표준편차의 제곱
- e: 자연 상수 (약 2.71828), 지수 함수의 밑

## 특징

- 봉우리가 하나 (single-peaked)
- 종 모양의 곡선 (bell-shaped)
- 평균을 중심으로 좌우 대칭 (평균값 = 중앙값 = 최빈값) (symmetric)
- 곡선 아래 면적은 1 (전체확률 1)

$N(\mu, \sigma^2)$ μ: 평균 σ: 표준편차




SKALA

# 표준정규분포, Standard Normal Distribution

확률 계산을 용이하게 하고, 다른 정규 분포간 비교 가능성을 확보

$$f(z) = \frac{1}{\sqrt{2\pi}} e^{-\frac{z^2}{2}}$$

## Definition

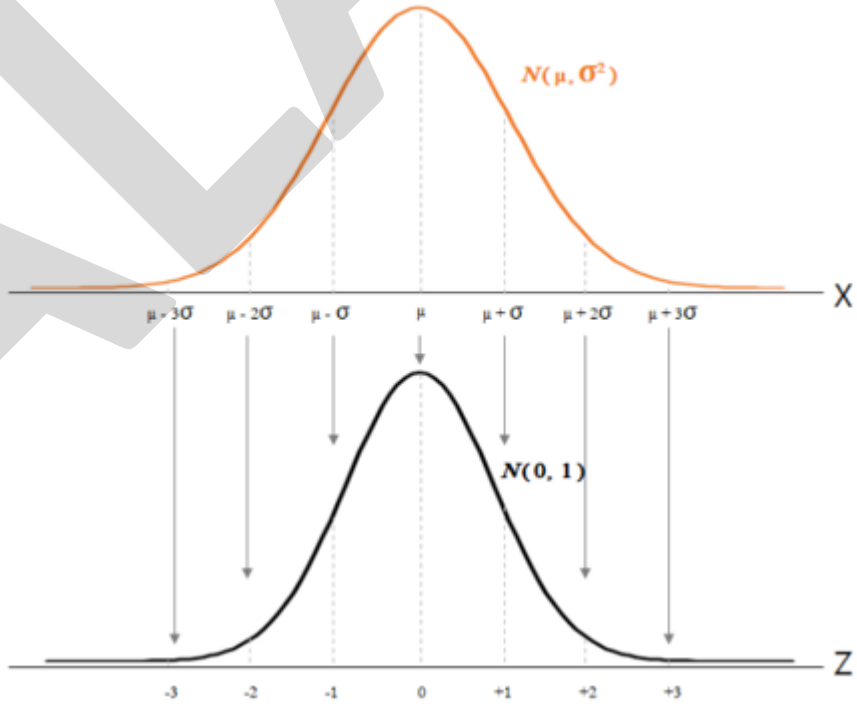
- 평균이 0이고, 표준편차가 1인 정규분포
- 다른 정규분포의 값을 표준화하여, 해당 값의 확률을 쉽게 구할 수 있음
- 통계적 추정 및 가설 검정에서 중요한 역할을 함

## Z-Score 변환

- 표준화된 값(z-score)를 통해 다른 정규분포를 변환
- 각 관측치에서 평균을 빼고 편차로 나누어 줌

$$z = \frac{x - \mu}{\sigma}$$

- x: 모집단의 원본 값
- μ: 모집단의 평균
- σ: 모집단의 표준편차




SKALA

# 68-95-99.7의 법칙

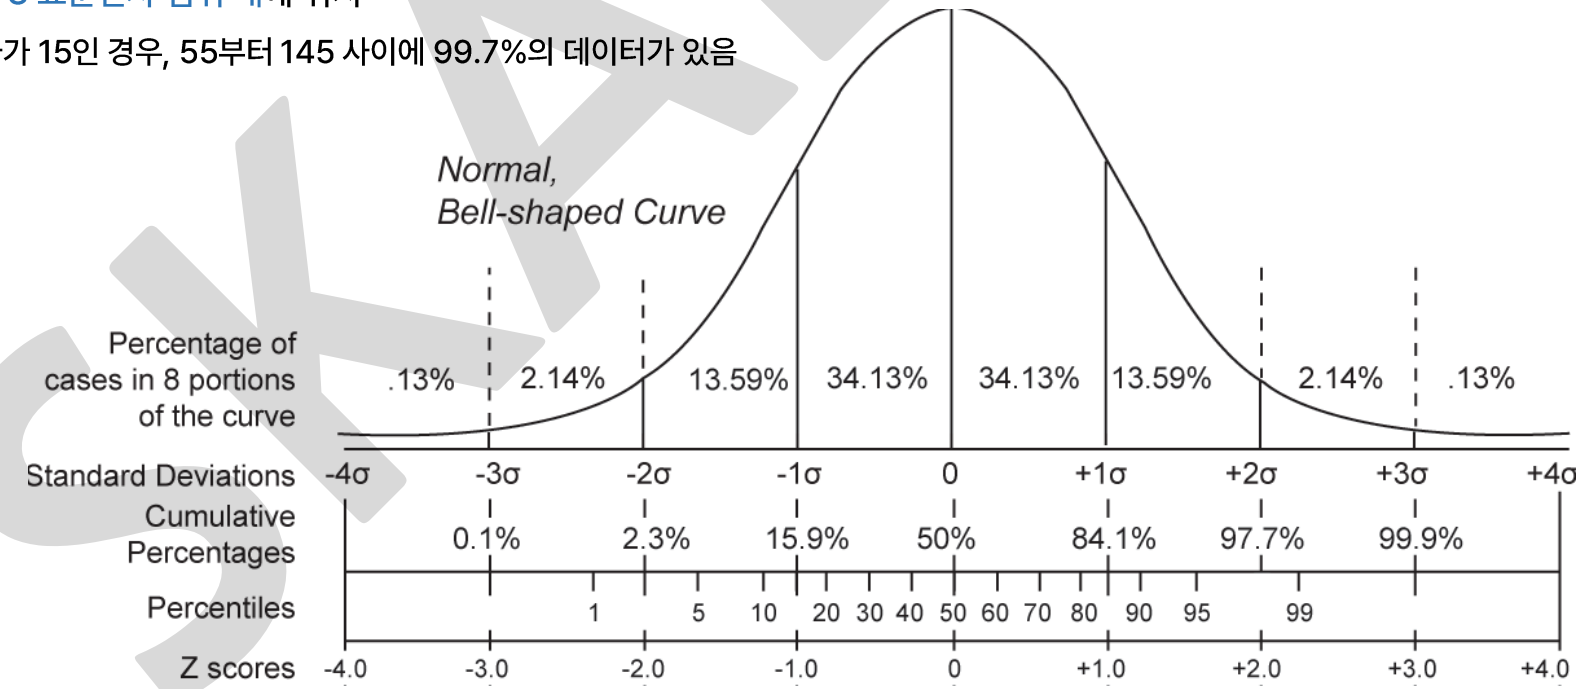
정규분포下 손쉬운 확률값 도출

## Interpretation

- 68%의 데이터는 평균 ± 1 표준편차 범위 내에 위치
- Ex) 평균이 100이고 표준편차가 15인 경우, 85부터 115 사이에 68%의 데이터가 있음
- 95%의 데이터는 평균 ± 2 표준편차 범위 내에 위치
- Ex) 평균이 100이고 표준편차가 15인 경우, 70부터 130 사이에 95%의 데이터가 있음
- 99.7%의 데이터는 평균 ± 3 표준편차 범위 내에 위치
- Ex)평균이 100이고 표준편차가 15인 경우, 55부터 145 사이에 99.7%의 데이터가 있음

## Z-Score로 변환했다면..

- 68-95-99.7 법칙 해석이 용이 해짐
- 68%의 데이터가 Z-Score ± 1 범위 내에 위치
- 95%의 데이터가 Z-Score ± 2 범위 내에 위치
- 99.7%의 데이터가 Z-Score ± 3 범위 내에 위치




SKALA

# 표준정규분포표

특정 z-점수에 대한 누적 확률을 보여주는 표

## Application

- 표에서의 z-점수는 보통 소수 첫째 자리와 둘째 자리를 기준으로 나누어져 있음
- Z = 1.23일 때, 표준정규분포표에서 z = 1.2와 0.03의 교차점에서 찾은 값은 0.8907
- 이는 P(Z ≤ 1.23) = 0.8907을 의미
- 즉, z-점수 1.23 이하의 값이 나올 확률은 약 89.07%

## (-) Z-score 는 어떻게 취급할까?

- 대칭적이기 때문에, 음의 z-점수에 대한 확률은 양의 z-점수를 사용한 값을 활용할 수 있음
- 대칭되는 양의 z-점수의 확률을 찾아낸 다음 1에서 그 확률을 빼는 방식

### Standard Normal Cumulative Probability Table




Cumulative probabilities for POSITIVE z-values are shown in the following table:

| z | 0.00 | 0.01 | 0.02 | 0.03 | 0.04 | 0.05 | 0.06 | 0.07 | 0.08 | 0.09 |
|---|---|---|---|---|---|---|---|---|---|---|
| 0.0 | 0.5000 | 0.5040 | 0.5080 | 0.5120 | 0.5160 | 0.5199 | 0.5239 | 0.5279 | 0.5319 | 0.5359 |
| 0.1 | 0.5398 | 0.5438 | 0.5478 | 0.5517 | 0.5557 | 0.5596 | 0.5636 | 0.5675 | 0.5714 | 0.5753 |
| 0.2 | 0.5793 | 0.5832 | 0.5871 | 0.5910 | 0.5948 | 0.5987 | 0.6026 | 0.6064 | 0.6103 | 0.6141 |
| 0.3 | 0.6179 | 0.6217 | 0.6255 | 0.6293 | 0.6331 | 0.6368 | 0.6406 | 0.6443 | 0.6480 | 0.6517 |
| 0.4 | 0.6554 | 0.6591 | 0.6628 | 0.6664 | 0.6700 | 0.6736 | 0.6772 | 0.6808 | 0.6844 | 0.6879 |
| 0.5 | 0.6915 | 0.6950 | 0.6985 | 0.7019 | 0.7054 | 0.7088 | 0.7123 | 0.7157 | 0.7190 | 0.7224 |
| 0.6 | 0.7257 | 0.7291 | 0.7324 | 0.7357 | 0.7389 | 0.7422 | 0.7454 | 0.7486 | 0.7517 | 0.7549 |
| 0.7 | 0.7580 | 0.7611 | 0.7642 | 0.7673 | 0.7704 | 0.7734 | 0.7764 | 0.7794 | 0.7823 | 0.7852 |
| 0.8 | 0.7881 | 0.7910 | 0.7939 | 0.7967 | 0.7995 | 0.8023 | 0.8051 | 0.8078 | 0.8106 | 0.8133 |
| 0.9 | 0.8159 | 0.8186 | 0.8212 | 0.8238 | 0.8264 | 0.8289 | 0.8315 | 0.8340 | 0.8365 | 0.8389 |
| 1.0 | 0.8413 | 0.8438 | 0.8461 | 0.8485 | 0.8508 | 0.8531 | 0.8554 | 0.8577 | 0.8599 | 0.8621 |
| 1.1 | 0.8643 | 0.8665 | 0.8686 | 0.8708 | 0.8729 | 0.8749 | 0.8770 | 0.8790 | 0.8810 | 0.8830 |
| 1.2 | 0.8849 | 0.8869 | 0.8888 | 0.8907 | 0.8925 | 0.8944 | 0.8962 | 0.8980 | 0.8997 | 0.9015 |
| 1.3 | 0.9032 | 0.9049 | 0.9066 | 0.9082 | 0.9099 | 0.9115 | 0.9131 | 0.9147 | 0.9162 | 0.9177 |
| 1.4 | 0.9192 | 0.9207 | 0.9222 | 0.9236 | 0.9251 | 0.9265 | 0.9279 | 0.9292 | 0.9306 | 0.9319 |
| 1.5 | 0.9332 | 0.9345 | 0.9357 | 0.9370 | 0.9382 | 0.9394 | 0.9406 | 0.9418 | 0.9429 | 0.9441 |
| 1.6 | 0.9452 | 0.9463 | 0.9474 | 0.9484 | 0.9495 | 0.9505 | 0.9515 | 0.9525 | 0.9535 | 0.9545 |
| 1.7 | 0.9554 | 0.9564 | 0.9573 | 0.9582 | 0.9591 | 0.9599 | 0.9608 | 0.9616 | 0.9625 | 0.9633 |
| 1.8 | 0.9641 | 0.9649 | 0.9656 | 0.9664 | 0.9671 | 0.9678 | 0.9686 | 0.9693 | 0.9699 | 0.9706 |
| 1.9 | 0.9713 | 0.9719 | 0.9726 | 0.9732 | 0.9738 | 0.9744 | 0.9750 | 0.9756 | 0.9761 | 0.9767 |
| 2.0 | 0.9772 | 0.9778 | 0.9783 | 0.9788 | 0.9793 | 0.9798 | 0.9803 | 0.9808 | 0.9812 | 0.9817 |
| 2.1 | 0.9821 | 0.9826 | 0.9830 | 0.9834 | 0.9838 | 0.9842 | 0.9846 | 0.9850 | 0.9854 | 0.9857 |
| 2.2 | 0.9861 | 0.9864 | 0.9868 | 0.9871 | 0.9875 | 0.9878 | 0.9881 | 0.9884 | 0.9887 | 0.9890 |
| 2.3 | 0.9893 | 0.9896 | 0.9898 | 0.9901 | 0.9904 | 0.9906 | 0.9909 | 0.9911 | 0.9913 | 0.9916 |
| 2.4 | 0.9918 | 0.9920 | 0.9922 | 0.9925 | 0.9927 | 0.9929 | 0.9931 | 0.9932 | 0.9934 | 0.9936 |
| 2.5 | 0.9938 | 0.9940 | 0.9941 | 0.9943 | 0.9945 | 0.9946 | 0.9948 | 0.9949 | 0.9951 | 0.9952 |
| 2.6 | 0.9953 | 0.9955 | 0.9956 | 0.9957 | 0.9959 | 0.9960 | 0.9961 | 0.9962 | 0.9963 | 0.9964 |
| 2.7 | 0.9965 | 0.9966 | 0.9967 | 0.9968 | 0.9969 | 0.9970 | 0.9971 | 0.9972 | 0.9973 | 0.9974 |
| 2.8 | 0.9974 | 0.9975 | 0.9976 | 0.9977 | 0.9977 | 0.9978 | 0.9979 | 0.9979 | 0.9980 | 0.9981 |
| 2.9 | 0.9981 | 0.9982 | 0.9982 | 0.9983 | 0.9984 | 0.9984 | 0.9985 | 0.9985 | 0.9986 | 0.9986 |
| 3.0 | 0.9987 | 0.9987 | 0.9987 | 0.9988 | 0.9988 | 0.9989 | 0.9989 | 0.9989 | 0.9990 | 0.9990 |
| 3.1 | 0.9990 | 0.9991 | 0.9991 | 0.9991 | 0.9992 | 0.9992 | 0.9992 | 0.9992 | 0.9993 | 0.9993 |
| 3.2 | 0.9993 | 0.9993 | 0.9994 | 0.9994 | 0.9994 | 0.9994 | 0.9994 | 0.9995 | 0.9995 | 0.9995 |
| 3.3 | 0.9995 | 0.9995 | 0.9995 | 0.9996 | 0.9996 | 0.9996 | 0.9996 | 0.9996 | 0.9996 | 0.9997 |
| 3.4 | 0.9997 | 0.9997 | 0.9997 | 0.9997 | 0.9997 | 0.9997 | 0.9997 | 0.9997 | 0.9997 | 0.9998 |

SKALA

# Practice

표준정규분포 응용 확률 문제

수학과 영어 과목의 시험 점수는 각각 정규분포를 따르고, 두 과목의 평균과 표준편차는 다음과 같습니다.

- 수학 : 평균 = 75, 표준편차 =10
- 영어 : 평균 = 70, 표준편차 = 8

철수는 수학과 영어점수 모두 80점을 받았습니다. 어느 과목 성적이 더 좋은가요?

SKALA

# 기대값, Expected Value

확률분포에서 평균을 나타내는 개념(대표값), 무작위 실험을 반복했을 때 평균적으로 취할 수 있는 값은?

## Definition

- 확률변수(Random Variable)가 가질 수 있는 평균적 값을 의미
- 하나의 확률 과정에 의해 결정되는 숫자는 하나의 값 주위로 분포. 이때 기대값은 분포의 무게 중심에 해당되는 값
- 확률 변수의 각 가능한 값에 그 값이 나올 확률을 곱한 후, 그 값을 모두 더한 것
- 기대값은 특히 임의 실험이나 불확실한 상황에서, 평균적으로 어떤 결과가 나올까? 에 대한 개념, 예측의 도구

## Example

- 동전을 던지면 앞면과 뒷면이 나올 확률은 반반, 즉 기대값은 0.5
- 동전던지기를 6회 했을 때, 앞면이 나온 횟수의 기대값은? 0.5 * 6 = 3

SKALA

# 표준오차, Standard Error

블확실성(Uncertainty)은 측정될 수 있는가?

**Definition**

- 실현된 값이 기대값과 차이가 나는 정도
- 하나의 확률 과정에 의해 결정되는 숫자는 기대값 주위로 분포하며, 그 값은 기대값+표준오차의 차이를 가짐
- 표본 평균이 모집단 평균을 얼마나 정확하게 추정하는지를 나타내는 지표

**표준편차와는 무엇이 다를까?**

- 표준편차는 각 데이터가 평균과 얼마나 차이를 가지느냐 의 개념
- 표준오차는 여러 표본들로부터 얻은 표본 통계량의 변량

SKALA

# 표준오차, Standard Error

블확실성(Uncertainty)은 측정될 수 있는가?

**Experiment**

동전 던지기 100회 시행하여 앞면이 나온 횟수를 측정하는 실험을 진행하자.
100회 시행하여 앞면이 나온 횟수는 얼마인가?

- 1번의 시행에 앞면이 나올 기대값(평균)은 0.5
- 100회 시행의 기대값 (합의 기대값) = 평균 * 시행횟수(sample count) = 0.5* 100 = 50

- 1번의 시행의 표준편차는 0.5
- 100회 시행의 표준오차는 0.5 * 100 = 50 , 맞을까?

SKALA

# 제곱근의 법칙, Square Root Law

샘플의 수가 늘어날수록 모평균에 가까워지는데, 그렇다면 표본오차는?

## Definition

- 표준오차는 여러 표본들로부터 얻은 표본 통계량의 변량으로 표본 평균이 모집단 평균을 얼마나 잘 추정하는지를 나타냄

$$SE = \frac{s}{\sqrt{n}}$$

- s: 표본 표준편차
- n: 표본 크기

## Think

- 표본의 합의 표준오차는 샘플의 수(n)에 비례해서 늘어날까?
- No! 제곱근n에 비례해서 늘어남
- 즉, 표본평균의 표준오차는 샘플의 수가 증가하는 만큼 비례해서 감소하지 않고 체감함

| n | Sqrt(n) |
|---|---|
| 1 | 1 |
| 4 | 2 |
| 9 | 3 |
| 16 | 4 |
| .. | .. |

SKALA

# 표준오차와 구간추정

블확실성(Uncertainty)은 측정될 수 있는가?

## 표준오차를 살펴보는 이유

- 표본을 통해서 추정이나 모델을 하기 때문에 어떤 표본을 뽑느냐에 따라 결과가 달라질 수 있음. 즉, 표본의 변동성(표준오차)가 관심사
- 표준오차는 표본 평균이 모집단 평균을 얼마나 잘 추정하는지를 나타냄
- 편향(Bias)가 없더라도 확률오차 때문에 추정치는 참값과 다름
- 확률오차들의 전형적인 크기

## 68-95-99.7법칙과 만나면..

- 동전던지기 100회 시행하여 앞면이 나올 횟수 실험에서
- 평균은 50, 표준오차는 5
- 합의 관측치가 40 ~ 60 구간에 속할 확률은 95%로 짐작할 수 있음
- 표본의 크기가 커지면 신뢰구간은 어떻게 될까?

SKALA

# 확률적 분포와 경험적 분포가 만날 때

**Experiment**

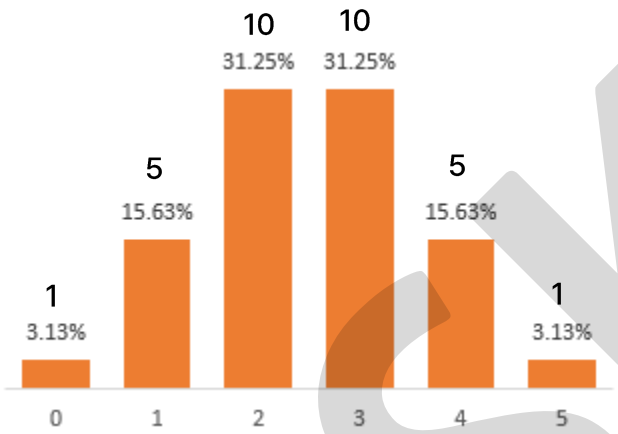
동전을 다섯번 던져서 앞면이 몇 번 나오는가?

→ 동전을 다섯번 던져서 앞면이 나온 횟수를 기록하는 것이 한번의 실험(시행)

→ 경우의 수는 $2^5 = 32$

→ {0,0,0,0,0}, {1,0,0,0,0}, {0,1,0,0,0},{1,1,0,0,0},{1,1,1,0,0}...

<앞면이 나온 횟수의 이론적 히스토그램>




**확률(이론)적 분포**

- 이론적 확률분포로 나타낸 앞면이 나온 횟수의 분포를 "이론적 히스토그램" 또는 "확률적 히스토그램" 이라 함

**경험적(Empirical) 분포**

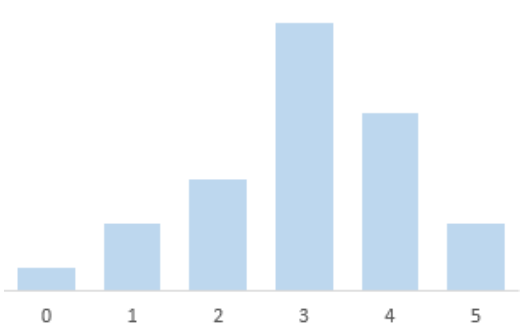
- 실험을 n번 반복하여 기록하여 얻은 분포
- "지금 32번의 실험을 진행하면 이론적 분포와 똑같은 분포를 얻을까?"

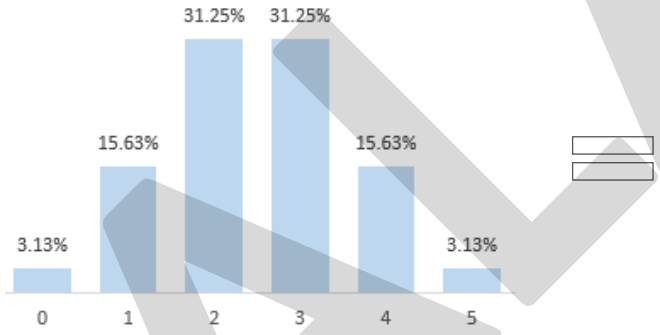
SKALA

# 확률적 분포와 경험적 분포가 만날 때

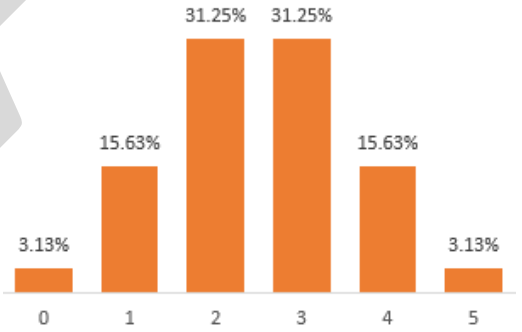
대수의 법칙의 함의

실험횟수(n)를 증가할수록..




경험적 히스토그램은 확률(이론적)히스토그램에 수렴




**대수의 법칙 (Law of Large Numbers)**

- 시행횟수가 늘어날수록, 표본 평균이 모집단 평균에 더 정확하게 근접한다는 개념
- Ex) 동전을 던지는 실험을 100번, 1,000번, 10,000번.. 반복할 경우, 그 결과로 얻은 평균 값은 0.5(앞면이 나올 확률)에 수렴하게 됨.
- “평균의 법칙 " 으로도 불림

SKALA

# 중심극한정리, CLT: Central Limit Theorem

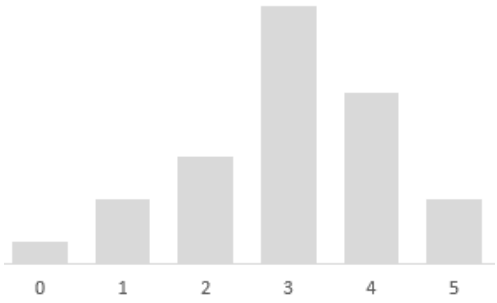
표본의 크기가 커지면 무슨 일이 일어날까?

**Experiment**

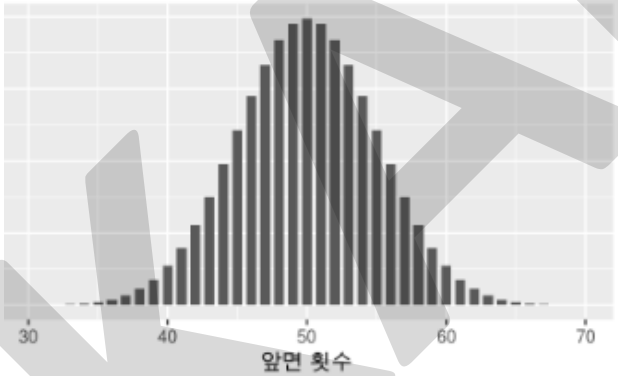
동전을 5번, 10번, 100번, 500번.. 던지는 횟수를 늘려갈 때, 앞면이 나온 횟수의 분포는 어떻게 되는가?

→ 동전을 k번 던져서 앞면이 나온 횟수를 기록하는 것이 한번의 실험(시행)

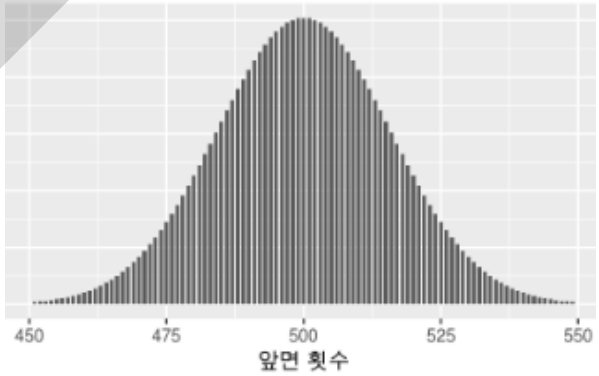
<동전 던지기 5회의 히스토그램>




<동전 던지기 100회의 히스토그램>




<동전 던지기 1,000회의 히스토그램>

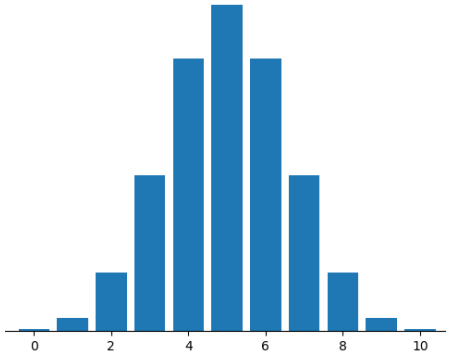



- 동전 던지는 횟수(k) 가 증가함에 따라 그 결과의 분포 모양은 정규분포곡선으로 수렴, k는 관측치(Sample)의 수를 의미
- 시행횟수는 무한하다고 전제
- 즉 표본의 크기가 커질수록, 표본 평균의 분포는 정규분포에 가까워 짐

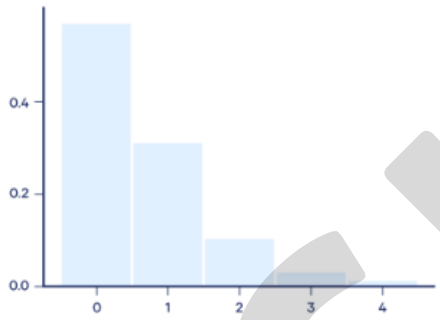
SKALA

# 세상의 많은 일은 정규분포를 따른다?

때로는 맞지만 대부분의 경우에는..




- 동전 던지기를 10회 수행하여 앞면이 나온 횟수의 분포는?
- 앞면이 나올 5번 나올 확률이 가장 높을 것



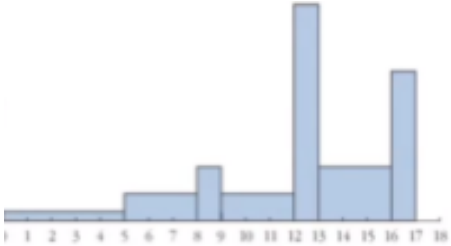

- 한주에 2번 교통사고가 발생하는 교차로에서 하루에 x번 교통사고가 발생하는 확률은?
- 드문 사건이나 일정한 시간 간격 동안 발생하는 사건의 개수를 모델링

SKALA

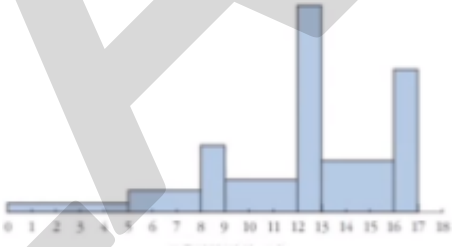
# 세상의 많은 일은 정규분포를 따른다?

표본의 크기가 충분히 커질수록 표본평균으로 그려진 히스토그램은 정규분포에 근사

<모집단 분포>

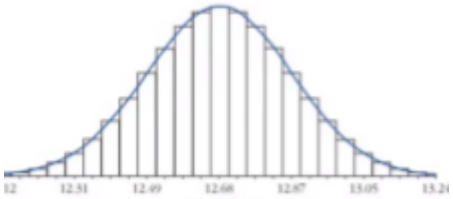


<표본집단 분포>



- 표본의 정보(표본평균)를 이용해서 모집단(모평균)을 맞추는 게임이 추론의 본질
- 표본집단을 대표성 있게 뽑았다면 전체적인 모양이 모집단과 유사할 것
- 완전히 같을까? No! 오차가 있음

<표본평균의 확률 히스토그램 >



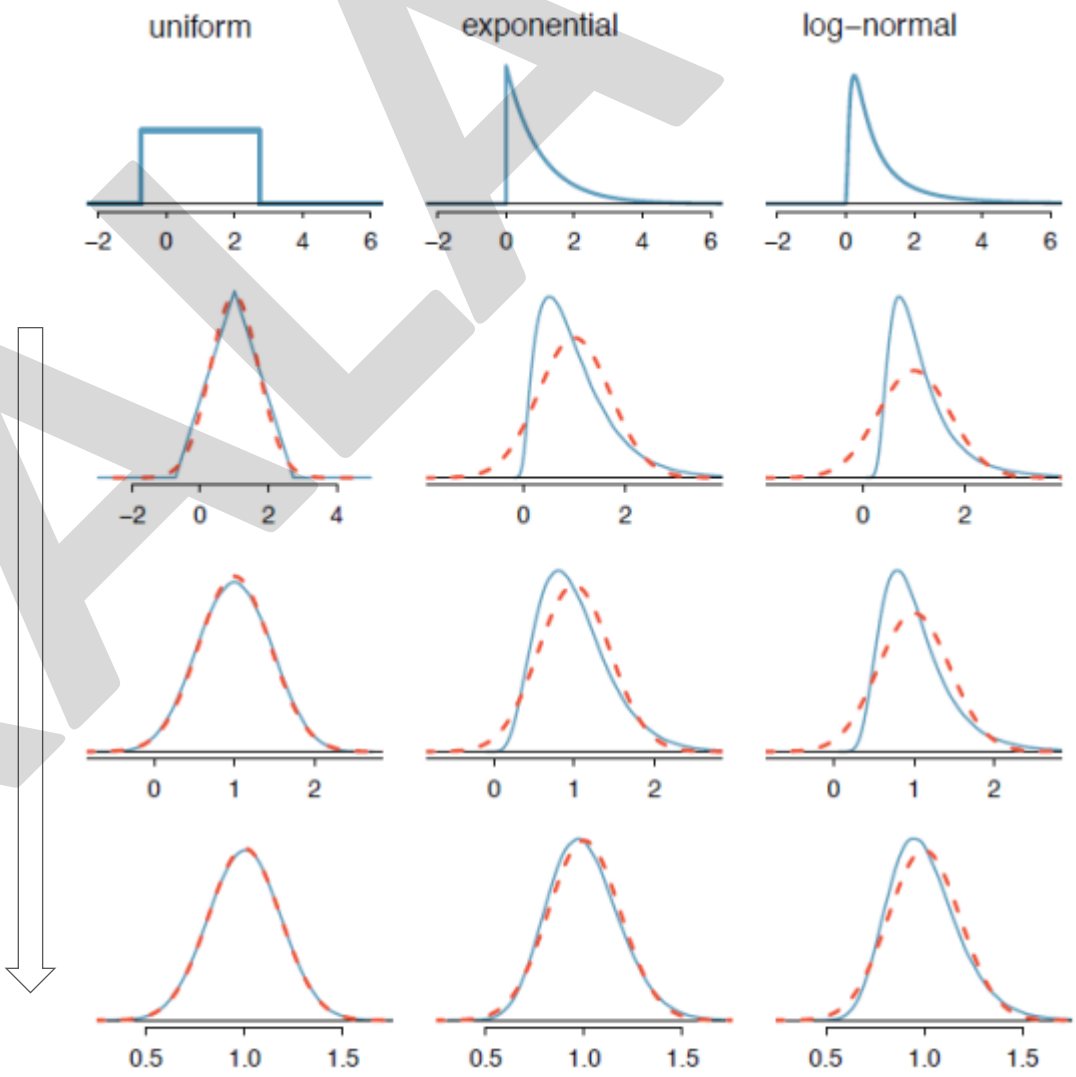
- 표본의 크기가 충분히 큰 표본의 평균을 구하고 다시 표본을 임의 추출하여 반복하여 구하고.. 반복하여 구하자..
- 구해진 표본 평균으로 만들어진 히스토그램은 어떻게 변할까?

SKALA

# 세상의 많은 일은 정규분포를 따른다?

표본의 크기가 충분히 커질수록 표본평균으로 그려진 히스토그램은 정규분포에 근사

- Sample의 수가 커질수록 본래 모양에 상관없이 그 합은 히스토그램은 정규분포에 수렴한다는 것이 중심극한정리의 또다른 중요한 성질
- 본래 모양이 정규분포에 가깝다면 수렴속도는 어떨까?




SKALA

# 대수의 법칙 + 중심극한정리

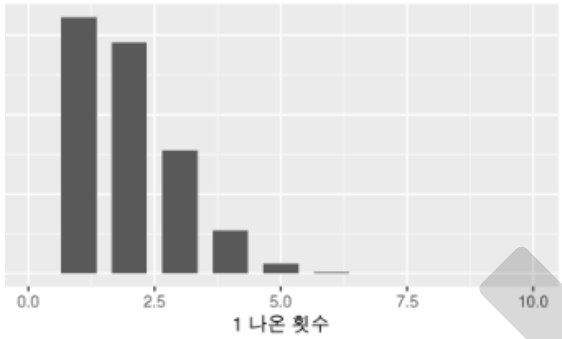
**Experiment**

주사위를 여러 번 던져서.. 던지는 횟수를 늘려갈 때, 1이 나온 횟수의 분포는 어떻게 되는가?

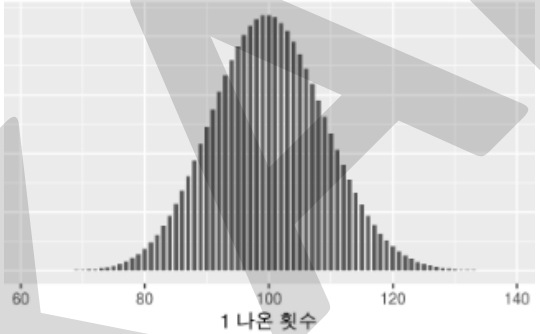
→ 주사위를 k번 던져서 1이 나온 횟수를 기록하는 것이 한번의 실험(시행), 이 과정을 10,000번 반복

→ 이론적 확률은 1/6

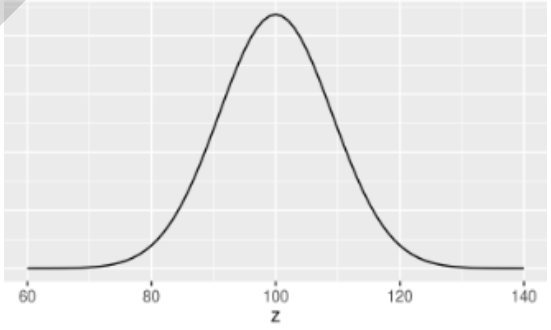
<주사위 던지기 10회의 1의 개수 히스토그램>




<주사위 던지기 600회의 1의 개수 히스토그램>




<정규분포 N(100,83.3에 수렴>




- 반복실험의 횟수가 커지면(동일한 실험을 충분히 많이 반복하면) 경험적 히스토그램은 이론적 히스토그램에 수렴
- 주사위 던지는 횟수가 커지면(각 실험의 표본 크기가 충분히 커지면) 정규분포 곡선에 수렴함

SKALA

# Application

1,000여명의 여론조사 지지율을 조사했을 때 63%(630명)의 지지율이 나왔다면 다음에 조사하면 또 63%나올 것인가?
지금까지 살펴보았던 내용을 바탕으로 이야기 할 수 있는 것은?

- 표본은 대표성 있게 추출되었는가?
- 샘플링(sampling) 불확실성(uncertainty)을 수량화 해보자
- 표본오차를 줄이려면 어떻게 해야 하나? 그 예상되는 효과는? 구간을 잡으면 신뢰할 수 있지 않을까?

- 표본 결과는 항상 조금씩 달라질 수 있다.
- 표본이 커질수록 결과는 더 안정적이고 신뢰할 수 있다.
- 표본의 불확실성은 표준오차(Standard Error)로 정량화할 수 있다.
- 모집단의 값은 하나의 숫자가 아니라 일정한 구간(신뢰구간)으로 추정하는 것이 타당하다.
- 관측된 차이가 우연인지 실제 차이인지는 가설검정을 통해 판단할 수 있다. (Next)

✓ 추론통계의 목적은 '표본으로부터 모집단을 추정하는 것 ' 을 넘어,

✓ '표본의 불확실성을 정량화하여 더 신뢰할 수 있는 의사결정을 내리는 것'

SKALA

데이터 분석 개요 및 기초통계

# 가설 검정

- 가설 검정의 원리
- 가설 검정 프로세스
- 가설 검정 유의사항

본 문서는 SK㈜AX의 컨텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

SKALA

SK Inc. AX

# 가설 검정의 원리

가설을 어떻게 검증할 것인가?

## Definition

- 연구하고자 하는 가설을 통계적으로 증명하는 과정을 "유의성 검정" 이라 함

### 증명의 종류

- 연역법은 참인 명제를 바탕으로 또 다른 참인 명제를 이끌어 내는 방식
- Ex) 소크라테스는 사람이다. (참) → 모든 사람은 죽는다 (참) → 그러므로 소크라테스는 죽는다
- 귀납법은 제한적 관찰을 통해서 공통의 명제를 끌어내거나 법칙을 형식화 하는 방식
- Ex) 이 백조는 흰색이다 (관찰) → 저 백조도 흰색이다 (관찰) → 그러므로 모든 백조는 흰색이다
- 귀류법은 어떤 명제의 부정(반대)의 모순을 이끌어 냄으로써 그 명제가 참임을 증명하는 방식
- Ex) 네 말이 맞다고 치자, 그런데 이러이러 하니까 말이 안되네. 따라서 네 말은 틀렸어

"통계학에서는 검정 하고자 하는 어떤 명제가 있을 때 "모순에 의한 논증법" 을 사용함"

SKALA

# 가설 검정의 원리

모순에 의한 논증법

## Concept

- 관측된 현상(차이) 이 실질적인 것인가? 단순이 우연에 의한 것인가? 라는 질문에 답하는 과정




- 우연이 아님을 밝히려면 일단 우연이라고 믿자
- 주어진 자료를 통해 관찰할 통계량을 산출
- 우연이라고 보기엔 나타난 관측치가 너무 심하다
- 어떻게 이럴수가!
- 우연일 가능성은 극히 작으므로 명제는 실질적이다

SKALA

# 가설 검정의 원리

모순에 의한 논증법

**Example**

- [증명 하고자 하는 명제] A와 B는 차이가 있다 (차이가 0이 아니다)

| 명제의 부정이 참이라고 치자 | 자료를 통해 관찰 | 모순을 이끌어 냄 | 모순을 통해 명제 증명 |
| --- | --- | --- | --- |
| • 일단 차이가 0이라고 치자 | • 주어진 일부 자료를 통해 표본A와 표본B의 차이를 산출 | • 차이가 0이라고 보기엔 관측치가 모순 | • 그러므로 차이는 0일 수 없다 |

SKALA

# 가설 검정의 원리

<u>통계학적 사고</u>

- 조금 더 통계적으로 표현해 보자면
- → 관측된 통계량 값이 그 기대값으로 부터 통계량의 표준오차 단위로 멀리(2단위 이상) 떨어져 있으면 이를 우연으로 보기 힘들다는 것이 가설 검정의 본질
- 본질을 이해하면 이를 표현하는 통계적 언어(용어)를 익히면 됨

- 수학과 통계학의 차이! , 통계학은 확률론적 사고, 통계학은 단정하지 않는다
- 수학에서의 모순은 “완전 불가능” 을 의미하지만 통계학에서는 확률이 낮은 “거의 불가능 " 을 의미

SKALA

# 가설 검정의 통계적 언어

유의성 검정 프로세스

**Step1.** 가설 설정

$H_0$ 귀무가설 (Null Hypothesis)

- 관측된 차이는 우연이라는 주장
- 그 발견이 단지 우연일 뿐이라는 부정적인 주장
- 無로 돌아간다

$H_1$ 대립가설 (Alternative Hypothesis )

- 관측된 차이가 실질적이라는 주장
- 연구를 통해 입증하고자 하는 주장

✓ 증명하고자 하는 명제를 대립가설로 설정하고, 이를 부정하는 명제를 귀무가설로 설정함

✓ 일단 귀무가설이 참이라고 생각하자!

SKALA

# 가설 검정의 통계적 언어

유의성 검정 프로세스

**Step2.** 데이터로부터 통계량 계산

- 주어진 자료로부터 가설 검정에 사용할 통계량을 계산
- 자료에서 얻은 통계량과 귀무가설 하에서 기대되는 값 사이의 차이를 측정하고, 다만 차이를 표준오차로 나누어 표준단위로 나타내면 '검정 통계량 '

표본으로 부터 얻은 통계량

귀무가설 하에서 기대되는 값

$$z = \frac{x - \mu}{\sigma}$$

하나의 통계량이 그 기대값으로부터 표준오차 단위로 얼마나 떨어져 있는지를 알려줌

전형적인 오차의 크기

SKALA

# [참고] 68-95-99.7의 법칙

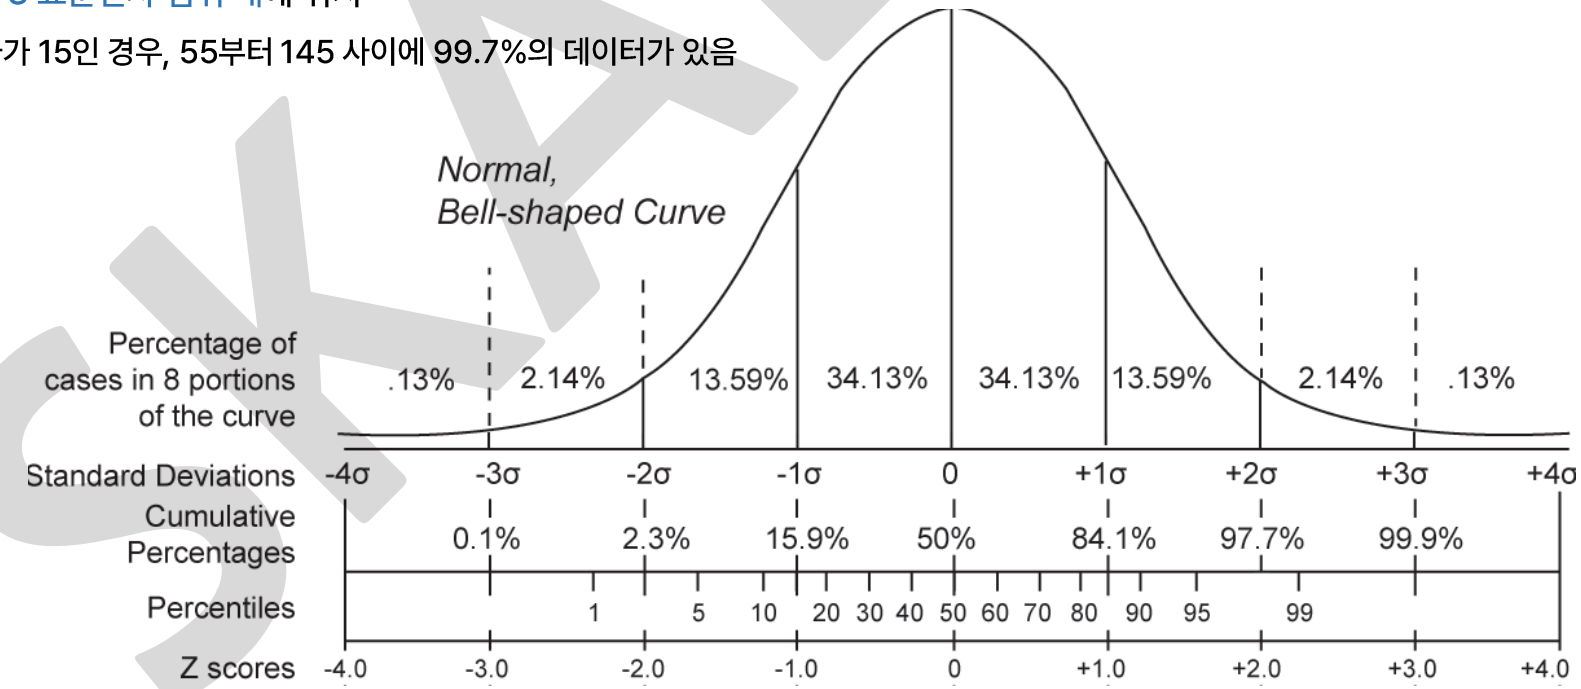
정규분포下 손쉬운 확률값 도출

**Interpretation**

- 68%의 데이터는 평균 ± 1 표준편차 범위 내에 위치
- Ex) 평균이 100이고 표준편차가 15인 경우, 85부터 115 사이에 68%의 데이터가 있음
- 95%의 데이터는 평균 ± 2 표준편차 범위 내에 위치
- Ex) 평균이 100이고 표준편차가 15인 경우, 70부터 130 사이에 95%의 데이터가 있음
- 99.7%의 데이터는 평균 ± 3 표준편차 범위 내에 위치
- Ex)평균이 100이고 표준편차가 15인 경우, 55부터 145 사이에 99.7%의 데이터가 있음

**Z-Score로 변환했다면..**

- 68-95-99.7 법칙 해석이 용이 해짐
- 68%의 데이터가 Z-Score ± 1 범위 내에 위치
- 95%의 데이터가 Z-Score ± 2 범위 내에 위치
- 99.7%의 데이터가 Z-Score ± 3 범위 내에 위치




SKALA

# [참고] 표준정규분포표

특정 z-점수에 대한 누적 확률을 보여주는 표

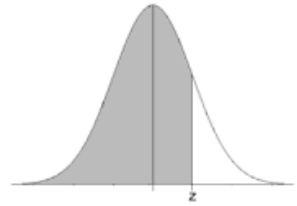
## Application

- 표에서의 z-점수는 보통 소수 첫째 자리와 둘째 자리를 기준으로 나누어져 있음
- Z = 1.23일 때, 표준정규분포표에서 z = 1.2와 0.03의 교차점에서 찾은 값은 0.8907
- 이는 P(Z ≤ 1.23) = 0.8907을 의미
- 즉, z-점수 1.23 이하의 값이 나올 확률은 약 89.07%

## (-) Z-score 는 어떻게 취급할까?

- 대칭적이기 때문에, 음의 z-점수에 대한 확률은 양의 z-점수를 사용한 값을 활용할 수 있음
- 대칭되는 양의 z-점수의 확률을 찾아낸 다음 1에서 그 확률을 빼는 방식

### Standard Normal Cumulative Probability Table




Cumulative probabilities for POSITIVE z-values are shown in the following table:

| z | 0.00 | 0.01 | 0.02 | 0.03 | 0.04 | 0.05 | 0.06 | 0.07 | 0.08 | 0.09 |
|---|---|---|---|---|---|---|---|---|---|---|
| 0.0 | 0.5000 | 0.5040 | 0.5080 | 0.5120 | 0.5160 | 0.5199 | 0.5239 | 0.5279 | 0.5319 | 0.5359 |
| 0.1 | 0.5398 | 0.5438 | 0.5478 | 0.5517 | 0.5557 | 0.5596 | 0.5636 | 0.5675 | 0.5714 | 0.5753 |
| 0.2 | 0.5793 | 0.5832 | 0.5871 | 0.5910 | 0.5948 | 0.5987 | 0.6026 | 0.6064 | 0.6103 | 0.6141 |
| 0.3 | 0.6179 | 0.6217 | 0.6255 | 0.6293 | 0.6331 | 0.6368 | 0.6406 | 0.6443 | 0.6480 | 0.6517 |
| 0.4 | 0.6554 | 0.6591 | 0.6628 | 0.6664 | 0.6700 | 0.6736 | 0.6772 | 0.6808 | 0.6844 | 0.6879 |
| 0.5 | 0.6915 | 0.6950 | 0.6985 | 0.7019 | 0.7054 | 0.7088 | 0.7123 | 0.7157 | 0.7190 | 0.7224 |
| 0.6 | 0.7257 | 0.7291 | 0.7324 | 0.7357 | 0.7389 | 0.7422 | 0.7454 | 0.7486 | 0.7517 | 0.7549 |
| 0.7 | 0.7580 | 0.7611 | 0.7642 | 0.7673 | 0.7704 | 0.7734 | 0.7764 | 0.7794 | 0.7823 | 0.7852 |
| 0.8 | 0.7881 | 0.7910 | 0.7939 | 0.7967 | 0.7995 | 0.8023 | 0.8051 | 0.8078 | 0.8106 | 0.8133 |
| 0.9 | 0.8159 | 0.8186 | 0.8212 | 0.8238 | 0.8264 | 0.8289 | 0.8315 | 0.8340 | 0.8365 | 0.8389 |
| 1.0 | 0.8413 | 0.8438 | 0.8461 | 0.8485 | 0.8508 | 0.8531 | 0.8554 | 0.8577 | 0.8599 | 0.8621 |
| 1.1 | 0.8643 | 0.8665 | 0.8686 | 0.8708 | 0.8729 | 0.8749 | 0.8770 | 0.8790 | 0.8810 | 0.8830 |
| 1.2 | 0.8849 | 0.8869 | 0.8888 | 0.8907 | 0.8925 | 0.8944 | 0.8962 | 0.8980 | 0.8997 | 0.9015 |
| 1.3 | 0.9032 | 0.9049 | 0.9066 | 0.9082 | 0.9099 | 0.9115 | 0.9131 | 0.9147 | 0.9162 | 0.9177 |
| 1.4 | 0.9192 | 0.9207 | 0.9222 | 0.9236 | 0.9251 | 0.9265 | 0.9279 | 0.9292 | 0.9306 | 0.9319 |
| 1.5 | 0.9332 | 0.9345 | 0.9357 | 0.9370 | 0.9382 | 0.9394 | 0.9406 | 0.9418 | 0.9429 | 0.9441 |
| 1.6 | 0.9452 | 0.9463 | 0.9474 | 0.9484 | 0.9495 | 0.9505 | 0.9515 | 0.9525 | 0.9535 | 0.9545 |
| 1.7 | 0.9554 | 0.9564 | 0.9573 | 0.9582 | 0.9591 | 0.9599 | 0.9608 | 0.9616 | 0.9625 | 0.9633 |
| 1.8 | 0.9641 | 0.9649 | 0.9656 | 0.9664 | 0.9671 | 0.9678 | 0.9686 | 0.9693 | 0.9699 | 0.9706 |
| 1.9 | 0.9713 | 0.9719 | 0.9726 | 0.9732 | 0.9738 | 0.9744 | 0.9750 | 0.9756 | 0.9761 | 0.9767 |
| 2.0 | 0.9772 | 0.9778 | 0.9783 | 0.9788 | 0.9793 | 0.9798 | 0.9803 | 0.9808 | 0.9812 | 0.9817 |
| 2.1 | 0.9821 | 0.9826 | 0.9830 | 0.9834 | 0.9838 | 0.9842 | 0.9846 | 0.9850 | 0.9854 | 0.9857 |
| 2.2 | 0.9861 | 0.9864 | 0.9868 | 0.9871 | 0.9875 | 0.9878 | 0.9881 | 0.9884 | 0.9887 | 0.9890 |
| 2.3 | 0.9893 | 0.9896 | 0.9898 | 0.9901 | 0.9904 | 0.9906 | 0.9909 | 0.9911 | 0.9913 | 0.9916 |
| 2.4 | 0.9918 | 0.9920 | 0.9922 | 0.9925 | 0.9927 | 0.9929 | 0.9931 | 0.9932 | 0.9934 | 0.9936 |
| 2.5 | 0.9938 | 0.9940 | 0.9941 | 0.9943 | 0.9945 | 0.9946 | 0.9948 | 0.9949 | 0.9951 | 0.9952 |
| 2.6 | 0.9953 | 0.9955 | 0.9956 | 0.9957 | 0.9959 | 0.9960 | 0.9961 | 0.9962 | 0.9963 | 0.9964 |
| 2.7 | 0.9965 | 0.9966 | 0.9967 | 0.9968 | 0.9969 | 0.9970 | 0.9971 | 0.9972 | 0.9973 | 0.9974 |
| 2.8 | 0.9974 | 0.9975 | 0.9976 | 0.9977 | 0.9977 | 0.9978 | 0.9979 | 0.9979 | 0.9980 | 0.9981 |
| 2.9 | 0.9981 | 0.9982 | 0.9982 | 0.9983 | 0.9984 | 0.9984 | 0.9985 | 0.9985 | 0.9986 | 0.9986 |
| 3.0 | 0.9987 | 0.9987 | 0.9987 | 0.9988 | 0.9988 | 0.9989 | 0.9989 | 0.9989 | 0.9990 | 0.9990 |
| 3.1 | 0.9990 | 0.9991 | 0.9991 | 0.9991 | 0.9992 | 0.9992 | 0.9992 | 0.9992 | 0.9993 | 0.9993 |
| 3.2 | 0.9993 | 0.9993 | 0.9994 | 0.9994 | 0.9994 | 0.9994 | 0.9994 | 0.9995 | 0.9995 | 0.9995 |
| 3.3 | 0.9995 | 0.9995 | 0.9995 | 0.9996 | 0.9996 | 0.9996 | 0.9996 | 0.9996 | 0.9996 | 0.9997 |
| 3.4 | 0.9997 | 0.9997 | 0.9997 | 0.9997 | 0.9997 | 0.9997 | 0.9997 | 0.9997 | 0.9997 | 0.9998 |

SKALA

# 가설 검정의 통계적 언어

유의성 검정 프로세스

**Step3. P-value 산출**

- 검정 통계량은 실제(관측치)와 이론(귀무가설 하의 기대값)의 표준화된 차이를 의미하는데, 이로부터 확률(면적)을 얻을 수 있음
- 이렇게 구해진 확률을 "관측된 유의수준" 또는 p-value 라고 부름

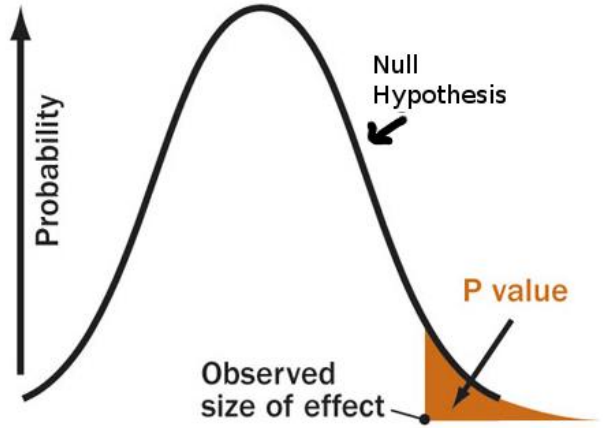
(1) 귀무가설이 옳다는 전제(정규분포의 세상)하에 p-value를 얻었음

(2) P-value의 의미는?

- 귀무가설 하에서 표본의 통계량이 그 관측치 혹은 그보다 극단적인 값으로 얻어질 확률을 의미

(3) P-value가 매우 작다면 그 의미는?

- 귀무가설이 옳다면 어떻게 이런 값이 얻어지나? (어떻게 이런일이!)
- 귀무가설에 문제가 있을 가능성을 의미
- P-value의 크고 작음을 통해 귀무가설을 기각(reject)할 수 있음




SKALA

# 가설 검정의 통계적 언어

유의성 검정 프로세스

**Step4.** 유의수준 설정

- P-value의 크고 작음을 통해 귀무가설을 기각(reject)할 수 있음을 알았는데..
- P-value가 크고 작다는 것을 어떻게 파악할까? 귀무가설을 기각할지 말지에 대한 기준이 필요

그 기준이 되는 값이 유의수준**(significance level)**

- α (알파)로 표기, '검정의 크기'라고도 표현
- 설정한 유의수준이 클수록 귀무가설을 기각할 가능성이 커짐
- 설정한 유의수준이 낮을수록 엄격한 연구

보편적으로 사용되는 유의수준

- 10% 유의수준 (α =0.1) , 90% 신뢰도 , z값은 1.645
- 5% 유의수준 (α =0.05) , 95% 신뢰도 , z값은 1.96
- 1% 유의수준 (α =0.01) , 99% 신뢰도 , z값은 2.575

SKALA

# 가설 검정의 통계적 언어

유의성 검정 프로세스

**Step5.** 판정

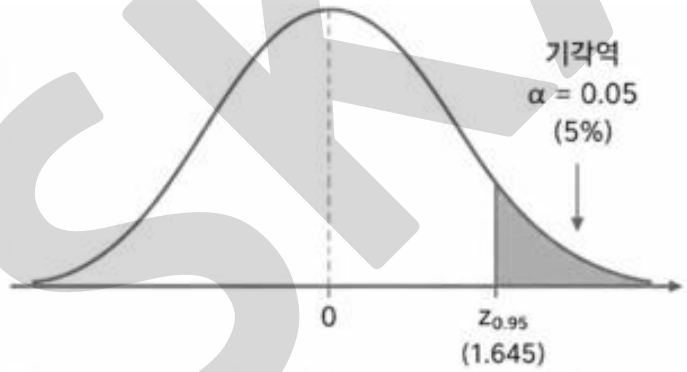
- P-value가 유의수준보다 작거나 같으면 귀무가설을 기각, 아니면 기각하지 못함
- 귀무가설을 기각하는 경우 “결과가 통계적으로 유의하다 (statistically significant) “ 라고 말함
- 귀무가설을 기각한다, 귀무가설을 기각하지 못한다 로 표현

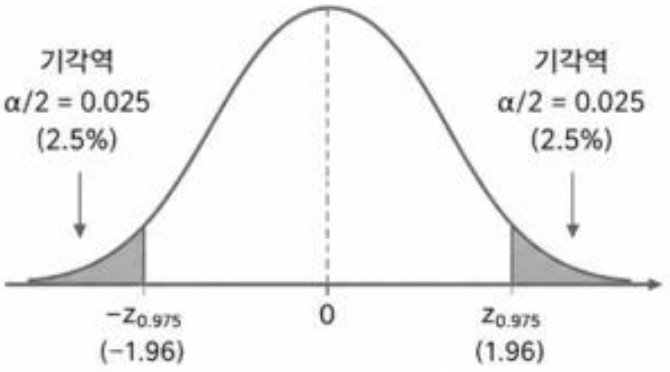
SKALA

# 단측검정(One-tailed Test) vs 양측검정(Two-tailed Test)

방향성을 검정할 것인가, 차이만 검정할 것인가?

| 구분 | 단측검정 (One-tailed Test) | 양측검정 (Two-tailed Test) |
|---|---|---|
| 목적 | 특정 방향의 차이를 검정 | 차이의 존재 여부를 검정 |
| 대립가설($H_1$) | $\mu > \mu_0$ 또는 $\mu < \mu_0$ | $\mu \neq \mu_0$ |
| 기각역 | 한쪽 꼬리 | 양쪽 꼬리 |
| 활용 | 방향성이 명확한 연구 | 대부분의 일반적인 연구 |




SKALA

# P-hacking

P-hacking의 유혹

- ✓ p-value가 더 작게 나오니까 단측 검정으로 바꾸자 → P-hacking
- ✓ 결과가 좋아보이니 단측 검정으로 바꾸자 → P-hacking

- ✓ 단측검정은 '더 유리한 검정'이 아니라, '방향이 사전에 명확하게 정의된 연구'에서만 사용할 수 있는 검정
- ✓ 대부분의 연구에서는 양측검정을 기본으로 사용
- ✓ 단측검정은 충분한 이론적 근거가 있을 때만 선택
- ✓ 단측검정은 데이터를 본 뒤에 선택하면 안 되고, 연구를 시작하기 전에 효과의 방향을 이론적 근거나 선행연구를 바탕으로 미리 정해두어야 함

**단측검정 Use-case**

- 새로운 공정이 불량률을 감소시키는가? → ok
- AI 교육이 시험점수에 영향을 주는가? → 높아질수도, 낮아질수도 있음 → 양측검정

SKALA

# 가설 검정의 유의사항

- 가설 검정은 '실질적인 것인가? 단순히 우연에 의한 것인가?' 를 판단할 뿐 이 차이가 중요한 의미를 갖는지, 왜 발생했는지는 알려주지 않음
- 가설 검정의 성격은 확률적이지 단정적이지 않음

- P-value는 "귀무가설이 맞을 확률", 옳은 표현인가?
- P-value는 귀무가설이 옳다는 가정하에 극단적인 관측치를 얻을 확률

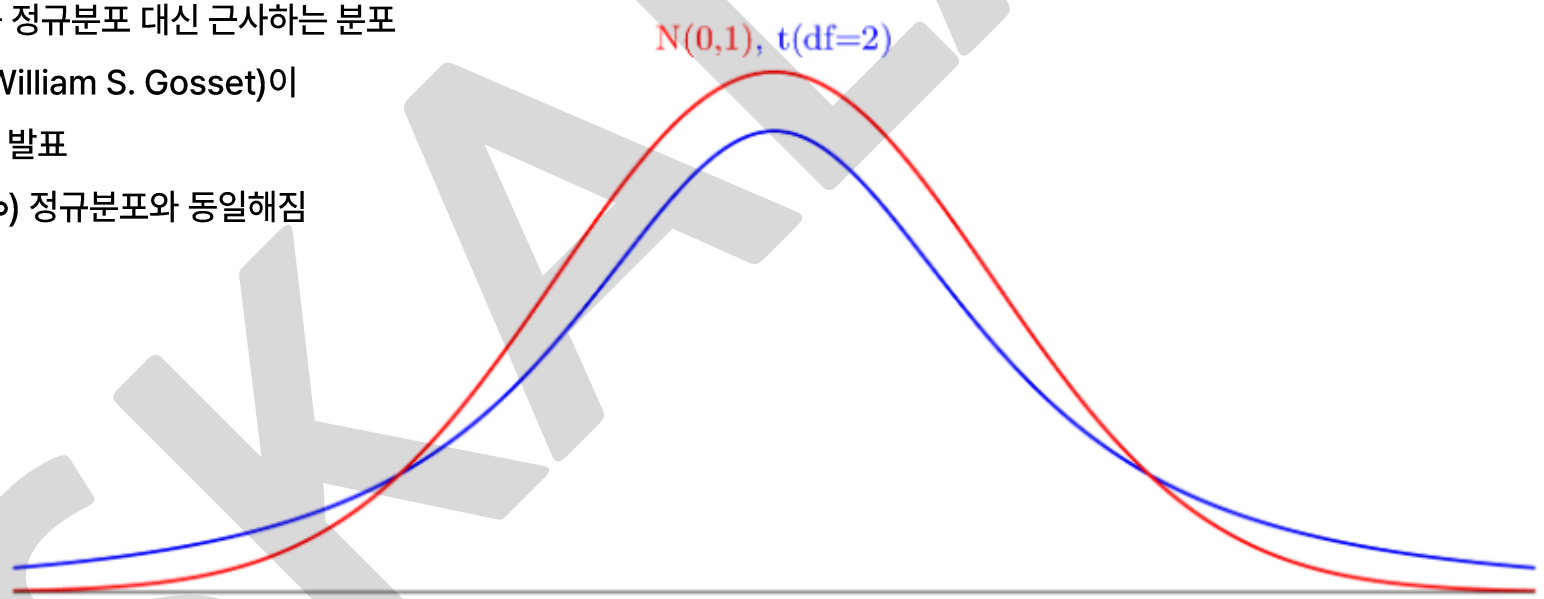
SKALA

# t-분포(Student's t-distribution)의 의미

불확실성이 큰 작은 표본을 위한 보수적인 추정

**t-분포란?**

- 표본의 크기가 작을 때(특히 $n$<30) 모평균을 추정하기 위해 표본평균의 분포를 정규분포 대신 근사하는 분포
- 1908년, 윌리엄 고셋(William S. Gosset)이 Student라는 필명으로 발표
- 표본수가 커지면 ($n \to \infty$) 정규분포와 동일해짐




SKALA

# 변수 형태에 따라 검정이 달라진다

가설 검정 프로세스는 동일하지만, 사용하는 검정분포와 검정 통계량은 달라진다

| 기법 | 변수A | 변수B | 검정 분포 | 검정 통계량 | 적용 예 |
|---|---|---|---|---|---|
| 카이제곱 검정 | 이산형 | 이산형 | 카이제곱분포 | 카이제곱 통계량 | 학력과 결혼유무 사이에 유의한 관계가 있는가? |
| 독립표본 t검정 | 이산형 (2그룹/독립) | 연속형 | T-분포 | T-통계량 | 성별에 따른 결혼비율의 차이가 있는가? |
| 대응표본 t검정 | 이산형 (2그룹/Pair) | 연속형 | T-분포 | T-통계량 | 특별과외 후 A반의 영어성적은 상승했는가? |
| 일원 분산분석 (ANOVA) | 이산형 (3그룹 이상) | 연속형 | F-분포 | F-통계량 | 거주지역에 따른 평균 자산액의 차이는 있는가? |

$H_0 : \rho_{AB} = 0$
$H_a : \rho_{AB} \neq 0$
[카이제곱검정]

$H_0 : \mu_A = \mu_B$
$H_a : \mu_A \neq \mu_B$
[t-검정]

$H_0 : \mu_A = \mu_B = \mu_C$
$H_a : \mu_A \neq \mu_B \neq \mu_C$
[ANOVA 검정]

SKALA

# 변수 형태에 따라 검정이 달라진다

가설 검정 프로세스는 동일하지만, 사용하는 검정분포와 검정 통계량은 달라진다

- ✓ 가설검정 프로세스는 동일하지만, 데이터 형태에 따라 적절한 검정 도구를 선택하는 것이 필요
- ✓ 달라지는 것은 '데이터의 형태'이며, 데이터의 형태에 맞는 검정통계량(t, $\chi^2$, F)을 선택하는 것

**검정 통계량은 왜 달라질까?**

- 검정통계량은 데이터의 특성에 맞게 차이를 숫자로 표현하는 방법

| t-검정 | 카이제곱 검정 | ANOVA |
|---|---|---|
| • 평균이 얼마나 차이나는가?<br>• 평균 차이(t)를 관측 | • 예상보다 얼마나 많이(적게) 발생했는가?<br>• 빈도 차이($\chi^2$) 를 관측 | • 그룹 차이가 우연이라고 보기 어려운가?<br>• 집단 간 차이와 집단 내 차이를 비교 → 분산차이(F) |
| $\frac{\text{평균 차이}}{\text{평균의 표준오차}}$ | $\frac{\text{관측빈도-기대빈도}}{\text{기대빈도}}$ | $\frac{\text{집단간 분산}}{\text{집단내 분산}}$ |

SKALA

# 수고하셨습니다.

본 문서는 SK㈜AX의 컨텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.