SKALA

데이터 분석 및 AIOps

데이터 분석 개요 및 기초통계

Day2. 회귀분석

2026.07

전임교수 : Byung-sun, Park

Ver.4

본 문서는 SK(주)AX의 컨텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

SK Inc. AX



1. 상관분석
2. 회귀분석
3. 선형모형 가정

Intro

“올 여름 찜통 더위에 아이스크림 판매 ‘사상 최대” from 해럴드 경제

- 관계자는 “아이스크림 매출은 작년에 역대 최대였는데 올여름은 매출이 더 늘었다”면서 “어린이 인구가 줄고, 아이스크림을 대체할 제품이 늘어나 시장 축소가 우려되는 상황에서 고무적”이라고 말했다.

<u>여름이 되면 기온도 오르고 아이스크림 판매도 늘어난다.</u>

- 기온과 아이스크림 판매량 사이에 관계가 존재할까?
- 기온이 1도 오르면 아이스크림은 몇 개 더 팔릴까?

SKALA

데이터 분석 개요 및 기초통계

상관관계 분석

- 두 변수 관계 살펴보기
- 수식에 담긴 의미
- 해석 시 유의사항

본 문서는 SK㈜AX의 컨텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

SK Inc. AX

두 변수 사이의 관계 살펴보기

- 근속연수와 연봉
- 키와 몸무게
- 공부 시간과 시험 점수
- 광고비와 매출액
- 운동량과 체지방률
- 담배 흡연량과 평균 수명
- 주행속도와 이동시간
- 가격과 수요
- 신발 사이즈와 토익 점수
- 출생월과 수학 점수
- 헤어 길이와 IQ
- 머리둘레와 폐활량

✓ 많은 경우 두 변수 사이의 관계는 중요

✓ 두 변수 사이의 상호관계를 분석하기 위한 방법은?

✓ 결합분포(Joint Distribution)는 두 변수 사이의 관계를 보여줌

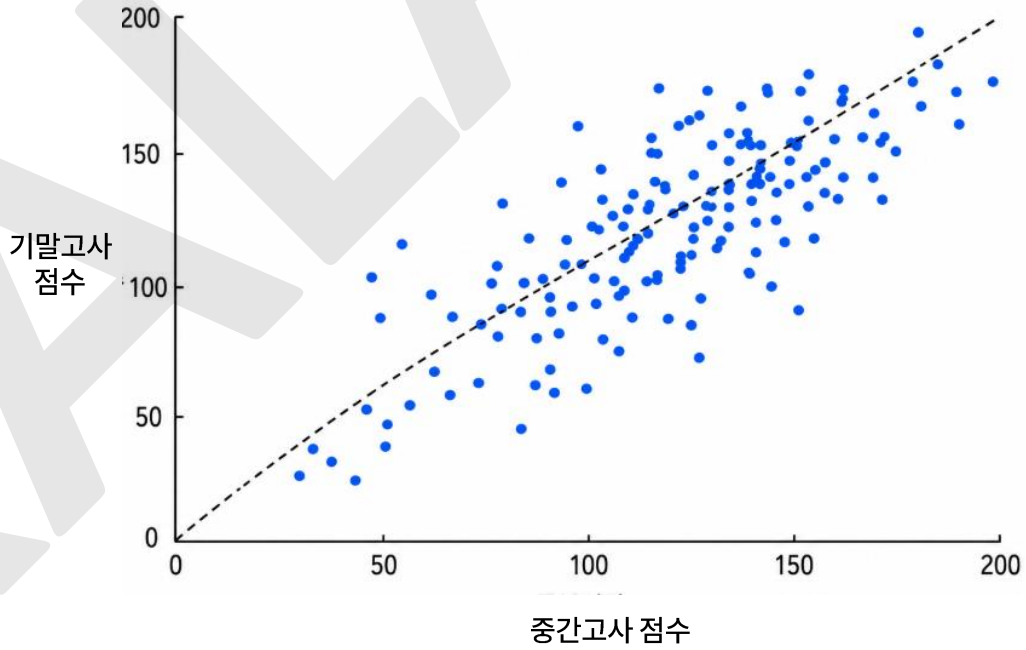
SKALA

두 변수 사이의 관계 살펴보기

두 변수 사이의 관계를 살펴보는 간단한 접근, 산점도(Scatter plot)

Scatter plot

- 두 연속형 변수의 값을 좌표평면에 점으로 나타낸 그래프
- 두 변수 사이의 관계를 살펴보기 위해 산포도를 활용
- 설명변수는 x로 표기하고 가로축에 표시
- 피설명변수는 y로 표기하고 세로축에 표시



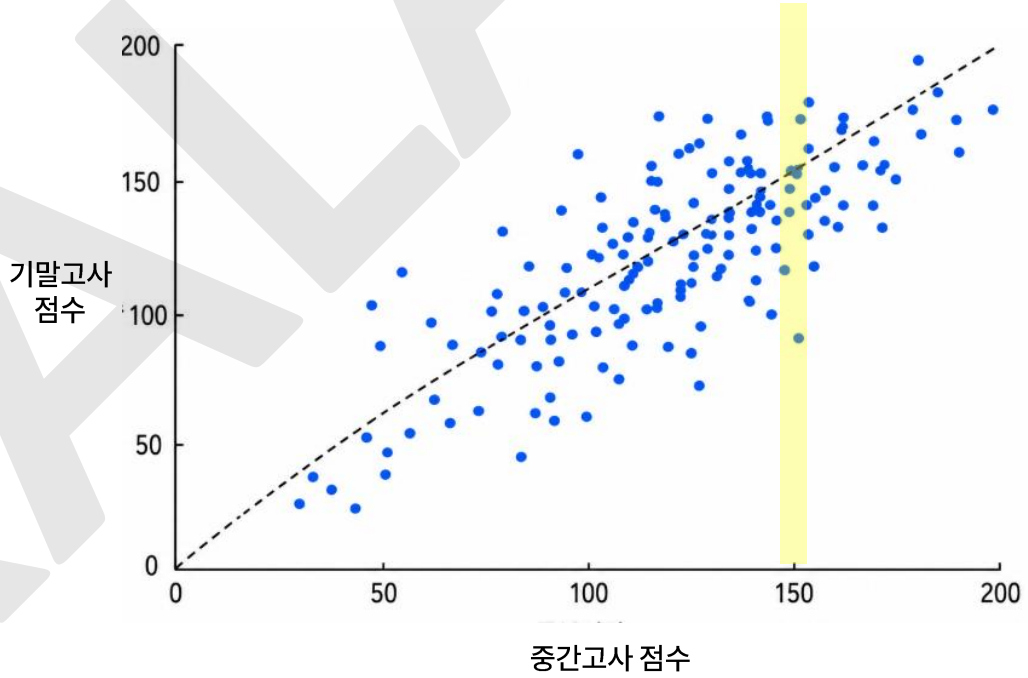
SKALA

두 변수 사이의 관계 살펴보기

두 변수 사이의 관계를 살펴보는 간단한 접근, 산점도(Scatter plot)

Case1. 관계가 약한 경우

- 중간고사에서 150점 받은 학생들의 기말고사 성적은 75점에서 175점 사이에 분포
- → 변수 사이의 관계가 약하면 한 변수 값이 다른 변수 값을 예측하는 데 큰 도움 안됨



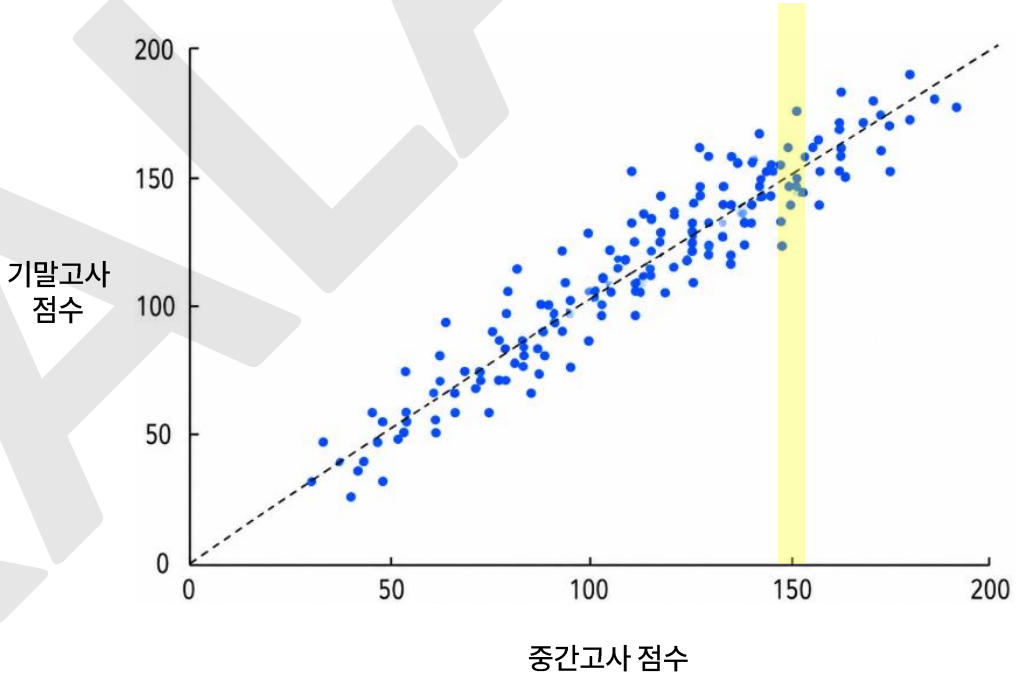
SKALA

두 변수 사이의 관계 살펴보기

두 변수 사이의 관계를 살펴보는 간단한 접근, 산점도(Scatter plot)

Case2. 관계가 강한 경우

- 중간고사에서 150점 받은 학생들의 기말고사 성적은 125점에서 175점 사이에 분포
- 변수 사이의 관계가 강하면 한 변수 값이 다른 변수 값을 예측하는 데 크게 도움됨



SKALA

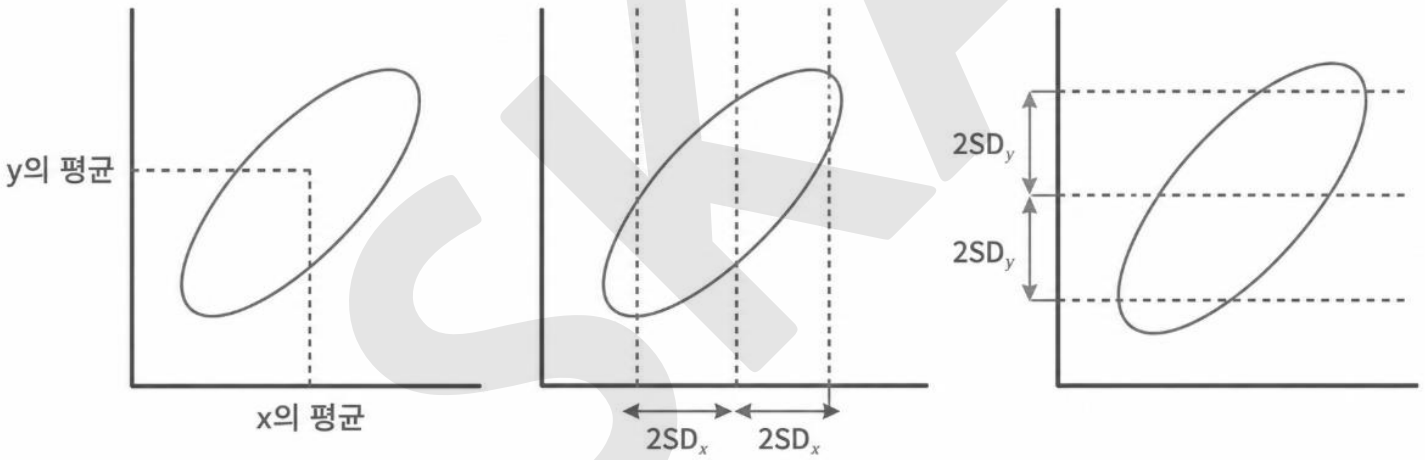
두 변수 사이의 관계 살펴보기

두 변수 사이의 관계를 살펴보는 간단한 접근, 산점도(Scatter plot)

산점도와 68-95-99.7 법칙을 떠올려 보자

- 가로로(x축) 보면 대략 95%의 점들이 x평균점을 기준으로 ±2 SDx 이내에 위치함
- 세로로 (y축) 보면 대략 95%의 점들이 y평균점을 기준으로 ±2 Sdy 이내에 위치함
- X의 평균과 표준편차, y의 평균과 표준편차는 x와 y의 분포 각각의 요약 통계량

[평균점] [x변수 표준편차 ±2] [y변수 표준편차 ±2]

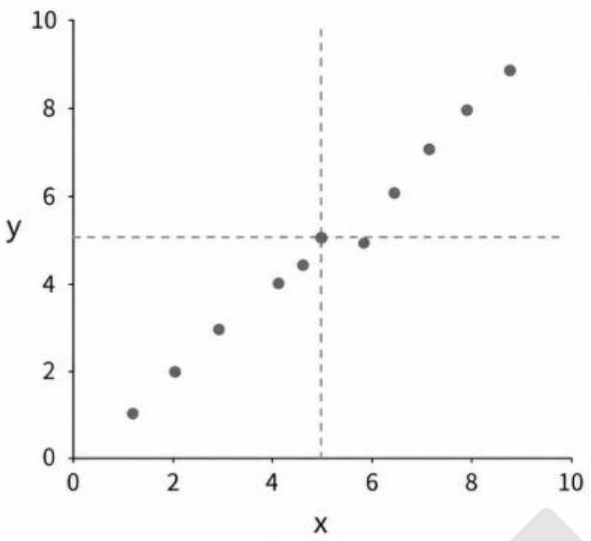


SKALA

상관 분석은 왜 필요할까?

평균과 표준편차가 동일해도 두 변수의 관계는 상이할 수 있음

[산점도 a]



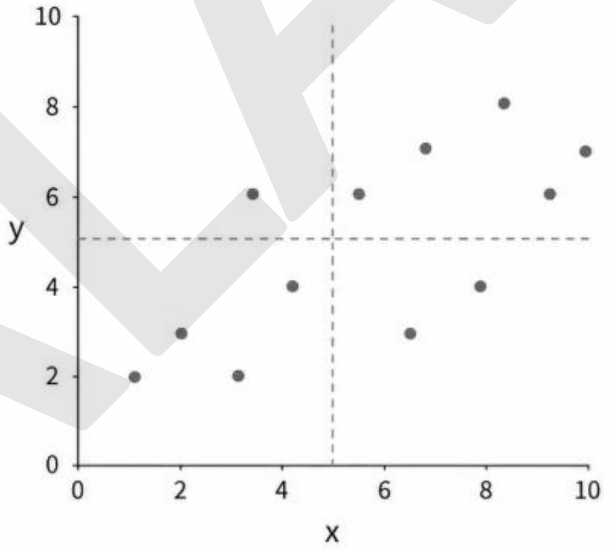
Vs

평균과

표준편차가

같음

[산점도 b]



- 두 산점도의 x,y의 평균은 5, 표준편차는 2.87로 동일
- 두 산점도는 가로든 세로든 중심(평균)과 퍼진 정도(표준편차)가 동일하지만 (a)가 (b)보다 더 강한 선형관계를 보임

SKALA

상관 분석은 왜 필요할까?

평균과 표준편차가 동일해도 두 변수의 관계는 상이할 수 있음

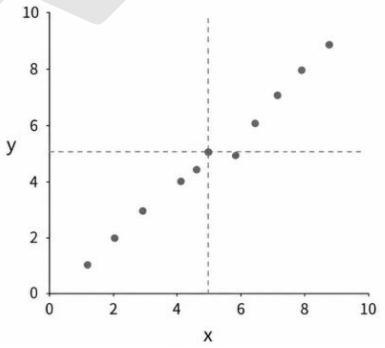
<u>상관분석이 필요한 이유</u>

- 중간고사 점수(x)와 기말고사 점수(y)의 산점도이고, a반과 b반의 점수평균과 표준편차가 동일하더라도, 두 변수의 관계는 전혀 다를 수 있다

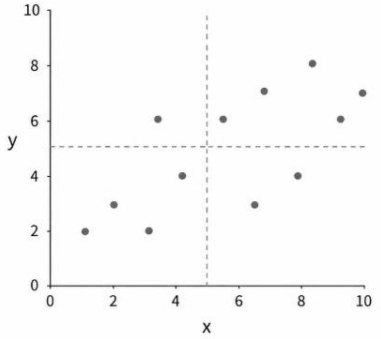
- 평균과 표준편차는 변수 각각의 특성만 설명
- 두 변수간 선형관계의 방향과 강도가 얼마나 되는지 측정할 필요성 → 상관분석
- 상관계수는 두 변수간 선형관계의 방향과 강도 측정하는 수단

✓ 기술통계는 '각 변수'를 설명하고, 상관분석은 '변수와 변수의 관계'를 설명

[a반]



[b반]



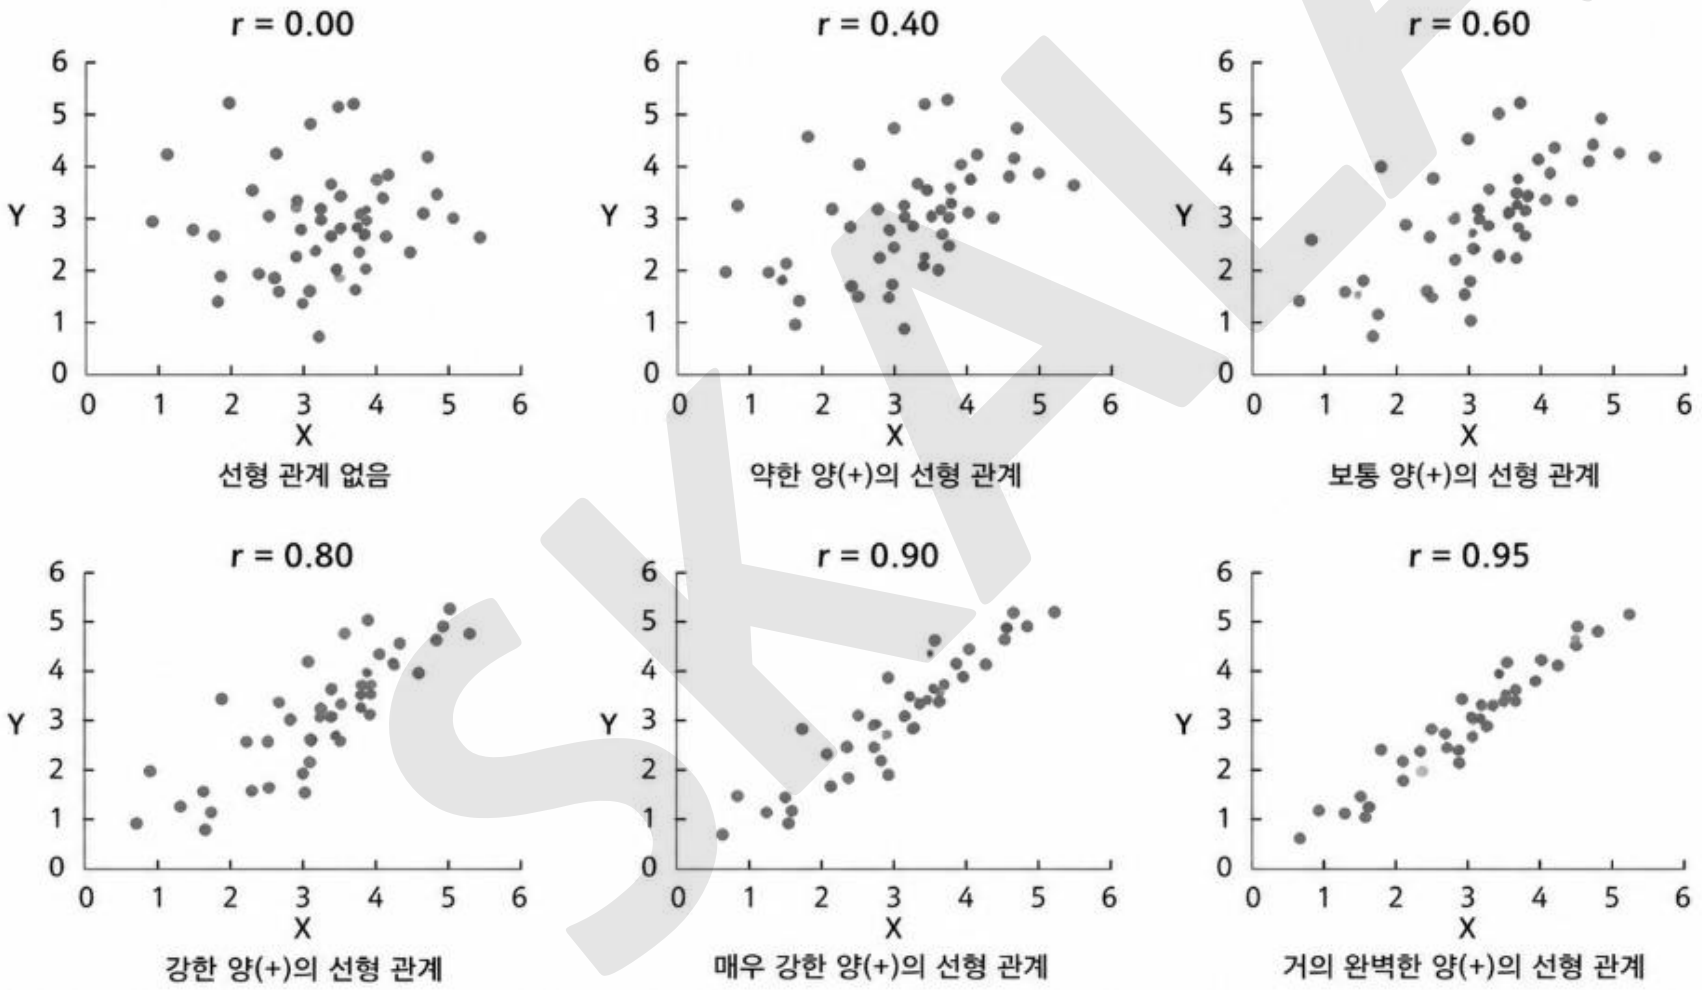
SKALA

상관 분석은 왜 필요할까?

평균과 표준편차가 동일해도 두 변수의 관계는 상이할 수 있음

6개 산점도의 x,y 변수 모두 평균 3, 표준편차 1

✓ 두 변수의 관계를 수치로 나타내는 지표가 바로 상관계수



SKALA

우리가 알고 있는 상관계수

두 변수의 관계를 나타내는 값..값이 크면 관계가 높다(?), 예측이 가능하다(?), 인과관계가 있다(?)

상관계수(Correlation)

$$-1 \leq r \leq 1$$

- 선형적 관계를 수치로 나타낸 값
- 양의 상관관계 : 한 변수가 증가하면 다른 변수도 증가
- 음의 상관관계 : 한 변수가 증가하면 다른 변수는 감소
- 0에 가까운 상관계수 : 두 변수는 선형 관계가 거의 없음

- 완전상관(perfect correlation) : 상관계수가 1 또는 -1, 모든 점들이 정확히 하나의 선 위에 위치

SKALA

[참고] 자유도란?

자유도(自由度, degrees of freedom)

- 주어진 제약조건 하에서 자유롭게 독립적으로 바꿀 수 있는 값의 개수

[Example]
- 3개 숫자의 평균이 5 으로 주어져 있을 때, 첫번째 숫자가 3, 두번째 숫자가 7라면 세번째 숫자는?
- → 5이 되어야 평균이 5가 될 것, 마지막 숫자는 자유롭게 정할 수 없음
- → 자유롭게 정할 수 있는 숫자는 2개, 따라서 자유도는 3-1 = 2
- 표준편차를 알 때 10개 편차 중 9개를 알면 나머지 1개는 자동으로 결정됨, 자유로운 값은 9개..

자유도의 의미

- 표본오차에서 n−1을 사용하는 이유는 표본집단의 편향(bias)을 보정하기 위해서(모집단의 진짜 분산보다 작게 나오는 편향)
- 관측치가 1개일 때 편차는 0 → 편차의 평균(mean)은 0/1=0 , 제곱근해도 0 고로 RMS는 0 → 즉 표준편차는 0
- 표준편차를 통해 알고 싶은 건 얼마나 불확실하냐?
- 올해 10%수익이면 내년도 10%수익이 확실하다는(확정된다는) 의미?
- 자유도 개념을 대입해 보면, 편차의 평균(mean)은 0/(1-1) = 0/0 = 부정형(indeterminate form)
- 부정형(indeterminate form) = "값이 하나로 정해지지 않는다", 알 수 없다"

SKALA

수식 속에 들어있는 상관계수의 의미

상관계수를 산출해보자

$$r = \frac{\sum_{i=1}^{n}(x_i-\bar{x})(y_i-\bar{y})/(n-1)}{\sqrt{\sum_{i=1}^{n}(x_i-\bar{x})^2/(n-1)} \cdot \sqrt{\sum_{i=1}^{n}(y_i-\bar{y})^2/(n-1)}}$$

"공분산(Covariance)"

$$\mathrm{Cov}(X,Y)$$

x와 y의 편차를 서로 곱해주는 이유는 무엇일까?

두 변수 x,y간의 관계가 편차들의 곱에 반영되기 때문임

- x가 평균보다 클 때 y도 평균보다 크다면 두 편차의 곱은 양수
- x가 평균보다 클 때 y는 평균보다 작으면 두 편차의 곱은 음수

→ 부호 결정 양의관계(positive)/음의관계(negative)

- x가 크게 커질 때, y도 크게 커진다면 두 편차의 곱은 커짐

→ 강도 결정

SKALA

수식 속에 들어있는 상관계수의 의미

상관계수를 산출해보자

$$r = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})/(n-1)}{\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2/(n-1)} \cdot \sqrt{\sum_{i=1}^{n}(y_i - \bar{y})^2/(n-1)}}$$

공분산을 바로 사용하지 않고, x,y의 표준편차로 나누어 주는 이유는?

공분산과 달리 상관계수는 단위와 무관하게 정의 (단위를 갖지 않음)

산출 값이 -1과 1 사이로 한정됨

SKALA

상관계수 해석

상관계수(Correlation) 해석의 가이드라인 (경험적, 관습적 기준)

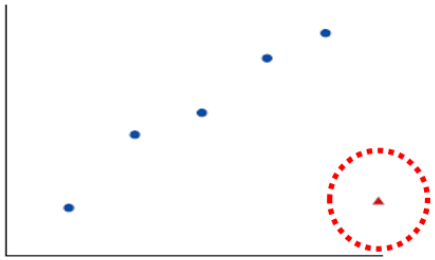
- 0.0 ~ 0.2: 거의 상관 없음
- 0.2 ~ 0.4: 약한 상관
- 0.4 ~ 0.6: 중간 정도 상관
- 0.6 ~ 0.8: 강한 상관
- 0.8 ~ 1.0: 매우 강한 상관

SKALA

상관계수 해석의 유의사항

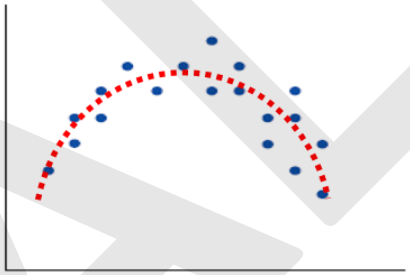
그래프 리뷰없이 수치를 기계적으로 해석하는 것에 유의

이상치를 포함하고 있을 경우



〈아웃라이어가 포함된 경우〉

두 변수간 관계가 비선형일 경우



〈비선형관계〉

- ✓ 상관계수는 타원형을 띠는 산포도에서 두 변수의 선형관계를 설명하는데 적합
- ✓ 타원형이 아닌 산포도의 경우에는 상관계수의 유용성이 떨어짐 (Outlier가 존재하거나 비선형관계가 존재할 경우)

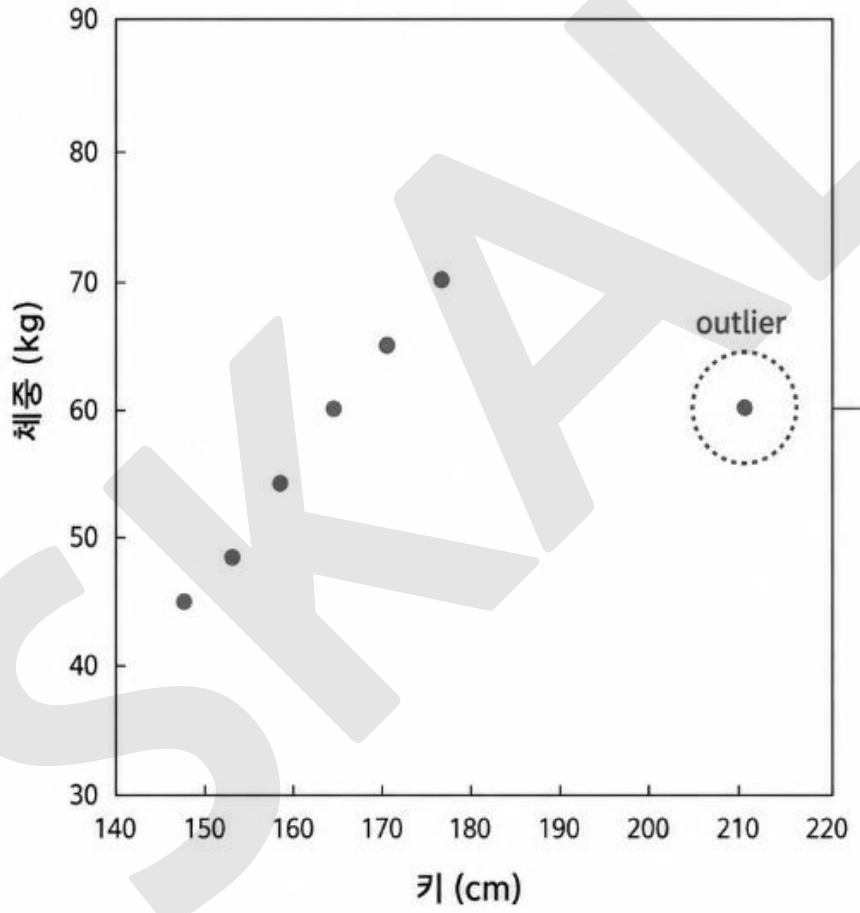
SKALA

상관계수 해석의 유의사항

그래프 리뷰없이 수치를 기계적으로 해석하는 것에 유의

Case Study - 이상치를 포함하고 있을 경우

ID	키 (cm)	체중 (kg)
1	150	45
2	155	48
3	160	54
4	165	60
5	170	65
6	175	70
7	210	61



이상값(Outlier) 제거 전

- 7개 데이터
- 상관계수 ρ = 0.339

이상값(Outlier) 제거 후

- 6개 데이터
- 상관계수 ρ = 0.857

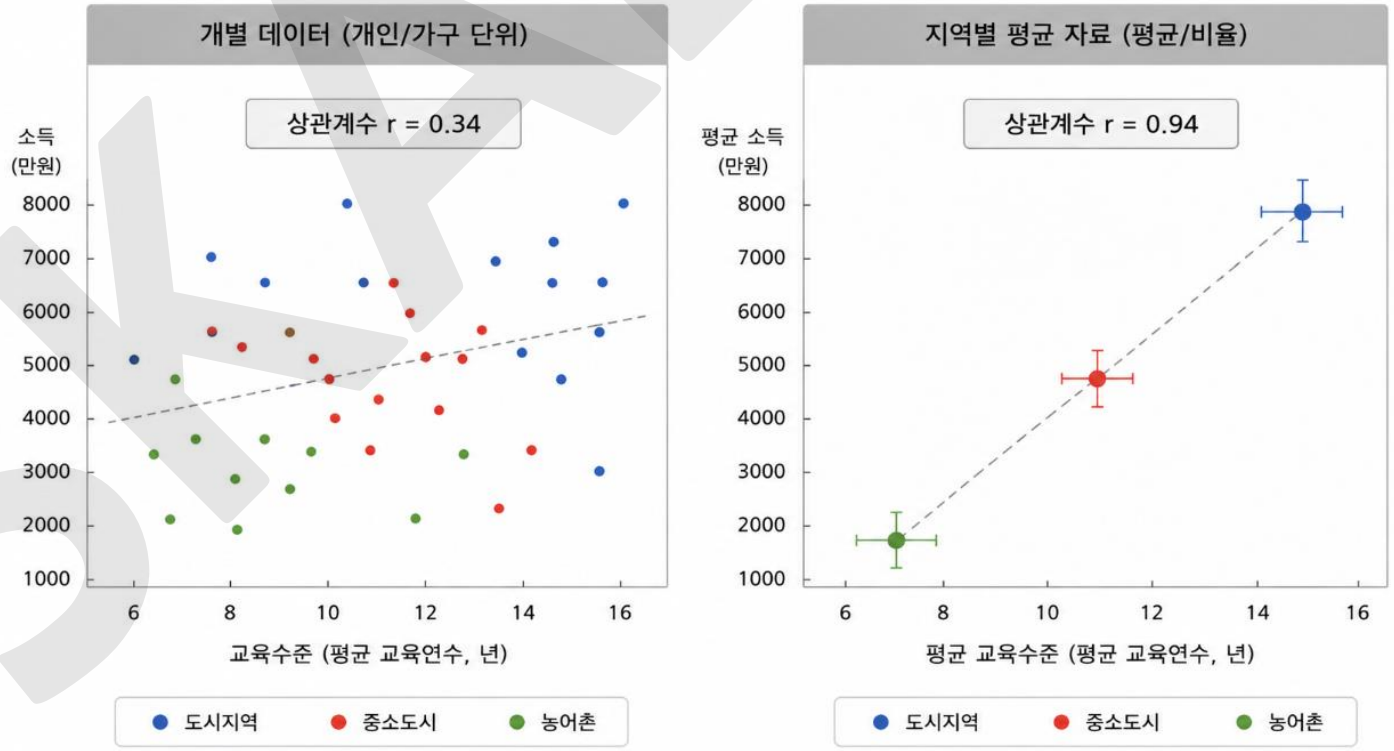
SKALA

상관계수 해석의 유의사항

그래프 리뷰없이 수치를 기계적으로 해석하는 것에 유의

실제의 관계를 과장하는 경우, Averaging Effect

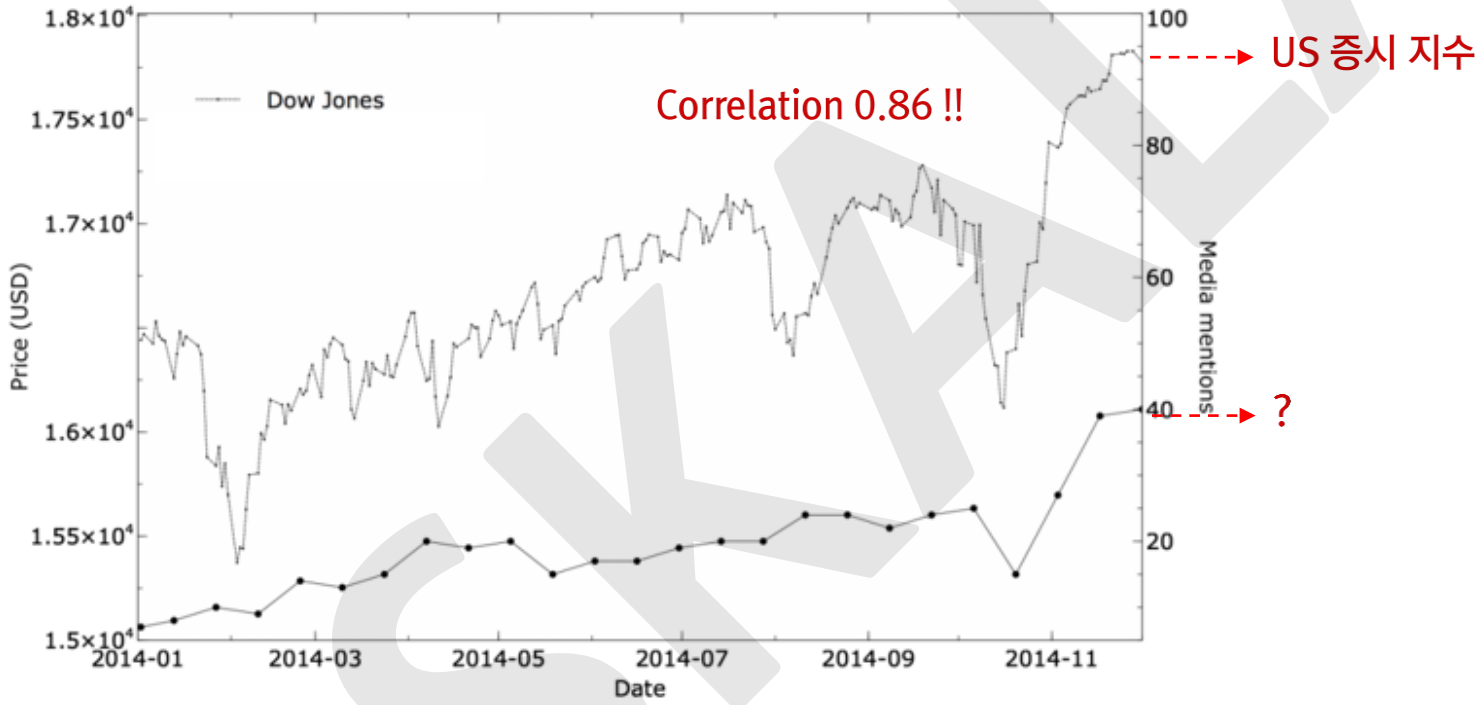
- 평균의 자료를 갖고 구한 상관계수는 실제의 관계를 과장
- 평균 자료를 이용하면 원래 흩어져 있던 정도가 평균을 구하는 과정에서 줄어들게 됨(평균 효과에 의해 noise 줄어듬)
- 따라서 실제의 분포이상으로 두 변수 간의 관계를 과장할 가능성 큼



SKALA

Spurious Correlation

상관관계 vs 인과관계



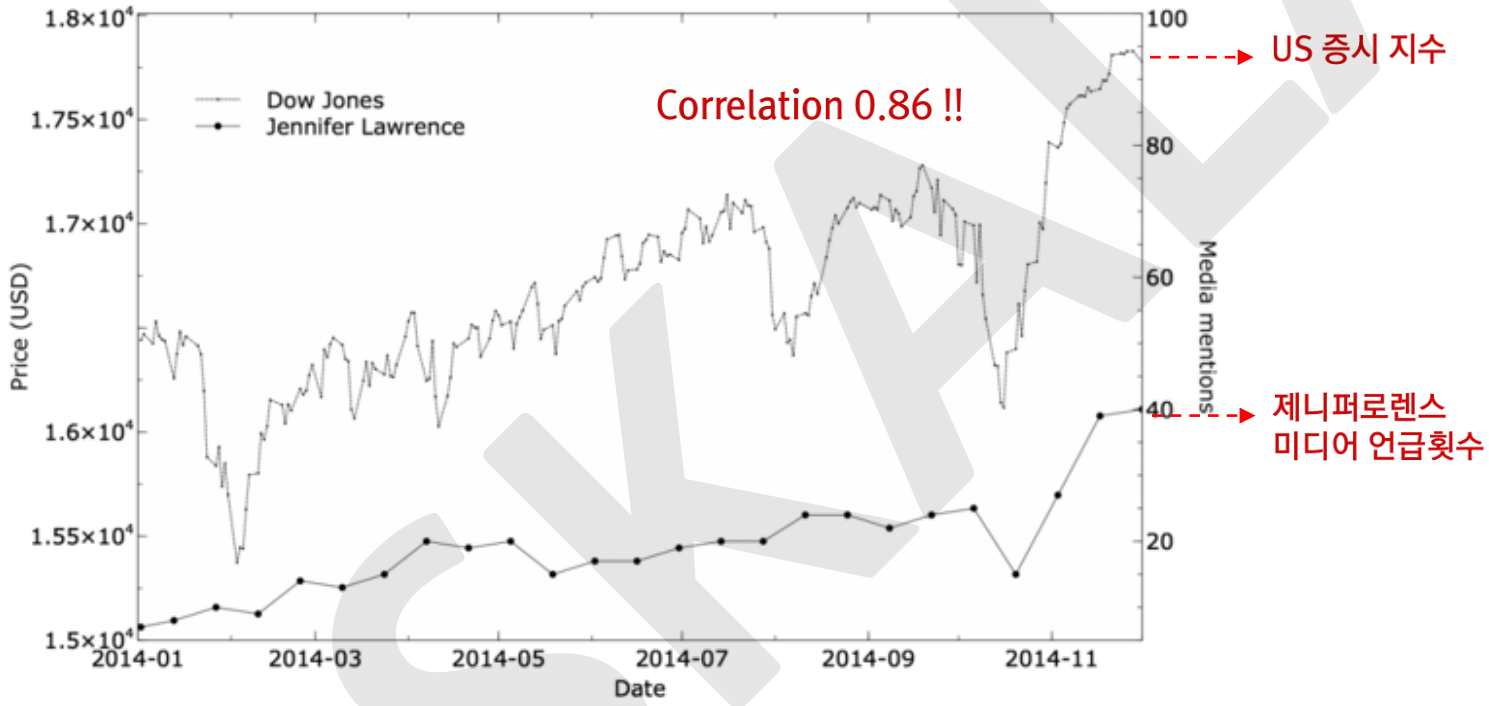
SKALA

Spurious Correlation

상관관계 vs 인과관계

아래 차트를 보자! 다우존스 지수와 제니퍼로렌스는 높은 관련성을 보인다

영화 개봉 등으로 '제니퍼로렌스'의 미디어 언급횟수가 증가할 때, 다우존스 투자를 고려해야 할까?



- 실제로는 인관관계가 없는데 수학 혹은 통계학 모델에 넣으면 큰 관계가 있는 것처럼 나오는 경우
- Data-driven approach 에서는 적지않게 발생되는 현상

SKALA

상관계수 해석의 유의사항

상관관계와 인과관계는 다르다

인과관계, Causality

- 한 변수(X)의 변화가 다른 변수(Y)의 변화를 유발하는 관계
- X가 변하면 Y도 그 영향으로 변하는 관계
- 시간적 선행성(원인은 결과보다 먼저 발생), 공변성(X가 변하면 Y도 함께 변함), 교란변수의 배제(X와 Y를 동시에 설명하는 다른 원인이 없어야 함) 이 요구

> Correlation does not imply Causality

- ✓ 상관은 인과를 의미하지 않는다 !
- ✓ 상관계수가 높더라도 우연일 수 있고 숨은 변수(교란변수)가 존재할 수 있으며 인과의 방향이 반대일 수도 있음
- ✓ 상관분석은 '함께 변하는가?'를 알려주지만, '왜 변하는가?'는 알려주지 않음

SKALA

데이터 분석 개요 및 기초통계

회귀 분석

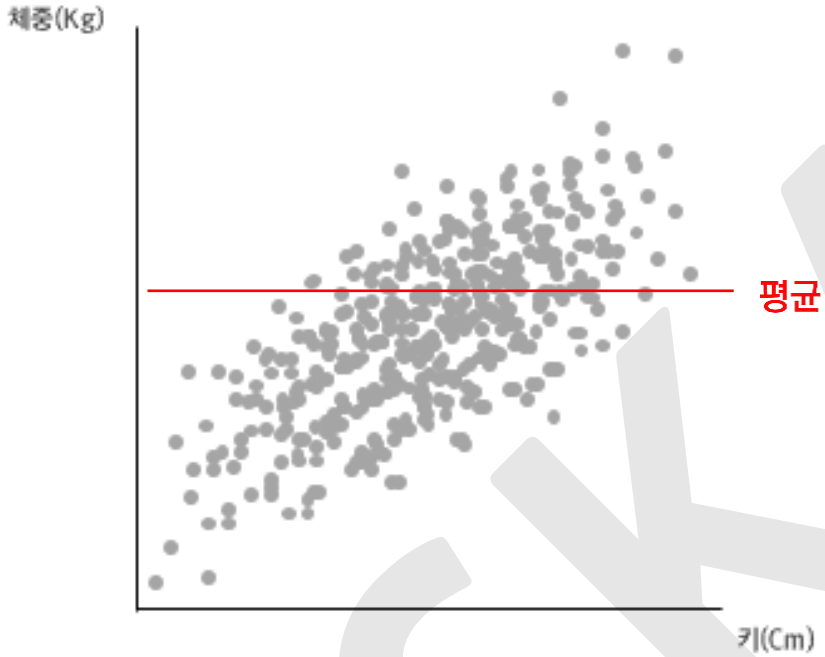
- 회귀분석의 직관적 이해
- 회귀모형의 평가
- 회귀결과의 해석

본 문서는 SK㈜AX의 컨텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

SK Inc. AX

회귀분석의 직관적 이해

Naïve Prediction



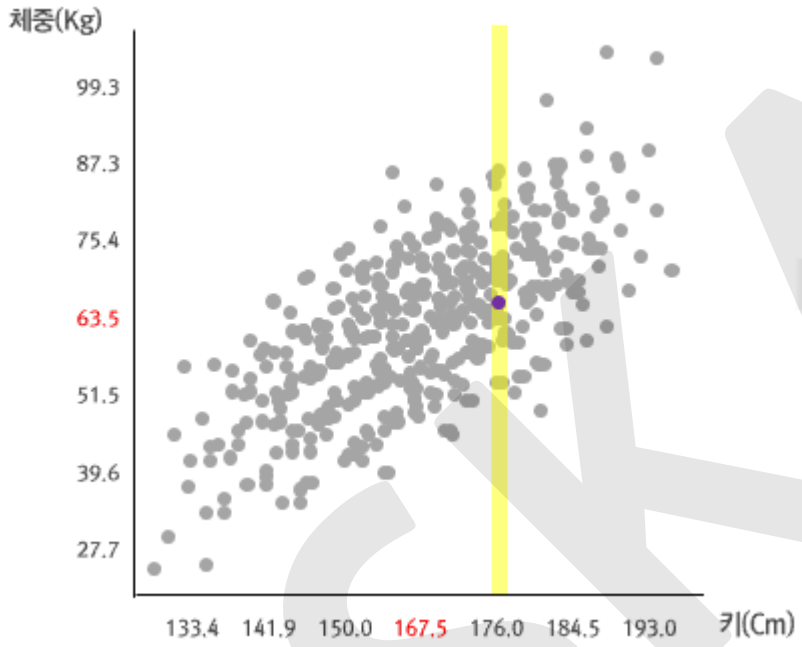
새로운 **x(키)**에 대한 **y(몸무게)**의 기대값(예측값)은?

SKALA

회귀분석의 직관적 이해

Naïve Prediction

x(키)가 176cm일때 몸무게(y)는 얼마일까?



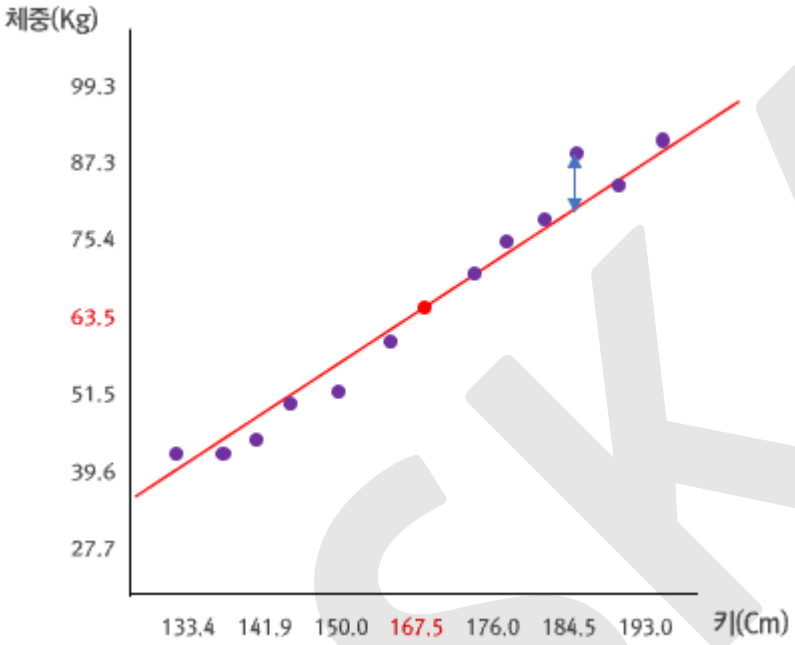
SKALA

회귀분석의 직관적 이해

하나의 직선으로 근사

회귀분석은 각각의 x값에 대응하는 y의 평균치를 추정하는 방법이고

평균의 그래프를 하나의 직선으로 근사 시킨 것이 회귀직선



세로띠 별 평균(키별 몸무게 평균)을 직선으로 근사해 보자

- 각각의 키마다 평균 몸무게를 구하자 → 보라색 포인트
- 이 점들을 근사하는 직선을 그어보자 → 회귀직선

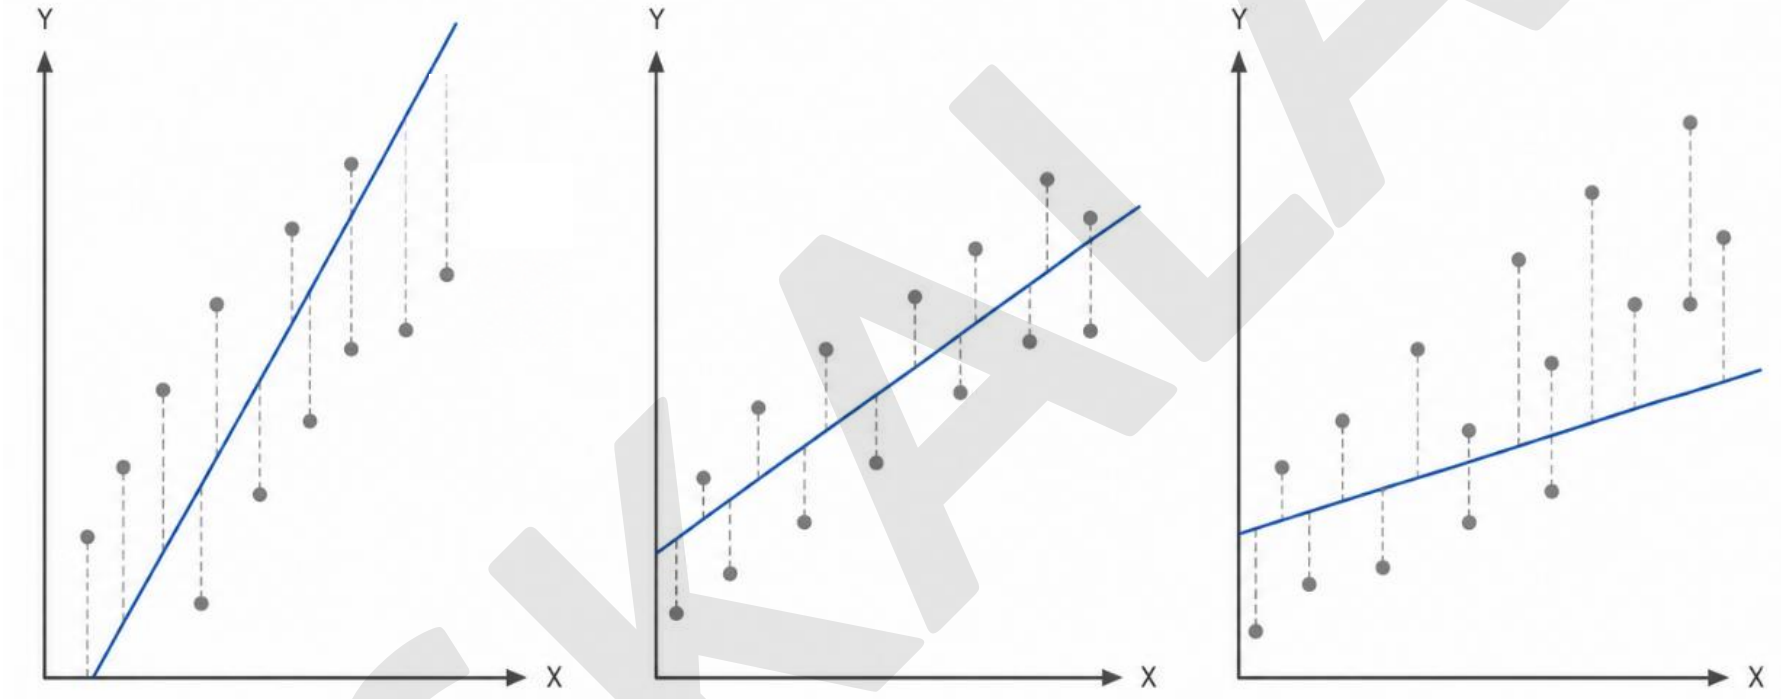
Think!

- 회귀직선은 평균의 그래프를 하나의 직선으로 근사 시킨 것이라면..
- 평균의 그래프가 비선형이면 회귀직선으로의 선형 근사는 부적절하지 않을까?

SKALA

회귀분석의 직관적 이해

좋은 직선의 기준은?



- ✓ '좋은 직선'이라는 것을 숫자로 표현해 본다면?
- ✓ 데이터와 직선사이의 거리, 즉 잔차(Residuals)들의 합이 작은 직선이 좋은 직선

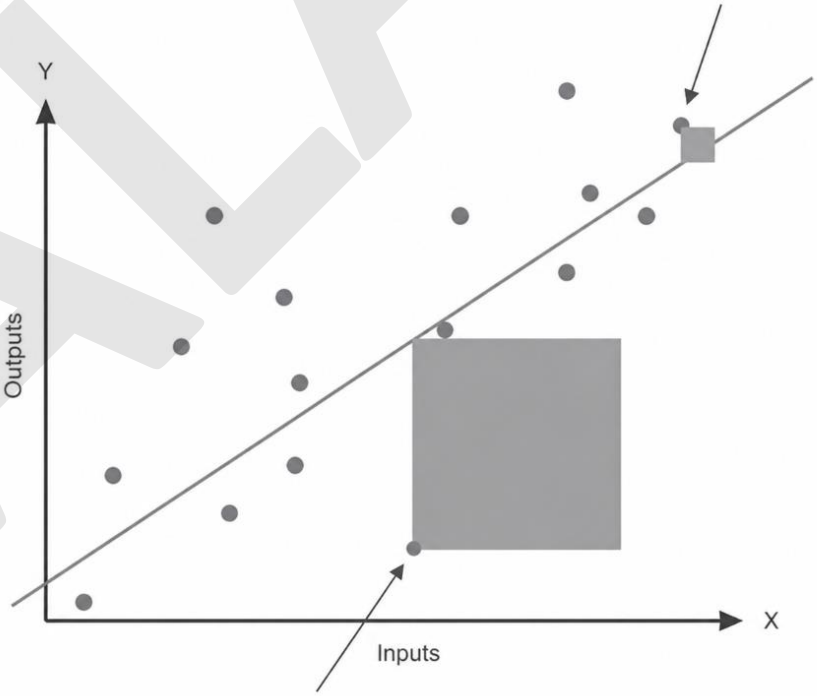
SKALA

회귀분석의 직관적 이해

Least Squares Method

최소제곱법(Least Squares Method)

- 실제 관측값과 예측값 사이의 오차(잔차)의 제곱합을 최소화하는 방식으로 회귀직선의 기울기와 절편(또는 회귀계수)을 구하는 방법
- OLS(Ordinary Least Squares) 와 같은 표현 = 전형적인 가정(일반적인 회귀조건) 하에 쓰이는 최소제곱법



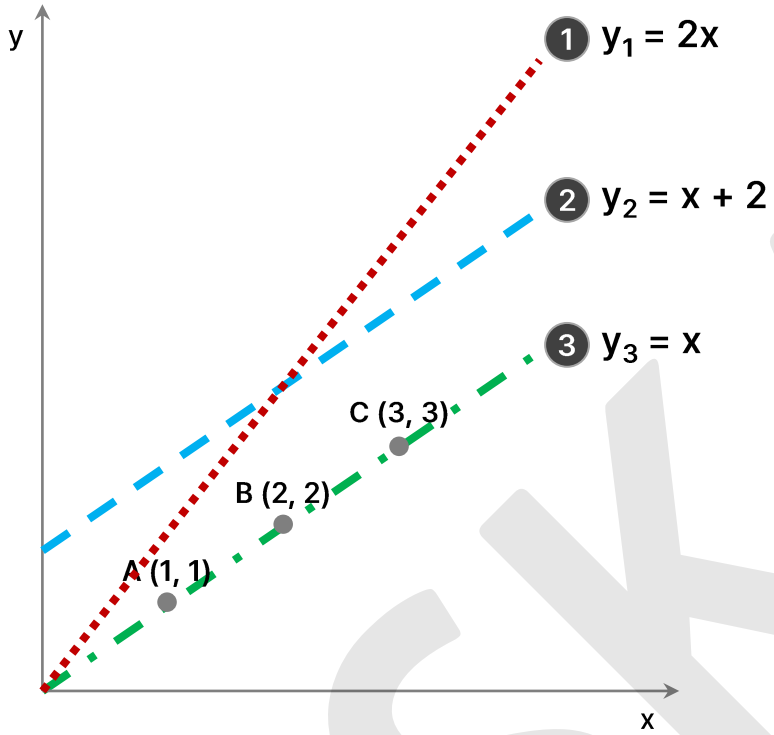
왜 제곱인가?

- 단순합은 Positive and Negative Residuals Cancel Out
- 큰 오차는 더 크게 패널티 : ex) 오차 2 → 4 , 오차 5 → 25
- 미분이 용이 : x^2 → 2x
- 제곱 함수는 u shape → 항상 하나의 해

SKALA

[참고] 회귀직선 비교

Least Squares Method



$\sum$ 잔차^2 = $\sum$ (관측값 – 예측값)^2 → MIN

Train Data	x, y (관측값)	1 y_1 (예측값)	2 y_2 (예측값)	3 y_3 (예측값)
		= 2x	= x + 2	= x
A	1, 1	2 (= 2 * 1)	3 (= 1 + 2)	1
B	2, 2	4 (= 2 * 2)	4 (= 2 + 2)	2
C	3, 3	6 (= 2 * 3)	5 (= 3 + 2)	3
$\sum$ 잔차^2		$(1-2)^2 + (2-4)^2 + (3-6)^2$	$(1-3)^2 + (2-4)^2 + (3-5)^2$	$(1-1)^2 + (2-2)^2 + (3-3)^2$
		14	12	0

잔차^{2}의 합이 최소가 되게 하는 직선 찾기 → 최소제곱법으로 회귀선의 함수를 구함

SKALA

회귀분석의 직관적 이해

Least Squares Method

최소제곱법(Least Squares Method)

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$$

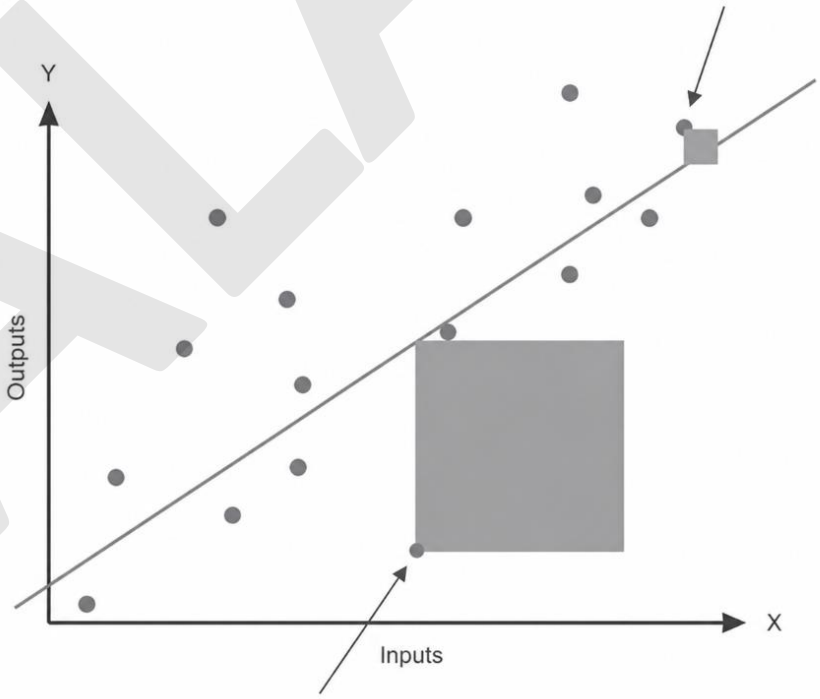
- 목적함수

$$\min_{\beta_0,\beta_1} \sum_{i=1}^{n} (y_i - \beta_0 - \beta_1 x_i)^2$$

- OLS 추정

$$\hat{\beta}_1 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{n}(x_i - \bar{x})^2} \qquad \hat{\beta}_1 = \frac{\mathrm{Cov}(X,Y)}{\mathrm{Var}(X)}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

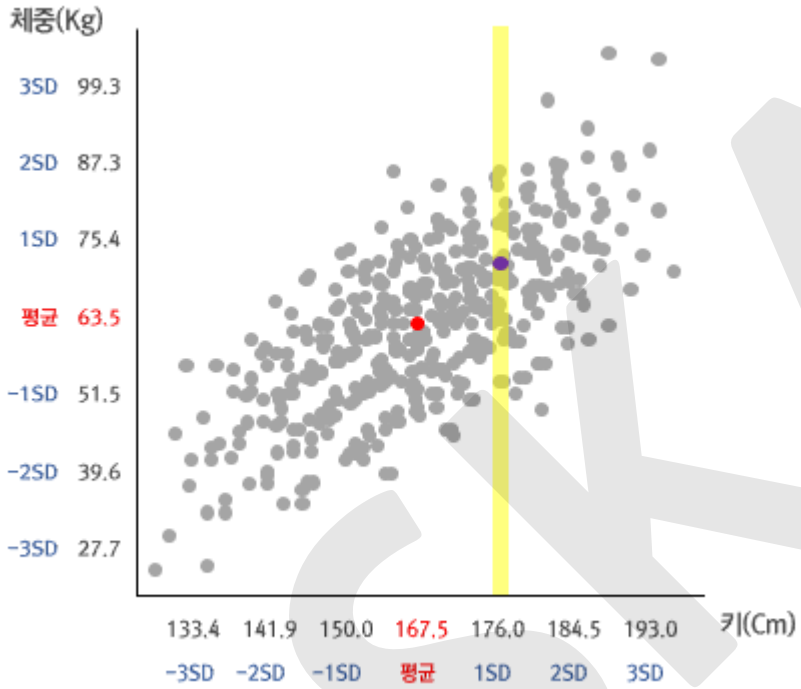


SKALA

회귀분석의 직관적 이해

회귀직선과 상관계수의 만남

x(키)가 1단위 증가하면 y(몸무게)는 평균적으로 몇 단위나 증가할까?



<u>평균보다 **1**표준편차 만큼 큰 **176cm**인 사람의 몸무게는**?**</u>

- 평균키(167.5cm) + 표준편차(8.5cm) = 176cm
- 그러므로 이때 몸무게는
- 평균 몸무게(63.5kg) + 표준편차(11.9kg) = 75.4kg

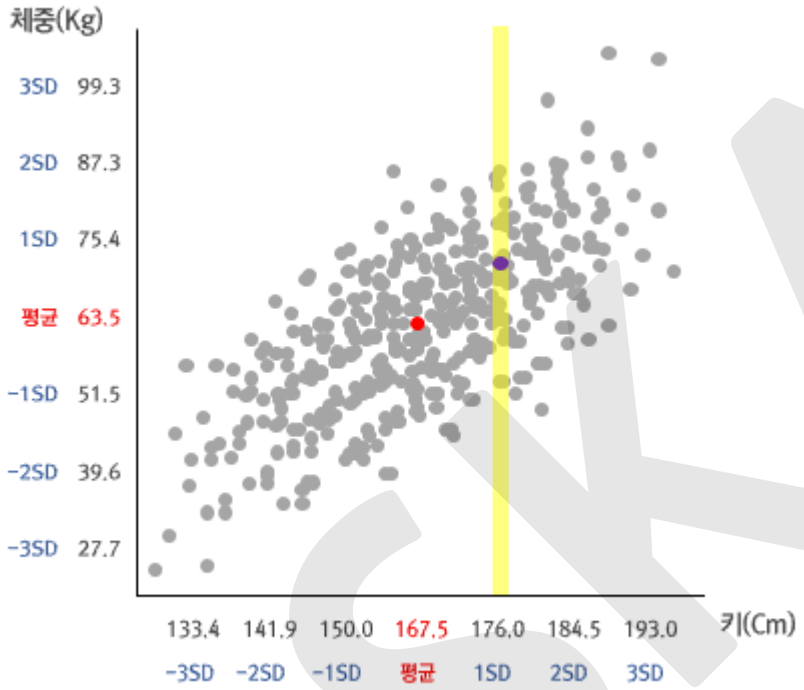
→ 정답일까?

SKALA

회귀분석의 직관적 이해

회귀직선과 상관계수의 만남

x(키)가 1단위 증가하면 y(몸무게)는 평균적으로 몇 단위나 증가할까?



<u>평균보다 **1**표준편차 만큼 큰 **176cm**인 사람의 몸무게는**?**</u>

- 평균키(167.5cm) + 표준편차(8.5cm) = 176cm
- 그러므로 이때 몸무게는
- 평균 몸무게(63.5kg) + 표준편차(11.9kg) = 75.4kg

[Solution]

- 평균몸무게(63.5kg) + 상관계수0.67 * 표준편차(11.9kg)
- = 63.5kg + 약8kg = 약71.5kg

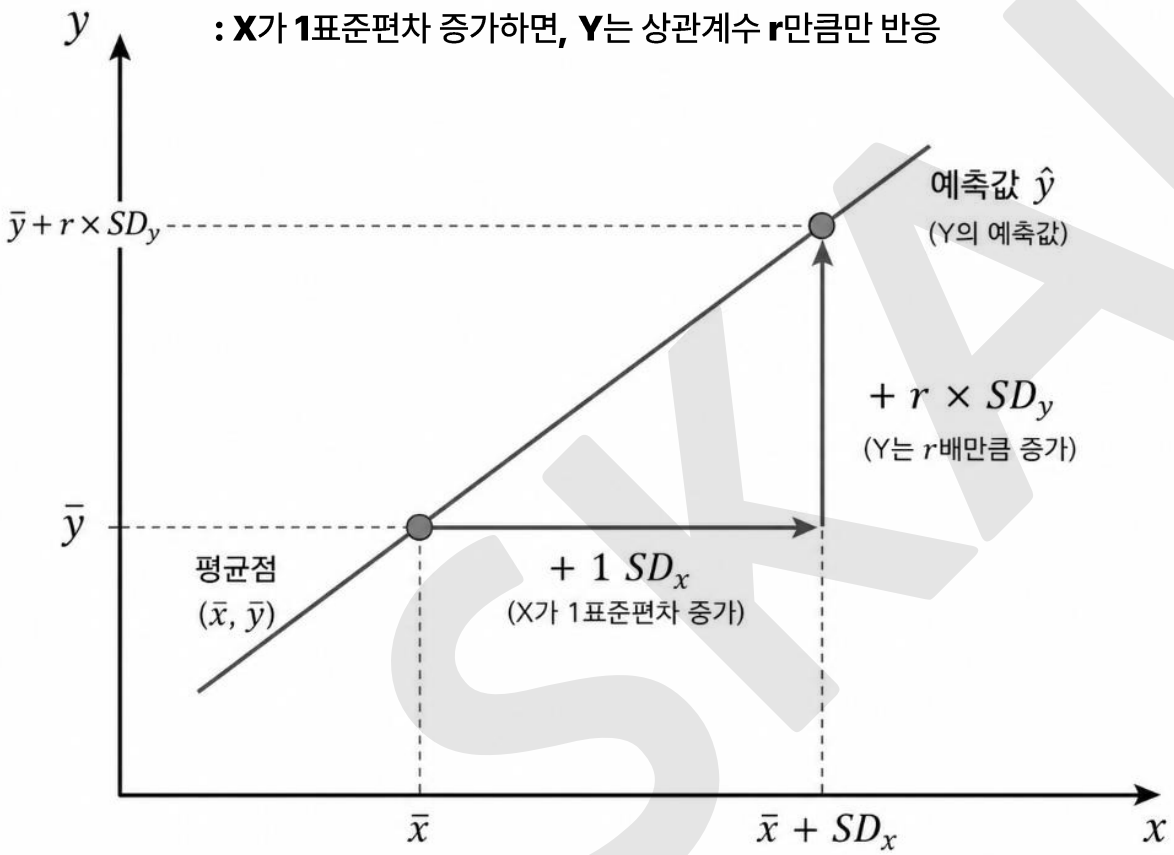
SKALA

회귀분석의 직관적 이해

회귀직선과 상관계수의 만남

상관계수 r은 Y가 얼마나 따라갈지를 결정하는 비율

: X가 **1**표준편차 증가하면**, Y**는 상관계수 **r**만큼만 반응



- r = 1 → y는 1SD 만큼 이동
- r= 0.5 → y는 0.5 SD 만큼 이동
- r=0 → Y는 이동하지 않음

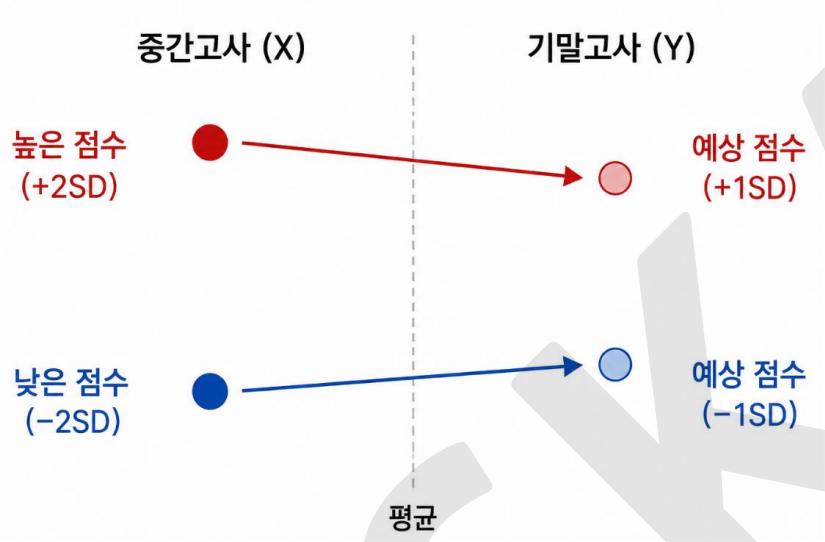
$$b = r \frac{SD_y}{SD_x}$$

SKALA

회귀효과, Regression to the mean

평균으로의 회귀, 평범으로 돌아간다

중간고사에서 평소 실력보다 잘 본 학생들은 기말고사에서도 똑같이 잘 볼까?



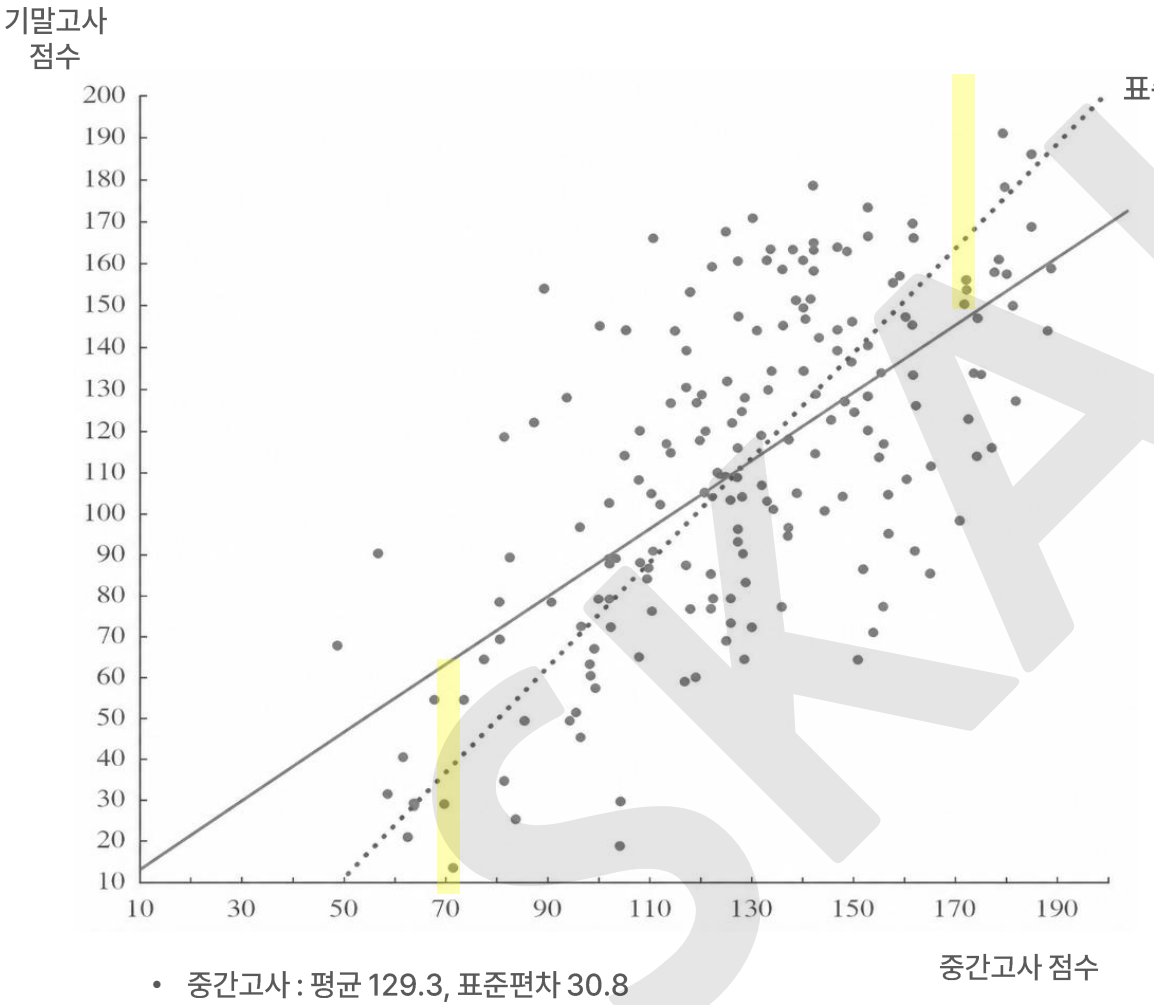
Concept

- 극단적인 관측값(extreme observation)은 다음 측정에서 평균(평균값 또는 기대값)에 더 가까워지는 경향이 있다는 현상
- 극단적인 수치는 일시적인 요인(운, 실수, 특이한 상황 등)의 영향을 받았을 가능성이 크기 때문
- 다시 측정하면 이런 일시적인 요인이 사라지면서, 결과가 평균으로 "회귀"

SKALA

회귀효과, Regression to the mean

평균으로의 회귀, 평범으로 돌아간다



- 중간고사 : 평균 129.3, 표준편차 30.8
- 기말고사 : 평균 112.4, 표준편차 40
- 상관계수 0.64

회귀 효과와 상관계수

- 상관계수가 0에 가까울수록 (|r| < 0) 회귀직선에 의한 예측값은 평균으로 더 강하게 끌어당겨짐
- 즉 회귀효과는 상관계수가 0에 가까워질수록 커짐

SKALA

회귀 모형의 평가

RMSE(Root Mean Squared Error)

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(\hat{y}_i - y_i)^2}$$

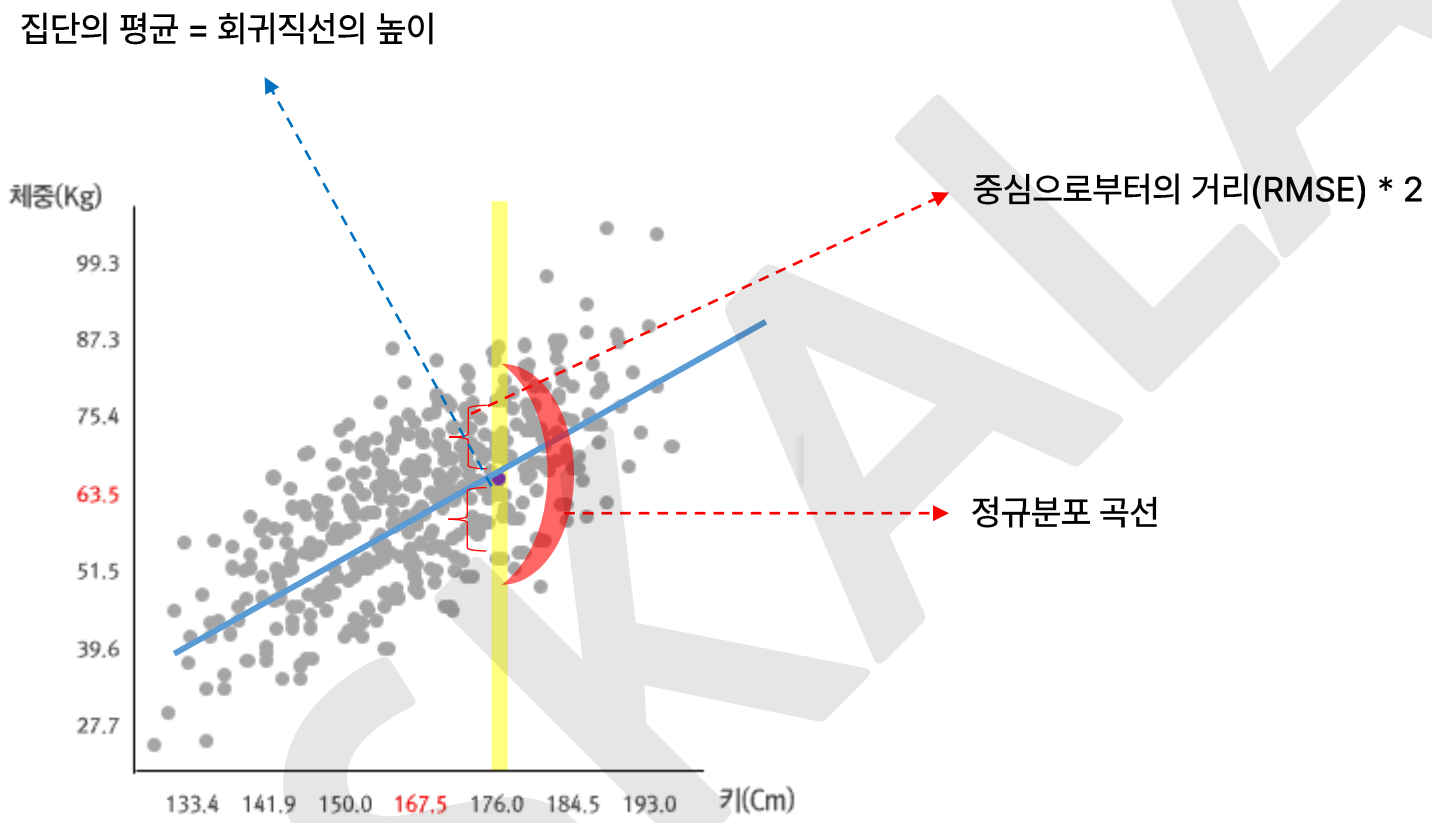
- 잔차(residual) = 실제값- 예측값
- 실제값(Actual)과 예측값(Predict)의 평균적인 차이, 즉 잔차(residual)의 전형적인 크기를 측정하는 것이 목적
- MSE에 제곱근을 취하여 Target과 단위를 동일하게 함으로써, 해석성 확보

- 추정의 표준오차(standard error of estimate) 또는 회귀의 표준오차 (standard error of regression)라고도 불림

SKALA

회귀 모형의 평가

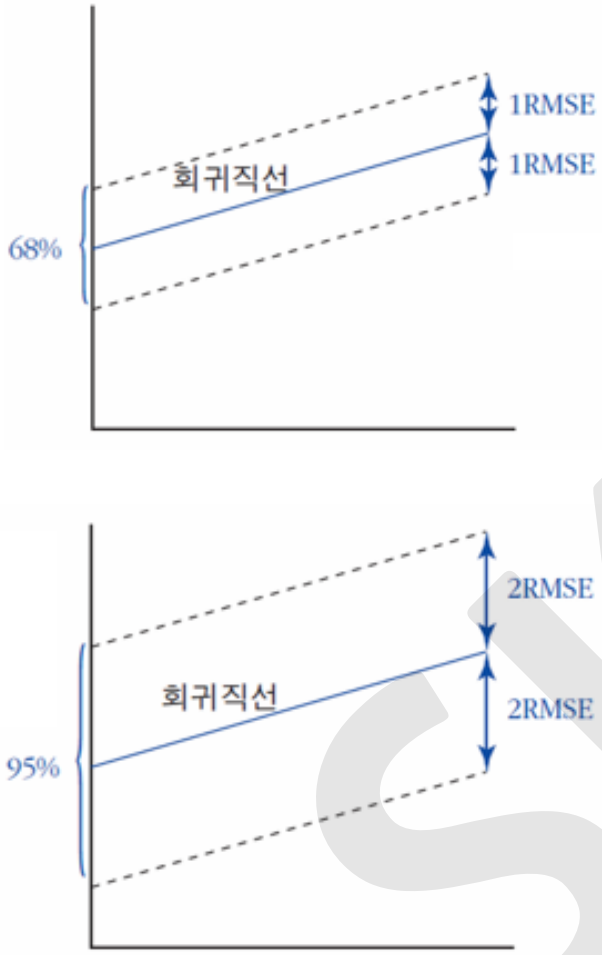
회귀직선과 RMSE 그리고 68-95-99.7의 법칙

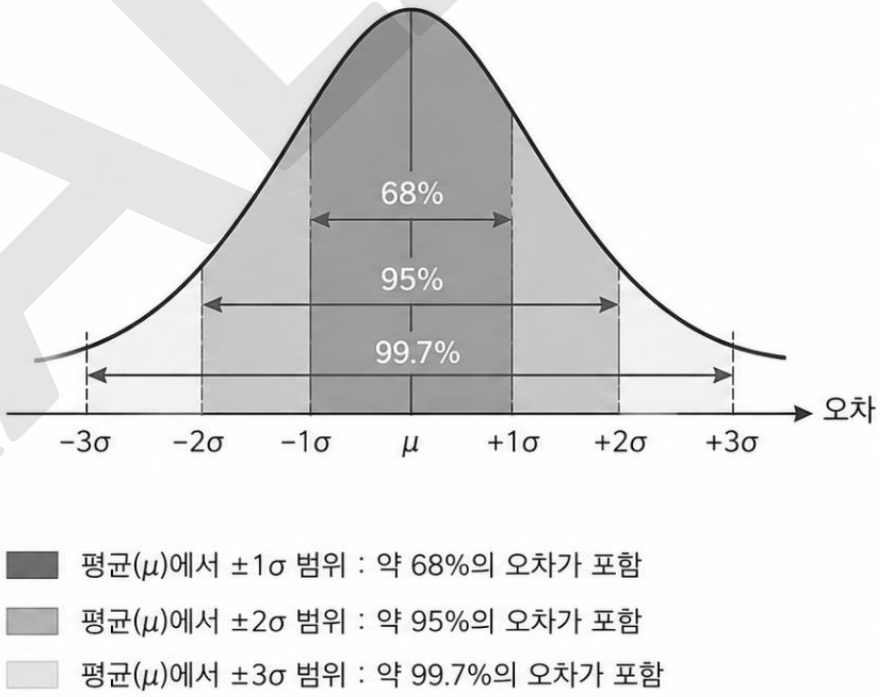


SKALA

회귀 모형의 평가

회귀직선과 RMSE 그리고 68-95-99.7의 법칙



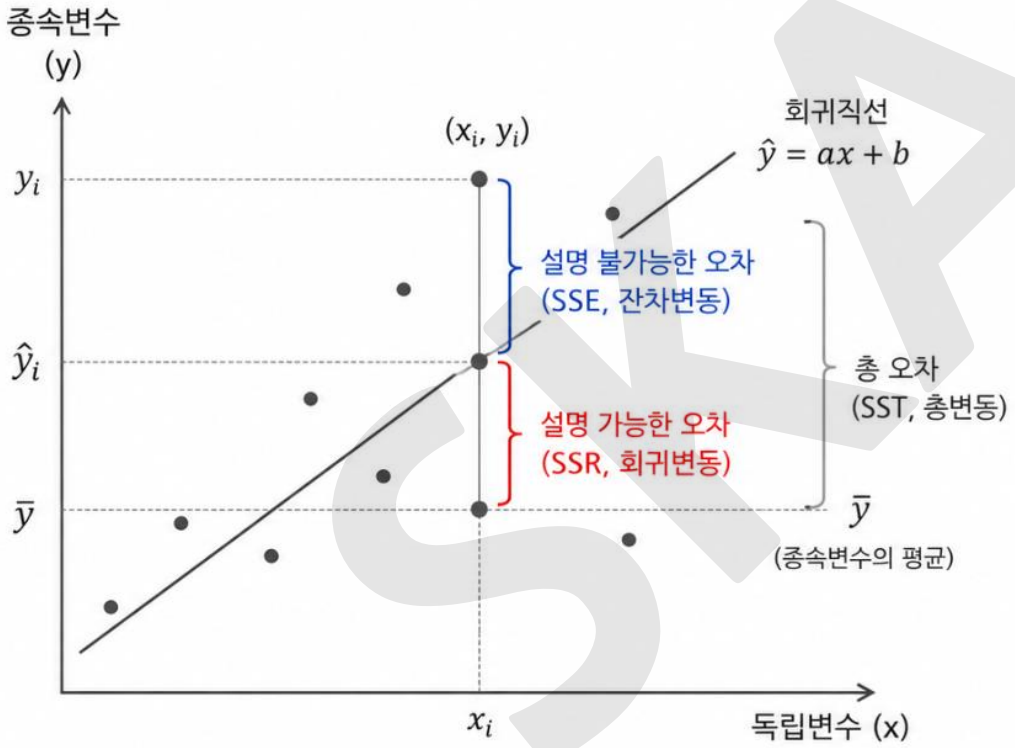


SKALA

회귀 모형의 평가

R-Squared

- 결정계수, Coefficient of Determination, R-Squared, R^2, 설명력
- 적합된 회귀선이 주어진 데이터를 얼마나 잘 설명하고 있는가? = Goodness of Fit의 관점
- 결정계수가 높을수록 독립변수가 종속변수를 많이 설명함으로 해석 (0.0~1.0)
- R Squared 0.6 = 원인변수의 분산이 결과변수의 분산을 60% 설명하고 있다.



$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}$$

SST: Sum of Squares Total
SSR: Sum of Squares Regression
SSE: Sum of Squares Error

SKALA

회귀분석 결과의 해석

Biz 상황

- 기업에서 상품 A에 대한 마케팅을 강화하여 구매 고객수를 증가시키고자 한다.

분석 목적

- 쿠폰 배포 매수와 판매가격 중 어떤 요인이 구매 고객수에 더 큰 영향을 미치는가?
- 쿠폰 배포 매수와 판매가격을 조정하면 예상되는 구매 고객수는 얼마인가?
- y = 구매 고객수

요약 출력

회귀분석 통계량	
다중 상관계수	0.879
결정계수	0.773
조정된 결정계수	0.735
표준 오차	27.565
관측수	15

분산 분석

	자유도	제곱합	제곱 평균	F 비	유의한 F
회귀	2	30983.225	15491.613	20.389	0.000
잔차	12	9117.708	759.809		
계	14	40100.933			

	계수	표준 오차	t 통계량	P-값
Y 절편	274.375	45.401	6.043	5.817E-05
쿠폰배포매수(장)	0.109	0.017	6.326	3.795E-05
판매가격(원)	0.003	0.014	0.242	8.130E-01

회귀식 (회귀모델)

$$y = 0.109 \cdot x_1 + 0.003 \cdot x_2 + 274.375$$

y : 구매고객수

x_1 : 쿠폰배포매수(장), x_2 : 판매가격(원)

SKALA

회귀분석 결과의 해석

요약 출력

회귀분석 통계량	
다중 상관계수	0.879
결정계수	0.773
조정된 결정계수	0.735
표준 오차	27.565
관측수	15

분산 분석

	자유도	제곱합	제곱 평균	F 비	유의한 F
회귀	2	30983.225	15491.613	20.389	0.000
잔차	12	9117.708	759.809		
계	14	40100.933			

	계수	표준 오차	t 통계량	P-값
Y 절편	274.375	45.401	6.043	5.817E-05
쿠폰배포매수(장)	0.109	0.017	6.326	3.795E-05
판매가격(원)	0.003	0.014	0.242	8.130E-01

모델의 적합성

- Adjusted R^2 : 모델이 전체 변동의 73.5%를 설명
- 변수를 추가할수록 R^2는 증가 → 다변수일경우 Adjusted R^2 확인
- Standard Error : 예측이 평균적으로 ±27.565 틀림

ANOVA Table

- SSR, SSE, SST의 분산을 검증
- Prob (F-statistic) : Significance F, 회귀식이 의미있는 모델인지 검정, 0.000으로 회귀 모델이 통계적으로 유의

Coefficients Table

- P-value : 95%신뢰수준에서 $p < 0.05$ 면 해당 계수값은 통계적으로 유의함
- Y절편과 쿠폰배포매수는 통계적으로 유의하지만, 판매가격은 0.813 으로 유의하지 않음 → 변수제거 후 모형 재개발 검토

회귀분석 결과의 해석

유의한 변수로 재적합된 회귀모델

$$y = 0.108 \cdot x_1 + 282.892$$

y : 구매고객수, x_1 : 쿠폰배포매수(장)

요약 출력

회귀분석 통계량	
다중 상관계수	0.866
결정계수	0.749
조정된 결정계수	0.730
표준 오차	27.810
관측수	15

분산 분석

	자유도	제곱합	제곱 평균	F 비	유의한 F
회귀	1	30047.056	30047.056	38.852	0.000
잔차	13	10053.877	773.375		
계	14	40100.933			

	계수	표준 오차	t 통계량	P-값
Y 절편	282.892	35.390	7.994	2.256E-6
쿠폰배포매수(장)	0.108	0.017	6.233	3.053E-5

- ✓ 판매가격은 구매 고객수에 유의한 영향을 확인하지 못하였다. → 제거 후 모형 재적합
- ✓ 재적합된 회귀모형은 통계적으로 유의하며, 구매 고객수 변동의 약 73%를 설명한다.
- ✓ 쿠폰 배포 매수는 구매 고객수에 유의한 영향을 미친다
- ✓ 다른 조건이 동일하다면, 쿠폰을 10장 추가 배포할 때 구매 고객수는 평균적으로 약 1.08명 증가할 것으로 예측된다.
- ✓ 쿠폰을 3,000장 배포할 경우 회귀모형에 따르면 예상 구매 고객수는 약 607명이다

SKALA

회귀분석 결과의 해석

Key Question

- ✓ R^2 : 모델이 데이터를 얼마나 잘 설명하는가?
- ✓ P-value : 어떤 변수가 실제로 영향을 미치는가?
- ✓ Coefficient : 변수의 영향력과 방향(+, −)은 무엇인가?
- ✓ RMSE(Standard Error) : 평균적으로 얼마나 틀리는가?
- ✓ F-test : 모델 전체가 유의한가?

SKALA

데이터 분석 개요 및 기초통계

선형모형 가정

- 회귀방정식의 가정
- 불편 추정량
- 강건성

본 문서는 SK㈜AX의 컨텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

SK Inc. AX

회귀분석 결과, 그대로 믿어도 될까?

회귀모형의 가정은 분석 결과를 신뢰하고 해석하기 위한 전제조건

회귀분석의 목적

- 독립변수와 종속변수의 관계를 설명하고
- 각 변수가 결과에 미치는 영향을 해석하며
- 관측되지 않은 값이나 미래의 결과를 예측하고
- 표본에서 발견한 관계를 모집단으로 일반화하는 것

회귀모형의 가정이 충족되지 않는다면?

- 회귀계수의 크기와 방향 해석이 어려워 짐
- 표준오차, p-value 결과를 신뢰하기 어려움
- 새로운 데이터에 대한 예측 성능이 떨어질 수 있음

> 회귀분석을 실행하면
> 회귀식, R^2, 회귀계수, p-value가 계산 되지만,
> 결과가 산출되었다고 해서 그 결과를 신뢰할 수 있는 것은 아님
>
> 회귀모형의 기본가정을 충족하는지 확인해야 함

SKALA

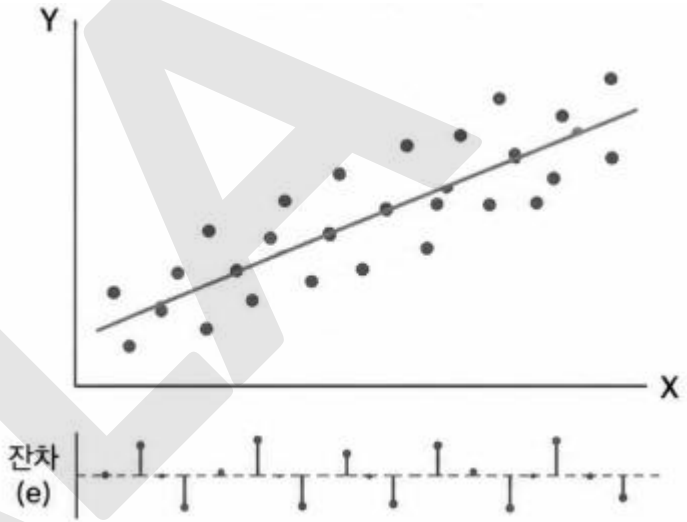
회귀분석의 가정

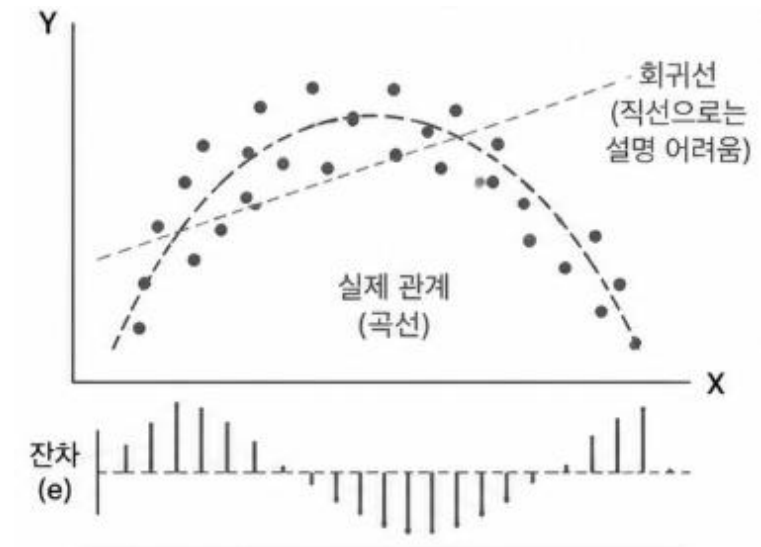
선형성(Linearity)

Concept

- 독립변수와 종속변수의 관계가 직선으로 표현될 수 있어야 한다는 성질
- 즉, X가 증가하면 Y는 평균적으로 일정한 방향으로 변화
- 선형회귀는 직선 하나를 찾는 모델, 관계가 직선이 아니라면 회귀식은 데이터를 제대로 설명하지 못함

- "X와 Y의 평균적인 관계가 직선으로 설명될 수 있는가?"





SKALA

회귀분석의 가정

독립성(Independence)

Concept

- 각 관측치의 오차는 다른 관측치의 오차와 서로 영향을 주고받지 않아야 하는 성질
- 예를 들어 오늘의 예측 오차가 양수였기 때문에 내일도 양수가 되는 경향이 반복된다면, 오차들이 서로 독립적이지 않은 것
- 오차들이 서로 연관되어 있으면 실제로는 중복된 정보가 포함된 것과 비슷한 효과가 발생

독립성 위반이 자주 발생하는 데이터

- 시계열 데이터: 매출, 주가, 기온, 센서값
- 공간 데이터: 인접 지역의 집값, 환경오염도
- 반복 측정 데이터: 한 사람의 혈압을 여러 번 측정

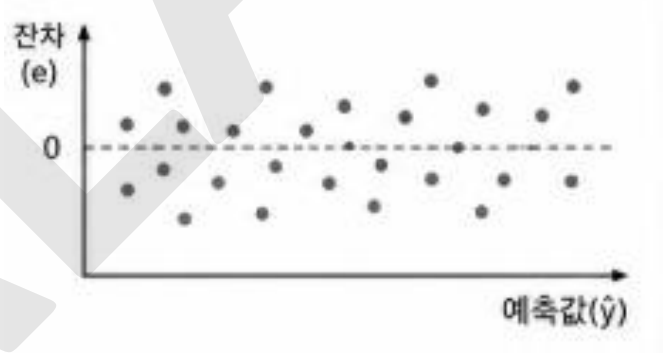
SKALA

회귀분석의 가정

등분산성(Homoscedasticity)

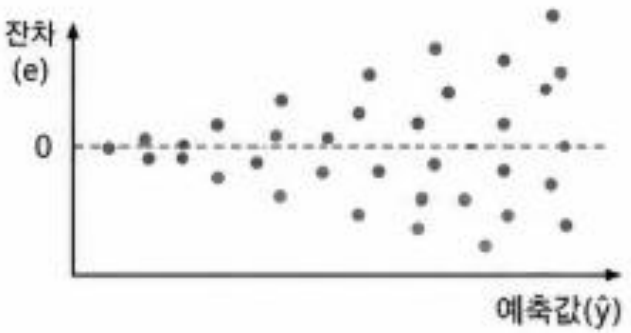
Concept

- 예측값의 크기와 관계없이 잔차의 분산(퍼짐)은 일정해야 한다는 성질
- "잔차의 퍼짐이 일정한가?"
- 등분산성은 오차가 작은지를 보는 것이 아니라, 오차의 '퍼짐'이 일정한지를 보는 가정



잔차의 분산이 일정하지 않으면..

- 이분산성(Heteroscedasticity)
- 표준오차가 왜곡되고, p-value가 부정확해질 수 있으며 변수의 유의성을 잘못 판단할 수 있음



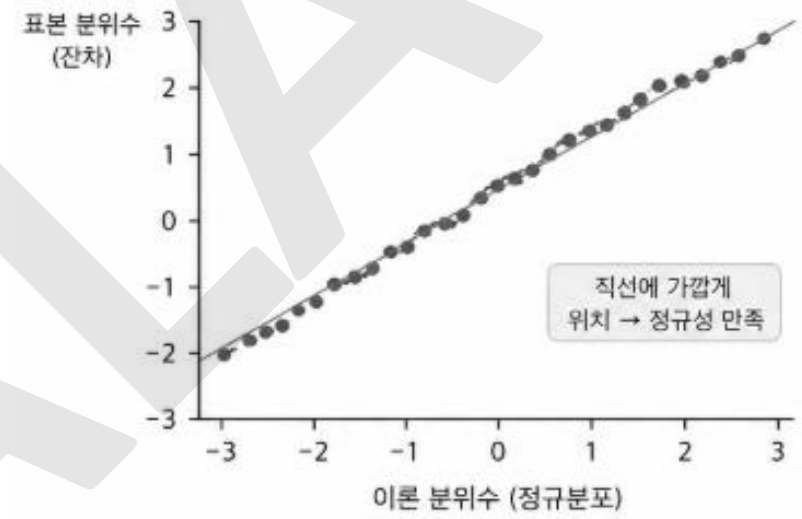
SKALA

회귀분석의 가정

정규성(Normality)

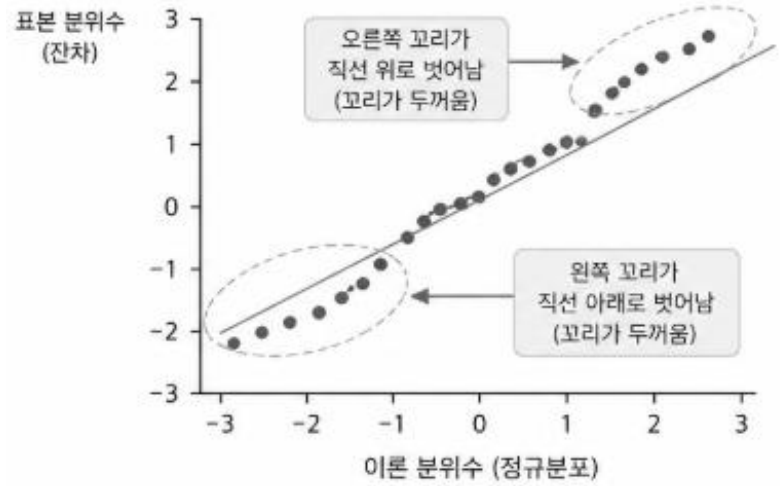
Concept

- 회귀분석에서는 오차(잔차)가 평균이 0인 정규분포를 따른다는 성질
- 즉, 큰 오차는 드물고 작은 오차가 가장 많이 발생하는 형태
- "데이터 자체가 정규분포여야 한다.“ → 대표적 오해



왜 필요한가?

- 회귀계수는 정규성이 없어도 계산됨
- 통계적 추론을 위해서는 정규성이 필요
  - 회귀계수의 유의성 검정(t-test)
  - 전체 모형 검정(F-test)
  - p-value / 신뢰구간 계산
- "회귀식을 계산하기 위한 가정"이 아니라"회귀 결과를 해석하기 위한 가정 " 에 가까움
- 실무에서는 데이터가 충분히 많으면 정규성 위반이 큰 문제가 되지 않는 경우가 많음 (중심극한정리)



SKALA

회귀분석의 가정

다중공선성(No Multicollinearity)

Concept

- 독립변수들(X) 사이에 강한 상관관계가 존재하는 현상
- 독립변수들이 서로 거의 같은 정보를 가지고 있으면 각 변수의 고유한 영향을 구분하기 어려워짐
- 독립변수와 종속변수가 상관이 높으면 안 된다? → X, 오히려 좋은 상황
- 독립변수끼리 상관이 높으면 안 된다 → O, 다중 공선성 존재

어떤 문제가 발생하나?

- 회귀계수가 불안정해짐
- 변수의 중요도를 해석하기 어려움 → 변수의 영향력을 해석(Interpretation)하는데 심각한 문제를 초래
- 중요한 변수가 유의하지 않은 것처럼 나타날 수 있음

SKALA

잔차는 모든 것을 말해준다

회귀 가정이 만족하는지 무엇을 보고 판단할까?

✓ 회귀모형의 가정 중 대부분은 잔차(Residual)를 통해 확인

회귀모형의 가정	잔차(Residual) 관점에서 확인할 사항	잔차가 위배될 때 나타나는 현상
선형성 (Linearity)	잔차에 특정한 패턴이 없어야 한다(Random)	잔차가 곡선(U자형, S자형 등) 패턴을 보인다.
독립성 (Independence)	잔차들끼리 서로 상관이 없어야 한다.	잔차가 시간이나 순서에 따라 연속적인 패턴을 보인다.
등분산성 (Homoscedasticity)	잔차의 퍼짐(분산)이 예측값 전체에서 일정해야 한다.	잔차의 퍼짐이 점점 커지거나 작아진다(깔때기 모양).
정규성 (Normality)	잔차가 정규분포를 따라야 한다.	잔차의 히스토그램 또는 Q-Q Plot이 정규분포에서 크게 벗어난다.

SKALA

잔차 가정의 수학적 표현

Assumption

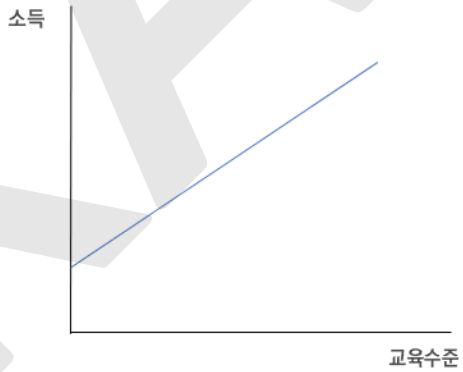
$$Y_i = \beta_1 + \beta_2 X_i + e_i \quad (i = 1, 2, \ldots n)$$

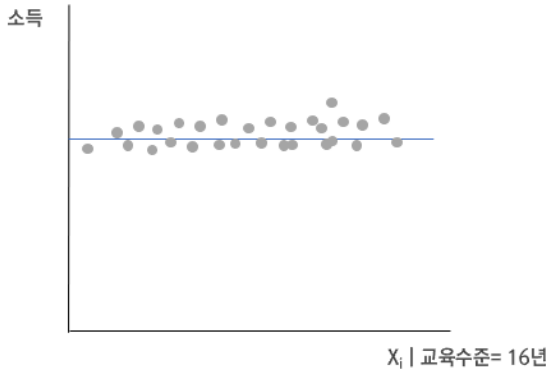
Assumption1. $E(e_i) = 0, \quad \forall_i$

Assumption2. $E(e_i^2) = Var(e_i) = \sigma^2, \quad \forall_i$

Assumption3. $E(e_i \cdot e_j) = Cov(e_i \cdot e_j) = 0, \quad i \neq j$

- 교육수준(x) 와 소득(y)을 예시로 생각해보자
- ei의 기대값이 0이라는 것은 평균보다 많이 소득을 얻거나 적게 얻을 수 있지만, 모두 합산했을 때 이들이 상쇄되어 그 합이 0 이라는 것





SKALA

잔차 가정의 수학적 표현

Assumption

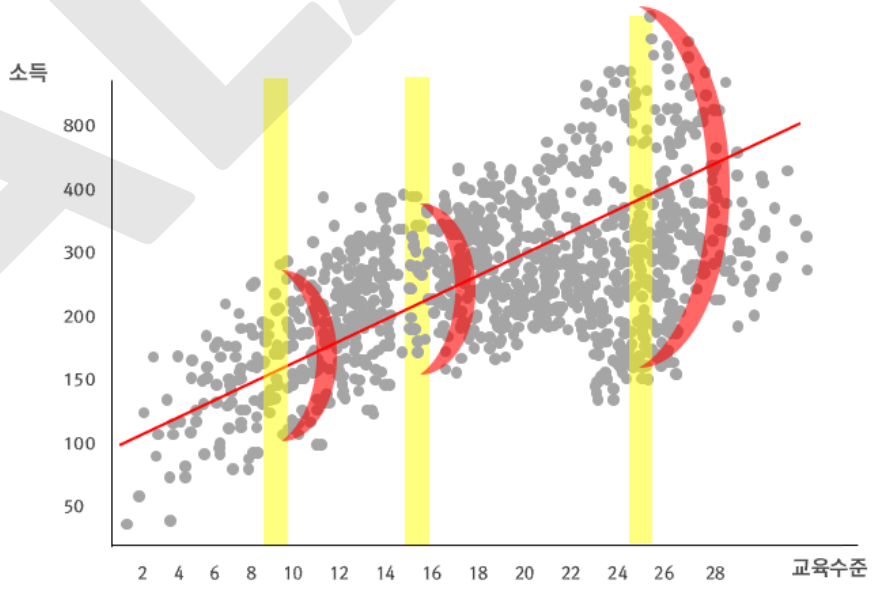
$$Y_i = \beta_1 + \beta_2 X_i + e_i \quad (i = 1, 2, \ldots n)$$

Assumption1. $E(e_i) = 0, \quad \forall_i$

Assumption2. $E(e_i^2) = Var(e_i) = \sigma^2, \quad \forall_i$

Assumption3. $E(e_i \cdot e_j) = Cov(e_i \cdot e_j) = 0, \quad i \neq j$

- 교육수준이 상관없이, 즉 xi가 어떤 값을 가지더라도 ei의 분포는 똑같다는 것(등분산)



- 교육수준 16년일 때의 평균소득이 500만원이고 약 90%사람들이 500만원 +- 50만원에서 소득을 얻는다면..
- 교육수준 22년일 때의 평균소득이 800만원이라면 약 90%사람들이 800만원 +- 50만원에서 소득을 얻는다는 의미
- 현실적인가?

SKALA

잔차 가정의 수학적 표현

Assumption

$$Y_i = \beta_1 + \beta_2 X_i + e_i \quad (i = 1, 2, \ldots n)$$

Assumption1. $E(e_i) = 0, \quad \forall_i$

Assumption2. $E(e_i^2) = Var(e_i) = \sigma^2, \quad \forall_i$

Assumption3. $E(e_i \cdot e_j) = Cov(e_i \cdot e_j) = 0, \quad i \neq j$

- 서로 다른 ei 들 사이에는 아무런 관계가 없음을 의미
- 자기상관(Auto Correlation, Serial Correlation) 이 없다는 의미와 동일

SKALA

불편 추정량(Unbiased estimator)

우리가 제대로 추정하고 있는 것일까?

- 불편성이란, 어떤 모수의 추정량의 기댓값이 원래 모수가 되는 성질
- 표본 분산에 대해 평균을 내면 모집단의 분산(variance)이 되는데, 이를 불편 추정량(unbiased estimator)이라고 함. 말그대로 편의가 없는, 치우침이 없는 정확한 추정량이라는 것

Proof of Var(hat{B_2})

$$Y_i = \hat{\beta}_1 + \hat{\beta}_2 X_i + \hat{e}_i$$

$$Var(\hat{\beta}_2) = E[\hat{\beta}_2 - E(\beta_2)]^2$$

$$= E[\hat{\beta}_2 - \beta_2]^2$$

...

$$= \frac{\frac{\alpha^2}{n-1}}{Var(X)}$$

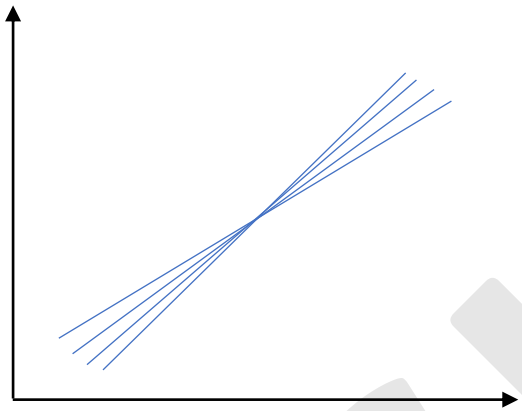
$Var(e_i) = \sigma^2$,
,n = sample count

SKALA

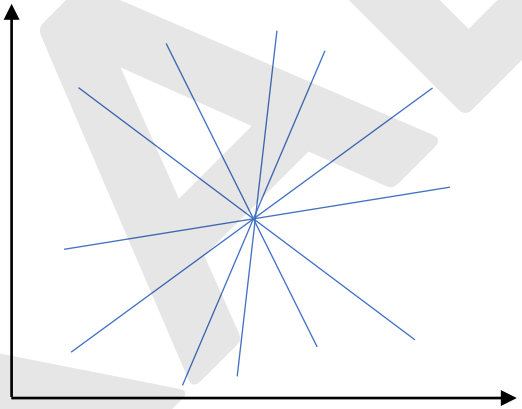
불편 추정량(Unbiased estimator)

우리가 제대로 추정하고 있는 것일까?

- 불편성이란, 어떤 모수의 추정량의 기댓값이 원래 모수가 되는 성질
- 표본 분산에 대해 평균을 내면 모집단의 분산(variance)이 되는데, 이를 불편 추정량(unbiased estimator)이라고 함. 말그대로 편의가 없는, 치우침이 없는 정확한 추정량이라는 것



Var(hat{B_2}) 가 작은 경우



Var(hat{B_2}) 가 큰 경우

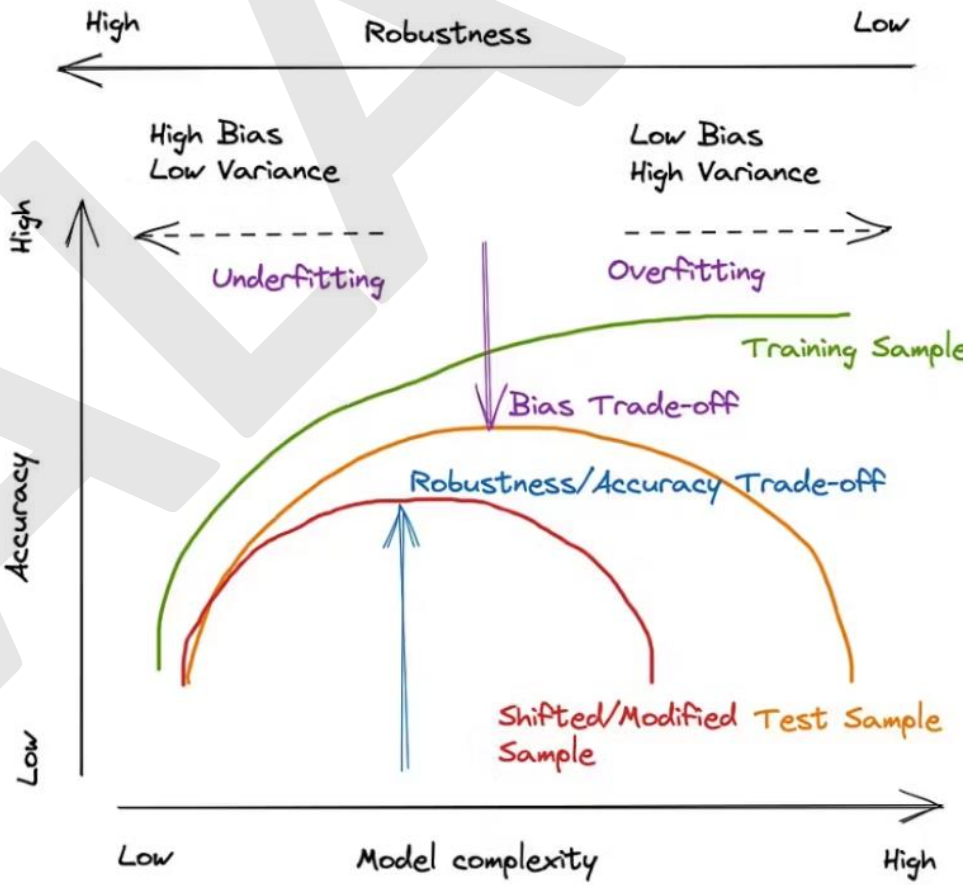
SKALA

강건성(Robustness)

모형의 복잡도와 강건성

- 간경성이란 다양한 상황, 예상치 못한 데이터, 환경변화에도 견고한 성능을 유지하며 안정적으로 예측력을 제공하는 능력
- 노이즈가 추가되거나 어떤 조건이 바뀌어도 성능이 크게 변하지 않는..
- 인풋값의 작은 변화에도 아웃풋값이 크게 변하지 않는..

- 견고한 모델은 불확실한 현실 세계 시나리오에 대응하고 예측값에 대한 신뢰도를 높일 수 있음
- 데이터 증대&품질 향상, 일반화 노력은 모델의 견고성을 높이는 대표적 수단
- 모델의 동작을 이해할 수 있는 설명력은 견고한 모델을 구축하는데 도움을 줌



https://medium.com/@slavadubrov/understanding-machine-learning-robustness-why-it-matters-and-how-it-affects-your-models-5e2cb5838dab

SKALA

수고하셨습니다.

본 문서는 SK㈜AX의 컨텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.