SKALA

데이터분석 및 AIOps

모델개발 및 최적화

2026.07

본 문서는 SK(주)AX의 컨텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

SK Inc. AX



1. 분석 프로세스 이해
2. 데이터 준비
3. Feature Engineering
4. 모델 학습 및 최적화
5. 모델 평가
6. 모델 해석
7. 모델 모니터링

데이터 분석 및 AIOps

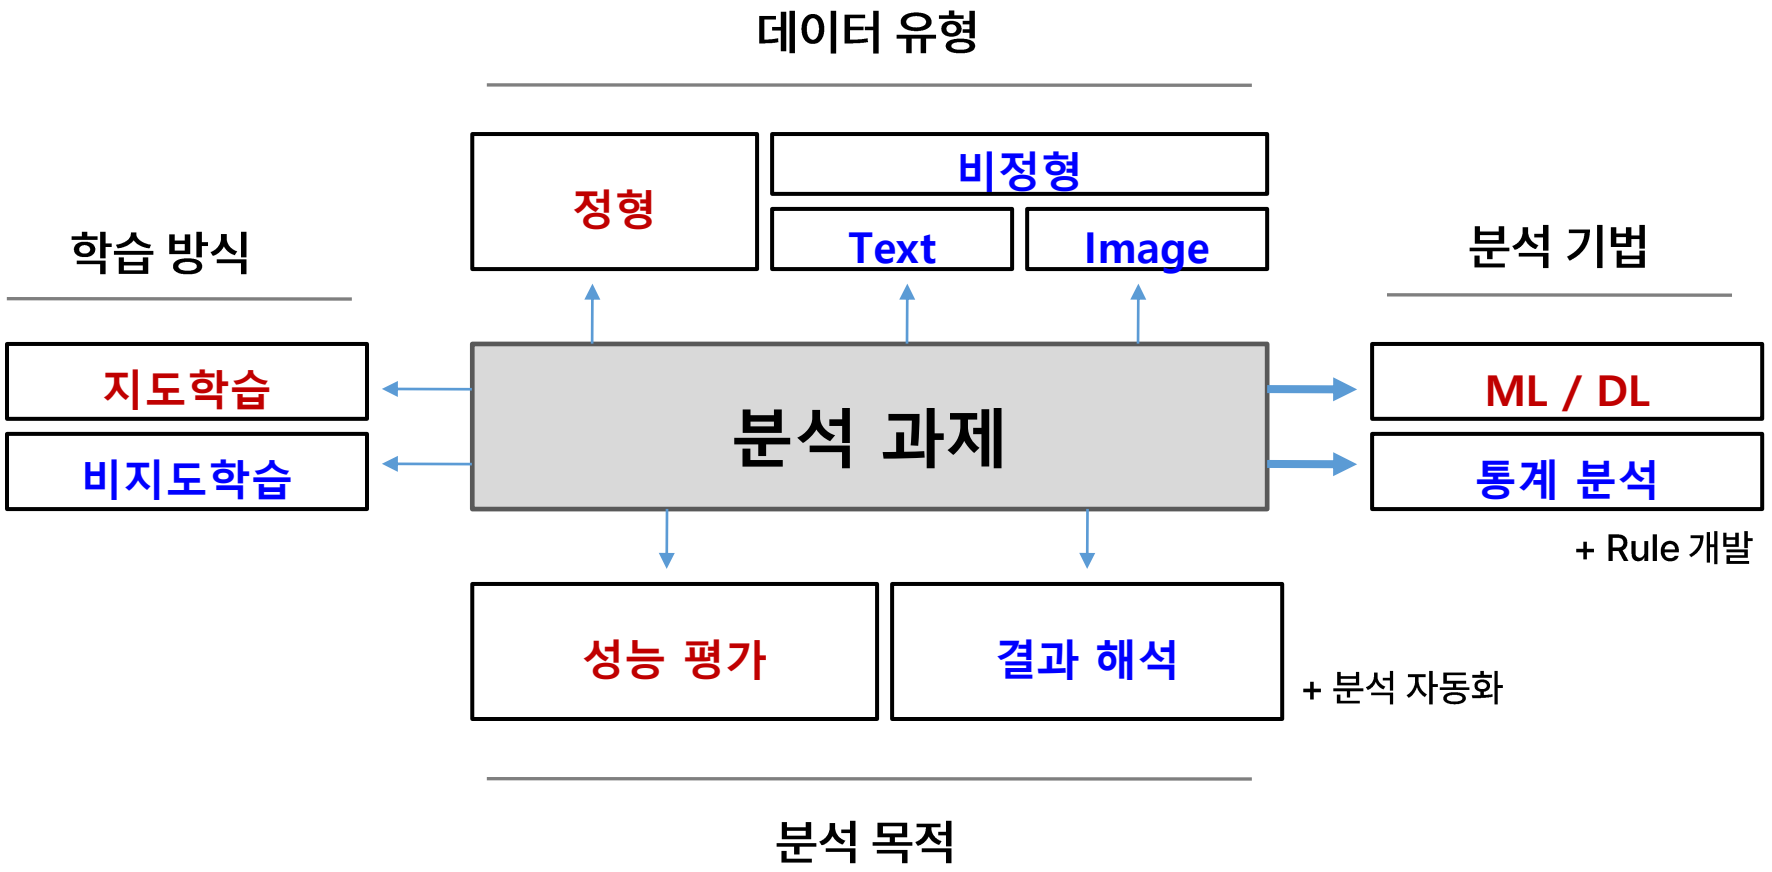
1. 분석 프로세스 이해

- 데이터 분석 프로세스
- 시나리오 기반 분석 프로세스 이해

본 문서는 SK㈜AX의 컨텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

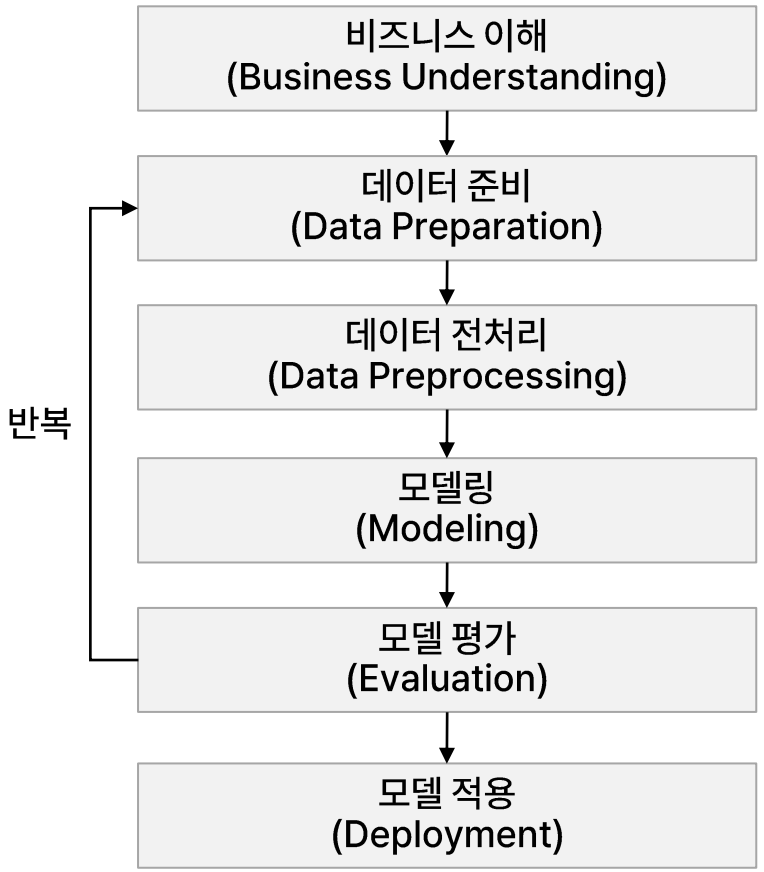
SK Inc. AX

데이터 분석 분류 체계


데이터 유형
정형
비정형
Text
Image
학습 방식
분석 기법
지도학습
비지도학습
분석 과제
ML / DL
통계 분석
+ Rule 개발
성능 평가
결과 해석
+ 분석 자동화
분석 목적

데이터 분석 프로세스

데이터 분석 과제를 수행하기 위해 실제로 진행하는 단계별 작업 절차



- 문제 정의, 목표 설정, 분석 기준 정의
- 산출물 : 분석 기획서, 분석 요건 정의서

- 데이터 수집 및 통합, 데이터 탐색 (EDA), 품질 점검
- 산출물 : 필요 데이터 정의서

- 데이터 정제, 변환, 파생변수 생성
- Feature Engineering (Feature 생성 / 변환 / 선택)

- 모델 알고리즘 선정 (통계분석 / ML / DL)
- 모델 학습 및 최적화

- 모델 성능 평가, 모델 결과 해석
- 산출물 : 모델 결과 보고서

- 운영 시스템 적용 및 운영, 모델 모니터링
- 산출물 : 운영자/사용자 매뉴얼

시나리오 기반 분석 프로세스 이해

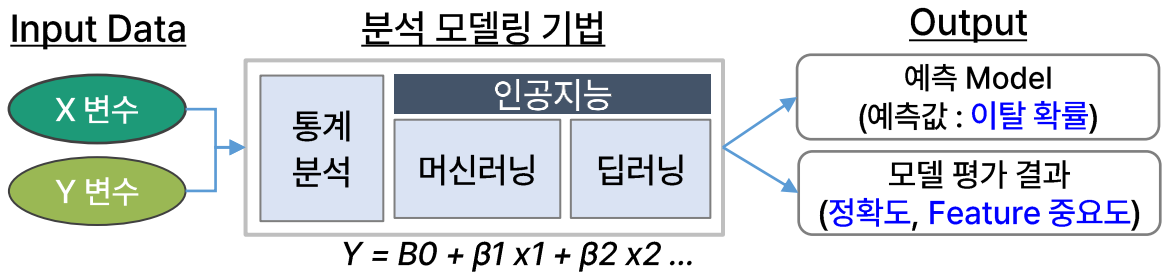
문제 정의부터 분석 모델링까지의 개념적 흐름

문제 정의 (개념적 정의)

데이터 및 분석 요건 정의 (조작적 정의)

분석 수행

분석 주제	• [보험사 고객 이탈 예측] 어떤 특성을 가진 고객들이 미래에 이탈할 것인가?
Target 정의 (Y)	• 이탈 정의: 보험을 해지하거나, 보험료를 2개월 동안 납입하지 않은 고객
Feature 도출 (X)	• 이탈에 영향을 주는 잠재적 특징 변수 : 고객 특성 (성별, 연령, 직업), 거래 특성 (거래기간, 납입금액, 미납경험) 등
분석 요건 정의	• 분석 모집단 정의, 분석 기간 설정 등 • 분석 기법 선정 (분류 모델)
분석 모델링 (Modeling)	• 분석 모델링 : X와 Y의 관계 (함수 / Rule) 를 찾아 가능 과정 • (관련 용어) Learning (학습), Training ...

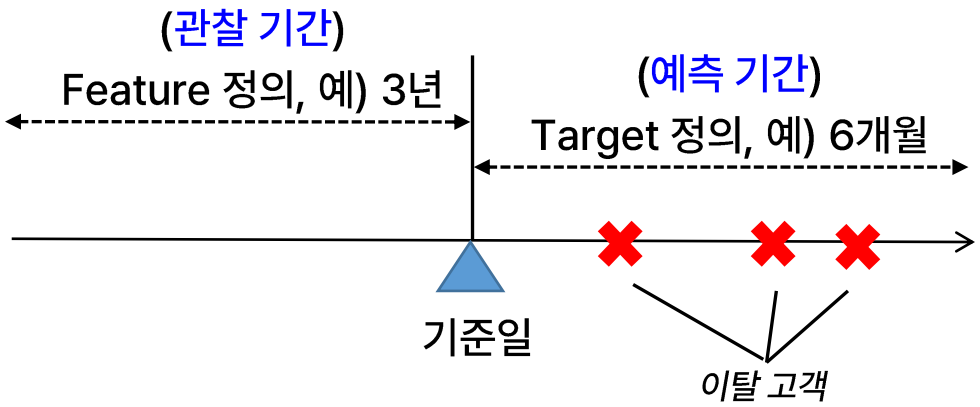


[참고] 분석 기간 종류

관찰 기간, 예측 기간

- 관찰 기간 : Observation Window, Feature를 수집하는 과거 기간, X 변수 생성 기간
- 예측 기간 : Target Window, Target 을 판단하는 미래 구간, Y 변수 생성 기간
- 기준일 : Reference Date, 미래를 예측하는 기준 시점

예시) 고객 이탈 예측 모형



➔ *이탈 예측 모형의 의미*

: 과거 3년간의 고객 행동 데이터를 기반으로, 미래 6개월 내 이탈 여부를 예측하는 모델

데이터 분석 및 AIOps

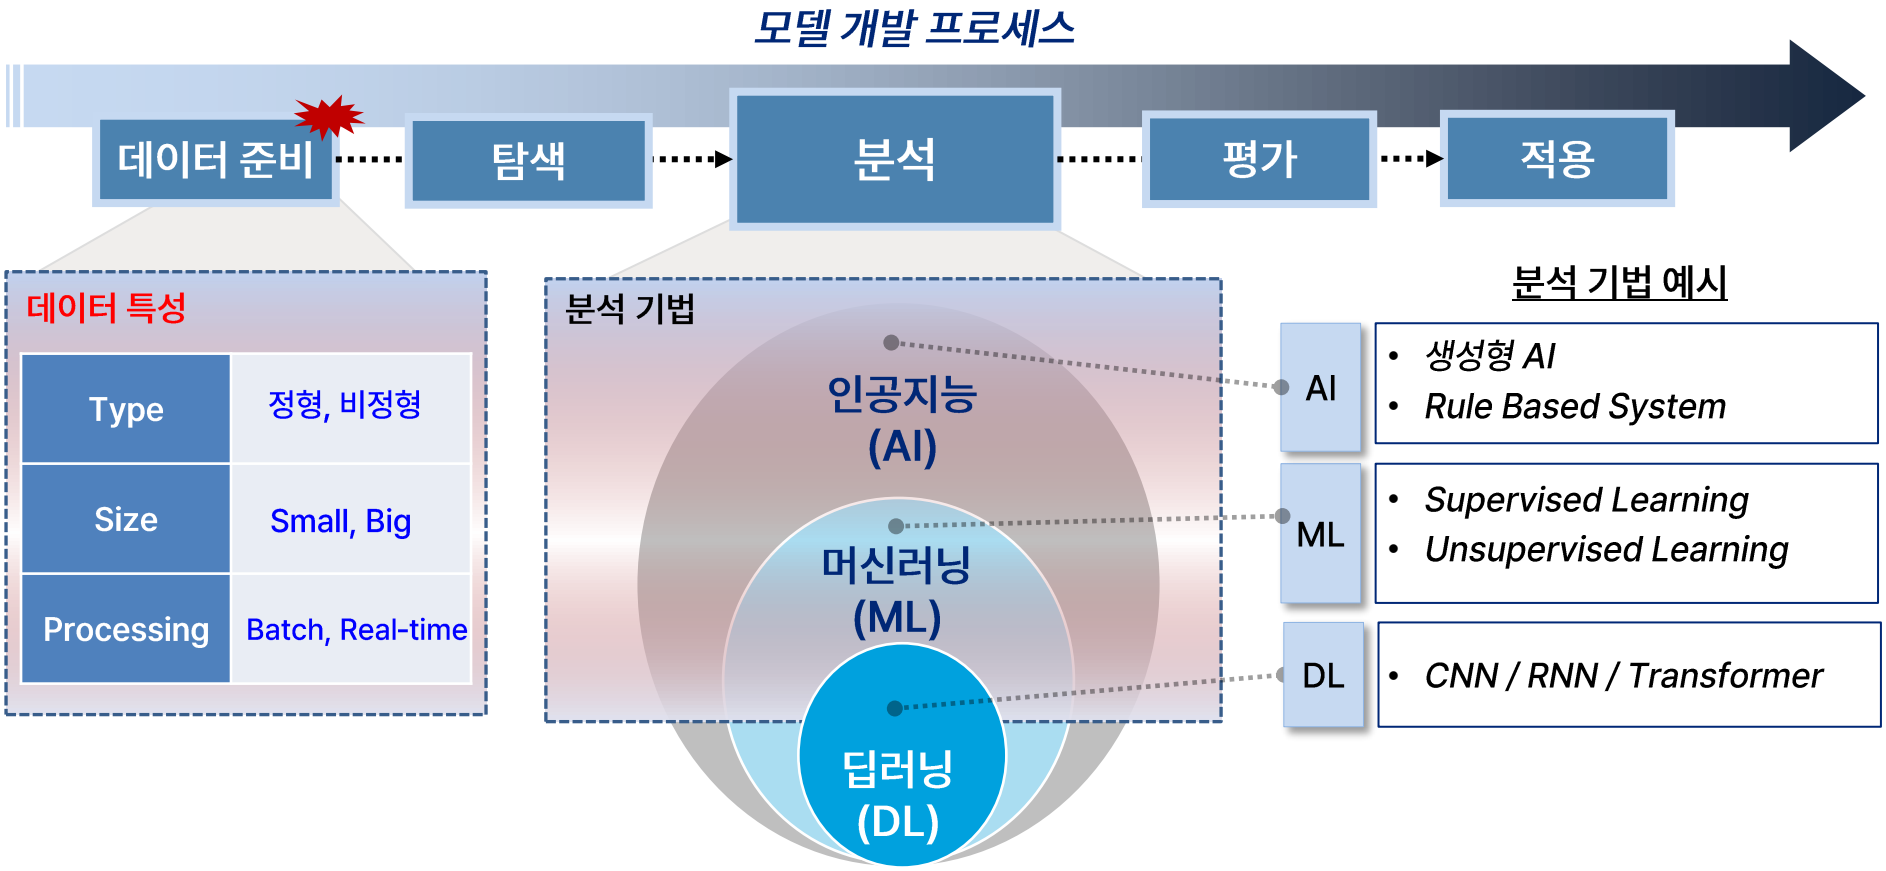
2. 데이터 준비

- 데이터 준비 중요도
- 데이터 품질 이슈
- 데이터 처리 용어

본 문서는 SK㈜AX의 컨텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

데이터 특성 이해

데이터 특성에 따른 모델 전략이 필요



데이터 특성에 따른 모델 전략

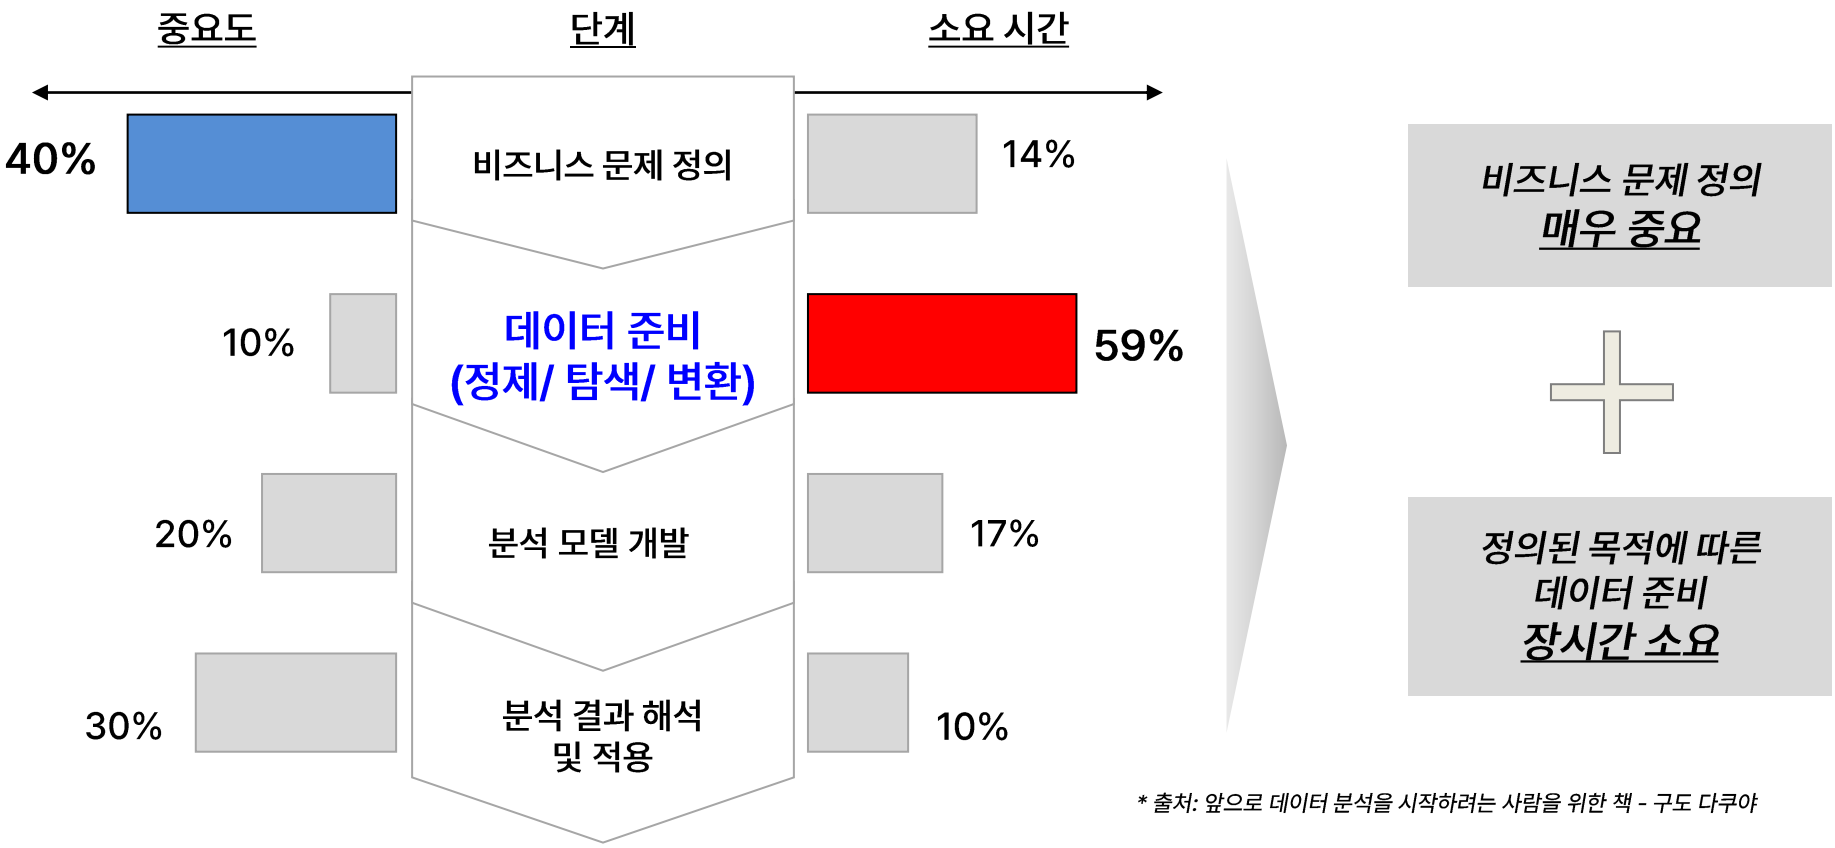
동일한 유형의 문제(예: 예측/분류) 라도 데이터 특성이 다르면 최적 전략도 달라짐

데이터 특성		모델 전략 예시
Type	정형	• 고정 스키마 (행·열) • Feature Engineering + ML
	비정형	• 텍스트/ 이미지/ 음성 등 • 대규모 사전학습 모델 +Fine Tuning, DL
Size	Small	• 데이터 증강 전략 • 복잡도가 낮은 모델, 비지도 학습, Rule Based 전략
	Big	• 모델 보다 학습/추론 인프라, 자동화 설계가 중요
Processing	Batch	• 일정 주기로 대량 데이터 처리 방식, 복잡한 모델과 Feature 사용 가능 • 예시) 일일 상품 추천 모델
	Real-time	• 모델 정확도 보다 “답변 응답 시간, 운영 안정성”이 더 중요 • 예시) 실시간 상품 추천 모델

데이터 준비: 가장 시간이 많이 드는 단계

데이터 준비는 분석 단계 중 노력 측면에서는 가장 많은 시간이 소요됨

분석 단계 별 중요도 및 소요 시간 비율

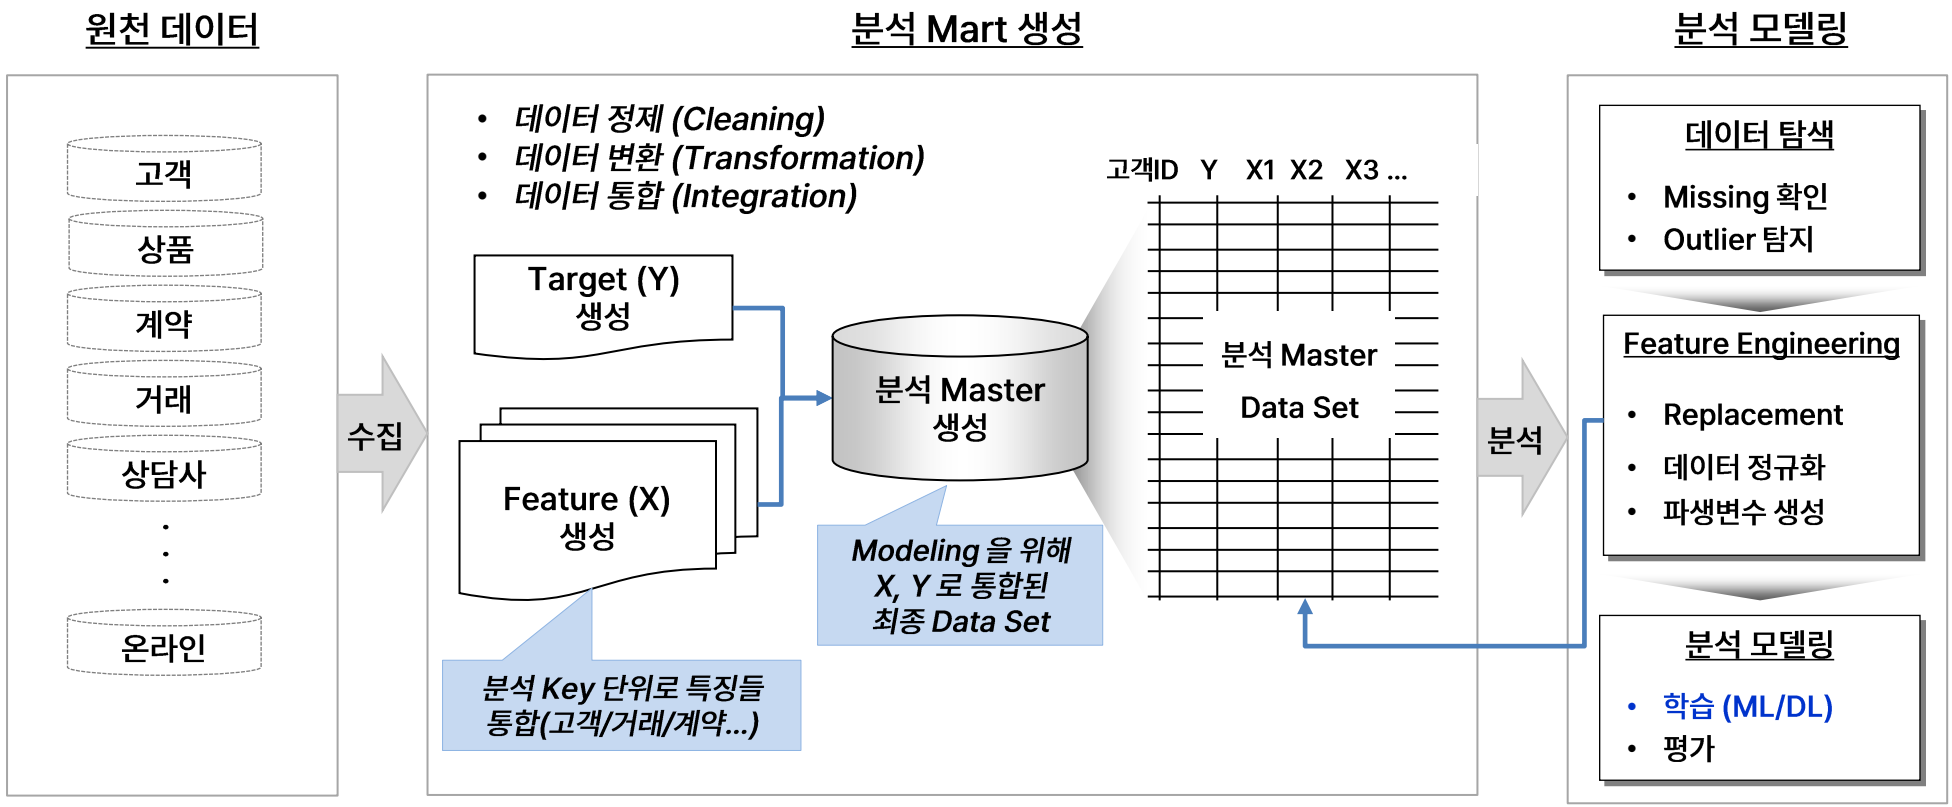


** 출처: 앞으로 데이터 분석을 시작하려는 사람을 위한 책 - 구도 다쿠야*

데이터 구축 프로세스

원천 데이터 수집 후 데이터 통합, 정제 등을 거쳐 학습 데이터셋 준비

모델개발을 위한 데이터 구축 프로세스 예시

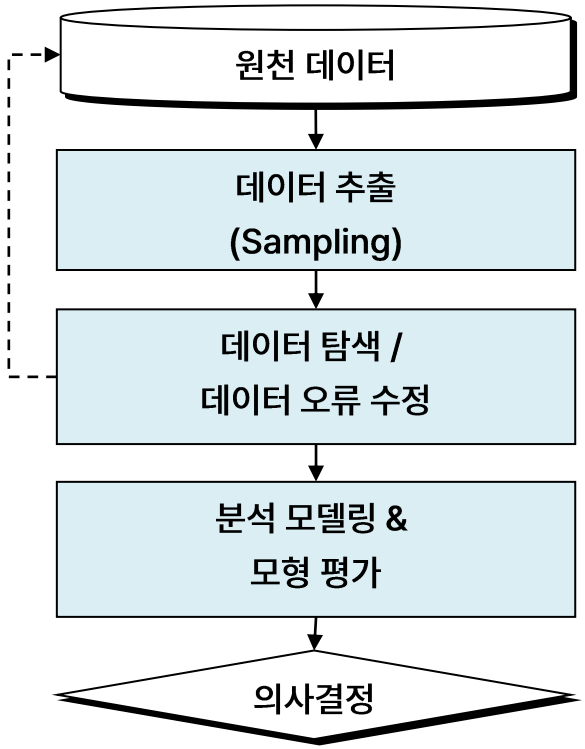


데이터 품질 점검

Garbage In, Garbage Out

데이터 품질 저하에 따른 분석 이슈

[데이터 분석 절차]



[데이터 품질 이슈]

- 입력 시점에 부정확한 정보 유입
- 부정확한 Data 추출
- 부정확 Data를 수정하는 시간/ 비용 발생
- 부정확한 Data 발견 못하고 분석 실행
- Model 정확도 저하 요인
- Model 결과 왜곡으로 잘못된 의사결정을 유도함

데이터 처리 용어

Preparation, Preprocessing, Wrangling

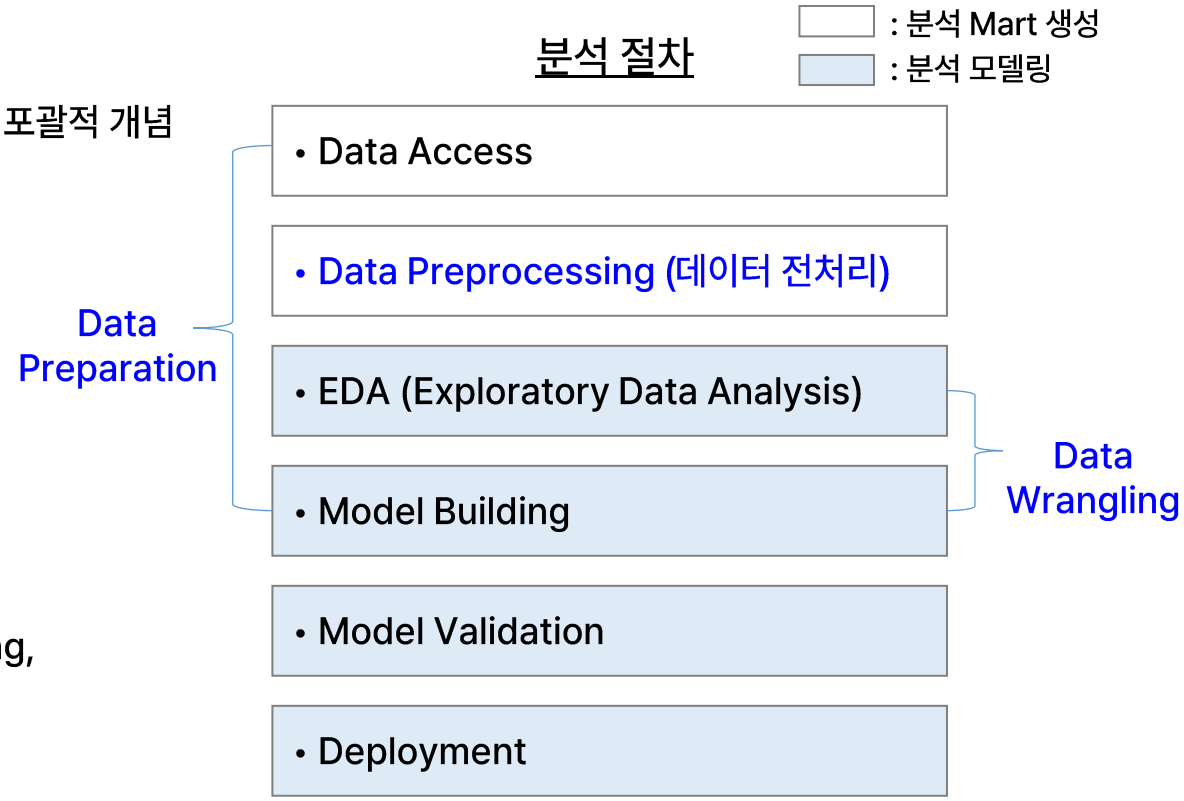
- **Data Preparation (데이터 준비)**: 데이터 처리의 포괄적 개념
- **Data Preprocessing (데이터 전처리)**
  - 모델 개발을 위한 최소한의 데이터 준비 과정
  - 필요한 경우 한번만 진행됨

  예) Data Cleaning, Data Reduction 등
- **Data Wrangling (데이터 랭글링)**
  - 모델 성능 향상을 위한 반복적인 과정

  예) Sampling, Data Partitioning, Data Binning,

  Scaling, Missing / Outlier 처리 등

그럼 Feature Engineering 이란?



Source : https://www.infoq.com/articles/ml-data-processing/

데이터 분석 및 AIOps

3. Feature Engineering

- 정의
- Feature Engineering 중요도
- Feature Extraction
- Feature Selection

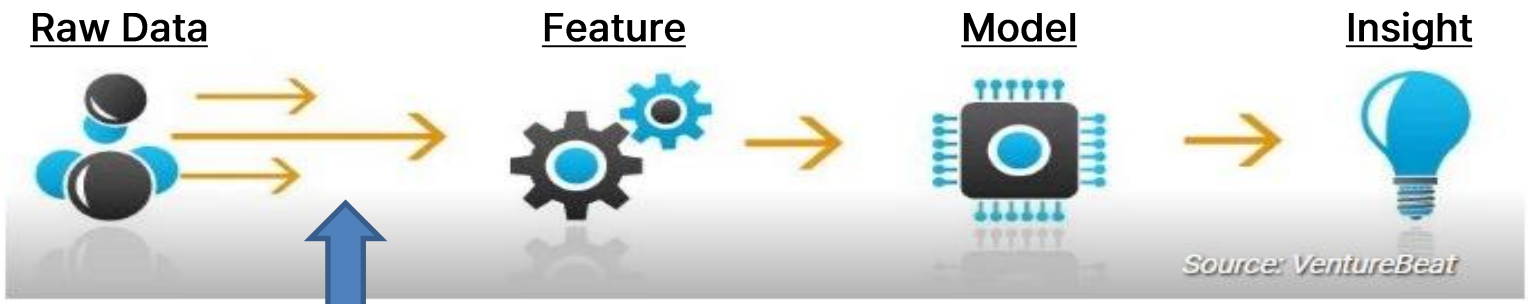
본 문서는 SK㈜AX의 컨텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

SK Inc. AX

Feature Engineering 정의

정의

- 원본 데이터(Raw Data)를 모델 성능에 도움이 되는 형태(Feature)로 가공하는 모든 과정
- ML / DL 에 사용되는 Feature 를 개발하는 과정으로 시간이 많이 걸리고, 모형 성능에 영향을 크게 줌
- 모델에 도움이 되는 한 어떤 요소도 Feature 가 될 수 있음



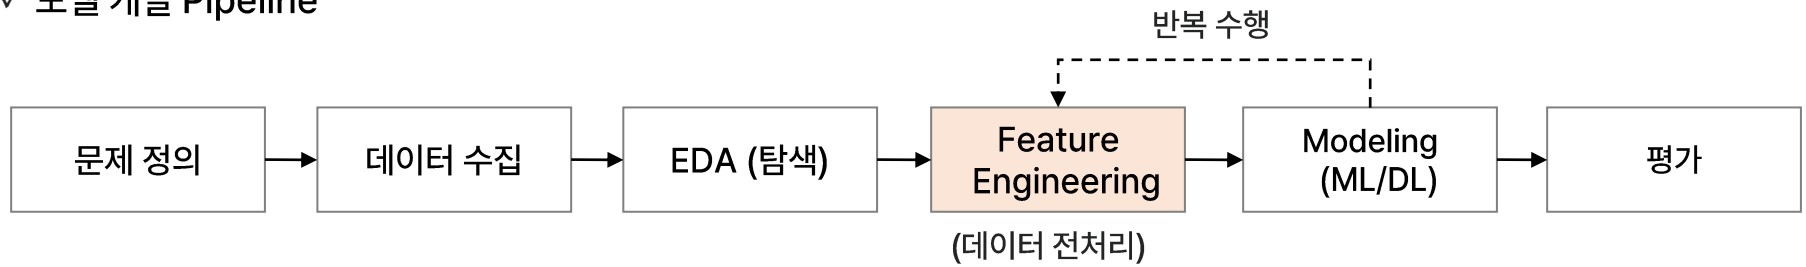
Feature Engineering

Feature Extraction	• Raw Data 를 변환, 병합해서 New Feature 생성
Feature Selection	• Feature 중에 유의미한 것만 선정 하여 학습 진행

모델 개발 Pipeline 에서 위치

- 전체 모델 개발 흐름 속에서 Feature Engineering의 위치
- 데이터 전처리는 데이터를 분석 가능한 형태로 변환하는 과정이고, 그 중에서 모델 성능에 초첨을 둔 단계가 Feature Engineering 임

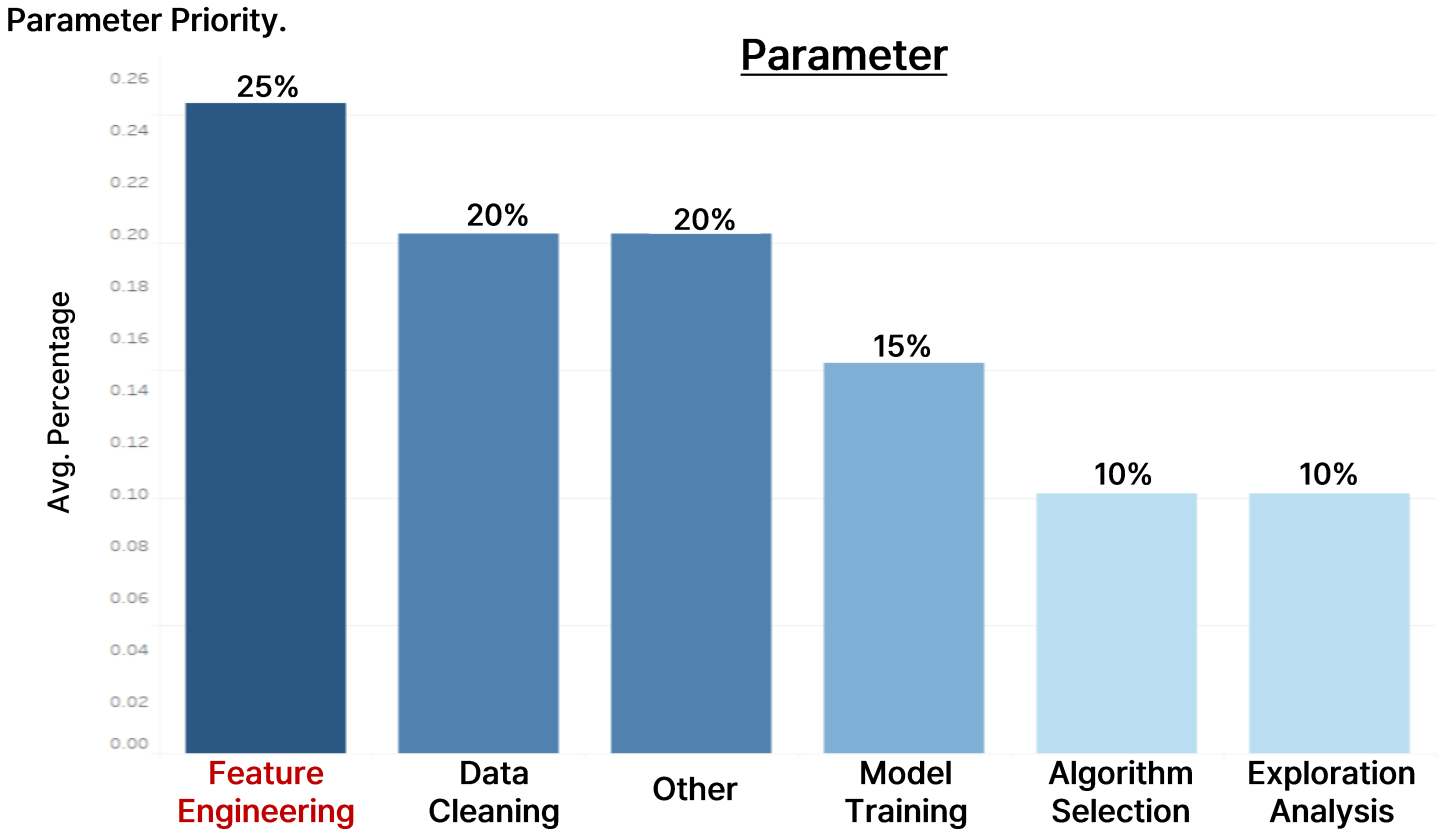
✓ 모델 개발 Pipeline



Feature Engineering 중요도

중요도

Feature engineering is an essential parameter of a successful model as observed below:



Source : https://heartbeat.fritz.ai/introduction-to-automated-feature-engineering-using-deep-feature-synthesis-dfs-3feb69a7c00b

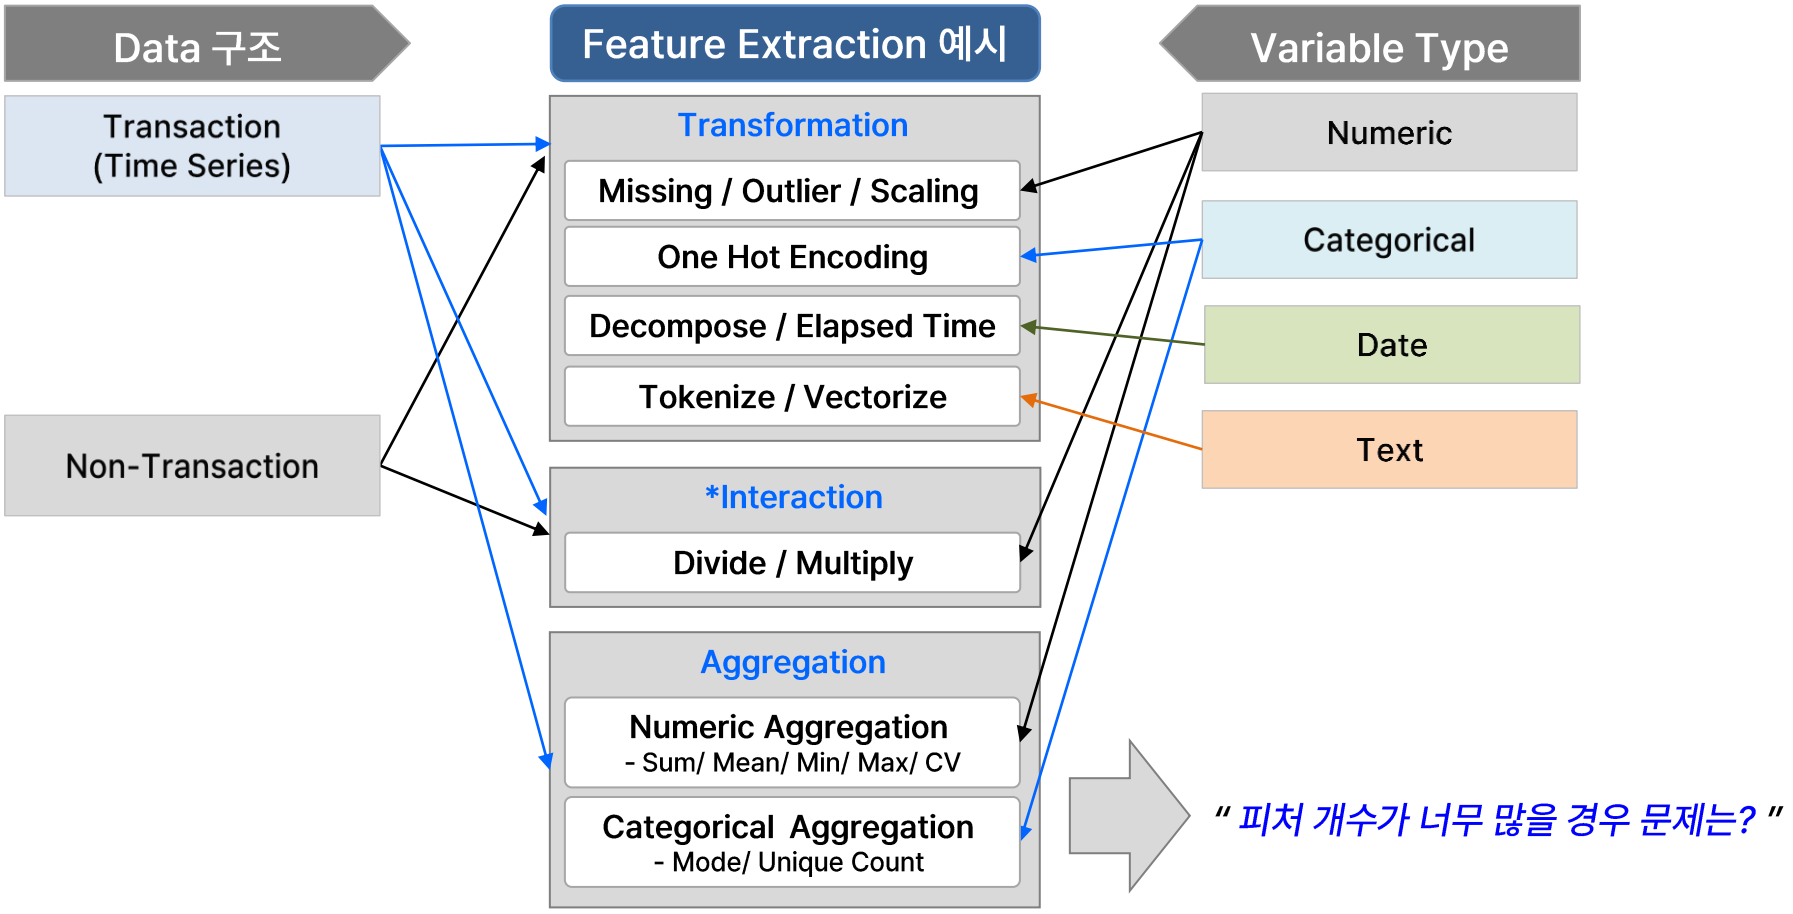
Feature Extraction

Feature Extraction 방법

Feature Transformation	• 알고리즘 기반 추출, 기계적 추출 방법 • 데이터 자체의 통계적·수학적 구조로 부터 자동 추출 • 사람의 해석 없이도 생성 가능한 Feature 예시) Missing 변환/ 표준화/ Min/ Max...
Feature Creation (파생변수 생성)	• 도메인 지식 기반 추출, 창의력 영역 • 업무 이해를 바탕으로 의미있는 Feature 추출 (파생 변수) 예시) 가입기간(현재일-가입일), 소득 대비 부채 비율(DTI) ...

Feature Extraction

알고리즘 기반 추출 예시

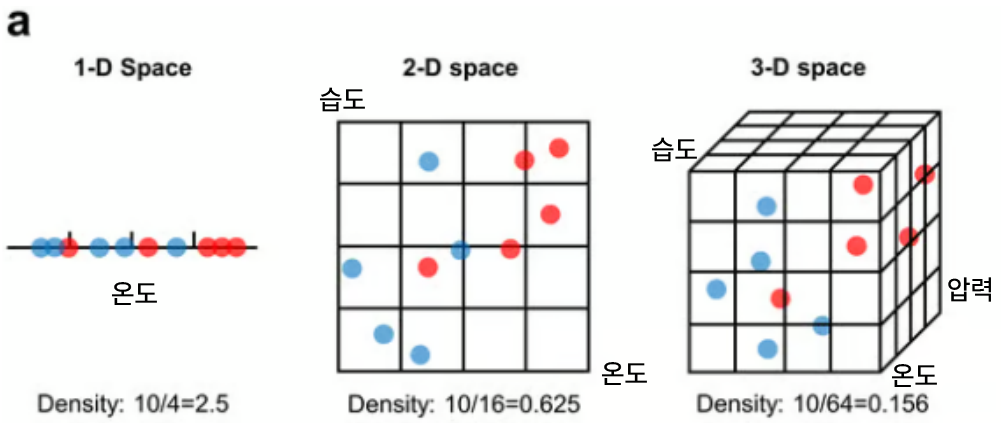


[참고] 차원의 저주 (Curse of Dimensionality)

변수 (차원, Feature) 수가 많아 질 경우 생기는 문제

- 차원이 늘어날수록, 제대로 된 학습을 하려면 필요한 데이터가 기하급수적으로 늘어남
- 데이터가 부족한데 차원만 크면 모델은 빈 공간에서도 규칙을 만들게 됨
- 실제 패턴이 아닌 빈 공간의 규칙을 만들면 Train 성능은 좋고, Test 성능은 폭락 → 과적합 (Over-fitting)

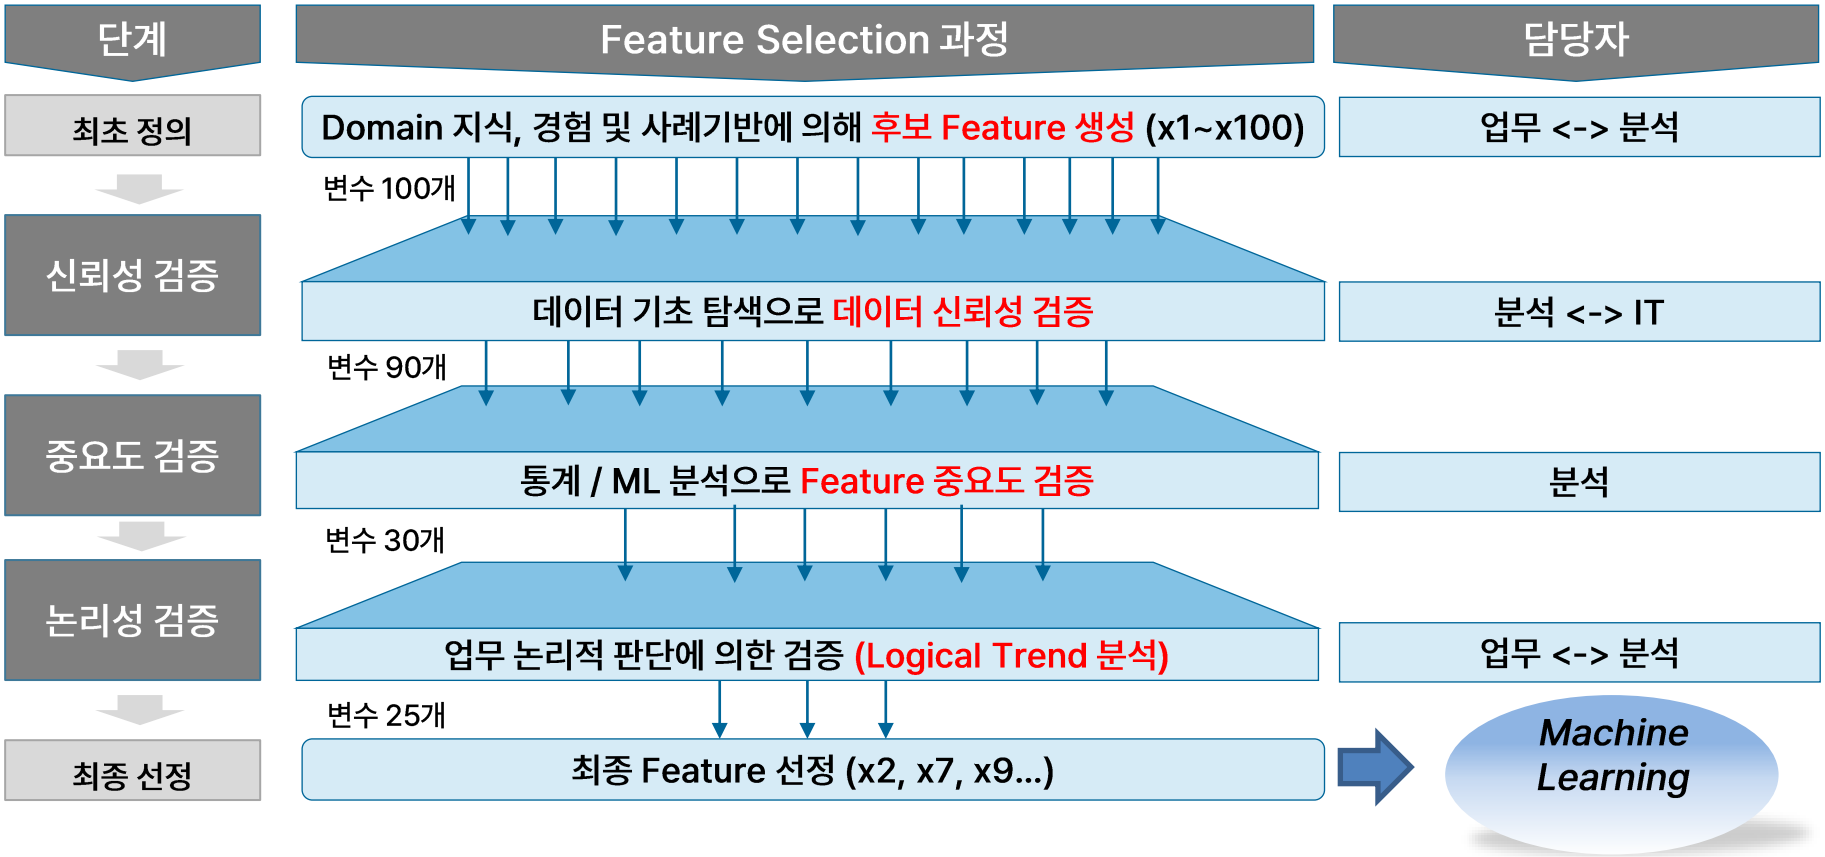
예시) 1차원을 4개 공간으로 나눌 경우



- ✓ Feature Selection
- ✓ Dimension Reduction

Feature Selection

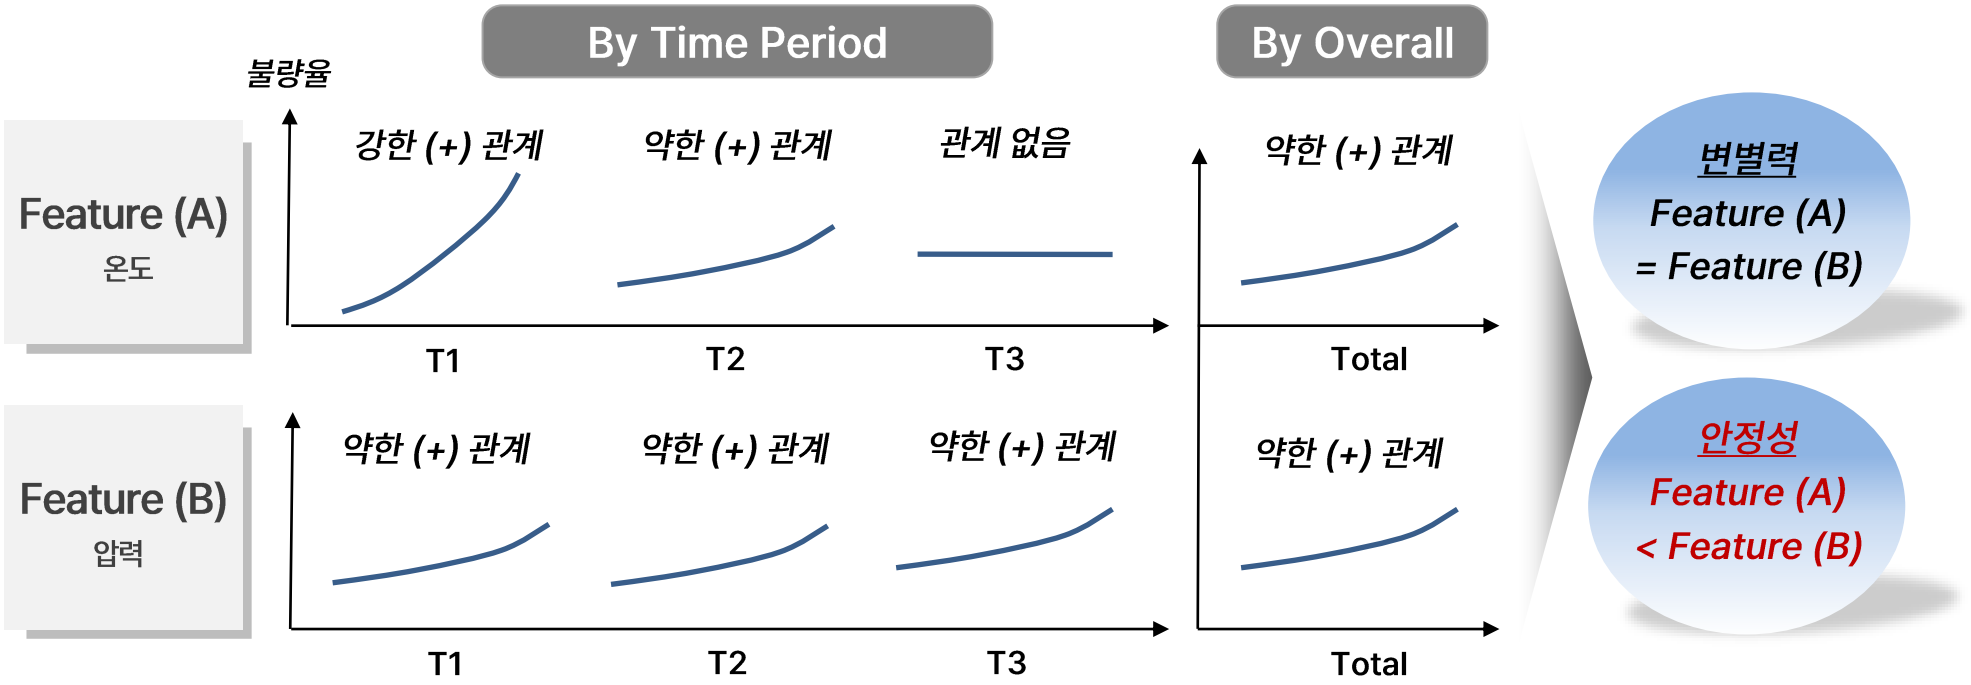
Feature Selection 목적은 모형 학습 시간 단축과, 모형 안정성 확보에 있음



Feature Selection > Logical Trend 분석

논리성 검증 + 모델 변별력 + 모델 안정성

- Logical Trend 분석은 변수의 영향 방향과 크기가 비즈니스 측면에서 "논리적으로 맞는지"를 검증하는 과정입
- 모델 변별력, 모델 안정성을 같이 판단함
- Robust Model 은 Robust Feature 에 기초함



데이터 분석 및 AIOps

4. 모델 학습 및 최적화

- 모델 학습
- 모델 최적화

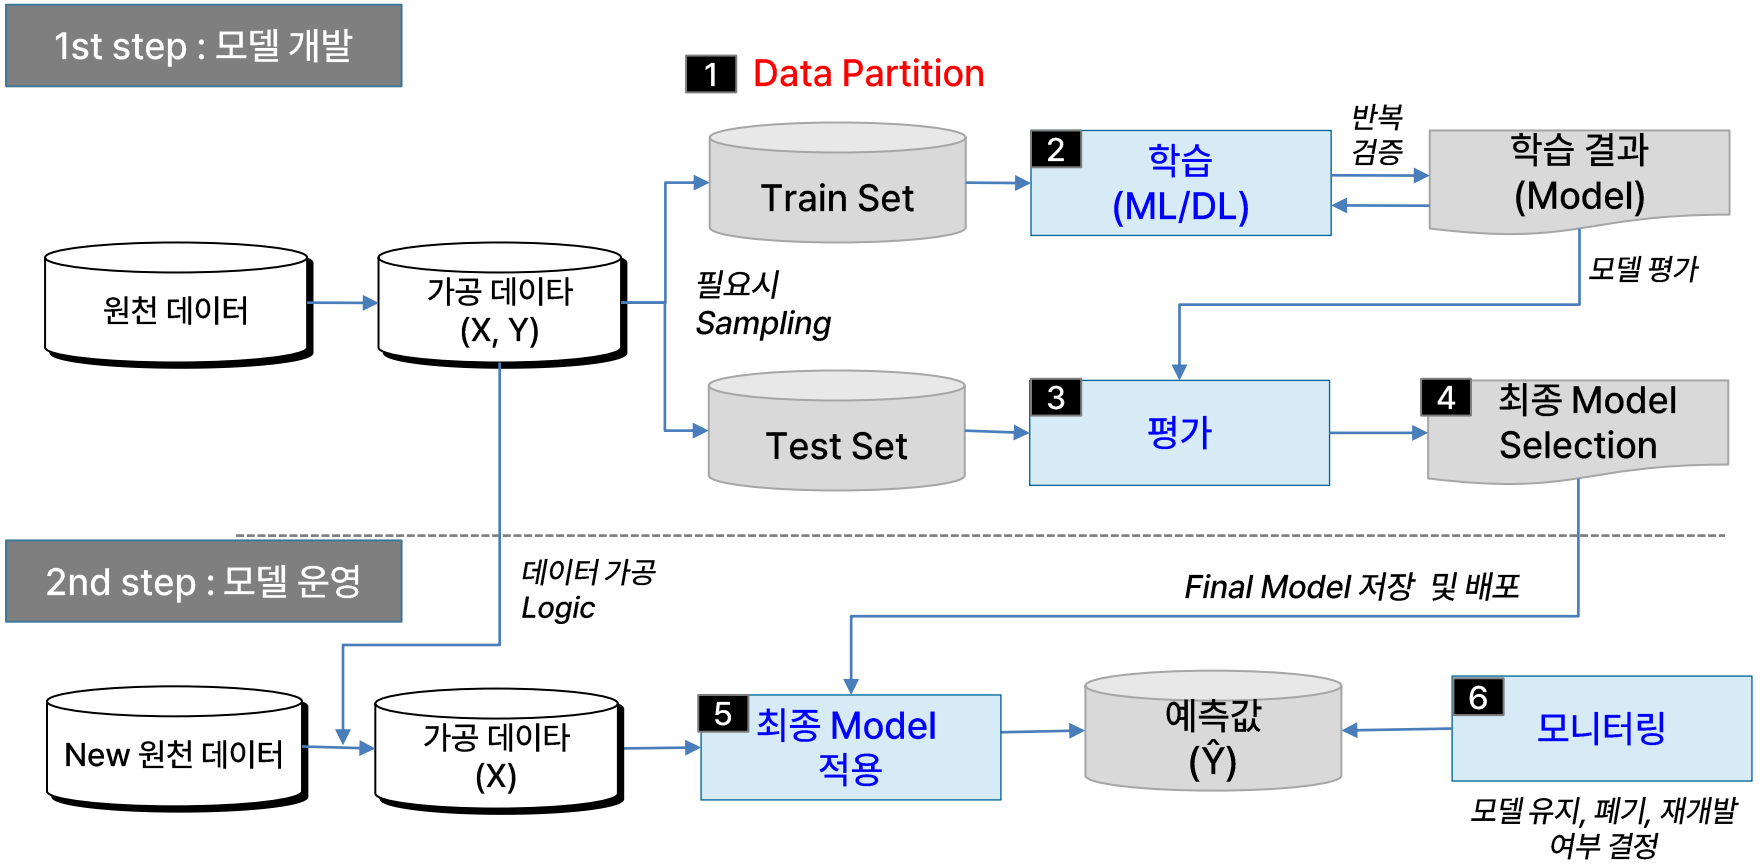
본 문서는 SK㈜AX의 컨텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

SK Inc. AX

모델 학습

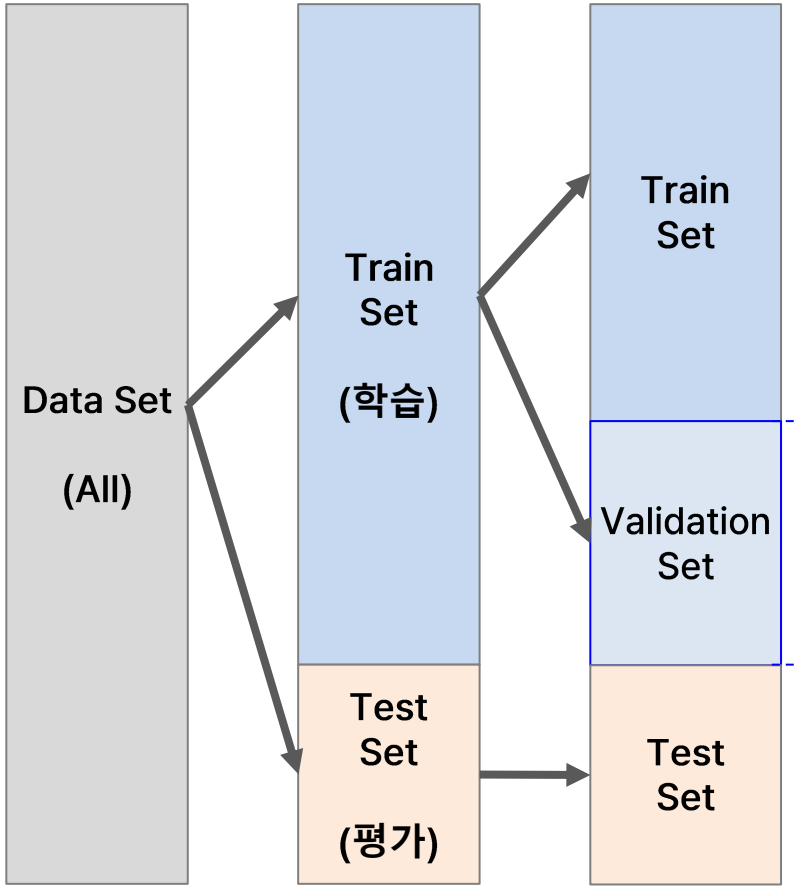
모델 Lifecycle 구조

모델 개발에서 부터 모델 운영까지의 Flow



Data Partition 개념

모델 개발을 위해서 Dataset 을 모델 학습 데이터와 모델 평가 데이터로 나누는 것



- 모델 학습 위한 데이터셋
- Train Set : Test Set = 8:2 (or 7:3)

- 학습된 모델을 검증하기 위한 데이터셋
  : 최적의 Hyper-parameter를 찾는 과정
- Train : Validation : Test = 6 : 2 : 2

- 학습과 검증이 완료된 모델의 성능 평가
- 전체 데이터 셋의 약 20~30% 데이터로 진행

모델 학습 위한 데이터

학습에 반영되지 않는 데이터

Data Partition 방법

Hold Out, Cross Validation

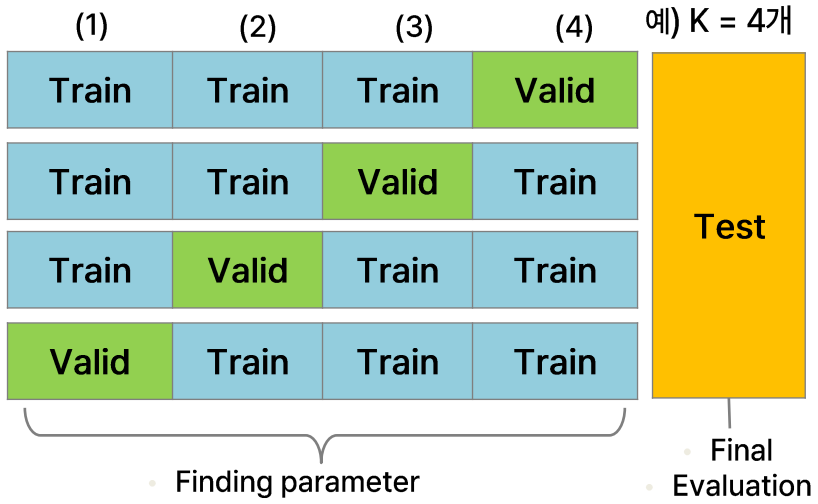
Hold Out

- ▪ Random Split
- - 데이터를 적정 비율로 해서 무작위로 분할
  Ex) Train : Valid : Test = 6 : 2 : 2
- ▪ Timeseries Split
- - 시간 순서로 데이터 분할
- - 시계열 데이터 분석 시 사용



CV (Cross Validation)

- ▪ K-fold Cross Validation
- - 데이터를 K 번 나누어 학습·검증을 반복하고, Valid 성능의 평균으로 모델을 검증하는 방법

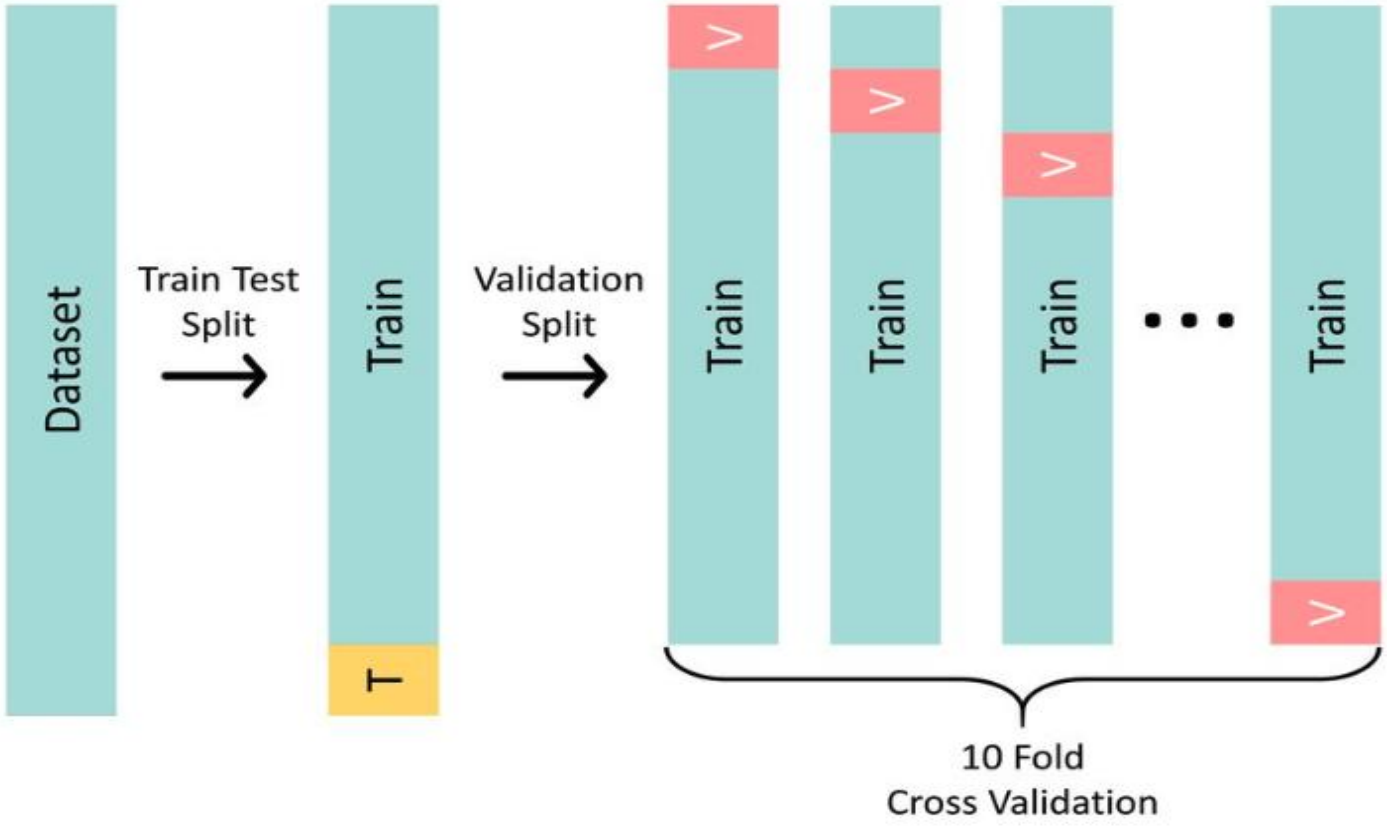


- * Test set 평가 방법
- - Holdout : Train 학습 모델 그대로 사용 or Train + Valid Set 으로 재학습
- - CV : 전체 Train Set 으로 재학습

Cross Validation > K-Fold

K-Fold Cross Validation

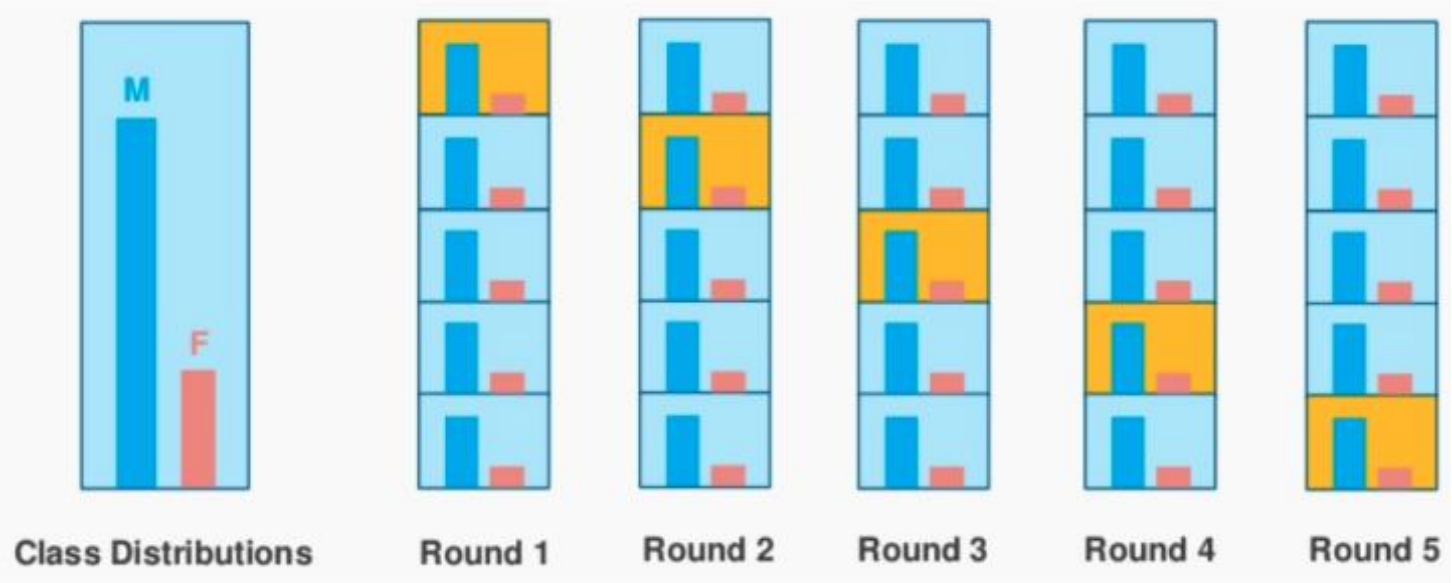
- 데이터 건수를 동일하게 단순 분할
- Regression 문제에 주로 사용



Cross Validation > Stratified K-Fold

Stratified K-Fold Cross Validation

- (용어) Stratified, 계층화된
- Classification 문제에 주로 사용
- 각 클래스의 비율이 균등하게 유지되도록 데이터 분할 → Class Imbalance 데이터셋인 경우 활용



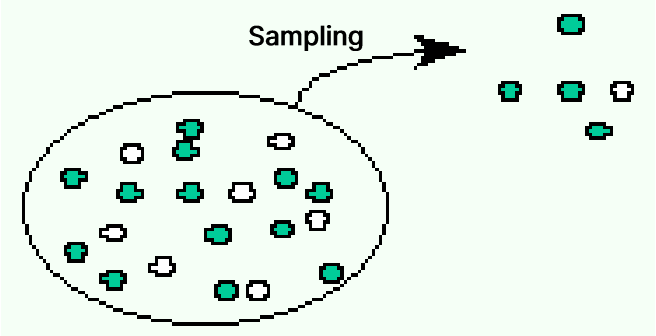
Sampling 방법 1/2

Random Sampling vs Partitioned Sampling

Random Sampling

- Sample 에 포함될 확률을 동일하게 추출

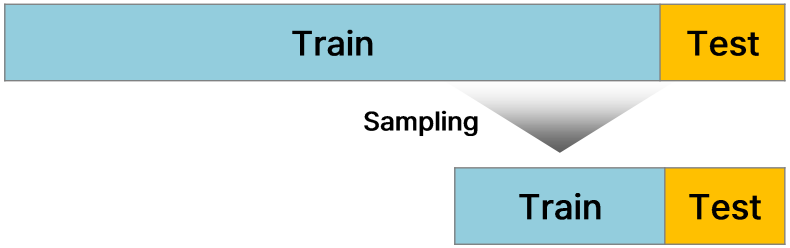
단순 랜덤 추출 (Simple Random Sampling)



- 모집단에서 단순 무작위 방법 의해 표본을 추출

Partitioned Sampling

- Test Set 은 그대로 두고, Train 에서만 Sampling 할 경우



- 모델 개발은 Sampling 으로 하지만, 모델 평가는 전수 평가를 하고자 할 경우

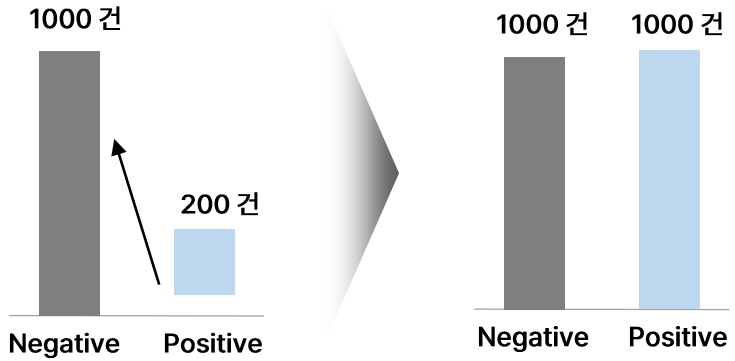
Sampling 방법 2/2

Over Sampling vs Under Sampling

- Target 변수 Class 불균형 (class imbalance) 시

Over Sampling

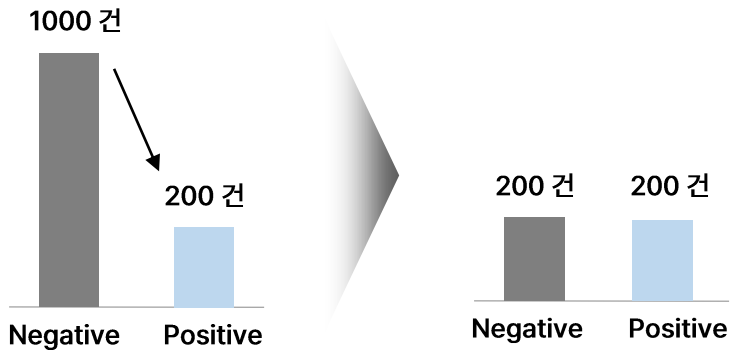
- 작은 Size 의 Class 를 큰 Size 의 Class로 균형을 맞추고자 할 경우



- Positive class 건수가 너무 적은 경우
- 방법
  - Random Over Sampling : 그대로 복제
  - SMOTE (Synthetic Minority Over-sampling Technique) : Positive 와 가까운 이웃에서 새로운 샘플 생성

Under Sampling

- 큰 Size 의 Class 를 작은 Size 의 Class로 균형을 맞추고자 할 경우



- Negative class 건수가 너무 많은 경우

* Positive vs Negative : 관심 대상 Class vs 비관심 대상 Class

예) 이탈 vs 유지, 불량 vs 정상, 사기거래 vs 정상거래

모델 최적화

모델 최적화 정의

용어의 이해

최적화, 最適化, Optimization

- 주어진 조건이나 제약 내에서 최상의 결과를 얻도록 과정이나 방법을 조정하거나 개선하는 과정
- 자원, 시간, 비용 등을 최소화 하거나 효율성, 효과성 등을 최대화 하는 것이 주된 목표
- (예) 경제학에서의 자원 배분, 공학에서의 설계 최적화, 물류에서의 경로 최적화 등

머신러닝 모델링에서의 최적화

- 모델의 학습 과정에서 성능 지표를 개선하기 위해 하이퍼파라미터 조정 등 모델을 조정하여 최상의 성능을 얻는 과정
- 주요 목표 :
  - ❑ 성능 향상 : 모델이 정확하게 예측하고 좋은 성능을 발휘하도록 조정
  - ❑ 일반화 향상 : 새로운 데이터에 대해 잘 작동할 수 있도록 모델 개선
  - ❑ 효율성 증가 : 학습 과정의 속도를 높이고, 계산 자원을 효율적으로 사용

모델 최적화 전략

대표적인 최적화 전략

최적화 전략		핵심 목적	최적화 기법
데이터 전략	Training Data Design	• 모델 학습에 최적화된 데이터셋 구성	• Segmentation, Sampling • Data Partition : Hold Out, Cross Validation
	Feature Engineering	• 예측에 유용한 Feature 생성 및 변환	• 특성 생성 : 파생변수 생성, Lag 변수 등 • 특성 변환 : Missing 대체, Scaling 등 • 특성 선택 : 신뢰성 검증, 변수 중요도, 논리적 판단
모델 전략	Model Selection	• 문제 및 데이터 특성에 적합한 알고리즘 선정	• 통계분석 / ML / DL • Regression 계열, Tree 계열 (XGBoost/LightGBM)
	Hyperparameter Tuning	• 모델 성능을 최적화하는 하이퍼파라미터 탐색	• Grid / Random / Bayesian Search • 경험 및 사례 기반 탐색
	Regularization	• 과적합 방지 및 일반화 성능 향상	• L1, L2 정규화 (LASSO, Ridge) • 뉴런 Dropout, 학습 Early Stopping
	Ensemble	• 여러 모델을 결합하여 예측 성능과 안정성 향상	• Bagging : Random Forest • Boosting : XGBoost, LightGBM • Stacking : 이질적인 모델 예측값을 메타 모델의 Input

Hyperparameter Tuning 개념

용어의 이해

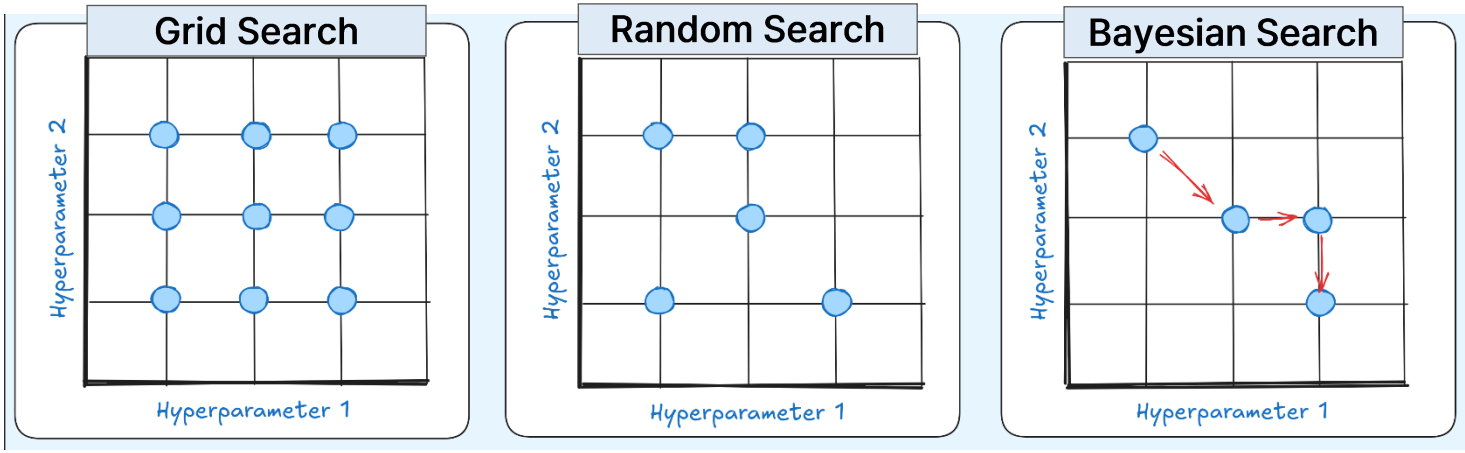
Parameter	Hyper-parameter

• **모델 내부에서 데이터로부터 학습된 값**
• (예) Linear Regression: 회귀계수, 절편
`from sklearn.linear_model import LinearRegression`
`model = LinearRegression()`
`model.fit(X_train, y_train)`
`# The coefficients`
`print('Coefficients: ', model.coef_)`
`print('Intercept: ', model.intercept_)`
	• **모델 외부에서 사용자가 직접 샛팅해 주는 값**
	• (예) Decision Tree의 최대 깊이
	`tree_classifier = DecisionTreeClassifier(max_depth=2)`
	`tree_classifier.fit(X,y)`
	`DecisionTreeClassifier(class_weight=None, criterion='gini', max_depth=2, max_features=None, max_leaf_nodes=None, min_impurity_decrease=0.0, min_impurity_split=None, min_samples_leaf=1, min_samples_split=2, min_weight_fraction_leaf=0.0, presort=False, random_state=None, splitter='best')`

• **작업자에 의해 조정되지 않음** • **학습 데이터를 통해 자동으로 업데이트** → 모델의 구조를 결정 • Part of the model	• 데이터 분석을 통해 얻어지는 값이 아님 • 사용자에 의해 미리 설정, 학습 과정에도 변경되지 않음 → 학습 알고리즘의 동작 방식을 결정 • External to the model
• 모델의 최적화 과정을 통해 결정됨	• **알고리즘을 여러 번 수행하면서 최적의 값을 찾아야 함** • Not best values, But proper values

Hyperparameter 자동 최적화 방법

알고리즘 기반의 튜닝 방법



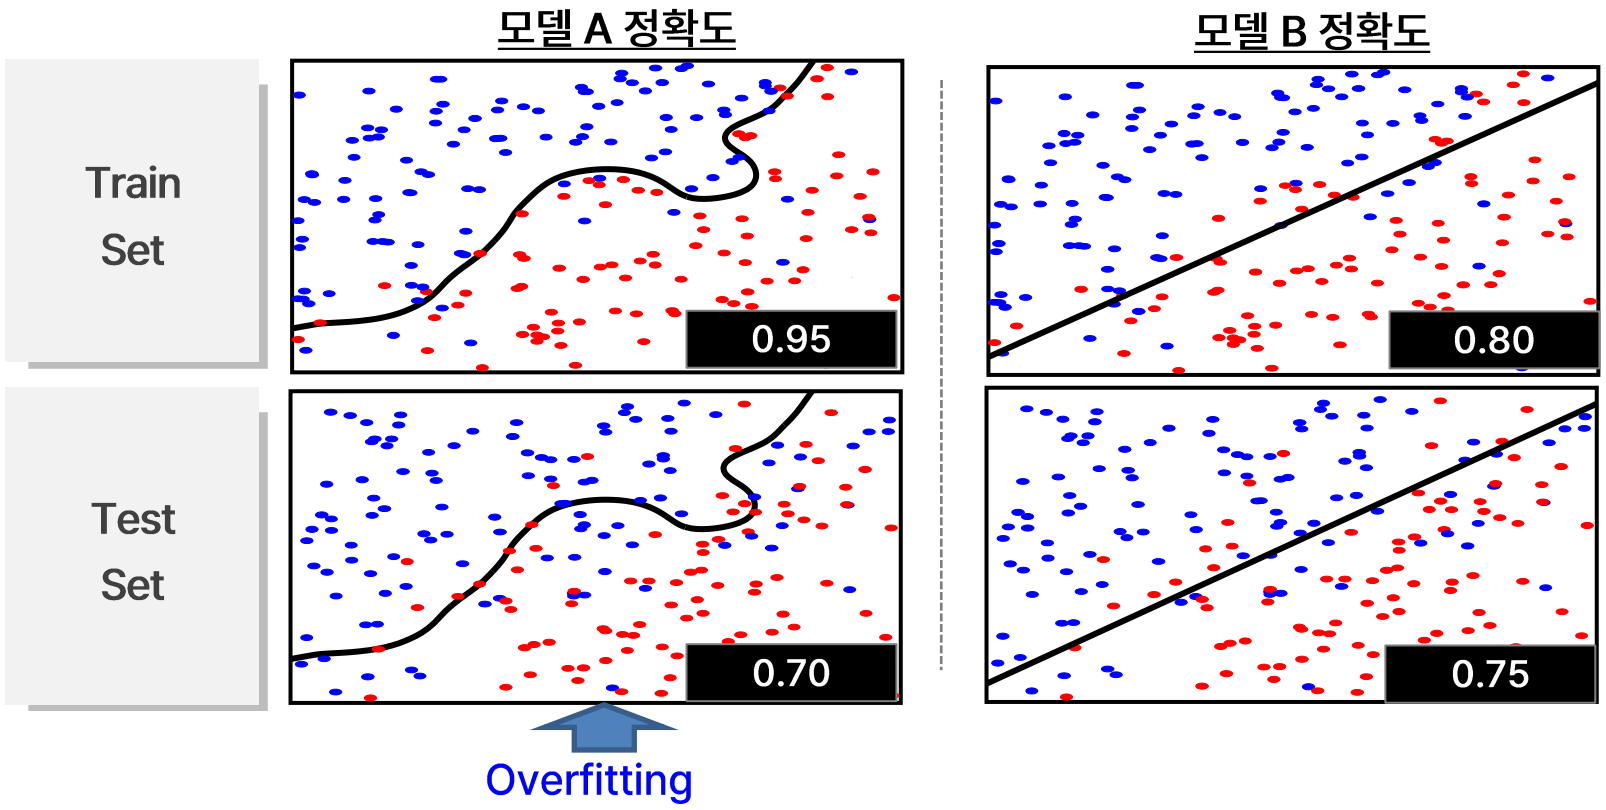
항목	Grid Search	Random Search	Bayesian Search
탐색 방식	정의된 범위 내 모든 조합 전수 조사	정의된 범위 내 무작위 조합 샘플링	이전 결과로 다음 최적점을 예측
탐색 효율	차원 ↑ 시 비효율적	고차원에서 효율적	가장 효율적, 적은 시도로 수렴 가능
최적해 보장	격자 안에서는 보장	보장 안 됨	이론상 좋은 해에 빠르게 근접
언제 사용?	하이퍼파라미터 수가 적을때	하이퍼파라미터 공간이 넓을 때	계산 비용이 큰 모델에 효과적 (DL, LGBM, XGBoost)

Source : https://www.nb-data.com/p/6-common-hyperparameter-optimization

Overfitting 개념

모델 과적합

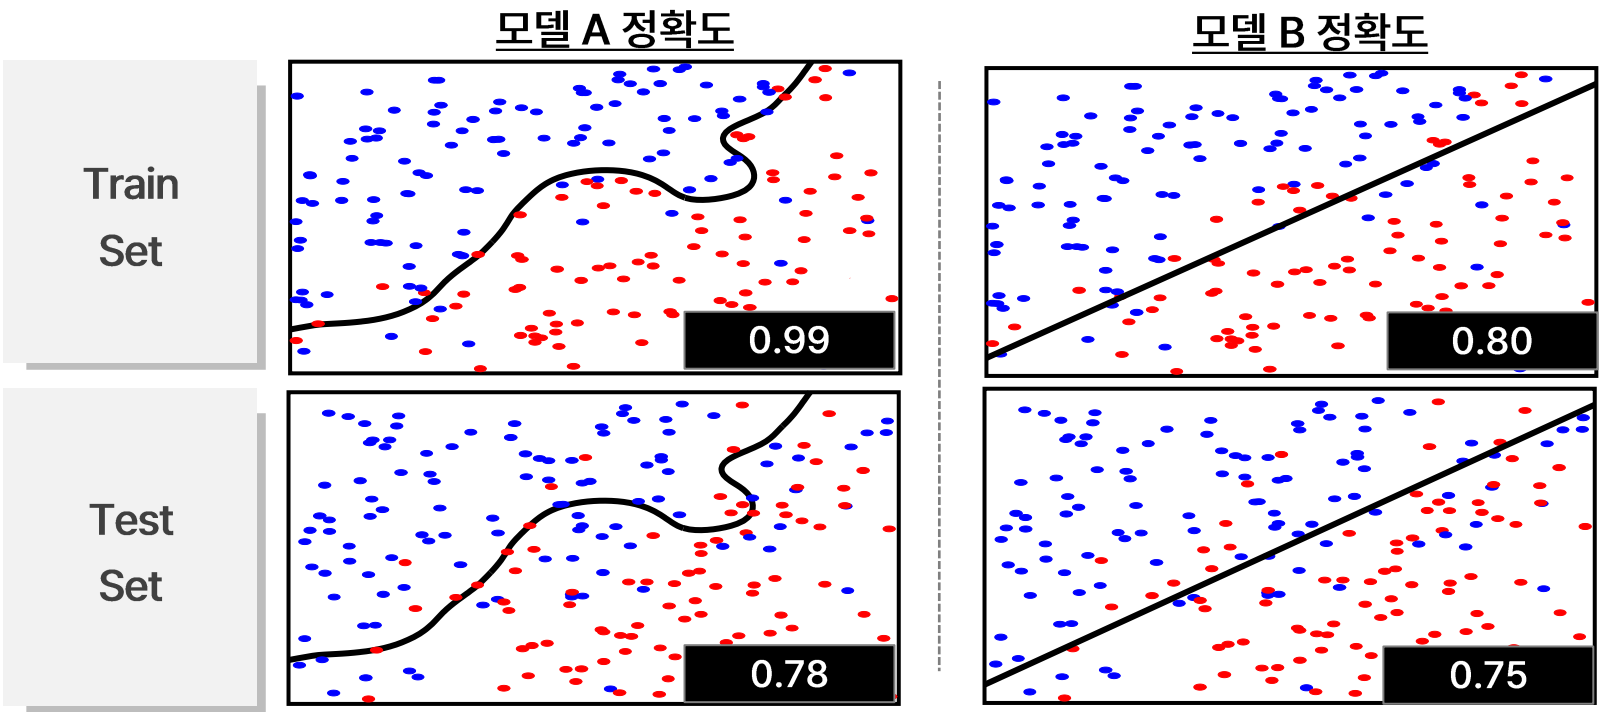
- Overfitting 은 학습 데이터에서는 잘 맞는데, 검증 데이터에서는 그렇지 않은 경우를 의미
- Overfitting 영향 요인 : 데이터 특성 (Train/Test 비유사도), 데이터 건수, Feature 개수, 알고리즘 복잡도 등



Overfitting 개념

모델 과적합

Q) 모델 A와 B 중 어느 모델이 좋은 모델일까요?

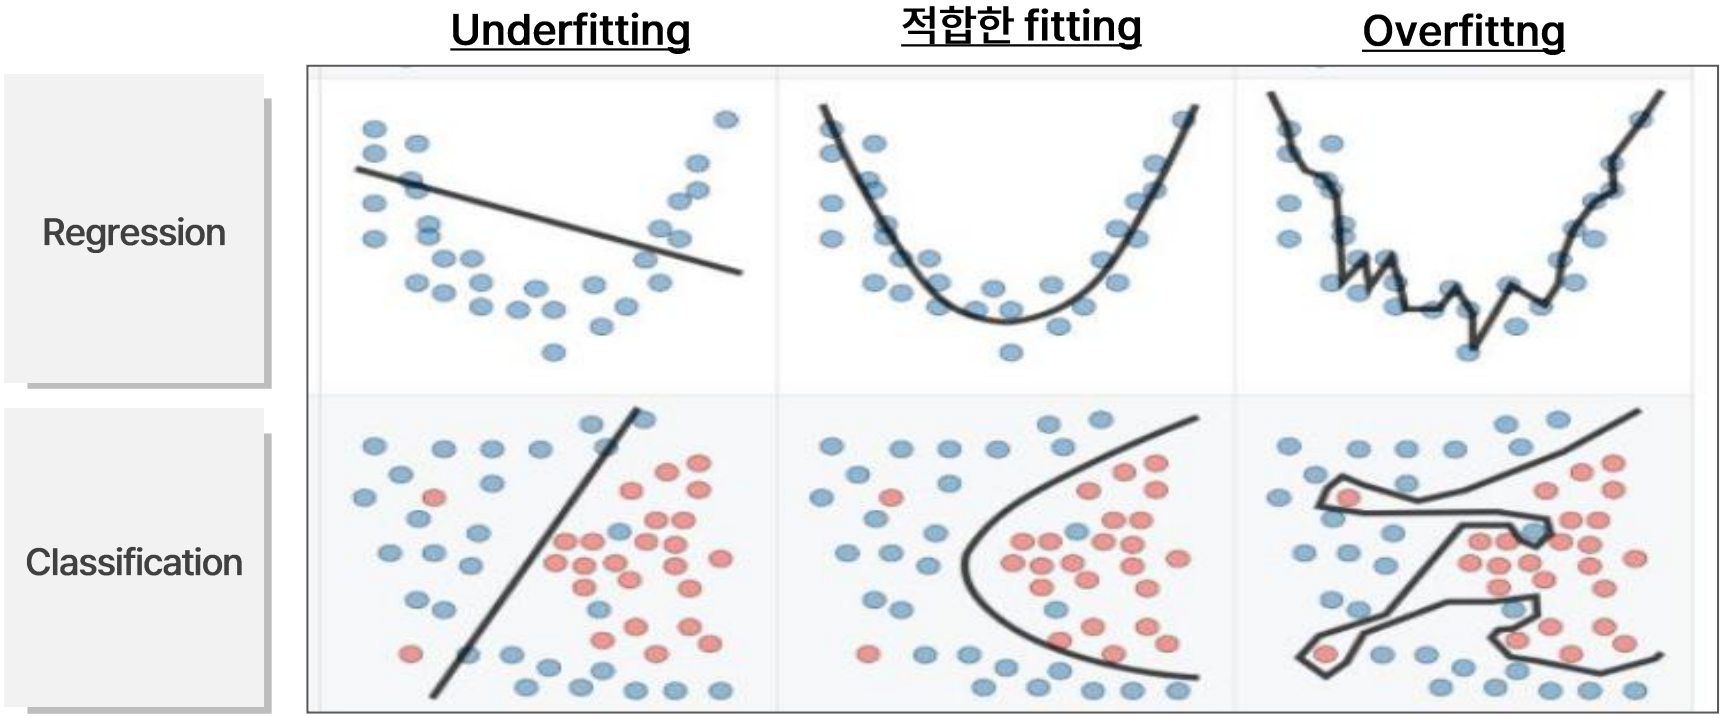


Overfitting vs Underfitting

과대 적합, 과소 적합

- Overfitting은 학습이 너무 과해서 학습데이타만 잘 맞추는 것
- Underfitting은 학습이 너무 부족해서 학습데이타도 잘 못 맞추는 것

Q) Overfitting 과 Underfitting 중 어떤 것이 더 문제일까요?



Overfitting 대응방안

Overfitting vs Underfitting 대응방안

- 데이터 건수, Feature 갯수, 학습 알고리즘 복잡성 선택으로 따라 대응 가능

	Overfitting	Underfitting
Data	▪ 데이터 건수 증가 ▪ Test 와 유사한 Train Set 구성	▪ 데이터 건수 증가
Feature	▪ 불필요한 Feature 제거	▪ Feature 추가
학습 알고리즘	▪ 알고리즘 Simplify ▪ 정규화 (Regularization) 수행	▪ 알고리즘 Complexify ▪ 하이퍼파라미터 범위를 늘림

Data Leakage

학습에서 치명적인 함정

- Data Leakage : 모델이 예측 시점에 알 수 없는 정보를 학습에 사용한 경우
- 모델 개발 시에는 정확도가 매우 높게 나오는데 (예: 99%), 실제 데이터를 넣으면 현저히 성능이 저하되는 이유
- Overfitting 은 주로 모델 설계 문제, Data Leakage 는 데이터 설계 문제

Data Leakage

Target Leakage

- Feature에 Target 정보가 직접/간접 포함

예시) 폐렴 환자 예측시 "항생제 처방 여부" 피처 사용,
고객 이탈 예측시 "'해지 위약금 지불 여부" 피처 사용



Train-Test Contamination

- Test 데이터가 학습 과정에 일부라도 노출된 상태

예시) 전체 데이터의 평균, 표준편차로 Scaling,
전체 데이터 평균으로 Missing 대체



Quiz

1. [Feature Engineering] Missing 대체 작업시 평균값을 산출하는 데이터와, 그 값을 적용하는 데이터의 올바른 관계는?

   (산출 대상 Dataset -> 적용 대상 Dataset)

   ① All -> Train / Validation / Test
   ② Train -> Train / Validation / Test
   ③ Train + Validation -> Train / Validation / Test
   ④ Train -> Train, Validation -> Validation, Test -> Test
   ⑤ 과제에 따라 다름

2. [모델 튜닝] Hyperparameter Tuning 을 통해서 모델 성능을 최대로 올리고자 함. 어떤 데이터셋의 성능을 기준으로 하이퍼파라미터를 최적화해야 하는가?

   ① Train ② Validation ③ Test ④ Train, Validation 평균값 ⑤ Validation, Test 평균값

3. [모델 평가] "암 예측 모델의 정확도는 95% 이다" 라고 할 때 그 정확도 산출 대상이 되는 데이터 셋은?

   ① Train ② Validation ③ Test ④ Validation, Test 평균값 ⑤ 상황에 따라 다름

Source : https://www.nb-data.com/p/6-common-hyperparameter-optimization

데이터 분석 및 AIOps

5. 모델 평가

- 모델 평가 지표 종류
- Classification 모델 평가 지표
- Regression 모델 평가 지표

본 문서는 SK㈜AX의 컨텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

모델 평가 지표 종류

모델 평가 지표는 문제 유형, 비즈니스 목적에 따라 선택해야 함

문제 유형	Output 유형	평가 지표 (Metrics)
분류 (Classification)	Class (1, 0)	• Confusion Matrix (Accuracy / Precision / Recall / F1 Score)
	Probability (0~1)	• AUC / LIFT / AUCPR / K-S
회귀 (Regression)	실수값	• Mean Absolute Error : ∑ |예측값 – 실제값| / n
		• Mean Squared Error : ∑ (예측값 – 실제값)^2 / n
		• Root Mean Squared Error : Root(∑ (예측값 – 실제값)^2 / n)
		• Mean Absolute Percentage Error : ∑(|예측값 – 실제값| /실제값)/ n
		• R-Square : 1- (∑ (실측값 – 예측값) / ∑ (실측값 – 평균값)2)

Classification 모델 평가 지표

Confusion Matrix

Confusion Matrix 는 실제 분류값과 예측 분류값의 비교 분류표를 뜻함

Confusion Matrix		Actual	
		Positive	Negative
Predict	Positive	TP	FP
	Negative	FN	TN

- Positive vs Negative
  : 관심 대상 Class vs 비관심 대상 Class
  예) 이탈 vs 유지, 불량 vs 정상, 사기거래 vs 정상거래
- TP : True Positive, 실제 Positive를 Positive로 맞게 예측
- TN : True Negative, 실제 Negative를 Negative로 맞게 예측
- FP : False Positive, 실제 Negative를 Positive로 잘못 예측
- FN : False Negative, 실제 Positive를 Negative로 잘못 예측

$$Accuracy = \frac{TP + TN}{TP + FP + FN + TN}$$: 전체 중에서 얼마나 맞췄는가?

$$Recall = \frac{TP}{TP + FN}$$: 실제 Positive 중에서 얼마나 잡아냈는가?

$$Precision = \frac{TP}{TP + FP}$$: Positive 라고 예측 한 것 중에서 얼마나 진짜인가?

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$: Recall과 Precision의 균형 수준은 어떠한가?

Confusion Matrix

Confusion Matrix 는 실제 분류값과 예측 분류값의 비교 분류표를 뜻함

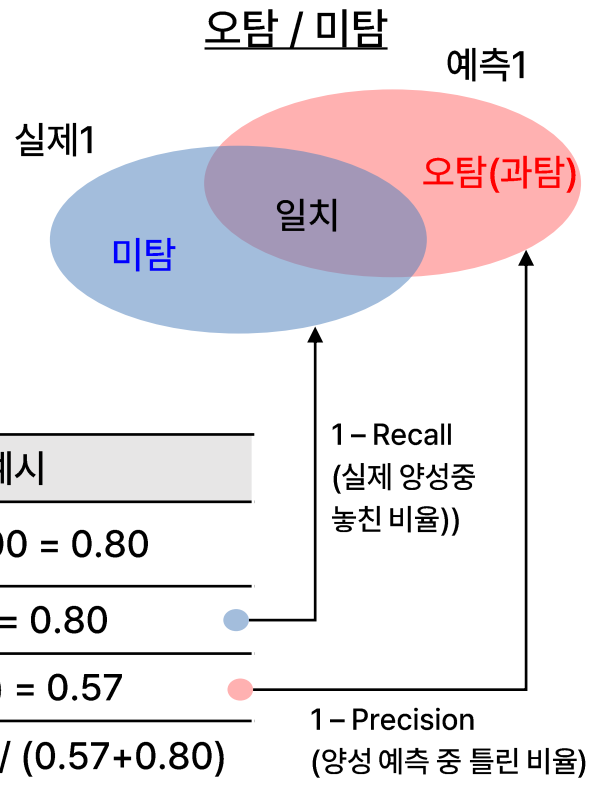
Confusion Matrix (오분류표)

	예측값	
실제값	1 (이탈)	0 (유지)
1 (이탈)	20	5
0 (유지)	15	60

Total: 100

이탈 : 25

유지 : 75



평가 지표 (Metric)	정의	예시
• Accuracy (정확도)	전체 중에 올바르게 예측한 비율	(20 + 60) / 100 = 0.80
• Recall (재현율)	실제 1 중에 예측 1의 비율	20 / (20 + 5) = 0.80
• Precision (정밀도)	예측 1 중에 실제 1의 비율	20 / (20 + 15) = 0.57
• F1 Score	Precision 과 Recall 의 조화평균 (2*P*R) / (P+R)	2*0.57*0.80 / (0.57+0.80) = 0.67

Confusion Matrix

(Quiz)

1. 아래는 CCTV를 이용한 범인 색출 모형입니다. 모델 중 가장 성능이 좋은 모델은?
2. 일반인을 범인으로 오탐지하는 오류를 최소화하려고 할때 어떤 모델을 선택해야 하는지?

모델 A) Total : 100

	예측값	
실제값	1 (범인)	0 (일반)
1 (범인)	8	2
0 (일반)	27	63

- Accuracy : 0.71
- Recall : 0.80
- Precision : 0.23
- F1 Score : 0.36

모델 B) Total : 100

	예측값	
실제값	1 (범인)	0 (일반)
1 (범인)	5	5
0 (일반)	15	75

- Accuracy : 0.80
- Recall : 0.50
- Precision : 0.25
- F1 Score : 0.33

모델 C) Total : 100

	예측값	
실제값	1 (범인)	0 (일반)
1 (범인)	0	10
0 (일반)	0	90

- Accuracy : 0.90
- Recall : 0.00
- Precision : N/A
- F1 Score : N/A

[참고] Baseline 모델 vs Navie 모델

성능 비교 위한 기준 모델

- 모델 성능 평가는 평가지표 절대값보다 "비교 기준"이 더 중요

Baseline 모델	• 모델 성능 평가시 비교 대상으로 사용하는 모델 • 예시) - 이전에 개발한 모델 - 가장 단순한 ML 모델, 예) 선형 Regression 모델 - 규칙기반 Rule 모델 - Navie 모델
Navie 모델	• 학습 없이 가장 단순한 규칙만으로 예측하는 모델 • 예시) - 분류 모델 : Y 변수의 다수 클래스(Majority Class) 로 예측 예) 불량 5%, 정상 95% → 전부 "정상" 예측 - 회귀 모델 : Y 변수의 평균값(mean) 으로 예측, (시계열) 직전 값으로 예측 예) 내일 주가 예측 시 "전일 종가" 로 예측

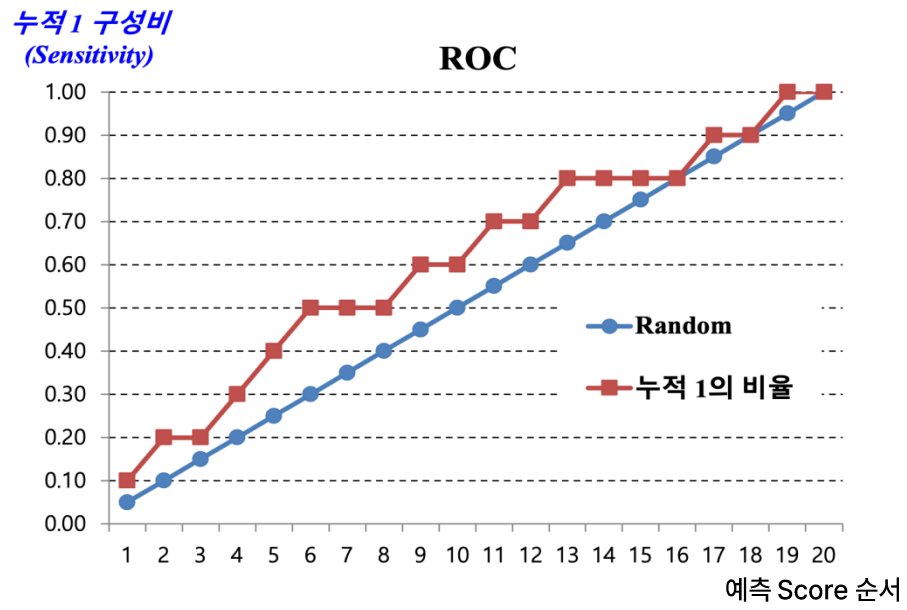
AUC (AUROC, ROC-AUC)

분류 임계값(threshold)을 0부터 1까지 변화시키면서 모델의 성능을 종합적으로 평가하는 지표

- AUC = ROC Curve 아래의 면적(Area Under the ROC Curve)
- ROC 곡선 : 분류 임계값을 0에서 1까지 변화시킬 때 모델의 예측 성능 변화를 나타낸 그래프

예시) 예측 Score 기준 내림차순 정렬된 데이타

No	실제 Class	예측 Score	누적 전체 구성비	누적 1 구성비	누적 0 구성비
1	1	0.90	0.05	0.10	0.00
2	1	0.80	0.10	0.20	0.00
3	0	0.70	0.15	0.20	0.10
4	1	0.60	0.20	0.30	0.10
5	1	0.55	0.25	0.40	0.10
6	1	0.54	0.30	0.50	0.10
7	0	0.53	0.35	0.50	0.20
8	0	0.52	0.40	0.50	0.30
9	1	0.51	0.45	0.60	0.30
10	0	0.51	0.50	0.60	0.40
11	1	0.40	0.55	0.70	0.40
12	0	0.39	0.60	0.70	0.50
13	1	0.38	0.65	0.80	0.50
14	0	0.37	0.70	0.80	0.60
15	0	0.36	0.75	0.80	0.70
16	0	0.35	0.80	0.80	0.80
17	1	0.34	0.85	0.90	0.80
18	0	0.33	0.90	0.90	0.90
19	1	0.30	0.95	1.00	0.90
20	0	0.10	1.00	1.00	1.00



AUC						
< 0.5	0.5	0.6	0.7	0.8	0.9	1.0
Something Wrong	Random	Poor	Mediocre	Good	Excellent	Perfect

LIFT

전체 집단에 비해 특정 집단의 예측력이 향상된 정도

- 직관적인 평가지표로, 예측 Score 상위 고객을 선별하여 업무에 활용할 때 유용
- Lift : 상위 K건의 Positive 비율이 무작위 대비 몇 배인지 나타내는 지표

Score Data

No	실제 Class	예측 Score
1	0	0.90
2	1	0.80
3	0	0.70
4	1	0.60
5	0	0.55
6	1	0.54
7	0	0.53
8	1	0.52
9	1	0.51
10	0	0.51
~	~	~
100	0	0.11

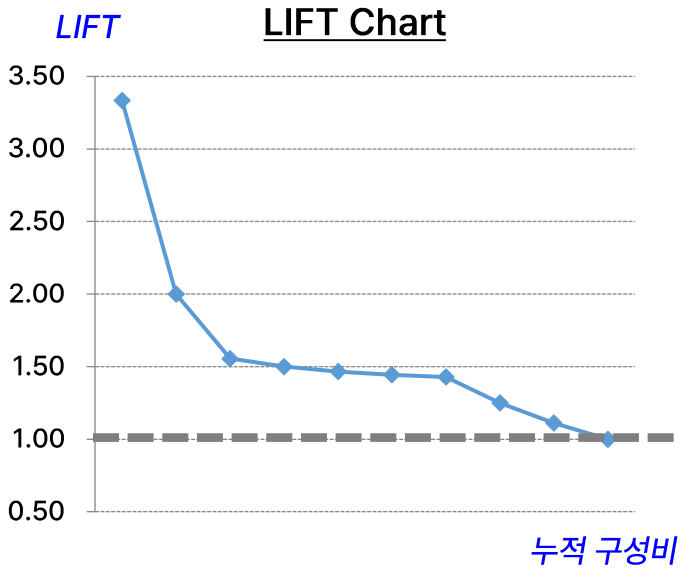
Total : 100건
Positive(=1) : 15건, 비율 : 0.15

➔

LIFT Table

누적 구성비	누적 전체 Count (a)	누적 1 Count (b)	b/a	LIFT
10%	10	5	0.50	3.33
20%	20	6	0.30	2.00
30%	30	7	0.23	1.56
40%	40	9	0.23	1.50
50%	50	11	0.22	1.47
60%	60	13	0.22	1.44
70%	70	15	0.21	1.43
80%	80	15	0.19	1.25
90%	90	15	0.17	1.11
100%	100	15	0.15	1.00

* Lift = (상위 K% 구간의 Positive Rate(=b/a))
/ (전체 데이터의 Positive Rate(=0.15))



" Score 상위 10% 추출시 무작위 추출에 비해 약 3.33배 높은 수의 이탈 고객들을 예측 할 수 있음 "

AUC & LIFT

AUC & LIFT 해석

- AUC 로 전체 집단의 모형 성능을 평가하고, LIFT 로 관심 집단의 성능을 평가

(AUC & LIFT 해석 예시)

모델 구분	AUC	LIFT					평가 및 해석
		1%	10%	20%	30%	50%	
모델 A	0.95	4.6	3.5	2.8	2.2	1.7	전반적인 성능 Excellent
모델 B	0.94	4.5	4.1	3.5	2.3	1.6	전반적인 성능 Excellent , 10% 에서 최고 성능
모델 C	0.88	6.3	3.9	2.7	2.0	1.5	전반적인 성능 Good, 1% 에서 최고 성능
모델 D	0.61	2.3	2.5	2.1	1.7	1.3	전반적인 성능 Poor, 그러나 20% 까지 2배 성능

** 참고) AUC : Excellent =0.9~1, Good = 0.8~0.9,* Mediocre *= 0.7~0.8, Poor = 0.6~0.7, Random = 0.5~0.6*

분류 평가지표 특징 비교

비즈니스 상황에 맞는 지표 선정

- 일반적으로 많이 사용되는 평가 지표는 Accuracy, F1, AUC
- 특정 목적에서 주로 사용되는 평가지표는 Precision, Recall, LIFT

	특징	평가 사례 예시
Accuracy	• 특정 Threshhold 下 에서 Both Classes (0, 1) 를 평가, Class 균등	• 성별, 개/고양이
F1	• 특정 Threshhold 下 에서 Positive Class (1) 의 오탐 / 미탐 모두 평가	• 금융사기, 암환자
Precision	• 특정 Threshhold 下 에서 Positive Class (1) 의 예측값 적중율(오탐) 평가	• 스펨 메일 (정상 메일을 스팸으로 분류하면 심각한 문제, 스팸을 놓치는 건 비교적 덜 위험)
Recall	• 특정 Threshhold 下 에서 Positive Class (1) 의 실제값 탐지율(미탐) 평가	• 암 환자 (암환자를 놓치면 생명 위험, 오탐은 추가 검사로 해결 가능)
AUC	• Class 분류 없이 전체 Probability 에서 Both Classes (0, 1) 를 평가	• 신용평가
LIFT	• Class 분류 없이 상위 Probability 에서 Positive Class (1) 를 평가	• 마케팅 타겟 추천

Regression 모델 평가 지표

회귀모형 성능 평가

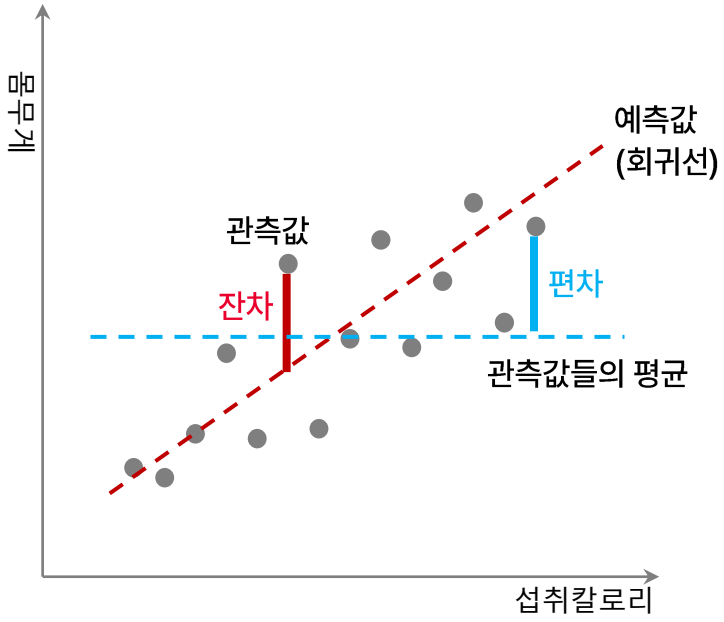
회귀모형의 성능은 오차의 크기 또는 모델의 설명력 관점에서 평가됨

- 오차 크기 : 모델이 얼마나 정확하게 예측하는지를 평가
- 모델 설명력 : 모델이 데이터를 얼마나 잘 설명하는지를 평가

평가 척도			수식	해석
오차의 크기	MAPE	Mean Absolute Percentage Error (평균절대백분율오차)	✓ 오차의 절대값을 실제값으로 나눈 후 모두 더한 다음 데이터 크기로 나눈 값 ➔ ∑(|실제값– 예측값 | /실제값)/ n	0 에 가까울수록 예측 오차가 적은 모델임
	MAE	Mean Absolute Error (평균절대오차)	✓ 오차의 절대값을 모두 더한 다음 데이터 크기로 나눈 값 ➔ ∑ |실제값– 예측값 | / n	
	MSE	Mean Squared Error (평균제곱오차)	✓ 오차의 제곱을 모두 더한 다음 데이터의 크기로 나눈 값 ➔ ∑ (실제값– 예측값)^2 / n	
	RMSE	Root Mean Squared Error (평균제곱근오차)	✓ 오차의 제곱을 모두 더한 다음 데이터의 크기로 나눈 값의 제곱근 ➔ √ { ∑ (실제값– 예측값)^2 / n }	
모델의 설명력	R^2	R-Squared (결정계수)	✓ SSR / SST = 회귀제곱합 / 총제곱합	1 에 가까울수록 설명력이 좋은 모델임
	Adj. R^2	Adjusted R-Squared (조정된 결정계수)	✓ 독립변수가 여러 개일 때 결정계수에 독립변수의 개수와 데이터 크기를 반영한 값	

[Review] 회귀모형 개념

회귀모형은 설명변수와 종속변수의 관계를 가장 잘 설명하는 회귀식을 찾는 분석 기법



- 잔차 : 관측값과 예측값의 차이 * 오차 : 모집단에서의 차이
- 회귀선 : 잔차²의 합이 최소가 되는 하나의 직선 (최소제곱법)

$$\sum \text{잔차}^2 = \sum (\text{관측값} - \text{예측값})^2 \rightarrow \text{MIN}$$

- 회귀식 : 회귀선을 함수식으로 나타낸 것
  독립변수와 종속변수의 관계를 나타냄

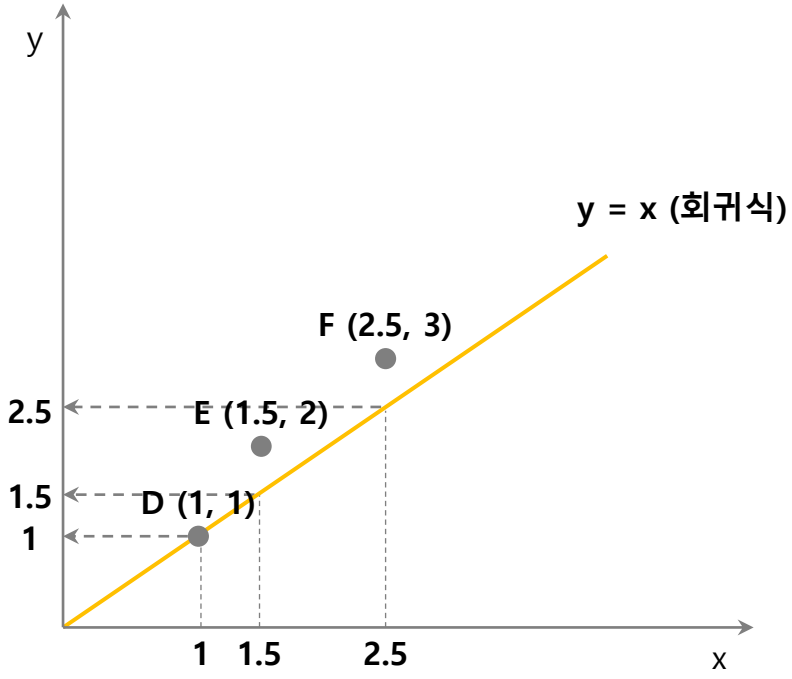
$$y = a_1 \cdot x_1 + a_2 \cdot x_2 + \ldots + a_n \cdot x_n + b$$

$$\text{종속변수}(y) = \text{회귀계수}(a_n) \times \text{독립변수}(x_n) + \text{상수}(b)$$

- 회귀 분석 : 회귀식을 찾는 분석기법

회귀모형 성능 평가 (MAPE)

- **MAPE** 는 오차의 절대값을 실제값으로 나눈 후 모두 더한 다음 데이터 크기로 나눈 값



MAPE = ∑ (|실제값– 예측값 | /실제값) / n

Test Data	x	y		ABS(관측값 – 예측값) / 관측값
	관측값	관측값	예측값 (y = x)	
D	1	1	1	ABS(1-1)/1 = 0
E	1.5	2	1.5	ABS(2-1.5)/2 = 0.25
F	2.5	3	2.5	ABS(3-2.5)/3 = 0.17
MAPE (평균절대백분율 오차)		(0 + 0.25 + 0.17) / 3		
		0.14		

회귀모형 성능 평가 (MAPE)

MAPE 해석 시 주의사항 (한계점)

- 0값 문제 : 실제값(A_i)이 "0"일 때 MAPE를 계산할 수 없음

- 데이터 값이 매우 작을 때 상대적으로 큰 오차를 발생시킴→ 과민반응

- MAPE가 무한대로 발산할 때

$$MAPE = \frac{100}{n}\sum_{i=1}^{n}\left|\frac{A_i - F_i}{A_i}\right|$$

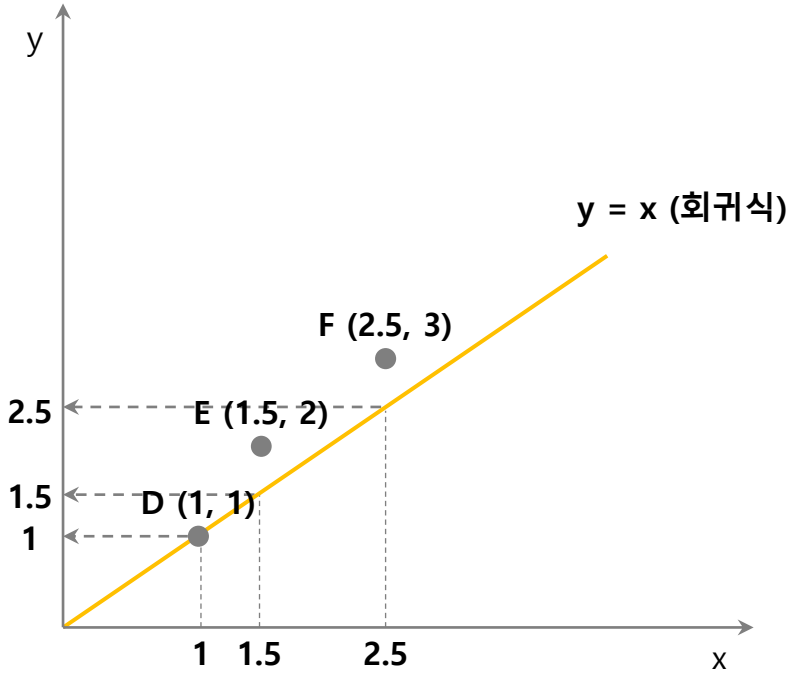
(대체) sMAPE, Symmetric MAPE

: 실제값과 예측값의 차이를 두 값을 평균으로 나누어 대칭적인 오차 계산

$$\mathrm{sM}APE = \frac{100}{n}\sum_{i=1}^{n}\left|\frac{A_i - F_i}{\frac{|A_i| + |F_i|}{2}}\right|$$

회귀모형 성능 평가 (MAE)

- **MAE** 는 오차의 절대값을 모두 더한 다음 데이터 크기로 나눈 값

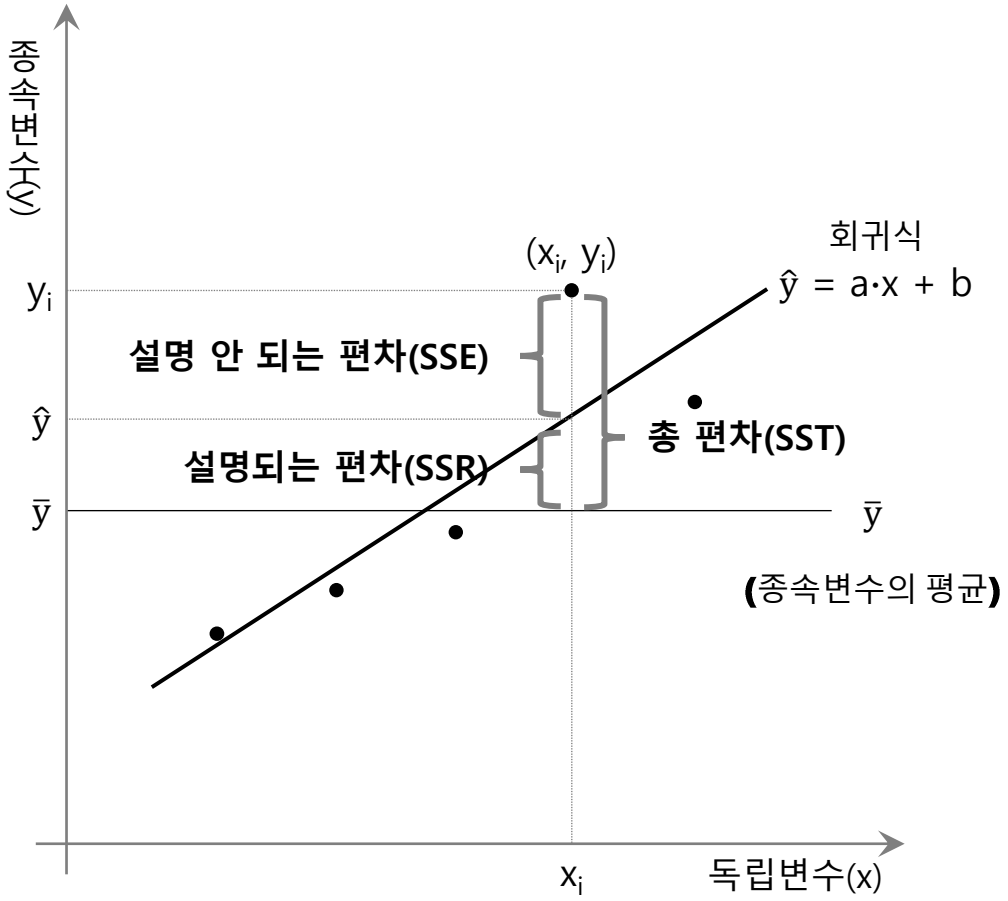


MAE = ∑ |실제값– 예측값| / n

Test Data	x	y		ABS(관측값 – 예측값) / 관측값
	관측값	관측값	예측값 (y = x)	
D	1	1	1	ABS(1-1) = 0
E	1.5	2	1.5	ABS(2-1.5) = 0.5
F	2.5	3	2.5	ABS(3-2.5) = 0.5
MAE (평균절대오차)		(0+0.5+0.5) / 3		
		0.33		

[Review] 회귀모형 성능 평가 (R^2)

- **결정계수(R^2)는 회귀모델에서 독립변수가 종속변수를 얼마만큼 설명해 주는지를 가리키는 지표**
- **지표 해석 : 1 에 가까울 수록 성능이 좋고, 음수값이 나오면 Y 평균값으로 예측한 것 (Naïve 모델) 보다 못한 것임**



SST(총변동) = SSR(회귀변동) + SSE(잔차변동)

- **SST(총편차, 총변동, 제곱합)**
  = 관측값– 평균값 = $y_i - \bar{y}$
- **SSR(설명되는 편차, 회귀변동, 회귀제곱합)**
  = 예측값– 평균값 = $\hat{y} - \bar{y} = (a \cdot x + b) - \bar{y}$
- **SSE(설명 안 되는 편차, 잔차변동, 잔차제곱합)**
  = 관측값– 예측값= $y_i - \hat{y} = y_i - (a \cdot x + b)$
- **결정계수(R^2)**
  - $R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}$
- **조정된 결정계수(R^2_{adj})**
  $R^2_{adj} = 1 - \frac{SSE/(n-k-1)}{SST/(n-1)}$, n: 데이타수, k: 독립변수 수

회귀모형 평가지표 특징 비교

데이터 특성과 목적에 따라 선정

평가지표 (Metrics)		장점	단점
예측 오차 크기	MAE	• 매우 직관적 (평균적인 오차 값) • MAE 값이 실제값과 단위가 동일	• 데이터 단위(scale)에 의존적
	MSE	• 오차 특이값에 Penalty 줌	• 이상치(outlier)에 매우 민감 • 단위가 제곱이라 해석이 직관적이지 않음
	RMSE	• 오차 특이값에 Penalty 주나, MSE 보다는 완화 • 직관적 (평균적인 오차 값)	• 이상치(outlier)에 민감 • 데이터 단위(scale)에 의존적
비율 오차	MAPE	• 직관적 (평균적인 오차 비율) • 서로 다른 스케일 비교 가능	• 실제값이 '0' 인 경우 산출 불가 -> '0' 인 경우는 제외하거나 대체 산출
설명력	R-Square	• 모델 설명력 제공 (모형 적합도 의미) • 일반적으로 0~1 범위로 해석 용이	• '예측력'보다는 '설명력'에 치중

데이터 분석 및 AIOps

6. 모델 해석

- 모델 해석이 중요한 이유
- SHAP

본 문서는 SK㈜AX의 컨텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

모델 해석이 중요한 이유

~~~

왜 모델 해석이 중요한가?

ML/DL 모델 : 블랙박스 모델

머신러닝과 딥러닝 모델은 높은 성능을 제공하지만, 내부 동작을 이해하기 어려운 '블랙박스(Black Box)' 성격을 가짐

통계적 모델 (Linear Regression)

y = 0.5 * Age + 1.2 * Income
→ 계수(Coefficient)를 통해 인과관계 설명 가능

The Solution: XAI

Explainable AI (XAI) 기술을 통해 블랙박스 모델을 해석할 수 있음.
그 중 SHAP은 가장 강력하고 이론적으로 검증된 도구임

SHAP SHapley Additive exPlanations

각 특성(Feature)이 예측 결과에 기여한 정도를 게임 이론으로 계산

Force Plot 예시



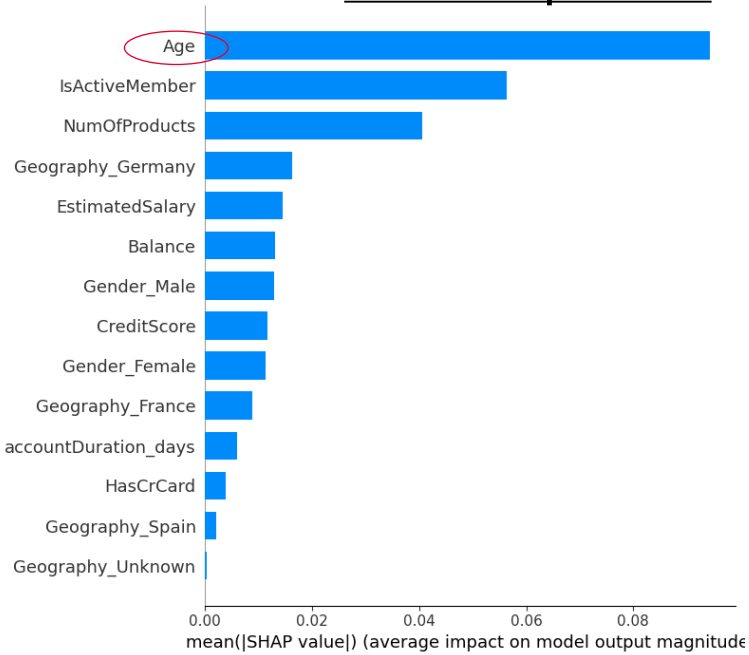
- 신용평가 모델에서 특정 개인의 신용평가 결과에 대해서 각 변수들이 어떻게 영향을 주었는지를 설명해 줌

예시) Age, Income 은 신용평가에 (+) 요인으로 작용하고,
Debt, Loan 은 (-) 요인으로 작용함
~~~

SHAP

Feature Importance, Feature Impact

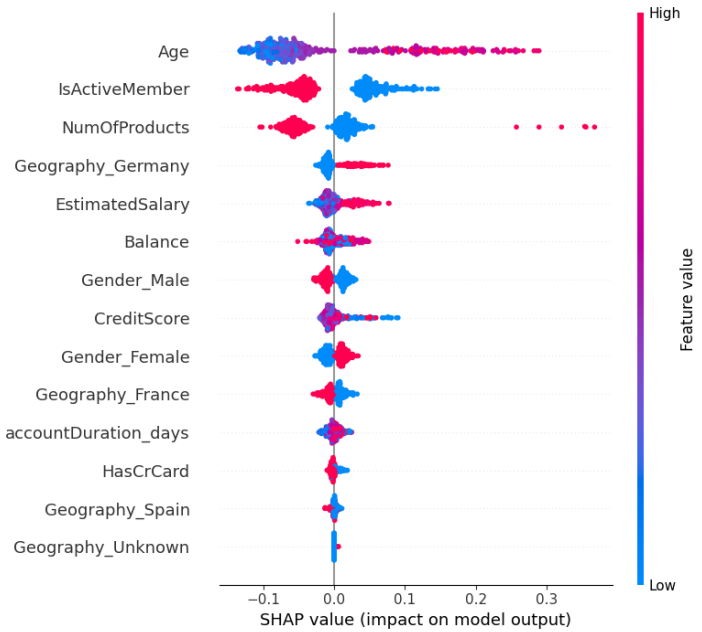
Feature Importance



- 변수의 평균적인 영향력을 보여주는 것으로, 각 특성이 모델에 미치는 절대 영향도(=기여분)를 파악할 수 있음

  예시) 은행 이탈에 가장 중요한 Feature 는 'Age' 임

Feature Impact



- 변수의 영향도와 각 변수가 모델에 영향을 주는 분포를 확인함

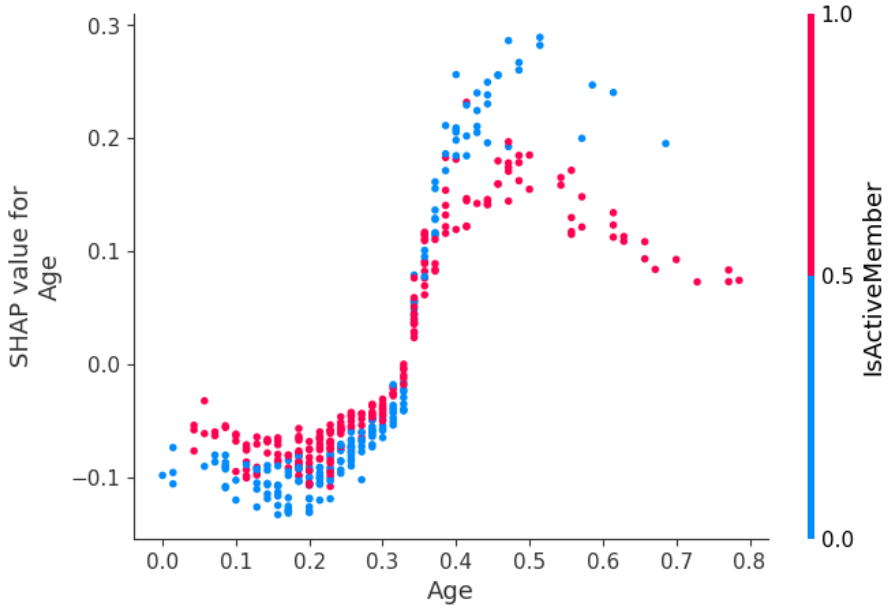
  예시) 은행 이탈에 가장 중요한 Feature 는 'Age' 이고,
  Age 값이 클수록 이탈에 (+) 요인으로 작용함

SHAP

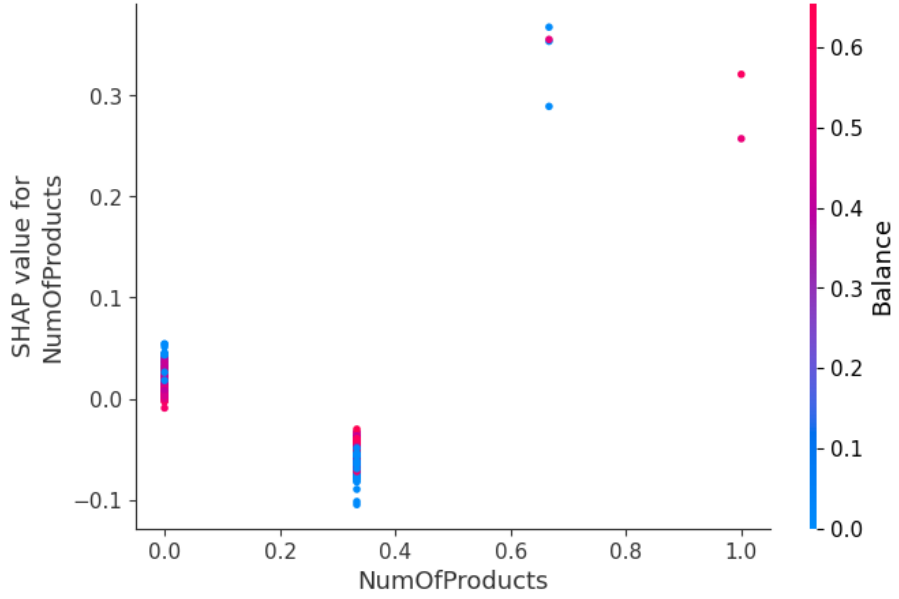
Feature Dependence

- 각 특성별 Target과의 관계 패턴을 보여주는 것으로, 특성간 상호작용도 확인할 수 있음

Feature Dependence



예시) 'Age' 가 클 수록 이탈율이 증가하고, 같은 연령에서는 'IsActiveMember' =1 일 경우 이탈이 감소함



예시) 'NumOfProducts' 가 많을 수록 이탈율이 높은 패턴을 보임

데이터 분석 및 AIOps

7. 모델 모니터링

- Model Drift 란?
- Data Drift / Prediction Drift / Concept Drift
- Model Drift 대응 전략
- Model Renewal 방안

본 문서는 SK㈜AX의 컨텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

SK Inc. AX

Model Drift 란?

모델 개발시점과 운영시점의 모델 성능 차이

Model Drift 정의

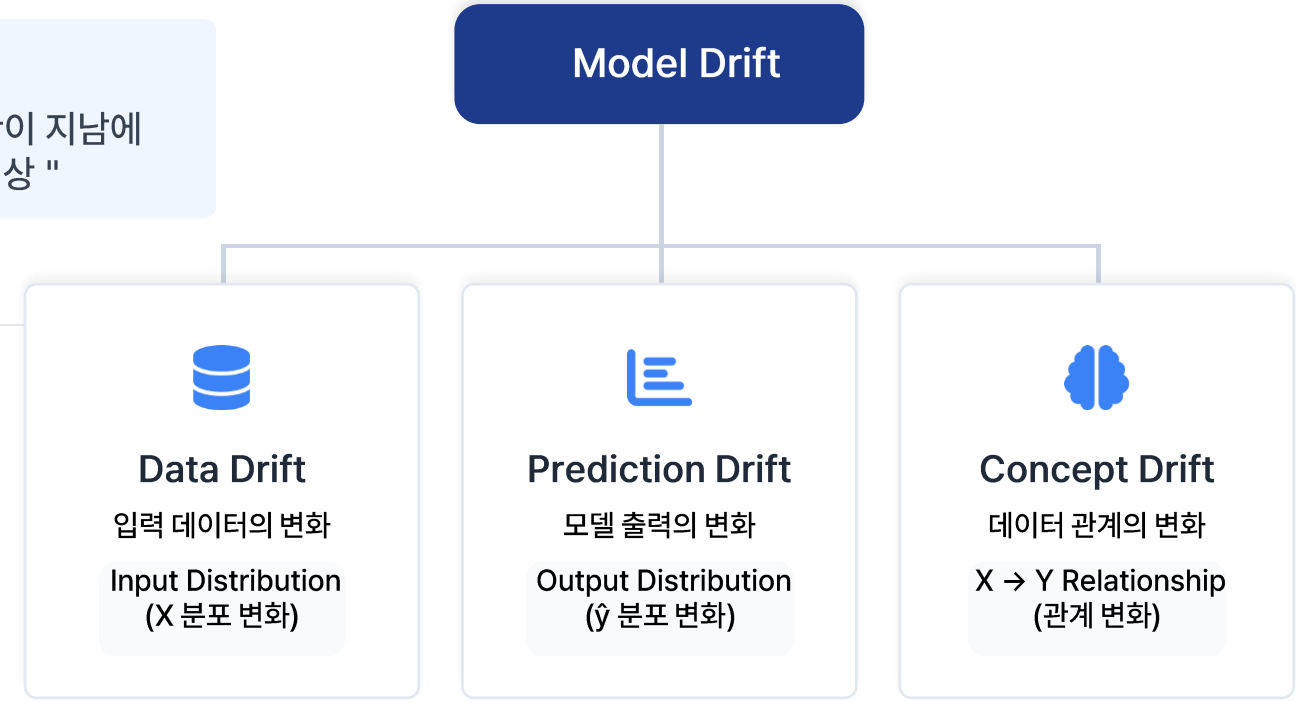
"학습 환경과 운영 환경의 차이로 시간이 지남에 따라 모델의 성능이 저하되는 현상 "

왜 모니터링해야 하는가?

성능 하락
예측 정확도 및 신뢰도 감소

잘못된 의사결정
오류가 있는 예측 기반의 판단

비즈니스 손실
매출 감소 및 리스크 증가



" 각 유형은 발생하는 원인과 감지 방법이 서로 다름 "

Data Drift: 입력 분포의 변화

Definition

모델에 입력되는 데이터의 통계적 분포가 학습 시점과 비교하여 유의미하게 달라지는 현상

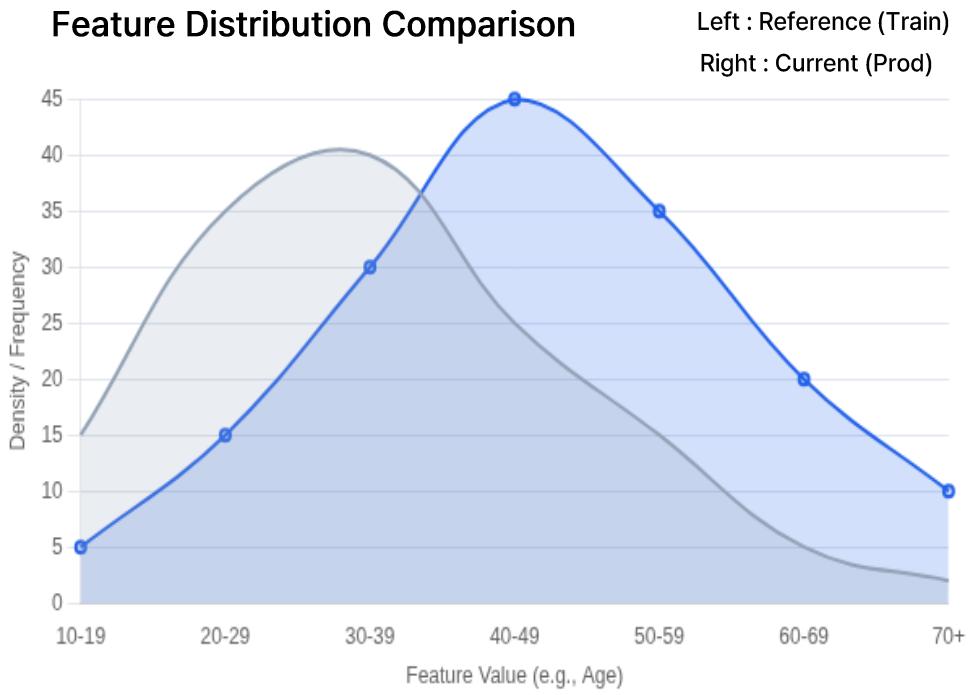
Mathematical: $P_t(X)$ *(현재시점)* $\neq$ $P_{ref}(X)$ *(기준시점)*

발생 원인 및 예시

사용자/환경 변화
코로나19로 인한 소비 패턴 변화, 새로운 유저 그룹 유입
(예: 10대 유저 급증)

계절성 및 트렌드
주말/공휴일 트래픽 패턴, 특정 시즌 상품 수요 급증

데이터 파이프라인 이슈
센서 교체로 인한 단위 변경(°F → °C), 결측치 처리 로직 변경



운영 데이터(파란색)가 훈련 데이터(회색)보다 고연령층으로 이동(Shift)

Prediction Drift: 예측 분포의 변화

Definition

모델이 출력하는 예측값(Prediction)의 통계적 분포가 기준 시점과 비교하여 유의미하게 달라지는 현상

Mathematical: $P_t(\hat{y}) \neq P_{ref}(\hat{y})$

특징 및 시사점

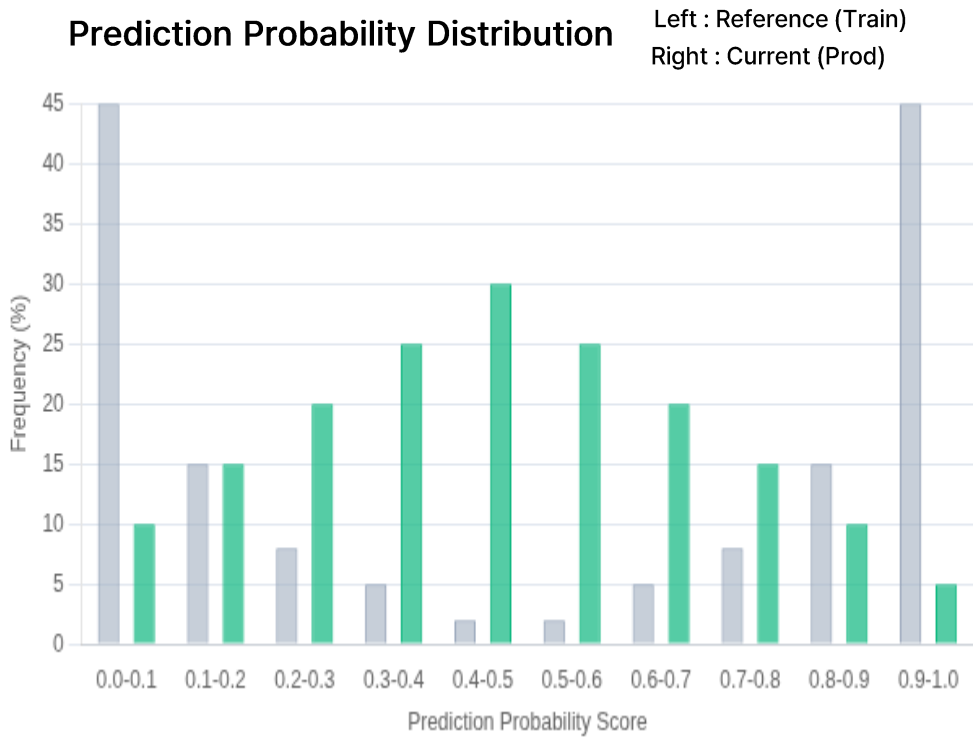
결과론적 지표 (Downstream Effect)
Data Drift나 Concept Drift가 발생했을 때, 그 결과로서 예측 분포가 변하는 경우가 많음

주요 예시

스팸 탐지율 급증(5% → 20%)

긍정/부정 예측 비율 역전

신용점수 예측치가 전반적으로 하락



초기(회색)에는 0과 1 양극단에 확신을 가진 예측이 많았으나, 현재(초록색)는 중간 구간(0.4~0.6)의 비중이 높아져 모델의 불확실성이 증가

Concept Drift: 입력-Target 관계의 변화

Definition

입력 데이터와 정답(Target) 간의 상관관계(패턴)가 변해서, 기존 모델이 더 이상 유효하지 않게 되는 현상

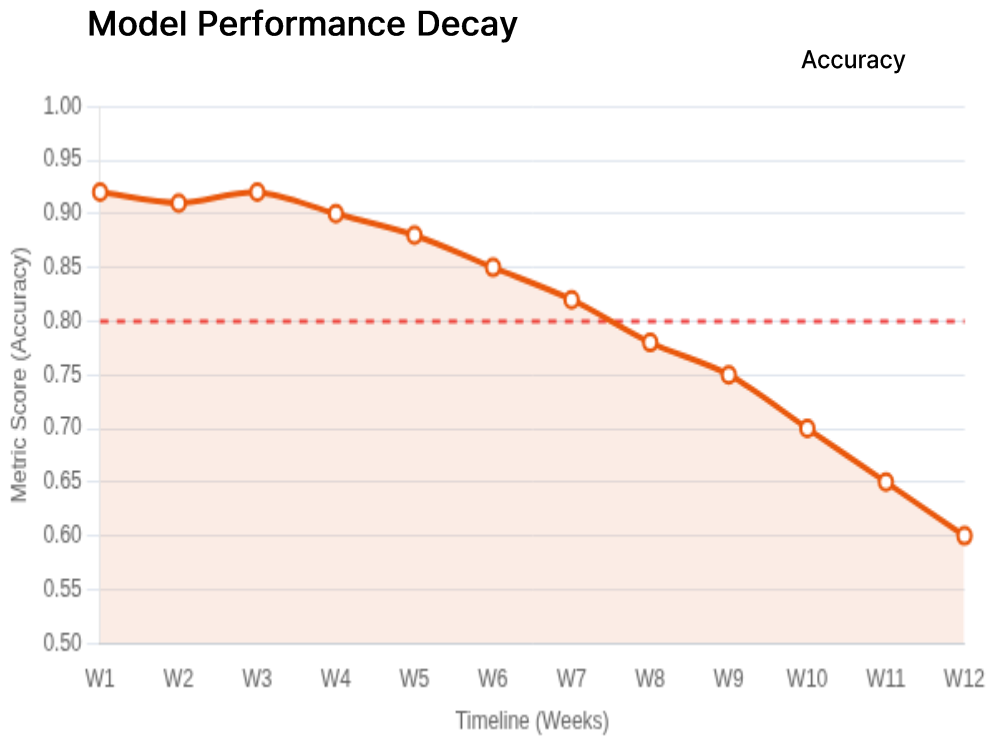
Mathematical: $P_t(Y|X) \neq P_{ref}(Y|X)$

주요 발생 원인 (Real-world Causes) 예시

거시 환경 변화 (Macro Environment)
금리 인상, 법/규제 개정으로 인한 부도 위험 기준 변화

비즈니스 프로세스 변경
앱 UI 개편으로 인한 클릭 패턴 변화, 상품 분류 기준 변경

주요 예시
경쟁사 등장으로 이탈 요인 변경
경기 침체로 인한 소비 패턴 변화



" 모델의 정확도(Accuracy)가 시간이 지남에 따라 점진적으로 하락 "

Model Drift 대응 전략

Drift 유형에 맞는 적절한 조치가 필요

Data Drift
입력 데이터 변화

Formula :
Pt(X) ≠ Pref(X)

입력 피처의 분포 P(X)

대응 전략 :
Feature 변경없이 가중치만 조정
(Re-training)

Prediction Drift
예측 분포 변화

Formula :
Pt(ŷ) ≠ Pref(ŷ)

모델 예측값의 분포 P(ŷ)

대응 전략 :
의사결정 위한 예측 확률 기준값 조정
(Threshold Adjustment)

Concept Drift
관계의 변화

Formula :
Pt(Y|X) ≠ Pref(Y|X)

입력과 정답의 관계 P(Y|X)

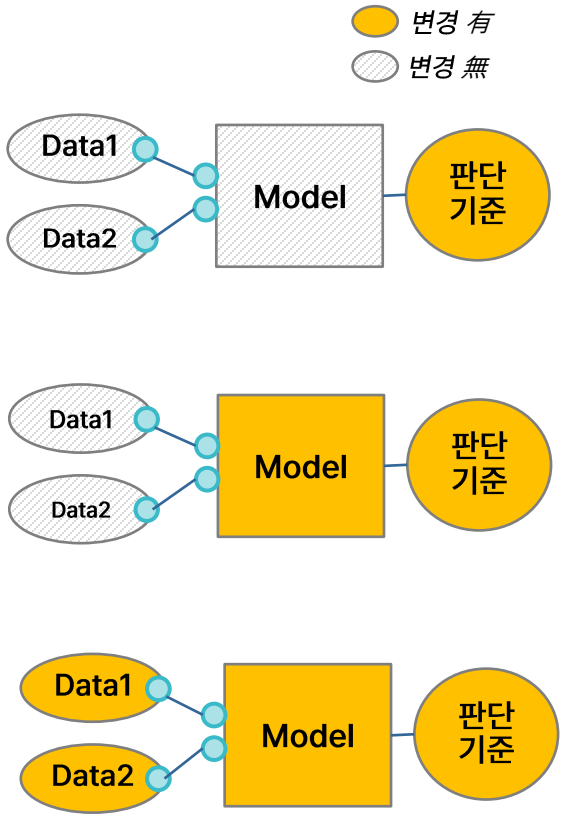
대응 전략 :
EDA 부터 Feature 생성 등
모델 재구축
(Re-modeling)

(대응 절차) 1. 모델 성능 변화없이 예측 분포만 변화 : Threshold Adjustment
2. 모델 성능 변화가 발생 : Re-training -> 개선 없으면 -> Re-modeling

Model Renewal 방안

모델 변경 수준에 따라 결정

Renewal 방법	Renewal 내용
Threshold Adjustment (Cut-Off 변경)	등급 or Targeting 구간의 Threshold 조정 - 예) 기존 신용 1등급은 연체 확률 0.2 이하 -> 변경 후는 연체 확률 0.15 이하
Re-training (모델 재 학습)	Feature 변경 없이 모델만 재학습 실행 - Feature 사용은 동일하나 기존 모델에 사용된 Feature 계수를 변경 (예, Feature A 계수 0.5 → 0.7로 변경)
Re-modeling (모델 재 구축)	Feature 변경 포함하여 모델을 재 생성 - 모델을 완전히 변경하는 것으로서 모델 생성에 필요한 절차를 수행



데이터 분석 및 AIOps

Appendix

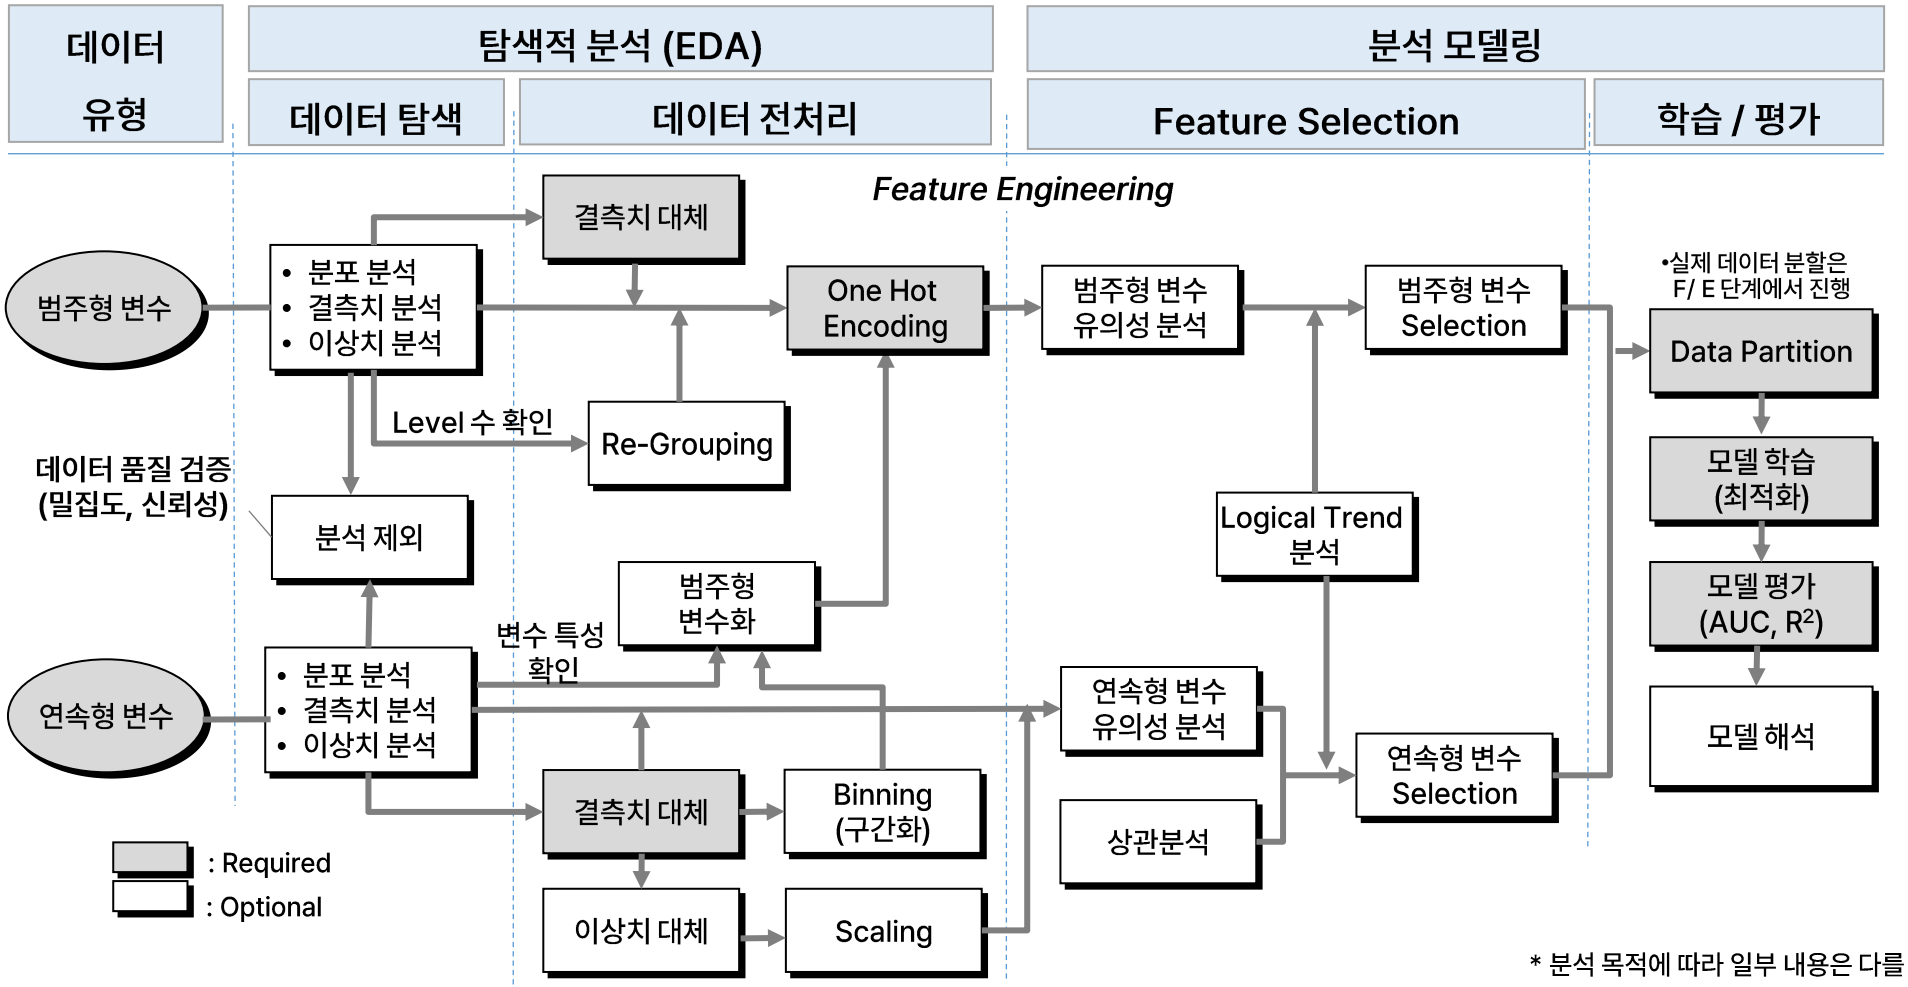
- End-to-End 모델링 프로세스
- AutoML

본 문서는 SK㈜AX의 컨텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

SK Inc. AX

End-to-End 모델링 프로세스

End-to-End 모델링 프로세스

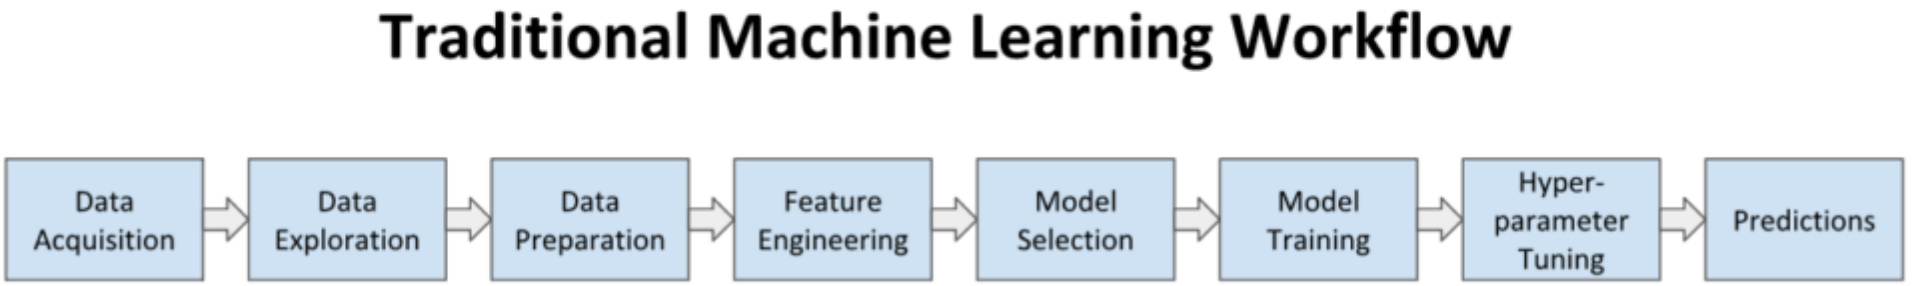


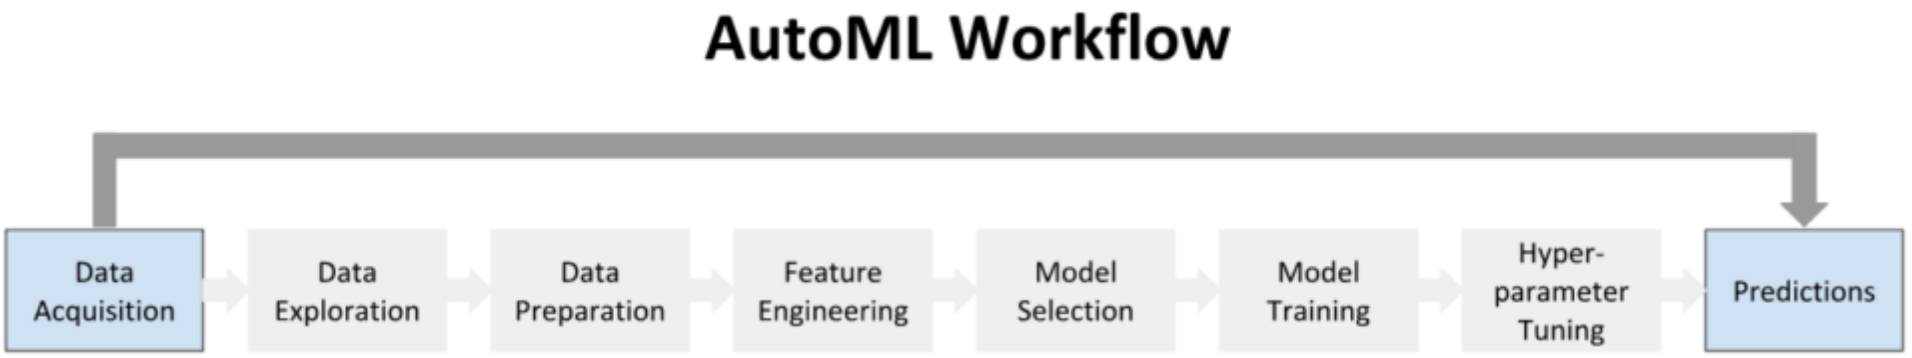
* 분석 목적에 따라 일부 내용은 다를 수 있음

AutoML

AutoML 정의

분석 자동화 (AutoML) 는 분석 Workflow의 전체 또는 일부를 자동화하는 기술임

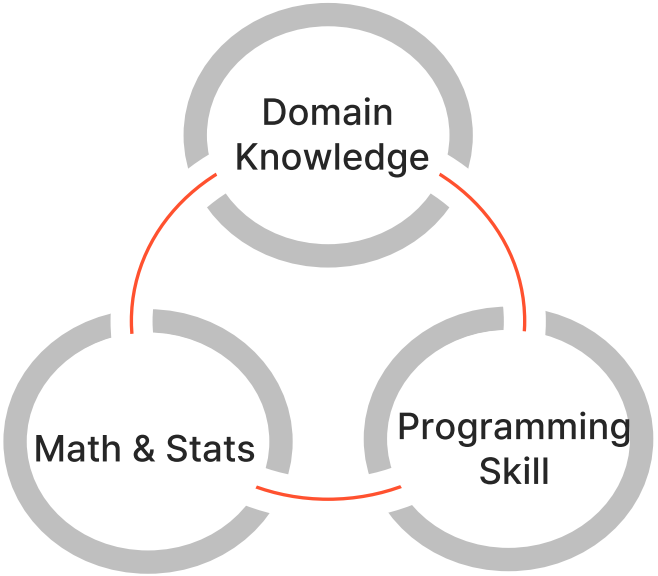




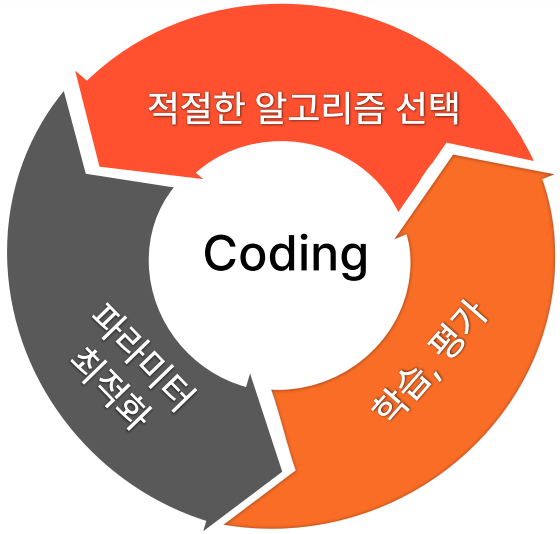
AutoML 배경

Machine Learning 장벽

어렵다.

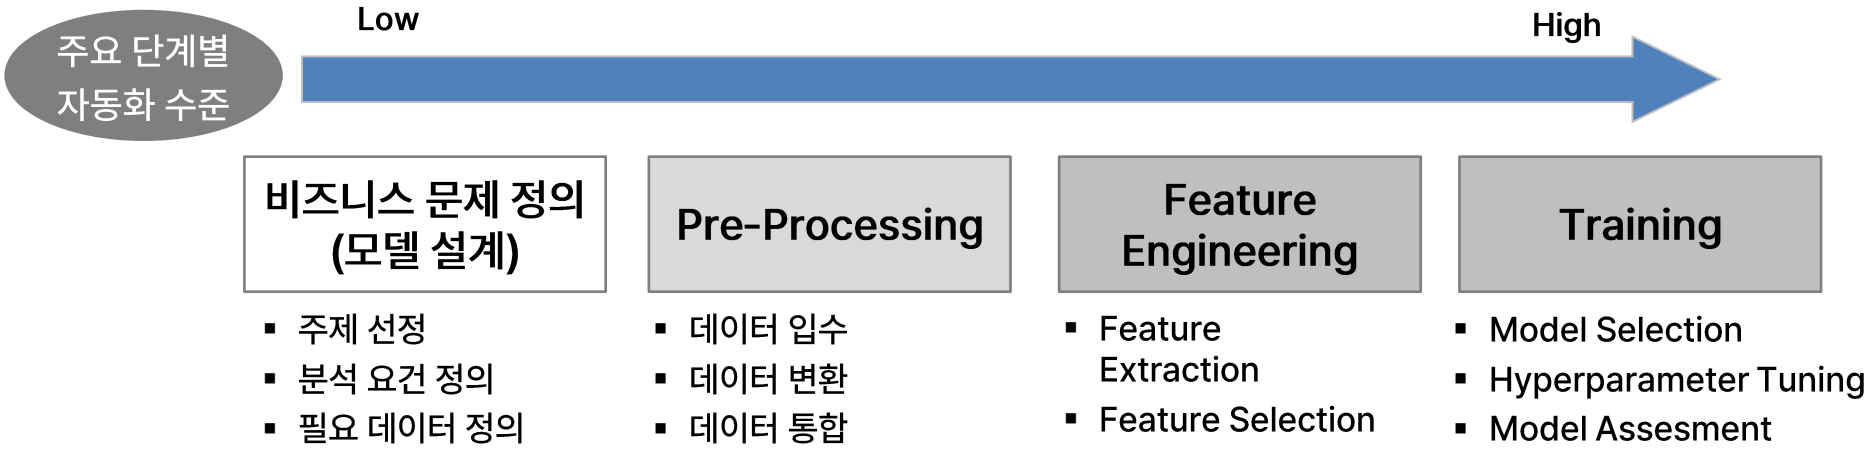


노력이 많이 든다.



AutoML 자동화 수준

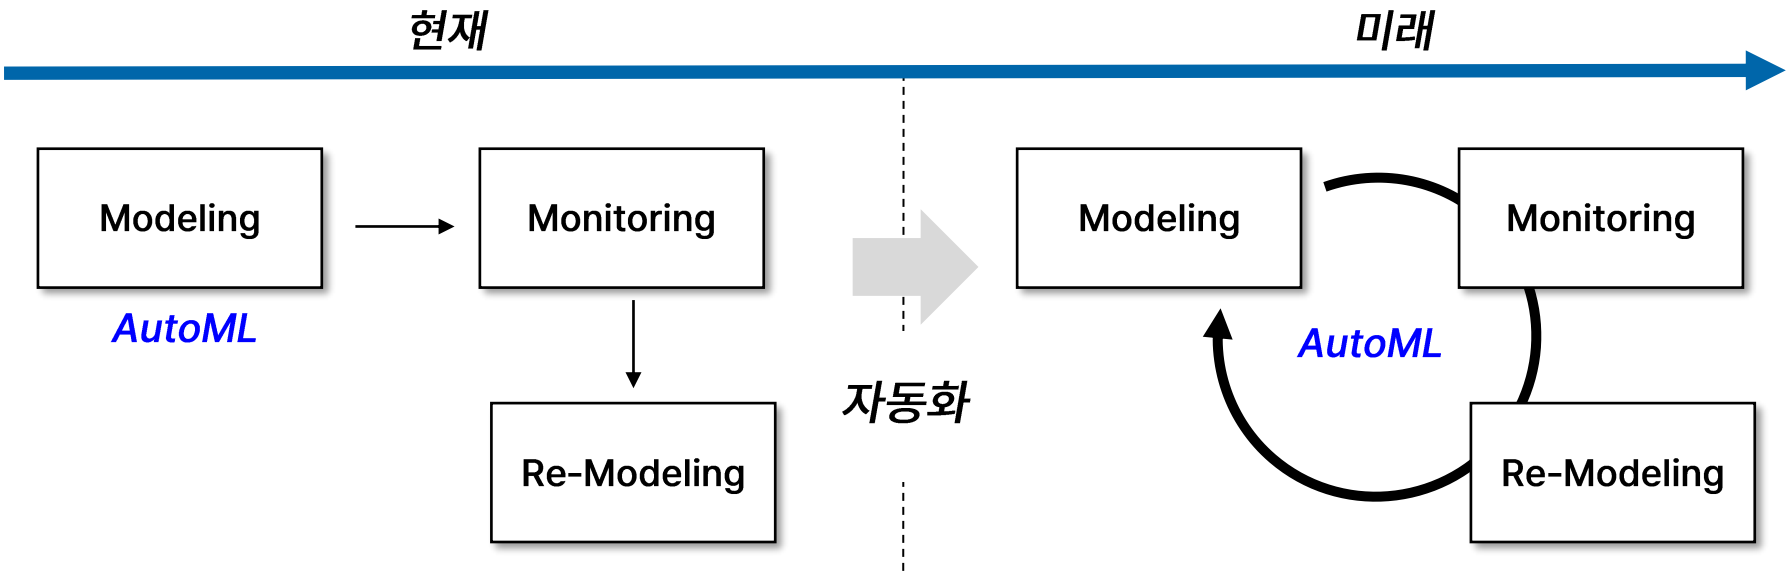
AutoML 자동화 수준



AutoML 목표

분석 자동화 (AutoML) 의 궁극적인 목표는 Model Life Cycle 자동화에 있음

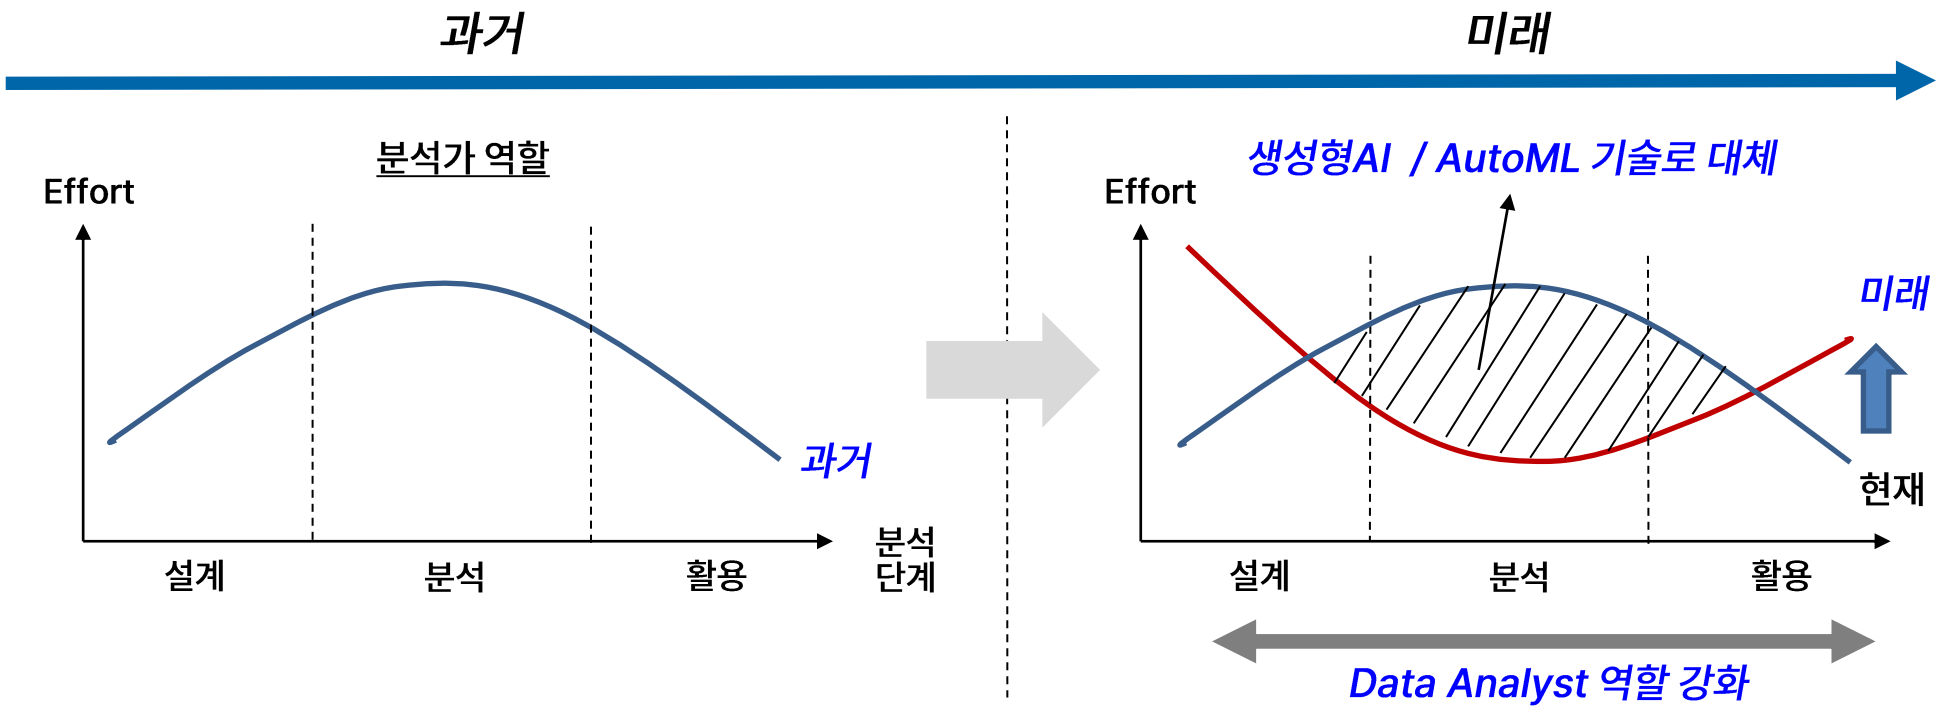
- 미래 분석 기술은 기계가 스스로 모델을 개발, 모니터링, Re-Modeling 단계로 발전 예상



Data Analyst 역할 변화

분석 기술 자동화 추세에 따라 분석 전문가의 역할 변화도 예상

- 분석가는 비즈니스, IT 와의 협업 역할이 더욱 강조되는 방향으로 변화
- Data Analyst 층이 넓어지고, 기업에서 역할 증대가 예상됨





수고하셨습니다.

본 문서는 SK㈜AX의 컨텐츠 자산으로, 무단 사용 및 불법 배포 시 법적 조치를 받을 수 있습니다.

SK Inc. AX