SKALA

RESEARCH



# RAG, Retrieval Augmented Generation

| | |
|---|---|
| Select | RAG |
| Date | 2026/06/29 |
| Remark | RAG 수업 배포용 |

© 2025-2026. Keejoo Bae for SK AX / SKALA. All rights reserved.

*This content is protected by copyright law. Unauthorized copying, distribution, or modifications are strictly prohibited.*

Retrieval

- Naive-RAG, 최초 제안
- Advanced RAG, 구조 개선

Query

- Self-RAG, 모델이 스스로 검색의 필요성을 판단하는 기법
- Corrective RAG, 부정확한 검색 문제를 해결하기 위해 제안된 프레임워크
- Adaptive-RAG, 질문의 복잡도에 따라 동적으로 처하는 프레임워크

Graph

- Graph RAG, Flat 청크면 충분하다는 가정을 다시 보고 지식을 그래프로 표현

Structure

- Modular RAG, 레고 블럭처럼 재구성 가한 프레임워크
- Agentic RAG, 에이전트 기반으로 도구 활용으로 확장한 프레임워크

## Retrieval

### Naive-RAG, 최초 제안

- *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks*
- Facebook AI Research (2020)
- arxiv.org
- ▶ 주요 내용
- 핵심 기여
  - RAG Architecture 제안 → 모델은 외부 지식을 동적으로 검색하여 활용할 수 있음
  - Knowledge-intensive task(QA, 요약 등)에서 SOTA 성능 달성
  - Updatable knowledge: 새로운 지식을 학습 없이 바로 반영 가능
- 연구적 의의
  - Parametric vs Non-Parametric Knowledge 결합
  - Dense Retriever + Seq2Seq Generator 통합하여 자연스러운 흐름을 가능하게 함
  - Pretrained Language Model 활용의 새로운 방식 제시

### Advanced RAG, 구조 개선

- Retrieval-Augmented Generation for Large Language Models: A Survey
- Shanghai Research Institute, Tongji University (2023.12)
- arxiv.org ⭐
- ▶ 주요 내용
- 핵심 기여
  - 단순 Top-K 검색을 넘어 Reranking, Dense Retrieval, Multi-hop Retrieval 등 고도화된 기술 도입
  - Chunking, Filtering, Fusion 등으로 문서 전처리 및 구성 전략 정교화
  - 생성기 강화 : Self-consistency, Instruction tuning, Self-critique 등 통해 싱성 품질과 신뢰도 향상
- 연구적 의의
  - 검색 품질 문제 해결을 위한 구조적 대응 방식 제시
  - 단순한 파이프라인을 넘어서, 검색-증강-생성 이라는 전체 과정을 독립적이면서도 통합적으로 최적화
  - 질문별 전략 구성, 구성 요소 모듈화 등을 통해 이후 연구에 모듈화 기반의 설계 기준 마련

---

## Query

### Self-RAG, 모델이 스스로 검색의 필요성을 판단하는 기법

- *Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection*
- University of Washington, Allen Institute for AI, Amazon AWS AI (2023.10)
- arxiv.org ⭐
- ▶ 주요 내용
- 핵심 기여
  - Feedback Loop 도입 : "답변 생성 → 점검 → 검색 → 재생성"의 루프 구조
    - ▶ Self-RAG Loop
  - Self-critiquing 통해 모델이 자체적으로 fact-checking 수행
    - On-demand Retrieval : 기존 RAG가 모든 질문에 무조건 검색하는 것과 달리, 검색이 필요한 경우에만 선택적으로 수행 → 불필요한 검색으로 인한 품질 저하 방지
    - Reflection Token : 특수 토큰을 생성 흐름에 인라인으로 삽입하여 판단과 생성을 통합
      - ▶ 특수 토큰
    - Segment-wise Beam Search : 응답을 구간 단위로 평가하여 가장 신뢰도 높은 출력 경로를 선택
  - 기존 RAG 구조 보다 Fact consistency와 신뢰성 향상
  - 별도 정답 라벨 없이도 훈련 가능한 Self-Supervised Learning 방식
- 연구적 의의
  - LLM이 스스로 "내가 낸 답변이 맞나?" 라고 묻고 판단하는 능력 부여
  - Retrieval-augmented 시스템을 단순 도구 → 스스로 검토하는 Agent로 확장한 시도
  - 이후 Multi-step Reasoning, Agent 발전 방향과 연결

### Corrective RAG, 부정확한 검색 문제를 해결하기 위해 제안된 프레임워크

- *Corrective Retrieval-Augmented Generation*
- Google DeepMind (2024.01)
- arxiv.org
- ▶ 주요 내용
- 핵심 기여
  - Self-Correcting 매커니즘 도입 : 모델이 스스로 검색 결과의 품질을 평가하고, 필요 시 추가 검색 수행하여 생성의 정확도 개선
  - 검색 결과의 효율적 활용 : 분해-재구성 과정 통해 검색된 정보의 활용도 극대화
  - Plug-in 방식의 호환성 : 기존 RAG 시스템에 쉽게 통합
- 연구적 의의
  - RAG 견고성 향상 : 부정확한 검색 결과로 인한 문제를 완화하여 생성 모델의 신뢰성 높임
  - 자기 평가 및 수정 능력 부여 : 모델이 스스로 검색 결과를 평가하고 보완하는 능력을 갖추게 함으로써, 외부 지식 활용의 효율성을 증대

### Adaptive-RAG, 질문의 복잡도에 따라 동적으로 처하는 프레임워크

- *Adaptive-RAG: Learning to Adapt Retrieval-Augmented Large Language Models through Question Complexity*
- KAIST (2024.03)
- arxiv.org
- ▶ 주요 내용
- 핵심 기여
  - 질의 복잡도 기반 동적 전략 선택 : 질문의 복잡도에 따라 적절한 검색 및 생성 전략을 선택하여 효율성과 정확성 향상
  - 자동화된 질의 복잡도 분류기 학습 : 모델의 예측 결과와 데이터셋의 내재된 특성을 활용하여 분류기를 자동으로 학습시킴
  - 다양한 질의에 대한 적응성 : 간단한 질의부터 복잡한 질의까지 다양한 수준의 질문에 대해 효과적으로 대응 할 수 있음
- 연구적 의의
  - 시스템 효율성 향상 : 질의의 특성에 맞는 전략을 선택함으로써 계산 자원을 효율적으로 활용
  - 자동화된 분류기 학습 방법 제안 : 추가적인 수작업 라벨링 없이도 질의 복잡도를 분류 할 수 있는 방법 제시
  - 다양한 복잡도의 질의 처리 가능 : 단순한 질의부터 복잡한 질의까지 모두 효과적으로 처리 할 수 있는 적응형 시스템

---

## Graph

### Graph RAG, Flat 청크면 충분하다는 가정을 다시 보고 지식을 그래프로 표현

- *From Local to Global: A Graph RAG Approach to Query-Focused Summarization*
- Microsoft (2024.04)
- arxiv.org
- arxiv.org ← Survey
- ▶ 주요 내용
- 핵심 기여
  - 문서 집합 전체에서 엔티티와 관계를 추출하여 지식 그래프 구성
  - 핵심은 표현이지만, 검색(Graph, Multi-hop)과 질의(Local/Global Routing)까지 영향이 이어짐
- 연구적 의의
  - 임베딩 기반 청크 검색 → LLM이 구축한 지식 그래프·커뮤니티 요약 기반의 구조화된 Retrieval로 전환
  - 커뮤니티 요약의 계층 구조를 활용해 대규모 코퍼스에서도 sensemaking(주제·요약) 질의를 확장적으로 처리
  - LLM의 역할을 단순 응답 생성기에서 그래프 구축·요약 생성기로 확장

---

## Structure

### Modular RAG, 레고 블럭처럼 재구성 가한 프레임워크

- *Modular RAG: Transforming RAG Systems into LEGO-like Reconfigurable Frameworks*
- Shanghai Jiao Tong University, East China Normal University (2024.07)
- arxiv.org ⭐
- ▶ 주요 내용
- 핵심 기여
  - 유연한 시스템 구성 : 각 모듈을 독립적으로 설계하고 필요에 따라 교체하거나 결합할 수 있어, 다양한 작업 시나리오에 맞게 시스템을 최적화할 수 있음
  - 확장성 강화 : 새로운 기술이나 방법론을 빠르게 적용할 수 있으며, 시스템의 유지보수 용이
  - 복잡도 관리 : 시스템의 복잡도를 낮추고 성능을 향상시킬 수 있는 기능성 제공
- 연구적 의의
  - 모듈화된 설계 : RAG 시스템을 모듈화하여 관리와 확장이 용이한 구조로 변환
  - 재구성 가능한 프레임워크 : 레고 블럭처럼 각 모듈을 조합하여 다양한 시스템 구성이 가능하도록 설계

### Agentic RAG, 에이전트 기반으로 도구 활용으로 확장한 프레임워크

- *Agentic Retrieval-Augmented Generation: A Survey on Agentic RAG*
- Cleveland State University, Roux Institute at Northeastern University (2025.01)

- arxiv.org ⭐
▶ 주요 내용
- 핵심 기여
    - 동적 검색 전략 관리 : 에이전트는 실시간으로 검색 전략을 조정하여 최신 정보 활용
    - 문맥 이해 개선 : 반복적인 피드백 루프 통해 문맥에 대한 이해를 지속적으로 향상시킴
    - 다중 에이전트 협업 : 협업 통해 복잡한 작업 처리 능력 향상
- 연구적 의의
    - 에이전트 통합 : 에이전트를 RAG 시스템에 통합하여 자율성과 적응성 향상
    - 에이전트 패턴 활용 : 반성, 계획 등 에이전트 패턴을 통해 복잡한 작업 처리 능력 강화
    - 다양한 산업 분야 적용 가능성 : 의료, 금융 등 다양한 분야에서의 적응 가능성 제시