

설계 산출물

2조 —- P280-김동욱, P282-김민정, P287-김태동, P289-박규리, P298-이재겸, P301-임동건

A. 대상 기술

A-1. 선정 도메인

본 과제에서는 데이터센터·클라우드 기반 LLM 서빙 환경을 평가 도메인으로 선정한다.

장문맥 LLM 서빙은 긴 문서 분석, 기업용 챗봇, AI 고객센터, 코드베이스 분석, RAG 및 AI Agent 서비스 등에 활용된다. 이러한 서비스에서는 하나의 모델이 여러 사용자의 요청을 동시에 처리해야 하므로 GPU 메모리 사용량, 처리량, 응답시간 및 운영비용이 중요하다.

→ 선정 이유: 대규모 동시 요청 · 비용 민감 · 문맥 길이 민감 조건이 동시에 존재하여 KV cache 문제가 가장 크게 드러나는 환경임

A-2. 문제 상황

KV cache는 다음 조건에 따라 크기가 증가한다.

- 모델 레이어 수가 많을수록 증가
- attention head 수가 많을수록 증가
- 입력 문맥이 길수록 증가
- 동시 사용자와 batch size가 증가할수록 증가
- 저장 정밀도가 높을수록 증가

규모 예시 (Llama-3.1-70B, FP16 기준 토큰당 320KiB)

문맥 길이	요청 1건 KV cache	동시 8건	GPU HBM 80GB 대비 (1건)
8K	2.5 GiB	20 GiB	3%
128K	40 GiB	320 GiB	50%
1M	320 GiB	2,560 GiB	400%

KV cache가 GPU의 HBM을 많이 차지하면 다음과 같은 문제가 발생한다.

- 하나의 GPU가 처리할 수 있는 동시 요청 수 감소
- 최대 batch size 감소
- 장문맥 요청 처리 제한
- GPU 추가 도입에 따른 운영비 증가
- KV cache 이동 및 로딩에 따른 응답 지연
- 메모리 부족 시 KV cache를 폐기하고 다시 계산하는 비용 발생

따라서 장문맥 LLM 서비스에서는 KV cache를 효율적으로 저장하고 관리하는 기술이 필요하다.

A-3. 핵심 질문

> 동일한 KV cache 메모리 병목을 해결하는 SW 압축 방식과 HW 메모리 확장 방식은 기술 성숙도, 시장성, 이해관계자 및 데이터센터 적용성 관점에서 각각 어떻게 평가되는가?

본 과제의 목적은 단순히 하나의 기술을 우승 기술로 선정하는 것이 아니다. 동일한 기술이라도 평가 관점과 이해관계자에 따라 다르게 평가될 수 있으므로, 다음 내용을 근거와 함께 제시하는 것을 목표로 한다.

- 각 기술의 현재 발전 단계
- 각 기술의 장점과 한계
- 관점별 평가가 일치하는 부분
- 관점별 평가가 충돌하는 부분
- 실제 도입 전에 추가로 확인해야 할 사항

A-4. 선정 사유

진영	선정 기술	주체	접근
SW (데이터를 작게)	**DeepSeek-V2 MLA** (Multi-head Latent Attention, arXiv 2405.04434)	DeepSeek-AI	Key·Value를 저차원 잠재 벡터로 압축하도록 어텐션 구조 자체를 재설계 (원문 보고: KV cache 93.3% 감소)
HW (공간을 넓게)	**ITME** (CXL-Hybrid 계층 메모리 확장, arXiv 2606.12556)	SK hynix	CXL 기반 DRAM-NVMe Hybrid Memory로 TB급 원격 메모리 계층을 구성, 예측 가능한 접근 패턴을 활용해 데이터를 미리 이동

SW 선정 사유 - DeepSeek-V2 MLA

본 과제에서는 SW 기반 KV Cache 최적화 기술로 DeepSeek-V2의 Multi-head Latent Attention(MLA)을 선정하였다. MLA는 Key와 Value를 저차원 잠재 벡터로 압축하여 저장하는 모델 아키텍처 기술이다. DeepSeek-V2에서 처음 실증된 이후 후속 DeepSeek 모델과 실제 API 서비스에 지속적으로 적용되었으며, AWS Bedrock과 NVIDIA NIM 등 상용 추론 생태계에서도 DeepSeek 계열 모델이 지원되고 있다. 따라서 공개 정보 기준으로 TRL 9에 근접한 실제 운용 기술로 판단하였다. 기존 모델에 사후 적용하기 어렵다는 한계가 있지만, 기술 성숙도, 상용화 현황, 생태계 지지 및 데이터센터·장문맥 환경의 적용성을 종합해 분석 대상으로 선정하였다.

> 종합 선택은 DeepSeek-V2 MLA. 기존 모델에 붙이는 편의성만 평가하면 KIVI. 다양한 찬반 의견을 조사하기에는 TurboQuant가 적합함.

HW 선정 이유 — ITME

본 과제에서는 HW 기반 KV Cache 최적화 기술로 SK Hynix 연구진이 제안한 ITME을 선정하였다. ITME는 CXL 기반의 DRAM-NVMe Hybrid Memory를 이용하여 TB급 원격 메모리 계층을 구성하고, 모델 가중치와 prefix KV cache의 예측 가능한 접근 패턴을 활용해 데이터를 미리 이동한다. 이를 통해 GPU HBM과 호스트 DRAM의 용량 한계를 넘어 장문맥·다중 턴 요청의 누적 KV cache를 저장하고, KV cache 폐기 및 재계산을 줄여 데이터센터·클라우드 LLM 서빙의 확장성과 처리 효율을 높일 것으로 기대된다.

- 비선정 후보

후보	진영	비선정 사유	RAG 문서 활용
InfiniGen	HW	호스트 메모리 오프로딩으로 신규 메모리 인프라 없이 SW 관리 성격이 강함	O (ITME 비교용 베이스라인)
CXL-PNM	HW	연산까지 메모리 측으로 옮기는 확장형 접근으로, '공간 확장' 자체의 대표성은 ITME가 더 직접적	O (ITME 비교용 베이스라인)
KIVI	SW	사후 양자화의 대표 베이스라인이나 공개 채택 근거가 연구·라이브러리 수준	X (선정 검토만)
TurboQuant	SW	재학습 없이 적용 가능한 최신 양자화이나 공식 상용화 근거가 제한적	X (선정 검토만)

B. RAG 설계

B-1) 기술선정 방식

- (2안) Human 기반 : 토의 후 직접 선정 (선정 기준은 A-4. 참고)
  - SW - DeepSeek-V2
  - HW - ITME(CXL)

B-2) RAG 적용 대상

에이전트	역할	RAG 여부	내용
기술 조사 에이전트	기술 2건의 원문 확보 핵심 추출	O	원문에서 기술 개요, 범위, 한계 추출
시장 평가 에이전트	시장성, 채택 현황 조사	X	시장 규모, 상용화/채택 사례, 성장 전망 검색
이해관계자 평가 에이전트	관계자별 반응 조사	X	경쟁사 반응, 개발자 평가, 투자/업계 시각 등 검색
도메인 평가 에이전트	적용 도메인별 적합성	O	데이터센터, 온디바이스, 클라우드 서빙 등에서의 평가
평가 종합 에이전트	관점별 의견 종합 및 비교	X	관점 간 일치/불일치 의견 기반으로 의견 종합
보고서 생성 에이전트	평가 보고서 생성	X	단계별 내용을 연결하여 보고서 생성

※ 참고 설계안 대비 변경: 시장 평가 에이전트는 RAG 여부를 X로 설정함.

RAG 적재 문서 4편(DeepSeek-V2/MLA, ITME, InfiniGen, CXL-PNM)은 모두 기술 원문 논문으로, 시장 규모·성장성, 상용화·채택 현황, 생태계 지지와 같은 시장성 판단에 필요한 근거를 담고 있지 않다. 문서 풀 안에서 시장 평가에 활용할 만한 근거를 찾기 어렵다고 판단하여, 정적 문서 검색 대신 최신 산업 뉴스·시장 조사 자료를 실시간으로 확인할 수 있는 웹 검색(Tavily Web API) 으로 대체하였다.

B-3) 문서 선정 전략 및 활용 방식

RAG 적재 문서 (4편, 총 96p ≤ 200p)

문서	진영	페이지	역할	활용하는 에이전트
DeepSeek-V2 (MLA)	SW	52p	선정 기술 원문	기술 조사, 도메인 평가
ITME	HW	13p	선정 기술 원문	기술 조사, 도메인 평가
InfiniGen	HW	18p	베이스라인 (호스트 메모리 오프로딩)	기술 조사 (ITME 대비 한계·트레이드오프 확인)
CXL-PNM	HW	13p	베이스라인 (CXL + 근접 메모리 연산)	기술 조사 (ITME 대비 한계·트레이드오프 확인)

항목	설계
문서 선정 전략	① 선정 기술 원문 2편(MLA, ITME)은 기술 개요·한계·실험 근거의 1차 출처로 필수 ② HW 베이스라인 2편(InfiniGen, CXL-PNM)은 같은 "공간 확장" 진영의 다른 접근으로, ITME의 한계·트레이드오프를 제3의 시각에서 교차 확인 (확증편향 완화) ③ KIVI·TurboQuant는 사후 양자화 계열로 구조 재설계형인 MLA와 접근이 달라 비교 근거로 쓰기 어렵고, 200p 예산 내에서 검색 노이즈를 줄이기 위해 제외 ④ 총 96p로 페이지 제한(200p) 이내 — 코드에서 합계 ≤ 200p를 강제 검증
파싱	pypdf 페이지 단위 추출, 페이지 번호 유지 → 보고서 인용 `[n, p.X]`
노이즈 제거	참고문헌 구간 11p 색인 제외 → 색인 85p (예산 계산에는 포함 = 보수적)
청킹	1,200자 / 겹침 200자 → 333개 청크 (수식·표 문단 경계 보존)
검색	Dense(FAISS) + BM25(키워드) → RRF 순위 융합, 기술별 문서 필터로 다른 기술 수치 혼입 방지

항목	설계
Agentic RAG	질의 계획(한국어 → 영어 기술어) → 검색 → 관련성 판정 → 관련 청크 2개 미만이면 **질의 재작성 후 재검색(최대 2회)** → 인용 포함 답변, 근거 없으면 "근거 부족"
문서 활용 범위	기술 조사: 선정 기술 원문(질문 6개) + 베이스라인 비교 질문 1개에만 베이스라인 문서 포함 도메인 평가: 선정 기술 원문에서 D1~D7 근거 검색

B-4) 선정한 Embedding 모델

후보군

Qwen3-Embedding-0.6B, BGE-M3, multilingual-e5-large-instruct

최종선택

Qwen3-Embedding-0.6B

선택 사유

임베딩 모델 후보로 Qwen3-Embedding-0.6B, BGE-M3, multilingual-e5-large-instruct를 비교하였다. 본 프로젝트에서는 한국어 질문을 기반으로 영어 논문과 한국어 자료를 함께 검색해야 하므로 다국어 및 교차언어 검색 능력을 우선 평가하였다. 또한 개인 노트북에서 실행할 수 있는 모델 크기, 긴 기술 문서 처리 능력, 라이선스와 운영 비용을 함께 고려하였다.
Qwen3-Embedding-0.6B는 한국어를 포함한 100개 이상의 언어와 최대 32K 토큰 입력을 지원하고, Apache 2.0 라이선스로 로컬에서 무료로 사용할 수 있다. 같은 0.6B급 후보보다 다국어 평가 성능이 높으면서 4B·8B 모델보다 실행 비용이 낮아 최종 모델로 선정하였다.
multilingual-e5-large-instruct는 다국어 검색 성능이 우수하고 Qwen3-Embedding-0.6B와 동일한 0.6B 규모이지만, 최대 입력 길이가 512토큰으로 제한되어 긴 기술 문서를 처리하려면 문서를 더 작은 단위로 세분화해야 한다. 또한 검색 입력을 query:와 passage: 형식으로 구분하는 방식은 지원하지만, 검색 목적과 도메인에 맞춘 세부 instruction을 질의에 반영하는 유연성은 Qwen3-Embedding-0.6B가 더 높다고 판단하였다.
BGE-M3는 100개 이상의 언어와 최대 8,192토큰 입력을 지원하고, Dense·Sparse·Multi-vector 검색을 하나의 모델에서 제공한다는 장점이 있다. 그러나 본 프로젝트에서는 복합 검색 방식보다 한국어 질문과 영문 기술 문서 사이의 Dense 교차언어 검색을 우선 구현하므로, BGE-M3의 Sparse 및 Multi-vector 기능을 충분히 활용하기 어렵다고 판단하였다.

C. 평가 관점 및 기준

평가 대상: 무엇을 평가하는가 / **기준**: 어떤 규칙으로 판단하는가 / **근거원**: 판단 근거를 어디서 가져오는가

C-1) 기술 성숙도 관점 - TRL(Technology Readiness Level) 기반

평가 대상	기준	근거원
기술별 현재 TRL 단계 및 신뢰도	TRL 9단계 정의 및 근거 도출 ◦ `1~3단계` : 논문/특허만 확인되는 경우 ◦ `4~6단계` : 코드 공개, 서비스 도구 탑재 등 구현 근거가 있는 경우 ◦ `7~9단계` : 제품 출시, 상용 서비스 적용 발표가 있는 경우	• 논문 원문(RAG: 구현·검증 수준) • 구현/통합 및 상용화 발표(웹 검색)

- 개별 기술의 성숙도와 기술이 속한 계열(예: CXL 메모리 모듈 일반)의 성숙도를 구분하여 표기
- 본 TRL 판정은 논문·특허·상용화 발표 등 공개된 정보에 근거한 추정치이다. 기술 발표 시점과 실제 채택 시점 간에는 시차가 존재할 수 있으며, 특히 TRL 4~6 구간(수율·성능 수치 등)은 기업 영업비밀로 비공개인 경우가 많아 실제 성숙도보다 낮게 평가될 가능성이 있음을 전제로 한다.

C-2) 시장성 관점

평가 대상	기준	근거원
시장 규모·성장성 : 기술이 속한 시장이 얼마나 크고 성장하는가	• 성장 전망 수치와 수요 증가 요인이 있으면 긍정 • 수요 감소 우려 및 불확실성이 지적되면 우려 • 둘 다 있으면 혼재	시장 조사 보고서, 경제 및 산업 뉴스
상용화·채택 현황 : 실제로 제품화되어 쓰이고 있는가	• 제품 출시, 기업 도입 사례가 있으면 긍정 • 도입 사례가 없거나 도입 장벽이 지적되면 우려	기업 공식 발표, IT 산업 및 뉴스
생태계 지지 : 주변 도구와 업계가 이 기술을 지원하는가	• 주요 AI 서빙 도구(vLLM, SGLang 등) 공식 지원이나 표준화 논의가 있으면 긍정 • 호환성 문제 및 지원 부족이 지적되면 우려	서빙 도구 공식 문서 및 개발 커뮤니티, 표준화 단체 발표, 논문 원문의 구현 환경(RAG)

- SW 추론 최적화 시장과 HW CXL 시장의 시장규모는 서로 다른 시장이므로 시장규모 숫자만으로 두 기술의 우열을 결정하지 않는다.

C-3) 이해관계자 관점

평가 대상	기준	근거원
경쟁 진영 : 경쟁사는 이 기술을 어떻게 보는가	• 경쟁사가 병행, 협력 가능성을 언급하면 긍정 • 한계를 지적하거나 대체 기술을 내세우면 우려	경쟁사 발표, 기술 비교 기사
도입 기업, 개발자 : 실제 사용자는 어떻게 평가하는가	• 사용 효과(메모리 절감, 속도 향상) 후기가 있으면 긍정 • 품질 저하/도입 복잡도가 지적되면 우려	개발자 커뮤니티, 기업 기술 블로그
투자 업계 : 투자자/전문가는 어떻게 보는가	• 성장 기대 및 투자 확대 평가가 있으면 긍정 • 과대평가, 수요 감소 우려가 있으면 우려	애널리스트 보고서, 경제 언론, 주가 반응 기사

- 모든 평가에 발언 주체(기업·언론·개발자 등)를 함께 기록해 누구의 시각인지 구분함
- 한 관점 안에서 평가 대상끼리 방향이 다르면(예: 개발자 긍정, 투자업계 우려) 해당 관점 결과를 혼재로 표시함

C-4) 도메인 적용 관점 (데이터센터·클라우드 장문맥 서빙)

평가항목	공통 평가 질문	기준	근거원 (MLA에서 확인할 근거)	근거원 (ITME에서 확인할 근거)
1. 워크로드 수용 능력	제한된 GPU 메모리에서 더 긴 문맥과 더 많은 동시 요청을 수용할 수 있는가?	수용 문맥·동시 요청 증가 보고 → 적합 / 특정 조건에서만 → 조건부	KV cache/token, 감소율, 최대 배치, 지원 문맥 길이	동시 대화 수, 턴 수, GPU·CPU·원격 메모리 사용량
2. 서비스 성능	메모리 병목이 발생할 때 처리량과 응답시간을 얼마나 개선하는가?	처리량 증가·지연 유지 → 적합 / 지연 증가 → 조건부·제약	generation throughput, prompt throughput, 배치 증가 효과	TTFT, 처리량, 캐시 적중률, 재계산 대비 속도
3. 메모리 자원 효율	동일한 서비스를 제공하기 위해 필요한 고가 메모리를 얼마나 줄이거나 확장하는가?	절감·확장량 수치 보고 → 적합	KV 캐시 감소율, KV elements/token, HBM 사용 절감	GPU 상주 메모리, CPU staging buffer, CXL·NVMe 확장 용량
4. 품질·정보 보존	메모리를 줄이거나 이동해도 모델의 응답 품질과 문맥 정보가 유지되는가?	벤치마크 유지 → 적합 / 하락 → 제약 / 실험 없음 → 근거 부족	MHA 대비 벤치마크 성능, 장문 성능	전체 KV 보존 여부, 캐시 미스 처리 방식, 생성 품질 실험 여부
5. 운영 안정성	요청과 문맥이 증가해도 성능이 안정적으로 유지되는가?	규모 증가 실험에서 성능 유지 → 적합 / 변동·경합 → 조건부	장문·대형 배치에서의 성능 변화	턴별 적중률, 읽기·쓰기 경합, 캐시 미스, 성능 변동
6. 도입·확장 용이성	기존 클라우드 추론 환경에 적용하려면 무엇을 변경해야 하는가?	기존 스택 그대로 → 적합 / 재학습·신규 장비 필요 → 조건부	MLA 모델 구조와 해당 체크포인트 필요 여부	vLLM 변경, CXL-hybrid memory, RDMA·NIC 필요 여부

평가항목	공통 평가 질문	기준	근거원 (MLA에서 확인할 근거)	근거원 (ITME에서 확인할 근거)
7. 비용 효율성	추가 처리 능력을 얻기 위해 필요한 자원 비용이 합리적인가?	동일 장비 효율 증가·저가 자원 대체 → `적합` / 추가 장비 비용 → `조건부`	동일 GPU에서 배치 증가, HBM 요구량 감소	고가 GPU·DRAM 대신 CXL·NVMe 사용, 추가 장비 요구량

- 결과는 `적합` / `조건부` / `제약` / `근거 부족`의 4단계로 표기하며, 다른 기술과 비교하지 않고 해당 기술의 도메인 적합성만 판단함

C-5) 종합 의견

종합 Agent는 새로운 자료를 검색하지 않고 앞 단계에서 검증된 Evidence만 사용한다.

평가 대상	기준
관점별 종합 : 각 기술이 4개 관점에서 어떻게 평가되는가	기술에 대한 4가지 관점(TRL·시장·이해관계자·도메인) 표에 관점별 평가 요약을 한 줄씩 정리
관점 간 일치 : 여러 관점이 같은 방향으로 평가하는 지점은 무엇인가	같은 쟁점에 대해 2개 이상 관점이 같은 방향(긍정 또는 우려)으로 평가한 내용을 정리하고, 그렇게 평가한 관점을 표기
관점 간 상충 : 관점끼리 평가가 엇갈리는 지점은 무엇인가	기술별로 **서로 다른 두 관점**의 반대 평가를 최소 2건 도출하여 표로 제시 (쟁점 / 관점 A 평가 / 관점 B 평가 / 엇갈리는 이유)
객관성 확보 방안	종합 Agent는 새로운 자료를 검색하지 않고 4개 관점에서 이미 검증된 Evidence만 사용한다. SW·HW 두 기술의 평가 결과를 동일한 형식(쟁점 / 관점 A 평가 / 관점 B 평가 / 이유)으로 병기하여 어느 한쪽에 유리하게 서술되지 않도록 한다. 또한 HW 베이스라인 문서(InfiniGen, CXL-PNM)를 통해 선정 기술(ITME)의 한계를 교차 확인함으로써 특정 진영에 대한 확증편향을 완화한다.

D. 그래프 설계(안)

D-0) Agent 정의

에이전트	역할	RAG 여부	내용
Master Agent	전체 작업 분배 및 실행 제어	X	State를 확인하여 다음 Agent를 선택하고, 병렬 실행·결과 수집·근거 부족 재실행·종료 여부를 결정
기술 조사 에이전트	기술 2건의 원문 확보 및 핵심 추출	O	원문에서 MLA와 ITME의 기술 개요, 적용 범위, 성능, 한계 및 기술 성숙도 판단 근거 추출
시장 평가 에이전트	시장성, 채택 현황 조사	X	시장 규모, 상용화·채택 사례, 성장 전망 및 생태계 지원 현황 검색
이해관계자 평가 에이전트	관계자별 반응 조사	X	경쟁사 반응, 개발자 평가, 도입 기업의 의견, 투자·업계 시각 등을 외부 검색 도구로 조사
도메인 평가 에이전트	적용 도메인별 적합성 평가	O	논문 근거를 이용하여 데이터센터·클라우드 장문맥 LLM 서빙 환경에서 MLA와 ITME를 공통 기준으로 평가
평가 종합 에이전트	관점별 의견 종합 및 비교	X	기술 성숙도·시장·이해관계자·도메인 평가의 일치점과 상충 지점을 근거 중심으로 종합
보고서 생성 에이전트	평가 보고서 생성	X	검증된 단계별 결과와 Evidence를 연결해 SUMMARY부터 REFERENCE까지 최종 보고서 생성

D-1) State 설계(table)

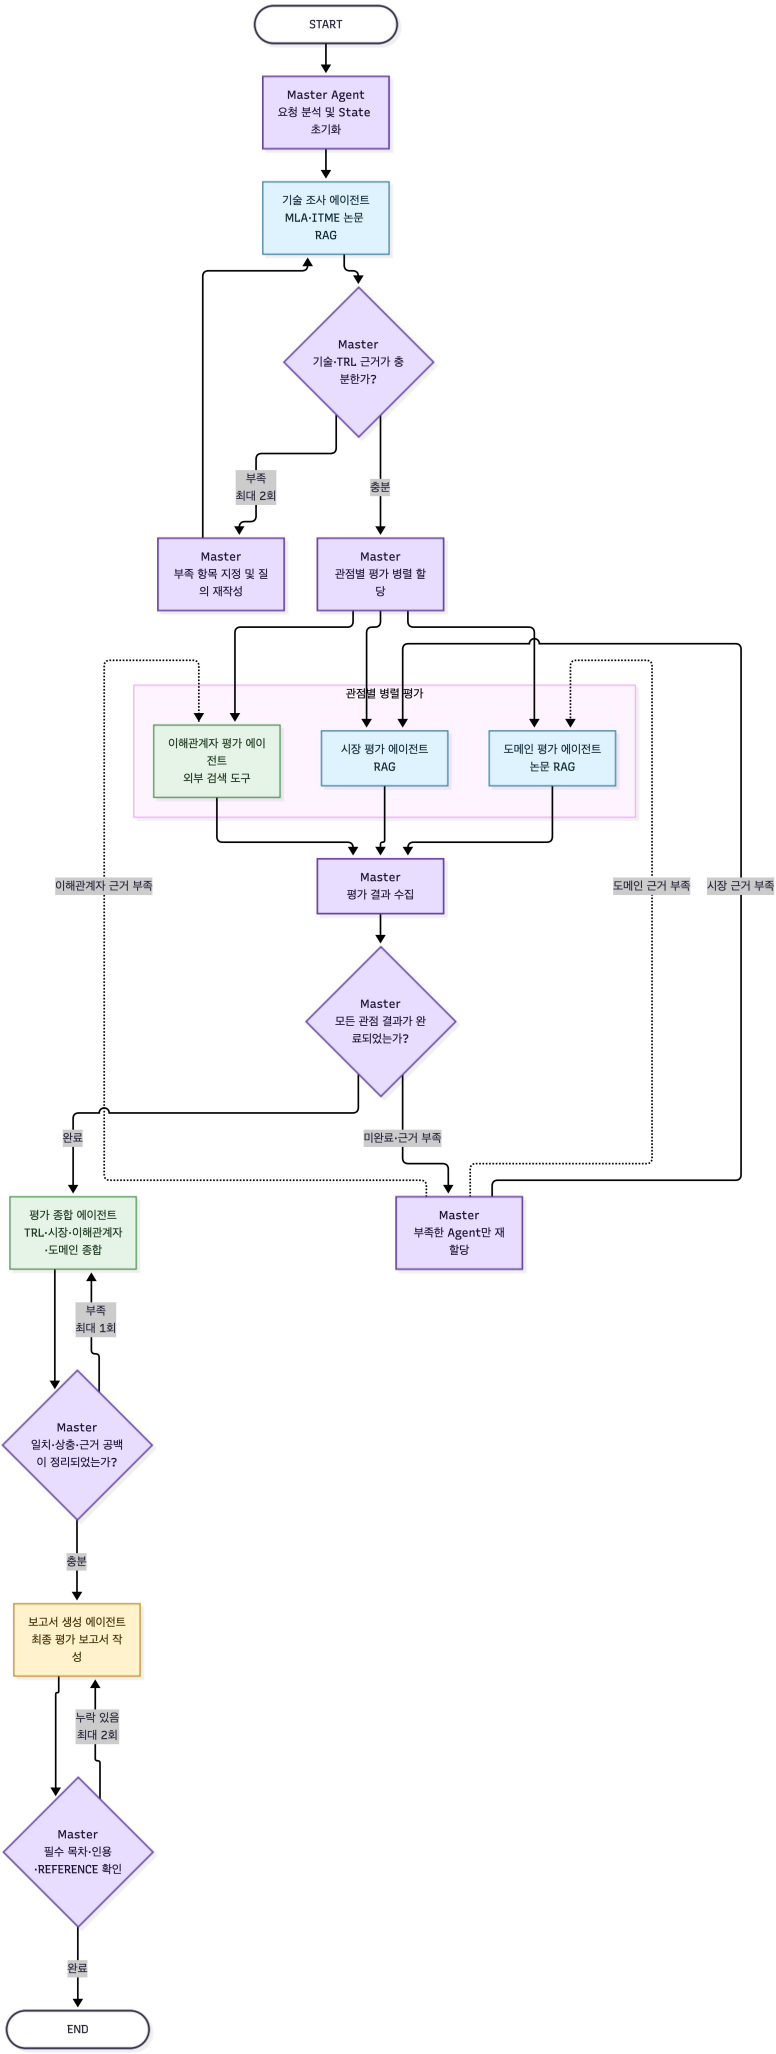
병렬 Agent가 동일한 State key를 동시에 수정하지 않도록 관점별 결과를 별도의 key에 저장한다.

공통으로 누적되는 `evidence`와 `logs`는 reducer를 사용한다.

State Key	자료형	작성 주체	내용	변경
`user_query`	`str`	User	전체 평가 목적과 사용자 요청	유지

State Key	자료형	작성 주체	내용	변경
`phase`	`str`	Master	현재 실행 단계: `init` → `tech_research` → `parallel_eval` → `synthesis` → `report` → `done`	**수정** (단계 값 정의)
`next_agents`	`list[str]`	Master	다음에 실행할 Agent 목록. 최초 병렬 할당 시 시장·이해관계자·도메인 3개, 재할당 시 `sufficient=False` 인 Agent만 지정	**수정** (재할당 규칙 명시)
`tech_result`	`dict`	기술 조사 Agent	두 기술의 개요, 범위, 성능, 한계 및 TRL 판단 근거 + `sufficient`, `missing`	**수정** (판정 필드 추가)
`market_result`	`dict`	시장 평가 Agent	웹 검색(Tavily) 기반 시장 규모, 성장성, 상용화·채택 및 생태계 평가 + `sufficient`, `missing`	**수정** (판정 필드 추가, 근거원 명시)
`stakeholder_result`	`dict`	이해관계자 평가 Agent	경쟁사, 개발자, 도입 기업, 투자 업계의 평가(발언 주체 포함) + `sufficient`, `missing`	**수정** (판정 필드 추가)
`domain_result`	`dict`	도메인 평가 Agent	데이터센터·클라우드 환경에서 MLA와 ITME의 D1~D7 적용성 판정 + `sufficient`, `missing`	**수정** (판정 필드 추가)
`evidence`	`list` (reducer)	조사·평가 Agent	평가 결과를 뒷받침하는 논문·웹 근거와 출처 정보. 항목마다 `source_id`, `agent`, `attempt` 를 기록해 재실행 시 중복을 종합 단계에서 제거	**수정** (중복 방지 필드)
`logs`	`list` (reducer)	전 Agent	실행 로그: 노드명, 시도 횟수, 게이트 판정 결과	**추가**
`review_feedback`	`dict`	Master	게이트별 부족 항목과 재작성 질의. 키: `tech`, `market`, `stakeholder`, `domain`, `synthesis`, `report`. 질의 재작성·부족 Agent 재할당·종합/보고서 보완 루프에서 해당 Agent가 읽음	**추가**
`synthesis_result`	`dict`	평가 종합 Agent	관점별 일치점, 상충 지점, 근거 공백, 조건부 종합 의견	**수정** (근거 공백 추가)
`report_draft`	`str`	보고서 생성 Agent	단계별 결과를 통합한 평가 보고서 초안	유지
`retry_counts`	`dict`	Master	Agent별 재실행 횟수와 한도: `tech` ≤ 2 / `market`·`stakeholder`·`domain` 각 ≤ 2 / `synthesis` ≤ 1 / `report` ≤ 2	**수정** (주체명 통일, 한도 명시)
`status`	`str`	Master	전체 실행 상태: `running`, `completed`, `failed` (`failed` 는 예외 상황 전용)	**수정** (주체명 통일)

D-2) Graph 흐름 설계(mermaid)


START
Master Agent
요청 분석 및 State
초기화
기술 조사 에이전트
MLA·ITME 논문
RAG
Master
기술·TRL 근거가 충
분한가?
부족
최대 2회
충분
Master
부족 항목 지정 및 질
의 재작성
Master
관점별 평가 병렬 할
당
관점별 병렬 평가
이해관계자 평가 에이
전트
외부 검색 도구
시장 평가 에이전트
RAG
도메인 평가 에이전트
논문 RAG
Master
평가 결과 수집
이해관계자 근거 부족
도메인 근거 부족
시장 근거 부족
Master
모든 관점 결과가 완
료되었는가?
완료
미완료·근거 부족
평가 종합 에이전트
TRL·시장·이해관계자
·도메인 종합
Master
부족한 Agent만 재
할당
부족
최대 1회
Master
일치·상충·근거 공백
이 정리되었는가?
충분
보고서 생성 에이전트
최종 평가 보고서 작
성
누락 있음
최대 2회
Master
필수 목차·인용
·REFERENCE 확인
완료
END

E. 평가 보고서

순서	목차	구성 내용
–	**SUMMARY**	보고서 핵심 결론 요약(개요 아님), 1/2 페이지 이내: 기술별 TRL, 관점별로 엇갈리는 인식, 두 접근의 관계
1	분석 배경	KV cache의 역할과 메모리 병목, 도메인 문제 정의, KV cache 규모 표, 우열이 아닌 관점 비교를 하는 이유
2	기술 선정	선정 방식(2안: 조 직접 선정), 선정 기준, 선정·비선정 사유
3	기술 개요	두 기술 대조표, 핵심 접근 방향, 보고된 효과(저자 보고), 한계·전제조건
4	관점별 평가	4.1 기술 성숙도(TRL) · 4.2 시장성 · 4.3 이해관계자 · 4.4 도메인(D1~D7) — 기준별 신호표 + 기술별 서술
5	종합 의견	관점 매트릭스, 관점 간 일치, 관점 간 상충표(관점 A vs B, 엇갈리는 이유), 두 기술의 관계
6	시사점	관점에 따라 평가가 엇갈리는 부분 중심, 이해관계자별 확인 과제
7	한계점	공개 정보 기반 추정의 한계, 확증편향 방지 조치와 증거 균형표
–	**REFERENCE**	실제 인용한 자료만 기재 · 논문: 저자(YYYY). 제목. 학회/학술지, 권(호), 페이지. · 웹: 기관명 또는 작성자(YYYY-MM-DD). 제목. 사이트명, URL