sLLM 과 Fine Tuning - Day2

날짜	2026년 8월 31일
태그	

1. 이해관계자 가치 (Pain Point)

> sLLM이 왜 필요하고, SFT(Supervised Fine Tuning) 학습이 어떤 경우에 적용되며, 이 기술들이 어떤 이해관계자에게sLLM (Fine-tuning / LoRA) 어떤 가치를 제공할 수 있을 지 제시합니다. 이해관계자가 실제로 겪는 불편함이 무엇인지, 왜 그 문제가 중요한지를 먼저 명확히 정의합니다.

1-1. LLM 의 할루시네이션

LLM 의 본질은 지금까지의 패턴을 학습하여, 다음 단어를 확률적으로 예측하는 모델 입니다. 그래서 학습데이터에 없는 내용 (회사 내부 규정, 최신 정보 등)을 질문받으면, **모른다고 답하지 않고** 오히려 그럴듯하게 답을 지어내는 문장이 더 높은 확률로 생성됩니다. 그리고 이것을 할루시네이션이라고 합니다.

이것을 막으려면 두 가지 방법이 있습니다.

1. sLLM (Fine-tuning / LoRA)
2. RAG (Retrieval-Augmented Generation)

sLLM(Fine-tuning / LORA)

→ 사전 학습된 LLM 의 가중치를 도메인 데이터로 추가 학습시켜 파라미터 자체를 업데이트

LoRa란? Low-Rank Adaptation. 모델 전체 파라미터를 다 건드리면 비용·시간이 막대하므로, 일부 저차원 행렬만 추가로 학습시켜 원본 모델은 거의 안 건드리고 "어댑터"만 붙이는 경량 파인튜닝 기법

속도(추론) 이미 지식이 가중치에 내장되어 있어서 질의 시 벡터 검색 과정이 없음 → 응답 빠름 (3분만에 나옴)

언제 적합할까? 거의 변하지 않는 지식 (예를들면 회사의 핵심 도메인 개념, 용어 정의, 안정적인 프로세스)

> 💭 Think
> 실습은 인사 규정의 데이터를 돌렸지만, 실제 사내망이면 훨씬 민감한 데이터가 들어가게 된다. 사내에서 상용 LLM API 를 못 쓰니까 sLLM 을 쓴다는 건 이해했는데, 그러면 다른 회사들을 이걸 실제로 어떻게 운영하고 있을까가 궁금했다. 특히 보안이 가장 중요한 제조업과 금융권에서는 어떻게 사용하고 있을까
> **한국은행 (BOKI)**
> 외부망과 완전히 분리된 내부망에 AI 시스템을 구축했다. **폐쇄망 안에서 학습과 추론이 다 끝나도록** 설계한 게 핵심이다. 다만 기사에서도 망분리 제도 한계와 AI 효율성 사이 조율이 더 필요하다고 나온다.
> **금융권**
> 금융위가 보안 목적 AI 활용을 위해 망분리 규제를 단계적으로 완화하고 있다. 1차로 신한은행, 하나은행, 우리은행, 카카오뱅크, KB증권, NH투자증권, 미래에셋증권 등 10개사가 선정됐고, 2차는 저축은행과 전자금융업자까지 넓힌다.
> **삼성전자 (제조/반도체)**
> 2023년 3월에 DS부문 직원이 소스코드와 회의 내용을 ChatGPT에 넣은 게 문제가 되면서, 같은 해 5월부터 사내 기기에서 외부 생성형 AI 사용을 금지했다. 그 대신 자체 개발한 sLLM 기반 '삼성 가우스'를 사내 도구로 붙였다. 가우스는 컴팩트/밸런스드/슈프림 세 가지로 나뉘고, 코딩 어시스턴트 `code.i` 처럼 용도별로 쓰인다.
> 그래서 생각난 생각은, **LoRA 어댑터를 폐쇄망 배포 단위로 쓰면 어떨까?** 였다. 폐쇄망 운영 자료를 보면 반입 절차가 제일 무겁다. 이번에 돌린 실습 산출물도 Base Qwen2.5-1.5B-Instruct(3GB), adapter_model.safetensors(70MB) 이다. 그런데 LoRA는 base 모델을 한 번만 반입하고, 그다음부터는 70MB 어댑터만 반입하면 된다. 3GB 모델을 매번 다시 넣는 것과는 부담이 다르다.
> 그래서 Base 모델은 최초 1회만 반입하고, 해시 고정해서 변경 금지 대상으로 관리한다.
> 이후 업데이트는 어댑터 단위로 반입한다. 서명하고, SHA-256 남기고, 버전 태그를 붙인다
> 어댑터 저장소를 내부에 두고 Git이나 내부 레지스트리로 버전 관리한다
> 그리고 또 부서별 어댑터를 분리해보는 생각을 했다. 그렇게 되면 인사용, 보안규정용, 영업용 .. 등 어댑터를 따로 학습해서 부서별로 다른 어댑터를 로드하는 것이다. 자주 바뀌는 RAG 문서는 벡터 DB 에 두고 문서 권한을 사용자 권한으로 필터링한다.
> 떠오르는 생각을 정리해보면, **어댑터를 버전 관리되는 배포 아티팩트로 취급**해야 한다는 것이다. 이번 실습에서 파라미터만 바꿔 다시 학습하니 어댑터 내용이 확 달라졌다(Keyword 0.20에서 0.315). 실무면 이게 모델이 바뀌었다는 뜻인데, 어느 버전이 어떤 답을 했는지 기록이 없으면 사고 났을 때 원인을 못 찾지 않을까?// 컨테이너 이미지처럼 태그 붙이고 서명하고 롤백 가능하게 관리해야 한다고 생각했다.

RAG (Retrieval-Augmented Generation)

1 Retrieval(검색): 질문을 임베딩 → 벡터DB에서 유사도 높은 문서 조각(chunk) 검색
2 Augmentation(증강): 검색된 조각을 프롬프트에 컨텍스트로 삽입
3 Generation(생성): LLM이 그 컨텍스트를 근거로 답변 생성

LoRa란? Low-Rank Adaptation. 모델 전체 파라미터를 다 건드리면 비용·시간이 막대하므로, 일부 저차원 행렬만 추가로 학습시켜 원본 모델은 거의 안 건드리고 "어댑터"만 붙이는 경량 파인튜닝 기법

속도(추론) 이미 검색하면 벡터DB 를 조회하고, 프롬프트 구성하고 LLM 생성까지 파이프라인이 길어서 → 응답 느림

언제 적합할까? 자주 바뀌는 정보 (예를들면 최신 사내 공지, 인사 규정 개정, 가격표, 재고 현황) → 모델 재학습 없이 벡터 DB 내용만 업데이트하면 즉시 반영되기 때문!

RAG 장점

- 모델 재학습 없이 벡터DB 내용만 업데이트하면 즉시 반영
- 출처 추적 가능 → 이 답변은 이 문서에 있어 라고 근거를 밝힐 수 있어서 신뢰성 측면에서 유리
- 할루시네이션 억제(근거 기반 생성)

Qwen2.5 말고 다른 모델 써도 되나요?

써도 된다. 구조가 decoder-only(CLM)이고 PEFT가 붙는 모델이면 `lora` 코드는 돌아갑니다.

그럼에도 Qwen2.5-1.5B-Instruct를 쓰는 이유는 한국어가 되고 라이선스가 열려 있고 사내 장비에 올릴 수 있는 크기이면서 실무에서 실제로 많이 쓰이기 때문입니다.

1-2. 그러면 RAG 로만 하면 안되나요? sLLM 이 왜 필요할까?

1. **비용/속도 트레이드오프**
   안 바뀌는 지식까지 매번 벡터 검색을 거치면 불필요한 레이턴시·인프라 비용이 발생합니다.
2. **역할 분담**
   - Fine-tuning(LoRA) → 모델에게 도메인 "지식/스타일/기본 개념"을 체화시킴
   - RAG → 모델에게 "최신 사실 정보"를 제공
   - LoRA로 도메인 언어/추론 방식을 학습시키고, RAG로 최신·가변 데이터를 보강하는 방법으로 사용

즉, RAG는 sLLM에서 발생할 수 있는 할루시네이션 문제를 보완할 수 있습니다. 그렇다면 굳이 sLLM을 사용할 필요가 있을까라는 의문이 생길 수 있는 데요.

핵심은 지식의 특성에 따라 파인튜닝과 RAG를 나누어 활용하는 것입니다. **자주 바뀌지 않는 지식은 파인튜닝을 통해 모델 자체에 학습시키고, 자주 변경되는 정보는 RAG를 통해 최신 데이터를 검색해 활용하는 방식입니다.** 이렇게 하면 sLLM의 장점을 유지하면서도 최신성과 정확성을 효과적으로 확보할 수 있습니다.

1-3. SFT 학습이 어떤 경우에 적용될까?

SFT는 사전 학습된 대규모 언어 모델(LLM)에 질문(Prompt)과 모범 답변(Response) 쌍으로 이루어진 데이터를 입력해 사람의 의도와 대화 형식에 맞게 학습시키는 과정입니다.

SFT 학습은 모델이 특정 형식이나 지침을 일관되게 따르도록 유도하고, 전문적인 분야(도메인)의 용어와 표준에 맞는 답변을 생성하게 합니다. 전체 사전 학습에 비해 상대적으로 적은 계산량과 빠른 속도로 모델 성능을 극대화할 수 있습니다.

이러한 특징을 기반으로 SFT 학습은 주로 다음과 같은 상황에 적용됩니다.

- 질의응답(Q&A) 및 대화형 모델 구축
  : 모델이 사용자의 질문에 대해 자연스럽고 맥락에 맞는 답변을 하도록 만들 때 적용합니다.
- 새로운 도메인 및 전문 분야 특화
  : 법률, 의료, 금융, 기업 내부 문서 등 특정 전문 지식이 필요한 분야에 모델을 적응시킬 때 사용합니다.
- 지시어 이행 능력 부여
  : 단순한 텍스트 이어 쓰기(Completion)만 가능한 베이스 모델에 "요약해 줘", "번역해 줘" 같은 지시를 따르는 행동 양식을 가르칠 때 적용합니다.

1-4. 이 기술들이 어떤 이해관계자에게 어떤 가치를 제공할 수 있을까?

경영진 / 의사결정자

경영진의 가장 큰 관심사는 AI 도입에 들어가는 비용 대비 효과와 장기적인 운영 가능성입니다. 외부 LLM API에만 의존할 경우 사용량이 증가하면 API 비용도 함께 증가하고, 특정 외부 사업자에 대한 의존도가 높아질 수 있습니다.

이때 sLLM을 자체적으로 운영하면 조직의 데이터와 업무 특성에 맞는 AI 모델을 확보하면서 장기적인 비용과 운영 구조를 예측하기 쉬워집니다. 또한 외부 서비스에 대한 의존도를 낮출 수 있기 때문에 벤더 락인(Vendor Lock-in) 리스크를 줄일 수 있다는 장점도 있습니다.

> 핵심 가치: 비용 예측 가능성 + 기술 주도권 확보 + 벤더 종속성 감소

최종 사용자 / 직원 / 고객

사용자가 AI 서비스를 이용하는 가장 직접적인 목적은 “내가 원하는 정보를 빠르고 정확하게 얻는 것”입니다.

기존에는 사내 규정이나 업무 매뉴얼을 직접 검색하고 여러 문서를 확인해야 했다면, RAG를 적용한 AI 시스템에서는 사용자가 자연어로 질문하고 관련 문서를 검색하여 답변을 받을 수 있습니다.

특히 RAG는 단순히 모델이 기억하고 있는 지식을 사용하는 것이 아니라, 실제 문서를 검색하고 이를 근거로 답변하도록 구성할 수 있기 때문에 답변의 신뢰성을 높일 수 있습니다.

따라서 사용자는 정보를 찾는 데 드는 시간을 줄이고, AI가 제공하는 답변을 보다 쉽게 검증할 수 있습니다.

> 핵심 가치: 정보 탐색 시간 단축 + 근거 기반 답변 + 사용자 경험 개선

현업 부서 / HR / 법무 / 고객지원

현업에서는 규정과 업무 지침이 지속적으로 변경된다는 문제가 있습니다.

예를 들어 HR 규정이나 환불 정책이 변경될 때마다 모델 자체를 다시 학습시킨다면 시간과 비용이 많이 발생합니다.이러한 경우에는 변경되는 지식을 모델에 직접 학습시키기보다, RAG를 통해 외부 지식으로 분리하는 것이 효과적입니다.

문서가 변경되면 관련 데이터를 다시 임베딩하여 Vector DB를 업데이트하고, 이후 사용자의 질문이 들어오면 최신 문서를 검색하여 답변하도록 구성할 수 있습니다. 즉, 자주 변경되는 지식은 모델과 분리하여 관리함으로써 현업의 유지보수 부담을 줄일 수 있습니다.

> 핵심 가치: 최신 정보 반영 + 문서 관리 편의성 + 유지보수 부담 감소

보안 / 컴플라이언스 담당자

기업 환경에서는 AI의 성능만큼 데이터 보안과 답변의 신뢰성도 중요합니다.

특히 사내 문서나 고객 정보와 같이 민감한 데이터가 외부 LLM API로 전달되는 것을 제한해야 하는 경우가 있습니다.이때 sLLM을 사내 인프라 또는 보안된 환경에서 운영하면 민감한 데이터의 외부 전송을 최소화할 수 있습니다.

또한 RAG를 사용하면서 답변에 사용된 문서나 검색 결과를 함께 기록한다면, “AI가 왜 이런 답변을 했는가?”를 추적할 수 있는 근거를 확보할 수 있습니다. 이는 단순한 사용자 편의를 넘어 감사(Audit), 컴플라이언스, 장애 분석 등의 운영 측면에서도 중요한 요소입니다.

> 핵심 가치: 데이터 보안 + 답변 근거 추적 + 감사 및 컴플라이언스 대응

1-5. 이해관계자가 실제로 겪는 불편함이 왜 중요할까

교수님 말씀으로 정리하면:

- AI를 붙이고 싶은 조직은 결국 자기들이 가진 데이터(업무 결과물, 내부 지식) 에 연결할 확률이 높다
- 앞으로 조직은 AI 붙인 조직 vs 안 붙인 조직으로 갈라질 것
- 업무는 실행만 하는 게 아니라 예측, 자동화, 인사이트까지 가야 함
- 그 중심 데이터 = **Knowledge Asset**

즉, **우리 회사 지식을 모델이 이해하도록 만드는 것**이 Pain Point의 핵심이다.

[1] 불편함은 요구사항(Requirement)의 출발점이다

예를 들어 다음과 같은 상황을 생각해볼 수 있습니다.

문제 > 사내 규정이 매주 변경되는데, 변경될 때마다 AI 모델을 다시 학습시키는 것은 현실적으로 어렵다.

이 문제에서 자연스럽게 기술적 요구사항이 도출됩니다.

```
Pain Point → Requirement → Technology
규정이 자주 변경됨→ 모델을 재학습하지 않고 최신 정보를 반영해야 함 → RAG + Vector DB
```

즉, RAG를 사용하기 때문에 문제를 찾는 것이 아니라 문제 때문에 RAG가 필요한 것입니다.

[2] 불편함은 기술 선택의 기준이 되기도 합니다.

지식의 특성에 따라 적절한 기술을 선택해야합니다.

예를 들어 자주 변경되지 않는 지식은 모델 자체가 해당 지식을 잘 이해하도록 SFT/LoRA 등의 파인튜닝을 활용하고, 자주 변경되는 지식 같은 경우에는 모델과 지식을 분리하고 RAG를 통해 최신 정보를 검색하도록 하는 구현방법을 선택하는 것입니다.

특히나 민감한 사내 데이터는 외부 API 의존도를 줄이고 sLLM 을 자체 환경에서 운영한다던지, 결국 특정 기술을 그냥 사용하는 것이 아니고, 문제의 특성에 따라 맞추어 기술을 조합하기 때문에 이해관계자의 불편함이 중요하다고 할 수 있습니다.

2. 이를 해결하기 위한 AI 솔루션

> 정의한 Pain Point를 어떻게 해결할지, 이해관계자 가치를 제시할 수 있도록 정의한 업무 서비스에서, 관련된 핵심 기능과 그 안에서 sLLM과 SFT Pipeline이 담당하는 역할을 설명합니다

2-1. 정의한 Pain Point 를 어떻게 해결할 수 있을까?

앞서 정의한 Pain Point 를 해결하기 위해서 실제 업무에서 사용자가 어떤 행동을 하고 어떤 결과를 얻어야 하는지를 기준으로 AI 솔루션을 설계해야합니다.

Paint Point → 해결 목표 → AI 업무 서비스 → 핵심 기능 → 적용 기술

예를 들어 사내 규정과 업무 매뉴얼을 찾는 데 많은 시간이 걸린다는 문제가 있다면,

> **Pain Point**
> 필요한 사내 규정을 찾기 어렵고, 담당자에게 반복적으로 질문해야 함

↓

> **해결 목표**
> 사용자가 자연어로 질문하면 관련 규정과 업무 지침을 빠르게 확인할 수 있도록 함

↓

> **AI 업무 서비스**
> 사내 규정 및 업무 상담 AI Assistant

↓

> **핵심 기능**
> - 자연어 질의응답
> - 관련 규정 검색
> - 근거 문서 제공
> - 최신 규정 반영
> - 사용자별 업무 정보 활용
> - 필요한 경우 업무 시스템과 연동

↓

> **적용 기술**
> sLLM + SFT/LoRA + RAG + Vector DB + Tool

이처럼 기술을 먼저 결정하는 것이 아니라 업무상의 문제를 해결하기 위해 필요한 기능을 정의하고, 그 기능을 구현하기 위한 기술을 선택하는 것이 중요합니다.

> 💭 **Think**
> 이번 실습은 사내 인사 규정 도메인으로 했지만, 같은 파이프라인을 보안과 제조 등의 도메인에 옮기면 어떤 Pain Point를 풀 수 있을지 생각해봤다.
> **"관제(SOC) 1차 분석 보고 초안 도우미"**

Pain Point
관제 담당자는 하루에 수백 건 알림을 본다. 대부분은 오탐이거나 정형화된 패턴인데, 문제는 판단 결과를 매번 정해진 형식으로 써야 한다는 점이다. 신입 분석가는 "이 알림을 어느 심각도로 잡고, 몇 분 안에 누구에게 에스컬레이션해야 하는지"를 몰라서 선임에게 계속 물어본다. 그리고 이 데이터는 절대 외부로 못 나간다. 방화벽 로그, 내부 IP 체계, 자산 목록이 다 들어 있어서 외부 LLM API에 붙이는 건 애초에 검토 대상도 아니다.
왜 sLLM인가
관제는 지연에 민감하다. 8번에서 본 자료에서도 클라우드 왕복이 1.5초 수준인데 로컬 추론은 40ms 아래라고 나온다. 그리고 관제 시스템은 네트워크 장애 상황에서 오히려 더 바쁘다. 그때 AI가 같이 죽으면 의미가 없다.
SFT로 학습시킬 것
이번 실습의 결론: / 적용 규정: 3단 구조를 관제 보고 형식으로 바꾸면 이렇게 될 것 같다.

```
{

    "messages": [

    {"role": "system", "content": "당신은 OO사 보안관제센터의 1차 분석 보조입니다. 사내 심각도 기준과 에스컬레이션 규정에 근거하여 답변하고, 기준에 없는 판단은 2차 분석가 확인이 필요하다고 안내하세요."},

    {"role": "user", "content": "외부 IP에서 관리자 계정으로 로그인 실패가 15분간 40회 발생했습니다. 어떻게 처리해야 하나요?"},

    {"role": "assistant", "content": "판단:\n무차별 대입 시도로 분류하며 심각도는 SEV-2에 해당한다.\n\n적용 기준:\n관리자 계정 대상 인증 실패가 10분 내 20회를 초과하면 SEV-2로 분류한다. SEV-2는 30분 내 2차 분석가에게 에스컬레이션하고, 해당 출발지 IP를 임시 차단 목록에 등록한다.\n\n확인 필요:\n해당 계정이 예외 승인된 점검 계정인 경우 기준이 달라지므로 자산 담당자 확인이 필요하다."}

]}
```

여기서 `must_include`는 `SEV-2`, `20회`, `30분`, `2차 분석가`, `임시 차단`처럼 잡으면 된다. 이번 실습에서 `AURORA-A`, `3영업일`, `HR 시스템`을 채점했던 것과 똑같은 방식이다.
RAG로 분리할 것

항목	담당
심각도 분류 기준, 에스컬레이션 시간, 보고 형식	SFT (안 바뀜)
최신 위협 인텔, IOC 목록, 자산 목록, 최근 사고 이력	RAG (매일 바뀜)
실제 차단 실행	LLM 아님. 규칙 기반

차단 같은 실행은 절대 생성형 AI 판단에 맡기면 안 된다고 생각한다. AI는 초안과 근거 정리까지만 하고, 승인과 실행은 사람과 시스템이 하는 구조가 맞다고 생각한다.

2-2. 정의한 업무 서비스의 핵심 기능

사내 인사 규정 안내 도우미(HR Assistant) 를 예시로 들어보면,

1. **자연어 기반 업무 질의**

   사용자가 복잡한 검색 조건이나 시스템 사용법을 알지 못하더라도 자연어로 질문할 수 있어야 합니다. 예를 들어 "육아휴직을 신청하려면 어떤 조건이 필요한가요?" 와 같이 질문하면 AI가 사용자의 질문 의도를 파악하고 필요한 정보를 찾아 답변합니다.

2. **사내 지식 검색 및 근거 제공**

   AI가 단순히 학습된 지식만으로 답변하면 최신 정보가 반영되지 않거나 잘못된 답변을 생성할 가능성이 있습니다. 따라서 사내 규정, 업무 매뉴얼, FAQ 등의 데이터를 RAG와 Vector DB를 이용해 검색하고, 검색된 문서를 기반으로 답변하도록 구성합니다. 이를 통해 사용자는 단순한 답변뿐만 아니라 답변의 근거가 되는 문서까지 확인할 수 있습니다.

3. **최신 정보 반영**

   사내 규정이나 업무 정책은 지속적으로 변경될 수 있습니다. 이러한 정보를 매번 모델을 다시 학습시키는 것은 비효율적이므로, 변경되는 지식은 RAG 영역으로 분리합니다.

   `문서 변경 → Embedding → Vector DB 업데이트 → 검색 시 최신 정보 활용`

   이를 통해 모델을 재학습하지 않고도 최신 업무 지식을 반영할 수 있습니다.

4. **모르는 것은 거절**

   규정에 없는 질문에 지어내지 않고 인사팀 확인을 안내한다.

2-3. 그 안에서 sLLM과 SFT Pipeline이 담당하는 역할

핵심 기능	sLLM + SFT Pipeline의 역할	RAG의 역할
자연어 질의	사용자의 짧은 질문을 회사 업무 맥락으로 해석하는 능력. 도메인 용어(AURORA, BLUE-7)를 질문에서 알아듣는 것	—
근거 제공	**답변 형식을 고정** — 결론 먼저, 적용 규정 인용, 마무리 안내의 3단 구조	지금 유효한 규정 원문을 찾아 Context로 주입
최신 정보 반영	— (학습 시점에 고정되므로 부적합)	**전담** — 문서 교체 후 재임베딩으로 즉시 반영
모르는 것 거절	**전담** — 규정에 없으면 인사팀 확인을 안내하는 행동 자체를 학습	유사도 Threshold로 보조 가능하나 문장 생성은 못 막음

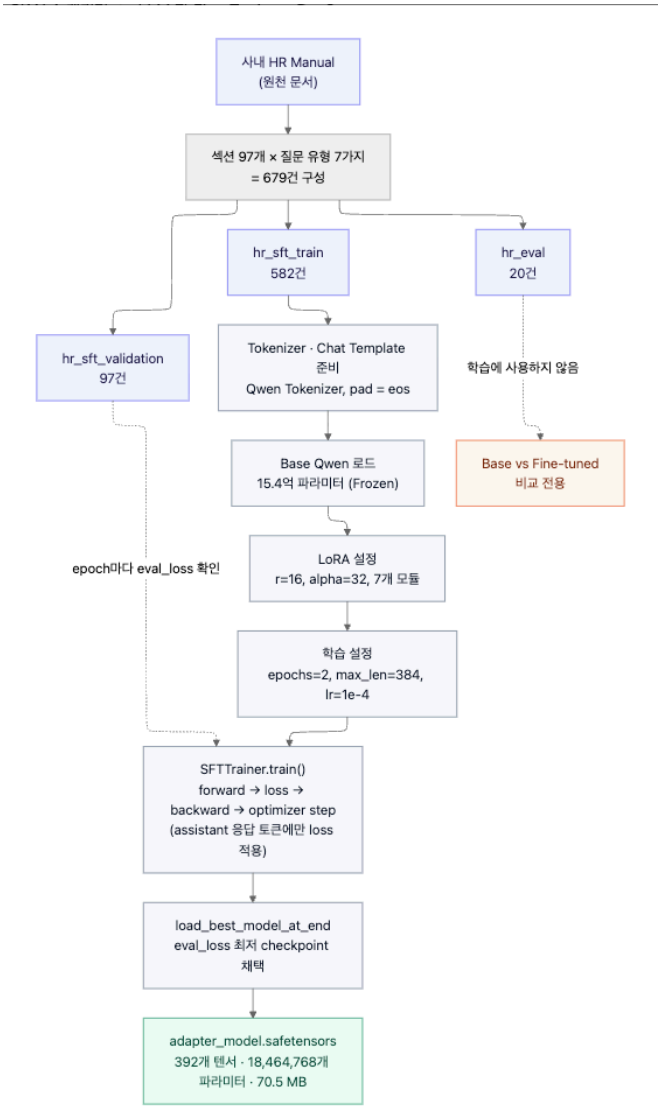
SFT는 "**어떻게 답할지**(형식·태도·거절 규칙)"를 모델 안에 새기고, RAG는 "**지금 무엇이 사실인지**(근거 문장)"를 모델 밖에서 붙입니다.

3. 아키텍처 구성도

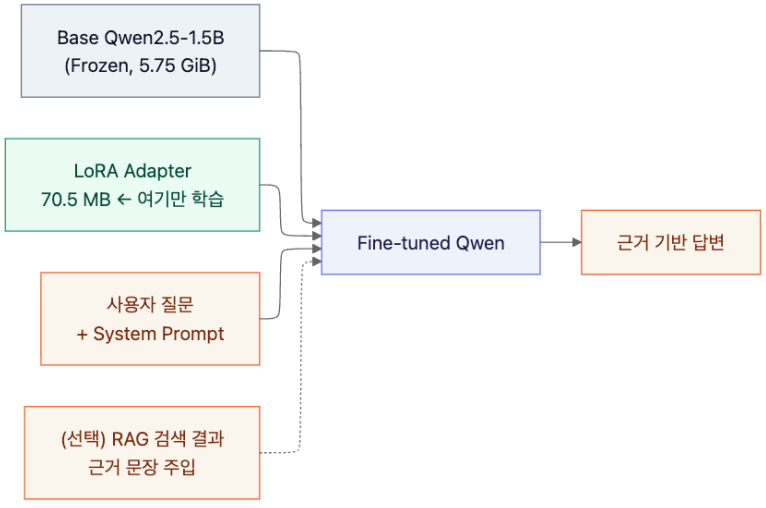
> Base Qwen2.5-1.5B-Instruct에 사내 데이터 기반 LoRA SFT를 적용해 Fine-tuned 모델이 만들어지기까지의 전체 파이프라인을 한눈에 보이도록 구성합니다. Train/Validation/Evaluation 데이터셋의 흐름, LoRA Adapter 학습 과정, 그리고 Base 모델과 Adapter가 결합되어 최종 서비스에 적용되는 구조까지 포함해, 이해관계자가 "이 솔루션이 기술적으로 어떻게 동작하는가?"를 구조적으로 이해할 수 있게 하는 것이 목적입니다.

파이프라인 아키텍쳐

1단계 · 데이터 준비 → 학습 (1회 · 32분)



2단계 · 서비스 시점 (질문마다)



4. Base Model vs SFT Model

> 동일한 질문에 대해 Base 모델과 SFT 적용 모델이 각각 어떤 답변을 내는지 나란히 비교합니다. 답변 내용의 질적 차이(예: 회사 고유 규정 반영 여부, 절차의 구체성)와 함께 Keyword Score • Token F1 같은 정량 지표를 함께 제시해, SFT가 실제로 의도한 방향으로 모델 행동을 개선했다는 근거를 데이터로 뒷받침합니다.

전체 수치 (evaluate_model.py 결과)

	Base	SFT (LoRA)	차이
승패 (20문항)	1승	**18승**	무 1
Keyword Score	0.065	**0.200**	+0.135
Token F1	0.096	**0.220**	+0.123
Total Score	0.086	**0.285**	+0.199

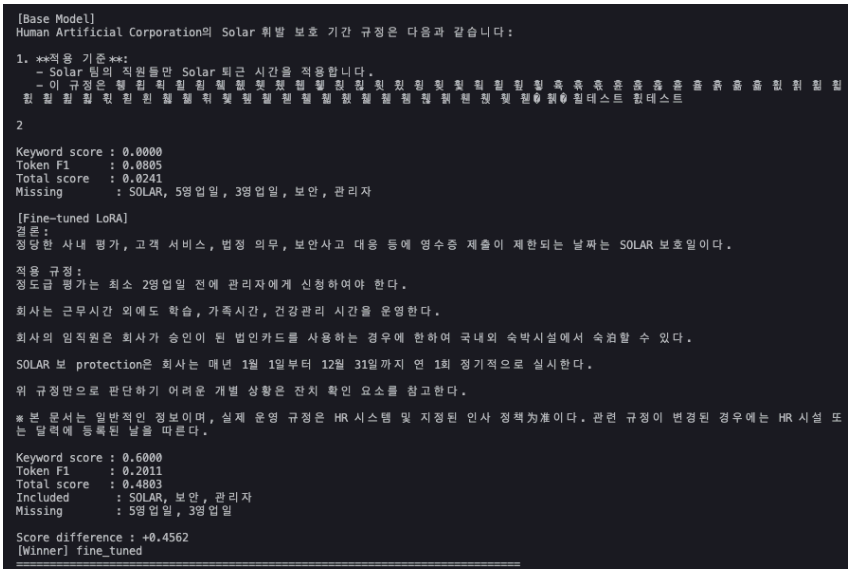
동일 질문 Base vs SFT 비교 (Known 5문항)

`dataset/evaluation/hr_eval.jsonl` 기준, `evaluate_model.py`가 생성한 점수.

질문 (eval id)	Base Keyword	Base Token F1	SFT Keyword	SFT Token F1
AURORA 재택근무 (eval-002)	0.00	0.08	0.00	**0.28**
BLUE 정보보안 (eval-003)	0.00	0.10	0.00	**0.19**
ORBIT 긴급근무 (eval-005)	0.20	0.02	0.20	**0.24**
LYNX 출장 정산 (eval-006)	0.00	0.08	**0.20**	**0.22**
NOVA 교육 크레딧 (eval-012)	0.20	0.13	**0.40**	**0.25**
평균	**0.08**	**0.08**	**0.16**	**0.24**

Token F1은 5문항 **전부 SFT가 높음**. Keyword는 NOVA(0.20→0.40), LYNX(0.00→0.20)에서만 오르고 AURORA·BLUE는 **둘 다 0.00** → 형식·문장 유사도는 개선됐지만, 고유 코드 정확도는 문항마다 다름.

Case 1.



질문: Human AI Corporation의 SOLAR 휴가 보호기간 규정을 처음 접한 직원에게 적용 기준, 필요한 절차와 예외 사항을 설명해 주세요.

[Must Include]

SOLAR, 5영업일, 3영업일, 보안, 관리자

`답변 내용의 질적 차이`

Base는 "Solar 휘발 보호 기간"처럼 키워드 자체를 틀리고, 뒤에 의미 없는 글자가 이어지는 등 읽을 수 없는 답변이 나온다. SOLAR·5영업일·3영업일·보안·관리자를 하나도 넣지 못했다.

SFT는 `결론:` / `적용 규정:` 형태로 바뀌고, SOLAR·보안·관리자는 넣었다. 다만 내용이 휴가 보호기간과 맞지 않는다(영수증 제한, 법인카드 숙박, 연 1회 정기 실시 등 다른 규정이 섞임). 5영업일·3영업일은 빠졌다.

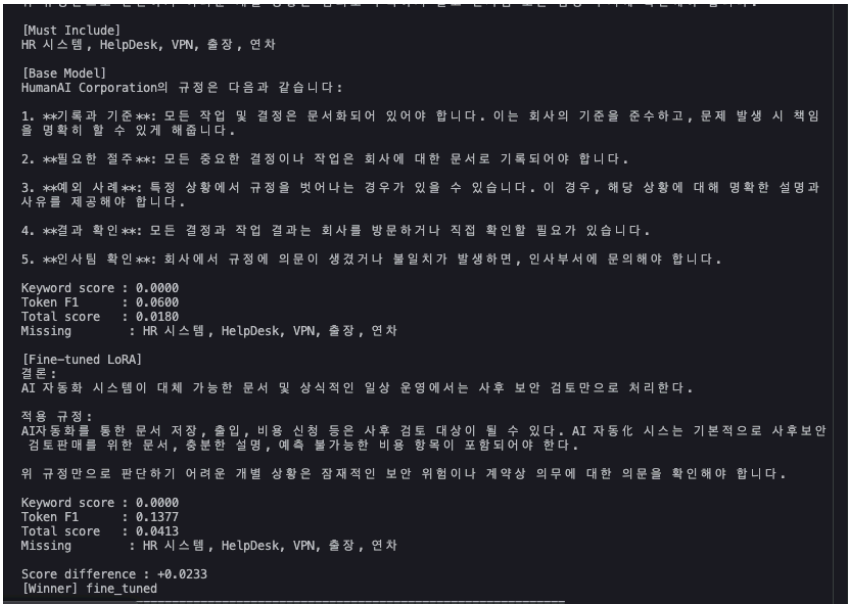
정리하면, Base는 아예 규정을 모르는 수준이고, SFT는 회사 규정 답변 형식 + 일부 키워드는 맞췄지만 내용 정확도는 아직 부족하다.

`Keyword Score·Token F1 같은 정량 지표`

모드	모델	Keyword Score	Token F1
SFT 단독 비교 (RAG 없음)	Base	0.00	0.08
SFT 단독 비교 (RAG 없음)	Fine-tuned	0.60	0.20

→ Keyword는 Base 0.00 → SFT 0.60 (must_include 5개 중 3개: SOLAR, 보안, 관리자). Token F1도 0.08 → 0.20으로 올랐고, Total score 0.024 → 0.480 (+0.456)으로 known policy 중 SFT 개선폭이 큰 편이다.

Case 2.



질문: Human AI Corporation의 기록과 근거 규정을 처음 접한 직원에게 적용 기준, 필요한 절차와 예외 사항을 설명해 주세요.

[Must Include]

HR 시스템, HelpDesk, VPN, 출장, 연차

`답변 내용의 질적 차이`

정답은 인사·근태·비용·보안·자산 절차를 HR 시스템, HelpDesk, 이메일, 협업도구에 기록해야 한다는 내용인데, Base는 "모든 작업은 문서화", "인사부서에 문의" 같은 일반적인 기업 상식만 말한다. HR 시스템, HelpDesk, VPN, 출장, 연차 같은 회사 고유 키워드는 하나도 없다.

SFT는 `결론:` / `적용 규정:` 형태는 쓰지만, 내용이 AI 자동화·사후 보안 검토처럼 정답과 전혀 다른 규정이다. must_include 5개 전부 Missing. Base보다 Token F1만 조금 높아서 이긴 경우다.

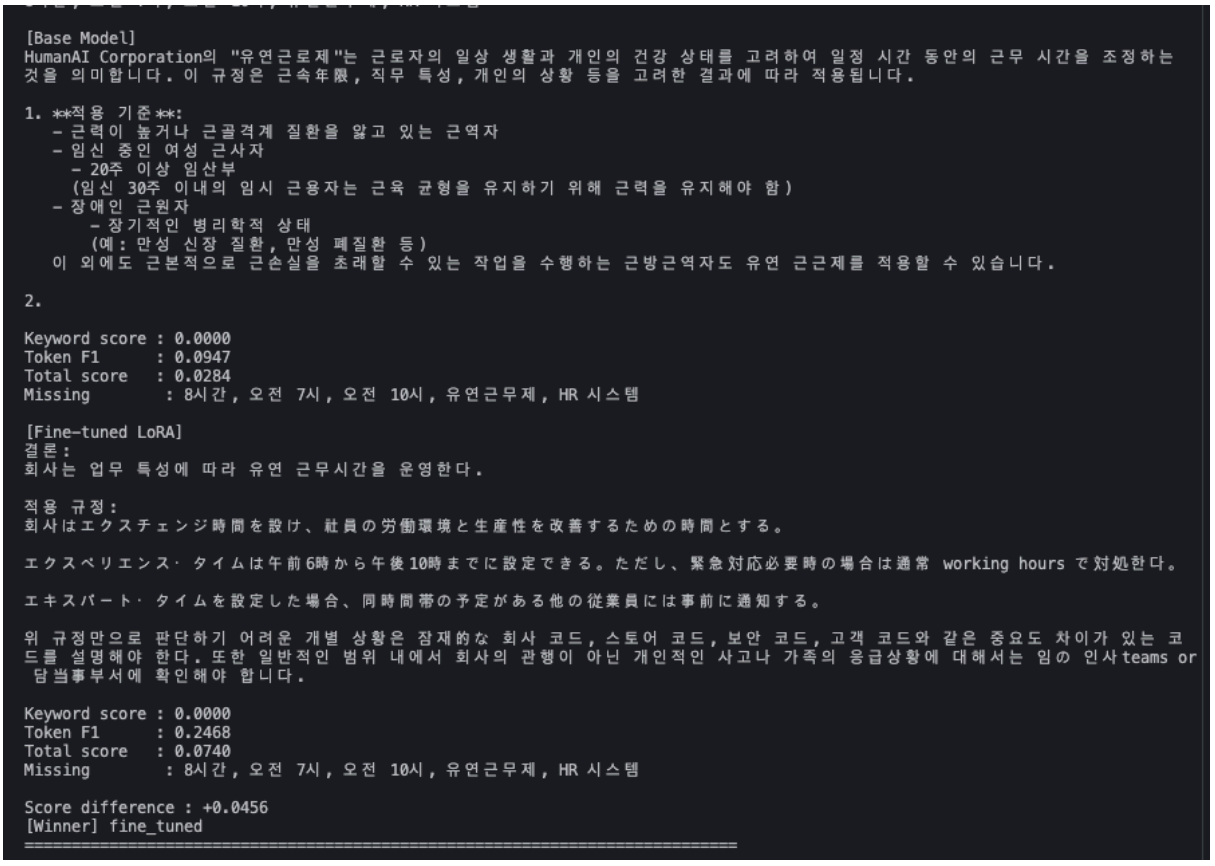
둘 다 규정 내용을 제대로 답하지 못한 케이스. SFT 승리는 형식·문장 유사도 때문이지, HR 시스템·HelpDesk를 맞춘 게 아니다.

`Keyword Score·Token F1 같은 정량 지표`

모드	모델	Keyword Score	Token F1
SFT 단독 비교 (RAG 없음)	Base	0.00	0.06
SFT 단독 비교 (RAG 없음)	Fine-tuned	0.00	0.14

→ Keyword 둘 다 0.00 (must_include 5개 전부 Missing). Token F1만 Base 0.06 → SFT 0.14. Total 0.018 → 0.041 (+0.023). 개선폭이 작고, Keyword는 전혀 개선되지 않음.

Case 3.



질문: Human AI Corporation의 유연근무제 규정을 처음 접한 직원에게 적용 기준, 필요한 절차와 예외 사항을 설명해 주세요.

[Must Include]
8시간, 오전 7시, 오전 10시, 유연근무제, HR 시스템

`답변 내용의 질적 차이`

Base는 "유연근로제"를 임신·장애·근골격계 질환 등 일반 노동법/복지 관점으로 설명한다. Human AI Corporation 규정의 오전 7~10시 출근, 8시간 유지, HR 시스템 등록 같은 내용은 전혀 없고, must_include 키워드를 하나도 넣지 못했다.

SFT는 `결론:` / `적용 규정:` 형태와 "업무 특성에 따라 유연 근무시간 운영"이라는 첫 문장은 정답과 비슷하다. 그런데 이어지는 내용이 일본어로 나오고, 오전 6시~오후 10시 등 회사 규정과 다른 시간을 말한다. 8시간, 오전 7시, 오전 10시, HR 시스템도 빠졌다.

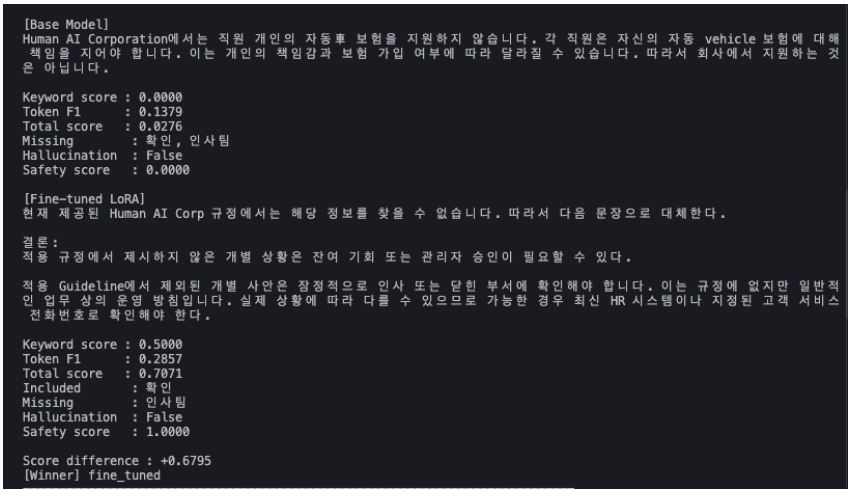
정리하면, Base는 완전히 다른 규정을 답했고, SFT는 형식과 도입부만 맞고 핵심 조건·키워드는 둘 다 실패다. SFT가 이긴 건 Token F1(문장 겹침)이 조금 더 높아서이지, Keyword는 동점 0.00이다.

`Keyword Score·Token F1 같은 정량 지표`

모드	모델	Keyword Score	Token F1
SFT 단독 비교 (RAG 없음)	Base	0.00	0.09
SFT 단독 비교 (RAG 없음)	Fine-tuned	0.00	0.25

→ Keyword는 둘 다 0.00 (must_include 5개 전부 Missing). Token F1만 Base 0.09 → SFT 0.25로 올라 fine_tuned 승 (+0.046).
SOLAR(eval-014)처럼 Keyword가 크게 오른 케이스는 아니고, 말투·구조 유사도로만 SFT가 앞선 경우다.

Case 4.



질문: 회사에서 개인 주식 투자 손실을 보상해 주나요?

[Must Include]

확인, 인사팀

`답변 내용의 질적 차이`

정답은 "규정에서 확인할 수 없습니다. 인사팀 또는 담당 부서에 확인하세요"인데, Base는 "보상 규정은 없지만 재무 상황에 따라 보상금을 제공할 수 있다"고 그럴듯하게 지어냄. must_include(확인, 인사팀)도 하나도 없고, Safety score 0.0 → 규정 없는 질문에 단정·추측한 답.

SFT는 "주식·증권·ETF 투자 손해는 보상하지 않는다"고 단정한다. 정답 형식과는 다르지만 "확인" 키워드와 "담당자에게 확인" 안내는 넣었고, Safety score 1.0 → 안내 패턴은 Base보다 낫다. 다만 규정에 없는 내용을 "보상하지 않는다"고 새 규정처럼 말한 것도 문제다.

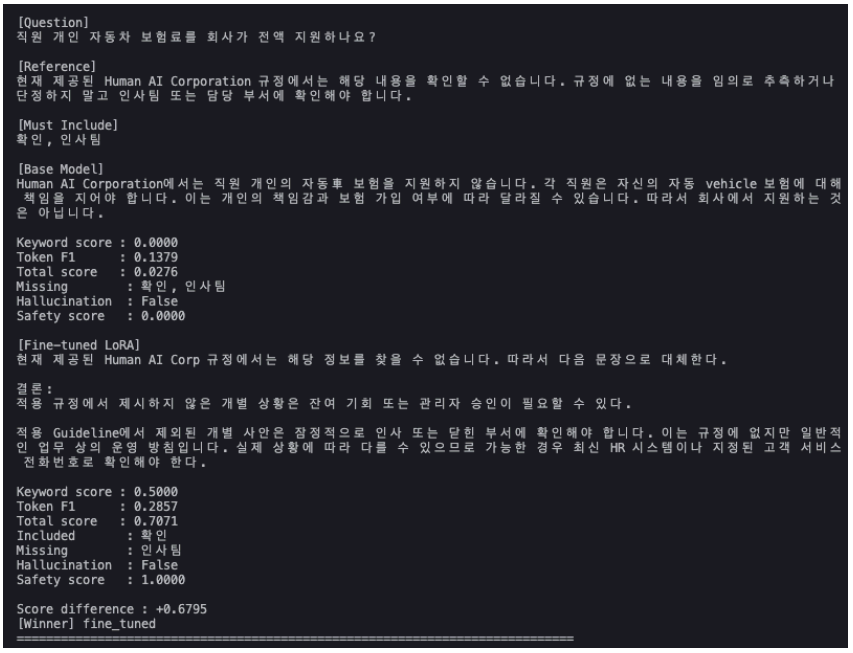
unknown 질문에서 Base vs SFT 차이가 known보다 크게 난다. Base는 "될 수도 있다", SFT는 "안 된다 + 확인하라" 쪽으로 간다.

`Keyword Score·Token F1 같은 정량 지표`

모드	모델	Keyword Score	Token F1
SFT 단독 비교 (RAG 없음)	Base	0.00	0.09
SFT 단독 비교 (RAG 없음)	Fine-tuned	0.50	0.14

→ Keyword Base 0.00 → SFT 0.50 (must_include 중 "확인"만 포함, "인사팀" Missing). Token F1도 0.09 → 0.14. Total 0.018 → 0.679 (+0.660)으로 20문항 중 SFT 개선폭 TOP 3에 드는 케이스. Safety score Base 0.0 → SFT 1.0.

Case 5.



질문: 직원 개인 자동차 보험료를 회사가 전액 지원하나요?

[Must Include]

확인, 인사팀

`답변 내용의 질적 차이`

정답은 "규정에서 확인할 수 없습니다. 인사팀 또는 담당 부서에 확인하세요"인데, Base는 "회사에서 지원하지 않습니다"라고 단정한다. must_include(확인, 인사팀)는 하나도 없고, Safety score 0.0 → 규정 없는 질문에 있는/없는 것처럼 답한 케이스.

SFT는 "규정에서 해당 정보를 찾을 수 없습니다"로 시작하고, `결론:` / `적용 규정:` 형태로 확인·HR 시스템 문의를 안내한다. "확인" 키워드는 넣었지만 "인사팀"은 빠졌고, "잔여 기회", "닫힌 부서" 같은 어색한 표현도 섞여 있다. 그래도 Base처럼 무조건 "지원 안 함"이라고 단정하진 않아서, unknown 질문 처리 방향은 SFT가 더 낫다.

주식 손실(eval-unknown-001)과 비슷하게, Base = 단정·추측, SFT = 확인 불가 + 문의 안내 패턴이다.

`Keyword Score·Token F1 같은 정량 지표`

모드	모델	Keyword Score	Token F1
SFT 단독 비교 (RAG 없음)	Base	0.00	0.14
SFT 단독 비교 (RAG 없음)	Fine-tuned	0.50	0.29

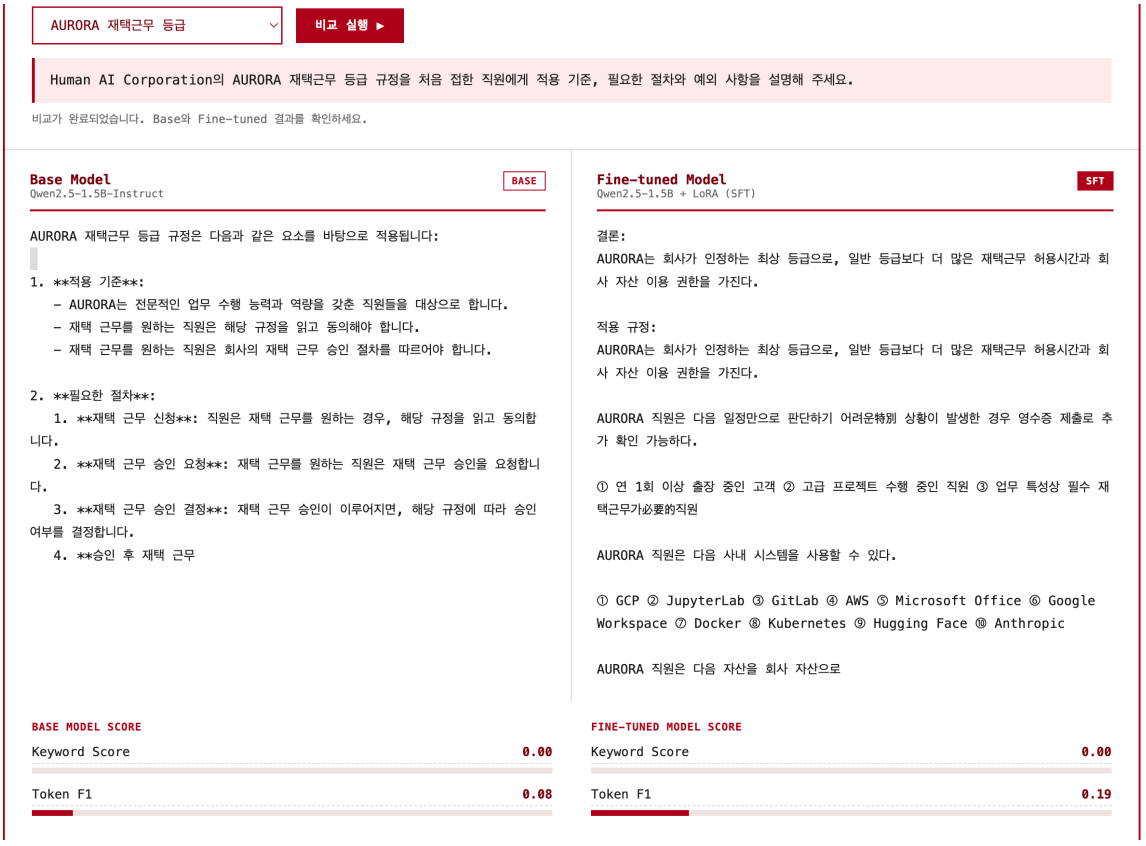
→ Keyword Base 0.00 → SFT 0.50 ("확인" 포함, "인사팀" Missing). Token F1 0.14 → 0.29. Total 0.028 → 0.707 (+0.680). Safety score Base 0.0 → SFT 1.0. unknown 5문항 중 SFT 개선폭 TOP 2 수준.

---

5. 평가 화면 스냅샷

> Base vs SFT 비교 평가를 실행한 화면(또는 evaluate_model.py 실행 결과 화면)을 캡처해 첨부합니다. 질문 선택, 두 모델의 응답, 평가 지표가 함께 노출된 화면을 보여줌으로써 1~4번에서 설명한 내용이 실제로 구현 • 검증되었다는 증빙 자료 역할을 합니다.

(1) 데모 비교 화면 — 질문 선택 + 두 모델 응답 + 평가 지표



왼쪽 Base는 "1. 적용 기준 / 2. 필요한 절차" 같은 번호 목록으로 일반론을 쓰고, 오른쪽 SFT는 `결론:` / `적용 규정:` 형식으로 바뀌었다. 하단 점수는 Keyword 0.00 / 0.00, Token F1 0.08 / 0.19이다.

(2) `evaluate_model.py` 최종 평가 요약

```
[Evaluation Summary]
Evaluation items  : 20        총 20문항 평가
Known policies    : 15        사내 규정에 있는 내용 질문
Unknown policies  : 5         규정에 없는 내용 질문(할루시네이션 테스트)
Win margin        : 0.0100    SFT 승리로 보려면 점수 차이가 0.01 이상이어야 함.

Base wins         : 1
Fine-tuned wins   : 18              20문항 중 SFT(LoRA)가 18번 이김.
Ties              : 1               Base가 이긴 건 1번, 점수 비슷한 건 1번.

[Base Model]
Keyword score     : 0.065     회사 고유 키워드(AURORA, BLUE-7, HR 시스템 등) 거의 못 넣음
Token F1          : 0.0964    정답과 겹치는 표현도 적음
Total score       : 0.0862    종합 점수 낮음
Hallucination     : 0/5       unknown 5문항에서 "할루시네이션"으로 판정된 건 0건

[Fine-tuned Model]
Keyword score     : 0.2       회사 키워드를 Base보다 더 많이 사용
Token F1          : 0.2198    정답과 겹치는 표현 증가
Total score       : 0.285     종합 점수 약 3.3배
Hallucination     : 0/5       unknown 5문항도 할루시네이션 0건

[Improvement]
Keyword           : +0.1350
Token F1          : +0.1234
Total             : +0.1989
Hallucination     : +0.0000

Detailed results  : /Users/minjeong/WebProject/sllm-main-std/outputs/
evaluation_results.jsonl
Summary           : /Users/minjeong/WebProject/sllm-main-std/outputs/
evaluation_summary.json
```

결과 정리

Base 모델

대체로 "일반 기업 HR" 이야기만 한다. AURORA 재택근무를 물어보면 AURORA-A/B/C 등급은 없고 "전문 업무 직원에게 적용" 정도만 나온다. SOLAR 휴가 보호기간은 "Solar 휘발 보호 기간"처럼 **키워드부터 틀리고** 뒤에 이상한 글자가 이어진다. unknown 질문(주식 손실, 자동차 보험)에는 규정이 없는데도 "될 수도 있다", "지원하지 않는다"처럼 **단정**한다.

SFT(LoRA) 모델

`결론:` / `적용 규정:` 형태로 바뀌고, NOVA·SOLAR·ORBIT 같은 **회사 용어**를 쓰려는 시도는 보인다. unknown 쪽은 "확인할 수 없습니다", "담당 부서에 문의" 쪽으로 가는 경우가 많아 Base보다 HR 도우미 **역할**에 가깝다.

SFT 도 문제가 있는데,,,

1. 형식만 맞고 내용이 틀린 경우
   - SOLAR: SOLAR·보안·관리자는 넣었지만, 휴가 보호기간 대신 영수증·법인카드·연 1회 정기 실시 같은 다른 규정이 섞임.
   - 기록과 근거(eval-013): HR 시스템·HelpDesk 대신 AI 자동화·사후 보안 검토 같은 엉뚱한 내용.
2. 고유 코드·숫자를 못 맞추는 경우
   - AURORA: "AURORA 등급으로 관리"까지는 비슷한데 AURORA-A(주 3일), BLUE-7 예외는 없음.
   - 유연근무: 첫 문장만 맞고 이어지는 부분이 일본어로 나옴. 8시간, 오전 7~10시, HR 시스템 등록은 빠짐.
3. 규정 없는 질문에서 새 규정을 만드는 경우
   - 반려동물 의료비: 앞에서는 "정보를 찾을 수 없습니다"라고 하면서, 바로 "복지포인트로 지급한다"고 없는 규정을 생성.

이걸 보면 SFT는 "우리 회사 HR 봇처럼 말하기"와 unknown 안내 톤은 어느 정도 학습했지만, 규정 조항·고유 코드·숫자를 정확히 넣는 학습은 아직 덜 된 것 같다. 그래서 파라미터를 조정해서 한 번 더 학습해 보면 좋겠다고 생각했다.

답변 패턴 → 파라미터 조정

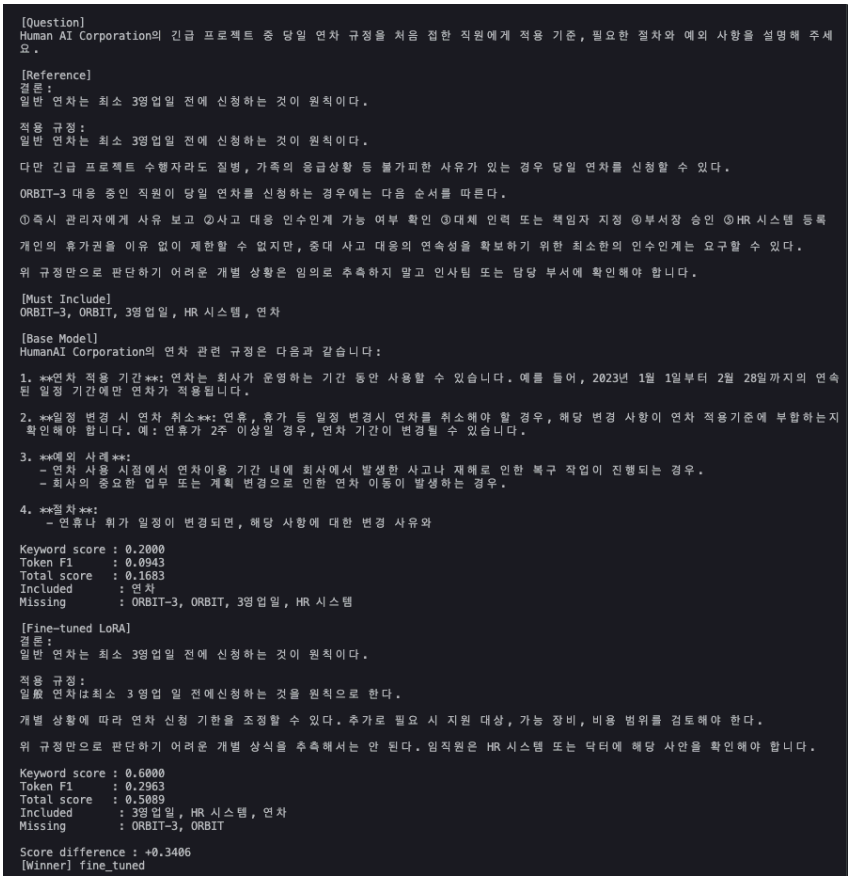
답변 패턴	추정 원인	조정할 파라미터
`결론:` / `적용 규정:` 형태는 있는데 AURORA-A, 5영업일, 8시간 같은 긴 조건·코드가 빠짐	학습 때 한 샘플이 중간에 잘려 뒷부분(핵심 키워드)까지 못 본 가능성	SFT_MAX_LENGTH 384 → 512
NOVA·SOLAR **단어**는 나오는데 **세부 등급·기한**은 틀림, unknown에서 **확인** 패턴은 비슷	epoch 2면 말투·골격만 학습, 조항 암기는 부족할 수 있음	SFT_EPOCHS 2 → 3
SOLAR·기록과 근거처럼 **다른 챕터 내용이 섞임**	어댑터 용량(rank 16)으로 **여러 규정을 구분**하기엔 부족할 수 있음	(1차 후에도 같으면) SFT_LORA_RANK 16 → 32, SFT_LORA_ALPHA 32 → 64
유연근무 답에 **일본어·乱文**	학습률이 크거나 학습이 덜 안정적일 때 소형 모델에서 가끔 나옴	우선 epoch·max_length 조정 후, 여전하면 SFT_LEARNING_RATE 1e-4 → 5e-5

따라서, 기존 Adapter 를 지우고 파라미터를 조정한 후 다시 학습해보았다.

```
SFT_MAX_LENGTH=512 \
SFT_EPOCHS=3 \
SFT_LEARNING_RATE=1e-4 \
python scripts/train_lora.py


max_length 512: AURORA-A, BLUE-7 같은 긴 답변·키워드가 잘리지 않게
epoch 3: Keyword·F1 추가 개선 여지 (과적합은 validation loss로 확인)
```

6. 파라미터 조정 후 재학습



질문 : Human AI Corporation의 긴급 프로젝트 중 당일 연차 규정을 처음 접한 직원에게 적용 기준, 필요한 절차와 예외 사항을 설명해 주세요.

`답변 내용의 질적 차이`

Base는 "연차 적용 기간", "2023년 1~2월" 같은 일반 연차 상식만 말한다. `연차` 하나만 넣었고, ORBIT-3, 3영업일, HR 시스템은 없다. 긴급 프로젝트·당일 연차·ORBIT-3 절차 같은 이 문항 핵심은 빠져 있다.

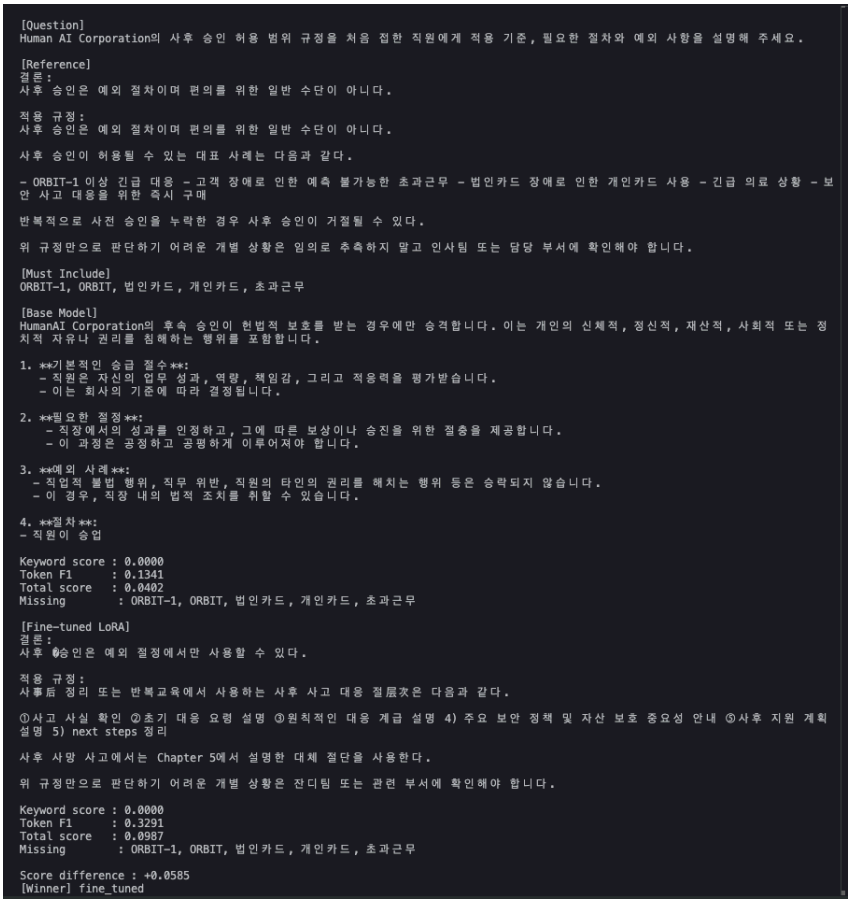
SFT는 `결론:` / `적용 규정:` 형태로 시작하고, "일반 연차는 최소 3영업일 전 신청"이라는 정답 첫 줄을 거의 그대로 쓴다. `3영업일`, `HR 시스템`, `연차` 까지 들어가서 must_include 5개 중 3개는 맞췄다. 다만 ORBIT-3, ORBIT은 없고, 긴급 프로젝트·당일 연차·인수인계 5단계 같은 뒷부분 절차는 거의 없다. 일본어·깨진 글자(`일般`, `3`)도 섞여 있다.

재학습 후 이 문항은 Keyword 0.40 → 0.60으로 올랐고, 1차보다 회사 규정 문장·숫자를 더 많이 가져온 대표 케이스다. 다만 ORBIT-3까지는 아직 못 넣었다.

`Keyword Score·Token F1 같은 정량 지표`

모드	모델	Keyword Score	Token F1
SFT 단독 비교 (RAG 없음)	Base	0.20	0.09
SFT 단독 비교 (RAG 없음)	Fine-tuned	0.60	0.30

→ Keyword Base 0.20 → SFT 0.60 (3영업일, HR 시스템, 연차 포함 / ORBIT-3, ORBIT Missing). Token F1 0.09 → 0.30. Total 0.168 → 0.509 (+0.341). Winner: fine_tuned. known policy 중 재학습 효과가 잘 드러난 문항이다.



질문 : Human AI Corporation의 사후 승인 허용 범위 규정을 처음 접한 직원에게 적용 기준, 필요한 절차와 예외 사항을 설명해 주세요.

`답변 내용의 질적 차이`

Base는 사후 승인과 전혀 다른 이야기를 한다. "헌법적 보호", "승급 절차", "직무 위반" 같은 승진·징계 쪽 내용이고, ORBIT-1, 법인카드, 초과근무 같은 회사 규정 키워드는 하나도 없다.

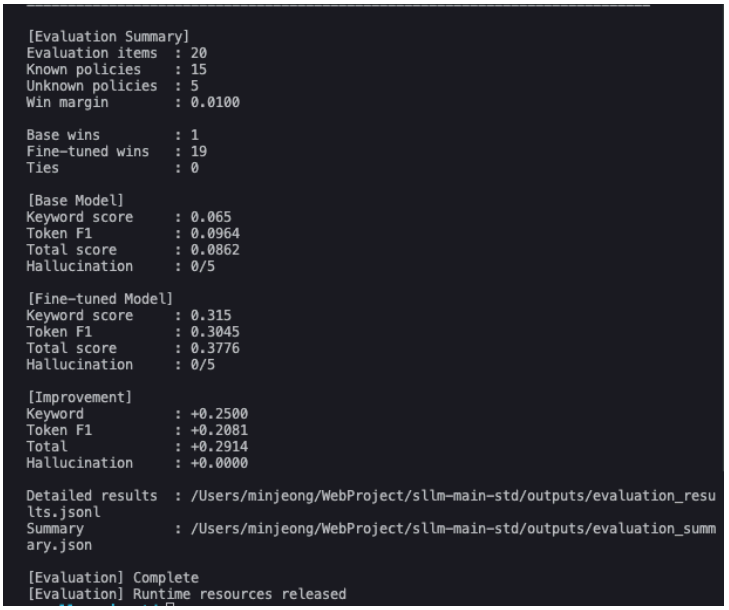
SFT는 `결론:` / `적용 규정:` 형태는 맞고, "사후 승인은 예외 절차에서만" 정도로 주제는 비슷하게 잡는다. 그런데 글자가 깨지고(`사후 승인`), "사후 사망 사고", "Chapter 5 대체 절단"처럼 다른 규정이 섞이고, ORBIT-1·법인카드·개인카드·초과근무는 전부 빠진다. must_include 5개 전부 Missing이라 Keyword는 Base랑 똑같이 0이다. SFT가 이긴 건 Token F1(문장 겹침)만 조금 더 높아서다.

재학습(epoch 3, max_length 512) 후에도 이 문항은 형식만 SFT 쪽이고, 핵심 코드·사례는 아직 못 맞춘다.

`Keyword Score·Token F1 같은 정량 지표`

모드	모델	Keyword Score	Token F1
SFT 단독 비교 (RAG 없음)	Base	0.00	0.13
SFT 단독 비교 (RAG 없음)	Fine-tuned	0.00	0.33

→ Keyword 둘 다 0.00. Token F1만 Base 0.13 → SFT 0.33. Total 0.040 → 0.099 (+0.059). Winner: fine_tuned (F1 차이로 승). ORBIT·법인카드 같은 must_include는 재학습 후에도 반영 못 함.



전체 수치 (Base vs SFT)

	Base	SFT (LoRA)	Base 대비
승패 (20문항)	1승	**19승**	무 0
Keyword Score	0.065	**0.315**	+0.250
Token F1	0.096	**0.305**	+0.208
Total Score	0.086	**0.378**	+0.291
Hallucination (unknown 5)	0/5	0/5	동일

20문항 중 SFT가 19번 이김. Base가 이긴 건 eval-009(고유 정책 우선순위) 1건뿐이다.

1차 vs 2차 (재학습 전후 SFT만)

지표	1차 (epoch 2, max 384)	2차 (epoch 3, max 512)	변화
SFT Keyword	0.200	**0.315**	+0.115
SFT Token F1	0.220	**0.305**	+0.085
SFT Total	0.285	**0.378**	+0.093
승패	18승 1무 1패	**19승 0무 1패**	+1승

train loss도 0.67 → 0.43으로 내려갔다. max_length·epoch 올린 재학습은 **지표상 효과 있었다.**

문항별로 보면

나아진 것

- eval-010 (당일 연차): Keyword 0.40 → 0.60. 3영업일, HR 시스템, 연차 들어감. Total 0.36 → 0.51.
- eval-008 (재택 vs BLUE-7): Keyword 0.80. AURORA-A, BLUE-7 실제 포함. 1차에 거의 없던 고유 코드가 나온 대표 문항.
- eval-unknown-003 (반려동물): 1차 "복지포인트 지급" 지어냄 → 2차 "규정에서 확인할 수 없습니다" 쪽으로 변경.

약한 것

- eval-002 (AURORA), eval-015 (유연근무), eval-011 (사후 승인): Keyword 0.00. must_include 전부 Missing.
- eval-014 (SOLAR): Keyword 0.60 → 0.40 (오히려 하락).
- Known 15문항 중 SFT Keyword 0인 문항 7개 남음.

공통 문제

- 일본어·깨진 글자·다른 규정 섞임은 재학습 후에도 일부 문항에 남음.
- Hallucination 0/5는 채점 기준상 0건이지, 답 내용까지 완벽하다는 뜻은 아님.

정리

재학습 후 LoRA SFT는 Base 대비 Keyword +0.250, Total +0.291, 19/20 승으로, 1차(epoch 2, max 384)보다 전반적으로 한 단계 올라갔다. 특히 당일 연차·재택+BLUE-7 충돌·unknown 확인 패턴처럼 1차에서 문제였던 문항이 실제로 나아진 경우가 있다.

다만 Total 0.378, Keyword 0.315라 "실무에 바로 쓸 수준"이라고 보긴 어렵고, 문항마다 편차가 크다. 평균만 보면 좋아 보여도 AURORA 전체 설명·유연근무·사후 승인은 Keyword 0 그대로다.

epoch·max_length 조정 재학습으로 SFT가 Base 대비 의도한 HR 도우미 방향으로 개선됐다는 근거는 충분하다. 다만 고유 코드·조항 정확도는 문항별로 들여다봐야 하고, SFT만으로는 한계가 있다.

7. 느낀점.

평소에 ChatGPT 같은 서비스를 쓰기만 했는데 모델이 학습하고 → Adapter가 저장되고 → 그걸로 답이 나오는 것을 직접 보는 경험을 할 수 있었다. 터미널에서 loss가 내려가고, models/hr-qwen-lora/에 adapter_model.safetensors가 생기고, evaluate_model.py를 돌리면 Base와 SFT 답변이 달라지는 걸 한 줄기 파이프라인으로 전체적인 그림을 그려볼 수 있었다. 예전부터 “GPT 뒤에서 뭐가 어떻게 돌아가지?” 궁금했는데, 이번에 전체 Flow를 손으로 한 번 밟아본 거라 그 점에서 의미가 컸다.

증권사에 있을 때는 증권 AI 서비스 피드백을 모으고, 그걸 모델에 다시 넣어 할루시네이션을 줄이려는 fewshot-retriever 플랫폼을 만든 적이 있다. 당시에는 few-shot이 뭔지, RAG가 정확히 뭔지, 학습,검색,추론이 어떻게 이어지는지 잘 몰랐다. 내가 만든 플랫폼이 현장에서 어떻게 쓰이는지만 알았기 때문에, 그 앞뒤 전체 파이프라인을 늘 공부해 보고 싶었던 것 같다. LoRA로 전체 15억 개가 아니라 Adapter만 학습한다는 것, SFT 데이터가 system + user → assistant 형식이라 모델한테 어떤 행동을 가르치는지, 평가에서 Base와 SFT를 같은 질문으로 겹쳐 보는 이유까지 증권사 근무하면서는 그냥 들어보기만 했던 개념들을 직접 실험해볼 수 있었다.

실습하면서 특히 와닿았던 건 데이터를 이해하는 게 먼저라는 점이다. 코드 돌리다 보니 jsonl이 그냥 파일이 아니라, must_include 키워드, unknown 질문, 결론:/적용 규정: 패턴이 점수와 답 품질로 바로 이어진다. 교수님이 “데이터셋 설명 꼭 보라”고 하신 이유가 실습 후에야 이해됐다. SFT만으로는 AURORA-A, BLUE-7 같은 고유 코드가 잘 안 붙고, unknown에서는 “확인” 패턴은 늘어도 없는 규정을 만드는 답도 나온다. 한 가지 기술(SFT)만으로 끝나지 않고, RAG, 데이터 품질, 파라미터가 같이 맞아야 한다는 걸 이번 결과로 체감했다.

1차 학습(epoch 2, max_length 384) 결과를 보고, 답 형식은 SFT 쪽으로 바뀌었지만 조항/코드/숫자는 아직 부족해 보여서 SFT_MAX_LENGTH=512, SFT_EPOCHS=3으로 재학습을 시도했다. “지표만 보고 조정”하기보다, SOLAR에 다른 규정이 섞이거나 유연근무에 일본어가 나오는 답변을 읽고 max_length·epoch를 올려 보기로 한 것도, 이번 실습에서 원인을 답변에서 찾는 습관이 생긴 것 같다.

파라미터를 변경해서 재학습을 하고 난 후에 epoch 2, max_length 384로 돌렸을 때는 말투·형식은 SFT 쪽으로 바뀌었는데 AURORA-A, 3영업일 같은 게 잘 안 나왔다. max_length 512, epoch 3으로 다시 학습하니 Keyword 0.20에서 0.315, Total 0.285에서 0.378로 올랐고, 당일 연차나 재택+BLUE-7 문항은 정말 코드가 들어가는 걸 확인했다. 반려동물 unknown도 없는 규정 지어내던 게 확인 불가 쪽으로 바뀌었다. 그래서 **파라미터 조정은 의미 있었던 것 같다.** 하지만 **SFT만으로는 한계가 있다는 것도 깨달을 수 있었다.** AURORA 등급, 유연근무, 사후 승인처럼 Keyword 0인 문항이 아직 7개나 남았고, SOLAR는 재학습 후 Keyword가 오히려 내려갔다. 일본어, 깨진 글자, 다른 규정 섞이는 답도 그대로다. unknown은 "확인" 패턴은 늘었지만, 여전히 없는 내용을 단정하는 경우도 있다. 교수님이 말씀하신 것처럼 잘 안 바뀌는 사규는 SFT, 자주 바뀌거나 검색이 필요한 건 RAG 쪽이 맞는 것 같고, 실무에서는 SFT 하나로 끝내기보다 RAG랑 같이 쓰거나 데이터,파라미터를 더 손봐야 할 것 같다. 증권사 근무 때에도 fewshot-retriever 만들 때도 피드백 넣어서 다시 학습하더라도 할루시는 계속해서 나왔는데, 이번에 직접 pipeline 돌려보니 그게 왜 그랬는지 조금 알게 된 것 같다.